Karpathy 从零构建大语言模型实战手册

从生活场景到实际操作：13步白话说明与空间图解

更新：2026-11-12

目录

1. 阅读说明
2. 建议日程与实验节奏
3. 步骤 1 建立环境与课程工作目录
4. 步骤 2 从导数实现 micrograd
5. 步骤 3 用名字数据构建 bigram 语言模型
6. 步骤 4 从字符窗口训练 MLP
7. 步骤 4–5 问答记录：把这几页真正读懂
8. 步骤 5 诊断初始化、激活与 BatchNorm
9. 步骤 6 不用 autograd 写完整 MLP 反向传播
10. 步骤 7 用层级结构扩大上下文
11. 步骤 8 从均匀聚合写到字符级 GPT
12. 步骤 9 从 UTF-8 字节构建 BPE 分词器
13. 步骤 10 先把 GPT-2 124M 的结构复现正确

14. 步骤 11 一项一项加速训练
15. 步骤 12 设置 token 预算、数据分片与多卡训练
16. 步骤 13 用验证、HellaSwag 与样本检查结果
17. 来源、缺口与验证范围

先建立直觉：13 步关键词、具象例子与类比

先把每一步想象成一个看得见的过程，再进入操作。下面集中保留每一步的关键词、人话解释、类比、微型例子和容易误解的地方。类比与演算是助手整理的学习辅助，不是讲者原话。

直接阅读原手册

1. 关键词拆解｜步骤 1：实验环境、数据、可复现性
2. 关键词拆解｜步骤 2：导数、计算图、链式法则、反向传播
3. 关键词拆解｜步骤 3：bigram、计数、概率、交叉熵、采样
4. 关键词拆解｜步骤 4：上下文窗口、embedding、MLP、minibatch、泛化
5. 关键词拆解｜步骤 5：初始化、激活分布、饱和、BatchNorm
6. 关键词拆解｜步骤 6：手写反传、张量雅可比、广播、梯度累积
7. 关键词拆解｜步骤 7：层级分组、感受野、WaveNet 风格
8. 关键词拆解｜步骤 8：语言模型、因果注意力、位置、残差、LayerNorm
9. 关键词拆解｜步骤 9：字节、UTF-8、BPE、预切分、词表
10. 关键词拆解｜步骤 10：GPT-2 结构、参数量、权重绑定、生成
11. 关键词拆解｜步骤 11：吞吐、基准测试、融合算子、混合精度
12. 关键词拆解｜步骤 12：token 预算、梯度累积、数据分片、DDP、成本
13. 关键词拆解｜步骤 13：训练集 loss、验证 loss、基准评估、HellaSwag、样本审阅

关键词拆解｜步骤 1：实验环境、数据、可复现性

把这一步想成厨房里的第一件事：不是做菜，而是把灶台、食材和配方卡摆好。同一道菜两个人做出来不一样，多半不是手艺差别，而是有人没记火候、没记食材批次。可复现性就是把「这一锅到底怎么来的」写下来，让未来的自己能重做同一锅。

一、六个关键词，各自对应厨房里的哪一件

环境（environment）：Python、PyTorch、依赖包、CPU 还是 GPU。两台机器装不同版本的 PyTorch，就像一个用烤箱、一个用平底锅；菜名相同，细节可能不同。记录版本是为了能解释差异，不是为了追求「越新越好」。

数据集（dataset）：模型的练习册。本步的 `names.txt` 有 32,033 行，一行一个名字；读错文件或读成空文件，相当于拿错练习册，后面 loss 再漂亮也没有意义。

随机种子（seed）：随机过程的起始编号，像洗牌前固定洗牌步骤。`torch.Generator().manual_seed(42)` 让「抽签」从同一起点开始；它不让模型变聪明，也不保证不同硬件的每个浮点数完全一致。

训练记录（run log）：配方卡。至少写清数据切分、模型形状、步数、学习率、种子、设备与代码版本。没有它，只剩一句「我昨天跑出来挺好」，无法定位结果来自哪一项改动。

训练/验证切分（split）：练习册不能同时当考卷。用同一批样本既更新参数又评估效果，分数会偏高；按名字（而不是按窗口）切分，才能避免同一个名字的不同片段同时出现在两边。

一次只改一项（one change at a time）：想比较两个方案，就只动一个旋钮，其余保持不动。一次改三处，即使 loss 降了，也说不清是哪一处起的作用。

二、几个动作在空间里落在哪

动作	落在哪里	你会看到什么
`Path('names.txt').read_text().splitlines()`	数据格	32,033 行文本进入内存
`set(''.join(words))`	词表格	26 个字母；再加点号成 27
`manual_seed(42)`	随机格	之后每步抽签可重复
训练/验证索引	切分格	两份互不重叠的名字列表
运行日志	记录格	一行实验条件 + 一行结果

一句话：**先有位置，才谈得上记录；先能重做，才谈得上比较。**

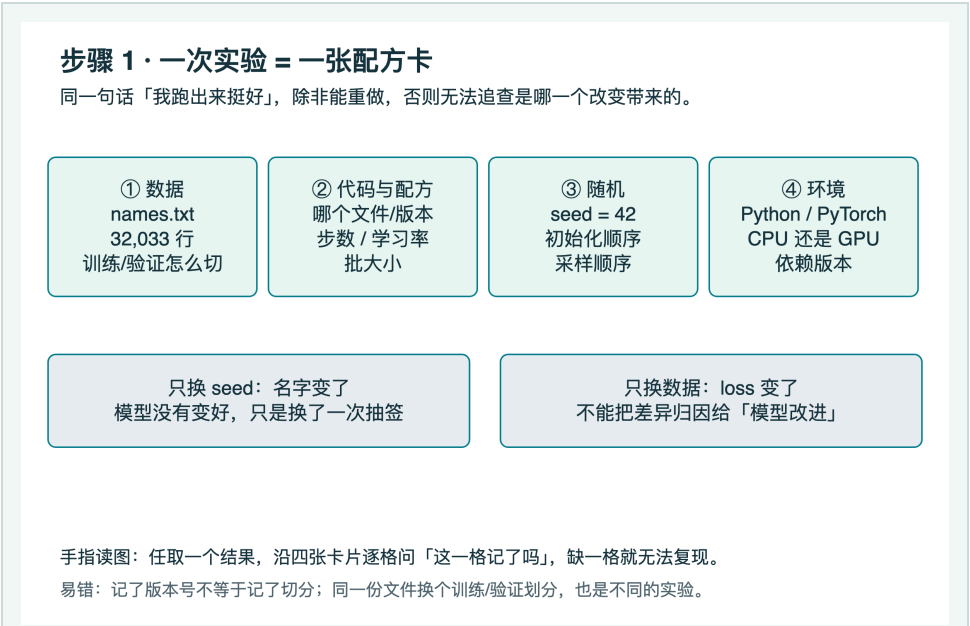

图注：助手绘制的教学示意，2026-11-10；四类记录与实际实验流程对应，不冒充课程截图或实验结果。

手指读图： 任取一次运行的结果，沿四张卡片逐格问「这一格记了吗」；缺哪一张，就说明哪一类差异无法排除。

三、一个小追踪：换 seed 到底改变了什么

同一份数据、同一段训练代码，把 seed 从 42 改成 0：

- 计数法采样的名字会变——因为抽签的起点变了；
- 在整本数据上算的平均 `-log(p)` 不会变——因为那是把全部真实字符对算一遍，与抽签无关；
- 如果训练里用到随机初始化，初始权重会变，训练曲线可能略有不同，但不同种子之间的差距通常小于「换数据」或「换模型」带来的差距。

所以看到两个结果不同时，第一步不是下结论「模型 A 更好」，而是问：**差异来自模型，还是来自随机性？**

四、常见误解

1. **「版本越新越好」**：不是。版本是记录项，不是评分项；换版本是为了可解释，不是为了追新。
2. **「重跑一遍 notebook 就是复现」**：不一定。内核里可能还留着上一次的变量，单元执行顺序也可能变了。
3. **「记了 commit 就够了」**：不够。数据切分、seed、步数、学习率缺一项，结果都可能对不上。
4. **「固定 seed 后结果必须逐位相同」**：不保证。不同硬件、不同算子实现可能有微小浮点差异。

五、合上书前的两个自问

- 如果只记得最终 loss 和步数，能重做出同一次实验吗？缺的是哪几格？
- 为什么「换 seed 导致名字不同」不能算作模型改进？

进入步骤 1 的操作正文 · 返回关键词导航

关键词拆解｜步骤 2：导数、计算图、链式法则、反向传播

把一次计算想成一条小型装配线：原料从一头进去，经过几道工序，最后出来一个数。导数回答「某个原料轻轻动一下，最终产物会动多少」；反向传播则从成品往回走，把「该谁负责」一站站分摊下去。这一步不是发明新数学，而是亲手把自动求导器平时替你做的事摊开。

还是看不懂？ 直接跳到「三岁小孩版」白话重讲，用五幕和实跑数字重新说一遍。

一、九个关键词，各站在装配线的哪一站

导数（derivative）：局部斜率。x 增加极小一点，输出大约变化 `dy/dx × Δx`。坡陡，轻推就变很多；坡平，推了也变化不大。

有限差分（finite difference）：用两次实际测量估坡度：`(f(x+h)−f(x))/h`。像用短尺量斜坡：h 太大测到一段平均坡，太小被计算机舍入误差干扰。它是独立参照，不是训练时用的方法。

计算图（computation graph）：把公式拆成节点和连线。`d = a*b + c` 里，a、b 先进乘法节点，得到的 u 再和 c 进加法节点。每条边表示「这个数怎么参与下一步」。

局部导数（local derivative）：只看某一站的敏感度。乘法 `u = a*b` 固定 b 时，`∂u/∂a = b`。它还没考虑后面所有工序。

链式法则（chain rule）：一串工序的总影响，等于沿路径把局部影响**相乘**。`a→u→d→L` 时，`∂L/∂a = ∂L/∂d × ∂d/∂u × ∂u/∂a`。像接力棒一站站传比例。

反向传播（backpropagation）：从 loss 节点逆着图走，把上游收到的影响乘以本地斜率，再交给前一站。它是**高效计算梯度的程序**，不是另一种导数。

拓扑顺序：先保证一个节点的下游梯度都准备好，再往它的父节点传。像先结算所有下游账目，再汇总供应商该承担的份额。

梯度累加：同一个数被用两次，它收到两条影响，必须相加。`a+a` 对 a 的导数是 `1+1=2`；代码里的 `+=` 正是把两张账单合并。

梯度下降（gradient descent）：梯度指 loss 上升最快的方向，就往反方向挪一点。学习率是每次挪的步幅：太大容易跨过谷底，太小进展慢。

二、每条式子，在图上怎么读

式子	手指走到哪	读到什么
`out = a*b + c`	先到乘法节点，再到加法节点	前向数值：u=6，d=10
`∂u/∂a = b`	停在乘法节点，看另一个输入	局部斜率 = 3
`∂L/∂a = ∂L/∂d × ∂d/∂u × ∂u/∂a`	从 L 往回，逐站相乘	2 × 1 × 3 = 6
`x.grad += ...`	同一节点被走两次	两条贡献相加，不是覆盖
`p.data -= lr * p.grad`	每个参数自己那一格	朝下坡方向挪一小步
`(f(x+h)-f(x))/h`	在曲线同一点左右各取一小段	用测量值独立核对 6

一句话：**前向算数值，反向乘斜率；形状相同的是数值，形状相同的是梯度，但两者含义不同。**

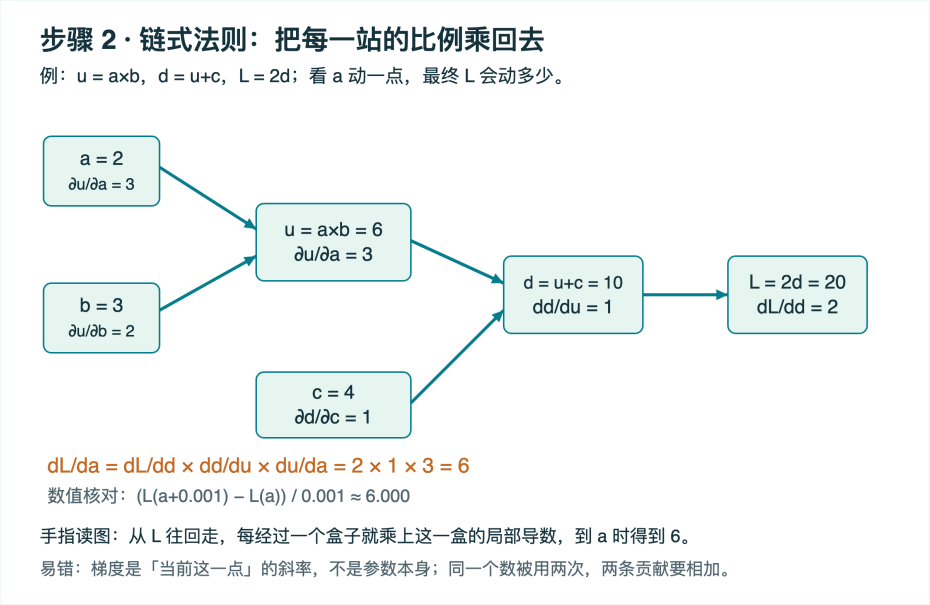

图注：助手绘制的教学示意，2026-11-10；例子 a=2、b=3、c=4 只用于手算，与 micrograd 的真实训练参数无关。

手指读图： 从最右边的 L 出发，每经过一个盒子就乘上这一盒标出的局部导数，走到 a 时得到 6；再回到曲线，用 0.001 的差分验证同一个数。

三、手算一遍：a 动一点，L 动多少

取 `a=2, b=3, c=4`：`u=6, d=10, L=2d=20`。

- `∂L/∂d = 2`（L 是 d 的两倍）
- `∂d/∂u = 1`（加法直传）
- `∂u/∂a = b = 3`（乘法里另一个因子）

三段相乘得 `∂L/∂a = 6`。若学习率 0.01，a 就从 2 变成 `2 − 0.01×6 = 1.94`。

再用差分核对：`(L(2.001) − L(2)) / 0.001 ≈ 6.000`。手算、链式、差分三条路给出同一个数，才说明这一站的实现没接错。

四、常见误解

1. **「梯度就是参数的值」**：不是。梯度是当前这一点、当前这批数据下 loss 对参数的局部敏感度。
2. **「梯度为零说明训练完成」**：不一定。也可能饱和、实现断开或这一批数据恰好平坦。
3. **「反向传播是另一种求导方式」**：它就是链式法则的高效实现，没有额外的数学。
4. **「同一节点只走一次」**：被用两次就要收两条梯度，漏加会让梯度偏小。

五、合上书前的两个自问

- 如果把 `+=` 写成 `=`，`a+a` 这种结构会得到多少梯度？错在哪一步？
- 学习率改成 1.0，a 一次更新后会变成多少？为什么可能直接跨过谷底？

进入步骤 2 的操作正文 · 返回关键词导航

关键词拆解｜步骤 3：bigram、计数、概率、交叉熵、采样

把这一节想成一间只卖 27 种珠子的「名字接龙小店」：26 个小写字母，再加一颗表示「名字结束」的点号。顾客递进上一颗珠子，店员翻账本、按比例抽下一颗；抽到点号就关门。整节内容其实是三个动作——**记账（数次数）、分摊（变概率）、抽签（采样）**——最后再让一块可以自己改数字的分数板 `W` 学着做同一件事。

本节引用的**真实数字**来自课程数据 `names.txt`：32,033 个名字、196,113 个字符、228,146 对相邻字符，词表 27 个；由助手在本机统计，只为对照数量级。**手算数字**（三个名字、三个字符的小账本）是助手编的教学例子，只为让人能跟着算完。

一、九个关键词，各自站在店里的哪个位置

字符级（character-level） 店里只有 27 个货架。名字 `emma` 不是一个整体，而是 e、m、m、a 四颗珠子，前后再加点号表示开场与收尾。拆到字符，是为了让词表小到能摊在桌上看清；代价是一个名字要抽四五次签，序列变长。它不表示模型「认识字母」，只是把字符当成 0 到 26 的编号。

bigram（二元组） 一次只看两颗**相邻**的珠子：左边那颗用来查账，右边那颗是要猜的答案。`emma` 拆成 `.e / em / mm / ma / a.` 五道题——两端加点号，才学得会「怎么开场」和「何时收尾」。整本数据共有 228,146 道这样的题。注意 bigram 不是「任意两颗字符」：e 和 a 在 emma 里并没有挨着，凑不成一道题。

计数矩阵 N（count matrix） 一本 27 行 × 27 列的账本：**行 = 现在手里是哪颗珠子，列 = 下一颗是谁**；每看到一次这种接法，就在交叉格子里放一张票。真实数据里 m 这一行共 6,642 张票：m→a 2,590 张，m→i 1,256 张，m→e 818 张，m→点号 516 张，m→o 452 张，m→y 287 张；m 后面接 g、q、x 一次都没出现过，那三格是 0。 空间读法：`N[行, 列]`。行号由当前字符决定，列号由下一个字符决定；两个下标写反，整本账就跟着错。 容易误解：N 里是票数，不是概率。整张表加起来是 228,146 张票，不是 1。

概率 P（probability，行归一化） 把同一行的票数除以这一行的总票数，得到「下一颗珠子各有多大机会」。m 行：2590/6642 ≈ 0.390，1256/6642 ≈ 0.189，818/6642 ≈ 0.123。 空间读法：**每一行自己变成一个完整的饼**，27 行就是 27 张饼，每张饼都要被完整分掉（行和 = 1）。 容易误解：不是把整张表除以总和。整表除以总和，得到的是「这种接法占全部票数的比例」，回答不了「m 后面谁更可能」。

加一平滑（add-one smoothing） 每个格子先假装至少出现过一次：全部加 1，再除以「原票数 + 27」。m 行分母从 6,642 变成 6,669，m→a 变成 2591/6669 ≈ 0.3885；原来为 0 的 g、q、x 三格各得 1/6669 ≈ 0.00015。 代价是真实的：a 原本 0.3899，平滑后掉到 0.3885——匀给未见组合的概率，正是从这些常见组合身上分走的。 容易误解：平滑不是免费保险；加 1 也不一定最好，加多少是「敢不敢相信没见过的接法」的取舍。

采样（sampling） 按这一行的概率抽一次签：把 0 到 1 的尺子按份额切段，随机落一根针，针落在哪段就选哪个字符。抽到谁，就用谁那一行继续抽；抽到点号收工。 整本数据上，这份计数模型的平均损失是 2.454；均匀乱猜 27 个字符是 3.296——这个差距就是「学到了一点接法」的证据。 容易误解：概率最高不等于必选；同一个模型每次生成的名字可以不同，这不是 bug，是抽签本身的性质。

负对数似然 / 交叉熵（NLL / cross-entropy） 模型给真实答案分配的概率是 p，这一次的惩罚就是 `-log(p)`：p=1 → 0，p=0.5 → 0.69，p=0.39 → 0.94，p=0.1 → 2.30，p=0.05 → 3.00；m 行里最小的平滑概率是 1/6669 ≈ 0.00015，对应约 8.81（整张表里最挤的 a 行是 1/(33,885+27) ≈ 0.00003，约 10.43）；若直接给 0，损失是无穷大。 空间读法：它是一把「惊讶尺」——横轴是概率，纵轴是这次损失的高度；概率越靠近 0，曲线越陡地冲上去。 容易误解：交叉熵不是准确率，也不是「对/错」标签；它衡量模型给正确答案分配了多少概率。单个样本若真的给到 p=1，损失确实是 0；但在真实语料上，没有任何模型能给每个真实后继都分配 1，所以整本书的 loss 只会逼近而不会等于 0。

one-hot 27 个开关，只按亮当前字符那一个。空间读法很关键：`one-hot @ W` 在数学上是一次 27 项点积，但因为只有一个位置是 1，其余全是 0，实现上等价于**把 W 的那一整行抽出来**——所以这一步的「神经网络」，第一层其实是在查表。 容易误解：one-hot 没有距离含义。两个 one-hot 向量的点积是 0，只说明它们不是同一个字符，不表示「毫无关系」。

logits 与 softmax logits 是归一化之前的分数，可以是负数，加起来也不必是 1；softmax 先取 exp（全部变正），再除以总和。教学数字：`[2.0, 1.0, 0.5, -0.5, -1.0]` → exp 后 `[7.39, 2.72, 1.65, 0.61, 0.37]`，总和 12.73 → 概率 `[0.58, 0.21, 0.13, 0.05, 0.03]`。 容易误解：logits 不是概率，别直接当百分比读；softmax 也不改变谁大谁小的排序，只是把分数压成份额。

二、每条计算表达式，在空间里怎么读

表达式	形状	手指走到哪	读到什么
`N[left, right] += 1`	原地加	行=当前、列=下一个，交叉的那一格	一张票
`N.sum(1, keepdim=True)`	(27,1)	横着扫过一行	这一行的总票数
`P / P.sum(1, keepdim=True)`	(27,27)	每格除以自己那一行的总数	27 行，每行各自和为 1
`P[ix]`	(27,)	抽出一整行	当前字符的 27 份份额
`multinomial(px)`	一个整数	在 0–1 尺子上落针	下一个字符的编号
`probs[range(N), ys]`	(N,)	每道题只取「真实答案那一格」	N 个真实答案的概率
`-log(p)`	一个数	在惊讶尺上竖直读高	这一次的惩罚
`softmax(logits)`	(N,27)	每行先 exp，再除以行和	每行 27 份份额
`xenc @ W`	(N,27)	只留一个 1，顺着它走	等价于抽 W 的一行
`backward()`	W.grad 为 (27,27)	每个格子该往上还是往下调	与 W 同形状的梯度

（表中为方便阅读的简写，完整调用见上文代码块；`N` 指一批样本数，整本数据的 loss 是对全部 228,146 对求平均。）一句话记住方向：**前向是把行变成份额，反向是把份额的误差摊回每一格**。形状相同不表示含义相同——`P` 是 (27,27) 的表、`logits` 是 (N,27) 的批次输出，`W` 才是 (27,27)；前者必须非负且每行和为 1，后两者完全不必。

三、四张空间图

第一张图把三个动作摆成一条流水线：票数、行、平滑后的份额、柱子高度。

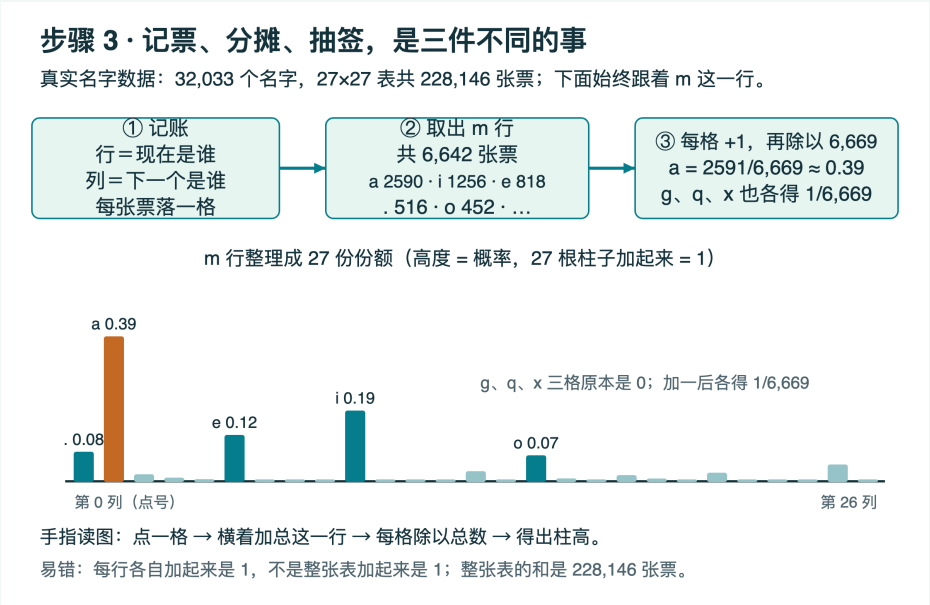

图注：助手绘制的教学示意，2026-11-10；票数与 m 行计数来自 `names.txt` 的真实统计，柱高按加一平滑后的概率绘制。不冒充课程截图或模型性能。

手指读图： 先在左边的表里点一格（行、列），再横着把这一行加总，最后让每一格除以总数——除出来的数就是右边一根柱子的高度。

第二张图把同一行概率接成尺子：采样不是「选最大的」，而是在这段长度上随机落针。

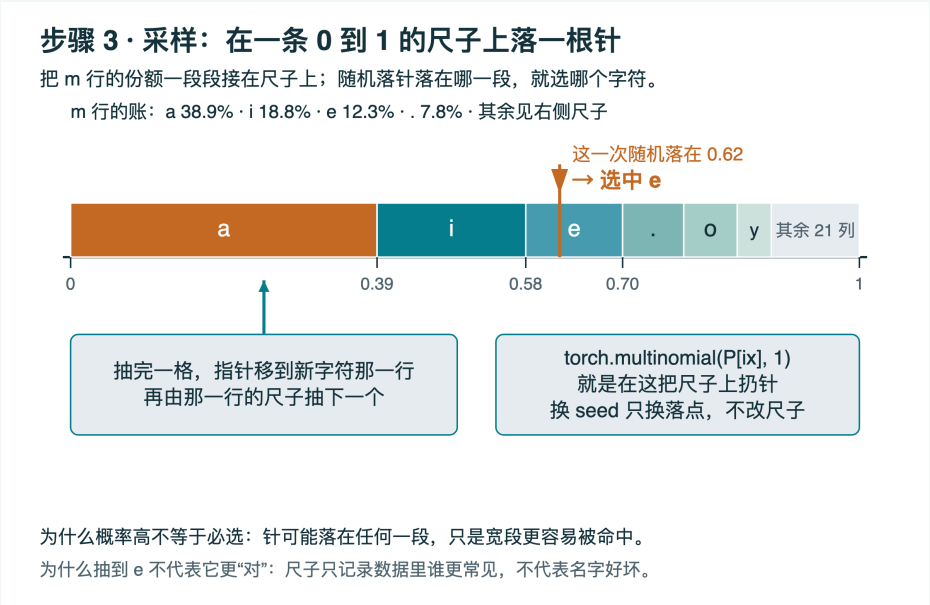

图注：助手绘制的教学示意，2026-11-10；分段宽度等于 m 行各字符的平滑概率，落针位置是虚构的一次抽样，用于说明机制。

手指读图： 从 0 出发，沿尺子走过 a、i、e 的段；针落在哪一段，下一个字符就是谁。

第三张图是交叉熵的形状：给真实答案的概率越低，这一次的惩罚越高。

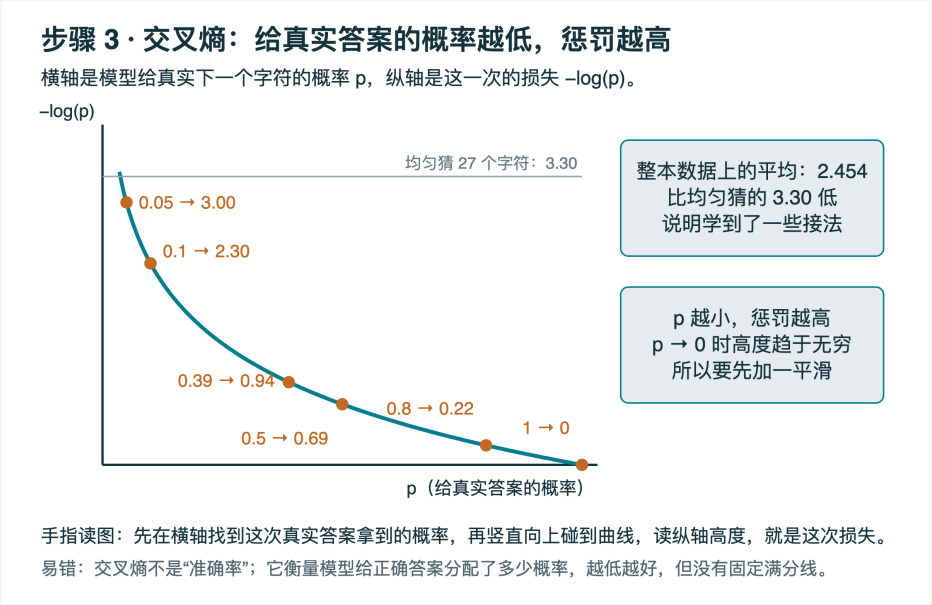

图注：助手绘制的教学示意，2026-11-10；曲线为 `-log(p)` 的真实形状，标注的概率点与整本数据的平均损失 2.454、均匀基线 3.296 均为实算。

手指读图： 先找到这次真实答案拿到的概率，竖直往上碰到曲线，再横着读纵轴的高度。

第四张图对照两条路：计数法直接数出份额，神经网络版用 one-hot 抽行、用 softmax 摊份额。

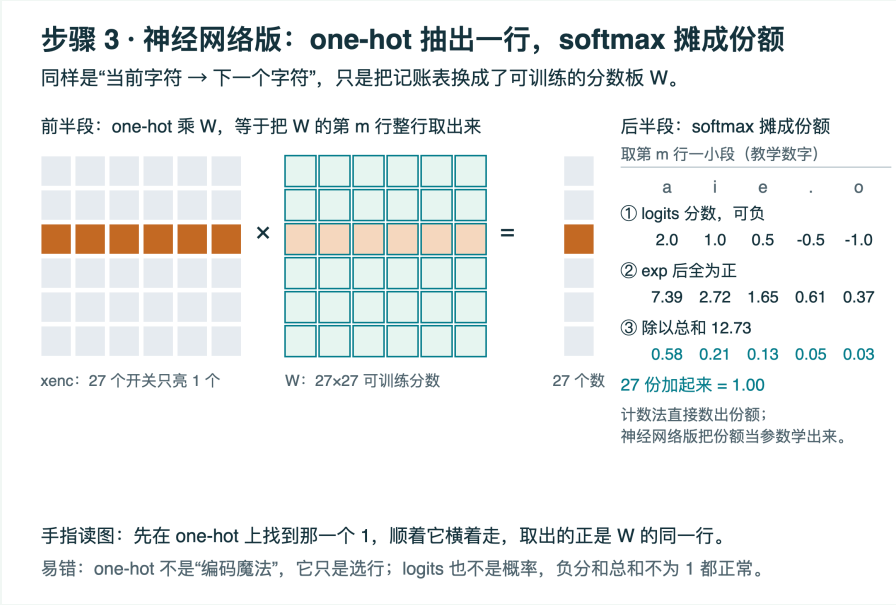

图注：助手绘制的教学示意，2026-11-10；图中 `W` 与分数为教学数字，只演示 one-hot 选行与 softmax 的计算关系，不对应任何真实权重。

手指读图： 先在 one-hot 里找到那一个 1，顺着它横着走，取出的正是 `W` 的同一行；再看这一行分数怎样被 exp 拉正、被总和除成份额。

四、手算一遍：三个名字、三个字符、一次抽签

把数据缩到能心算：三个名字 `mam`、`amm`、`maa`，词表只有 `. / a / m` 三个字符。两端加点号后一共 12 对。

先记账：

行（当前）	下一颗是 `.`	下一颗是 `a`	下一颗是 `m`	行总计
`.`	0	1	2	3
`a`	1	1	2	4
`m`	2	2	1	5

再加一、除以「行总计 + 3」：

行	概率（`.` / `a` / `m`）	分母
`.`	1/6 ≈ 0.17 · 2/6 ≈ 0.33 · 3/6 = 0.50	6
`a`	2/7 ≈ 0.29 · 2/7 ≈ 0.29 · 3/7 ≈ 0.43	7
`m`	3/8 = 0.375 · 3/8 = 0.375 · 2/8 = 0.25	8

生成一个名字，假设四次抽签依次抽到 m、a、m、点号：

1. 从 `.` 行出发，m 占 50%，抽到 m；
2. 到 m 行，`.` 和 a 各 37.5%，抽到 a；
3. 到 a 行，m 占 3/7 ≈ 43%，抽到 m；
4. 回到 m 行，抽到点号，收工——得到 `mam`。

这一次 m→a 的损失：平滑后的模型给真实答案 3/8，`-log(3/8) ≈ 0.98`。把 12 对全部算平均，这份小账本（平滑后）的平均损失约 1.00；均匀乱猜 3 个字符是 `log 3 ≈ 1.10`。只差 0.10，并不是因为模型背得好——恰恰相反，只有三个名字时每一行都接近均匀，原始计数的平均是 0.945、平滑后是 1.00，平滑把优势又抹掉了一点。数据越小、越均匀，loss 越贴着均匀基线；这也是为什么小数据上漂亮的 loss 不能直接当成本事。

五、五个常见误解

1. **「整张表加起来是 1」**：不是。每一**行**各自加起来是 1，整张表和是票数 228,146。
2. **「概率最高就会选中」**：不一定。0.39 只表示尺子上这一段占 39% 的长度。
3. **「平滑是免费的」**：不是。加一给没见过组合留了位置，代价是从常见组合那里匀走了概率。
4. **「计数法和神经网络是两套东西」**：在这个任务里几乎是同一件事——one-hot 乘 W 就是抽行，训练就是把 W 调成一张统计表。
5. **「生成的名字像人才算好模型」**：不像。判断要回到同一份数据上算平均 `-log(p)`，而不是挑几个顺眼样本。

六、合上书前的三个自问

- 若把 `N.sum(1)` 写成 `N.sum(0)`，哪一组数会变？概率表还有没有「每行和为 1」？
- 若把加一改成加 0.01，m 行里 g、q、x 的概率会变成多少？常见接法的概率会变大还是变小？

- 同一个模型、同一个种子，如果每次都把随机状态重置，两次采样会得到同一个名字吗？若把两次生成连着跑、不重置，结果为什么又不同？换种子改变的是什么、没改变的是什么？

进入步骤 3 的操作正文 · 返回关键词导航

关键词拆解｜步骤 4：上下文窗口、embedding、MLP、minibatch、泛化

从「只看上一个字符」改成「看前三个字符」，像做题时允许翻前几页笔记：能看到更多线索，但也要求模型学会把几条线索**拼在一起**再判断。这一步第一次出现「一层层加工」的网络，也是第一次需要区分「背下来」和「学会」。

一、十个关键词，各站在流水线的哪一段

上下文（context）：预测当前位置时允许查看的前文。`block_size=3` 表示固定看最近三个字符，不代表模型懂无限历史。

滑动窗口（sliding window）：每生成一个目标，窗口往前移一格。`... a b c d ...` 组成 `...→a`、`..a→b`、`.ab→c`、`abc→d`。同一个名字会产生很多道题，题目之间高度重叠。

embedding（嵌入向量）：每个字符对应一串可训练数字。可以想象把 27 个字符放到一张小地图上，训练会调整坐标；维度是坐标轴数，不是人类可命名的「元音/辅音」标签。

MLP（多层感知器）：几层「加权混合 + 非线性」。它接收拼好的上下文坐标，逐层变换，最后为 27 个候选字符打分。本步教学形状是 `(N,3,2) → (N,6) → (N,100) → (N,27)`。

tanh 激活：把数压到 –1 到 1 的平滑曲线，给网络非线性。输入太大时输出贴近边界、斜率接近 0，梯度难传（步骤 5 会专门诊断）。

logits：输出层给 27 个字符各一个未归一化分数；softmax 转成概率，再用交叉熵和真实下一个字符比较。

minibatch（小批次）：每次用一小组样本估更新方向，像抽一小叠练习题估薄弱点。批越小波动越大，批越大内存压力越高。

过拟合一个批次（overfit one batch）：先检查模型能不能记住一小份固定题目（本步常用 32 个样本）。它是管线自检：连这叠都背不下来，先查标签、梯度和更新；背下来也不证明会做新题。

训练/验证/测试切分：训练集更新参数，验证集挑方案，测试集尽量只在最后用一次。按名字切分，避免同一个名字的不同窗口跨两边造成泄漏。

泛化（generalization）：在没参与更新的名字上仍表现不错。训练 loss 下降只说明越来越会做练习册里的题。

二、每一步的形状，和它为什么必须是这个形状

阶段	形状	手指读图
取窗口	`(N, 3)`	N 道题，每题 3 个字符编号
查 embedding	`(N, 3, 2)`	每个字符变成 2 个坐标
拼接	`(N, 6)`	3 段坐标排成一行：3×2=6
隐层	`(N, 100)`	6 个数混合成 100 个新数
输出	`(N, 27)`	每个位置 27 个分数
loss	一个数	只取真实答案那一格算 `-log(p)`

本步教学网络的参数量可以数出来：MLP 两层是 `6×100 + 100 + 100×27 + 27 = 3,427`，再加上 embedding 表 `27×2 = 54`，一共 3,481 个可调数字。形状对不上时，先数元素总数，再数参数个数，比盯着 loss 有效。

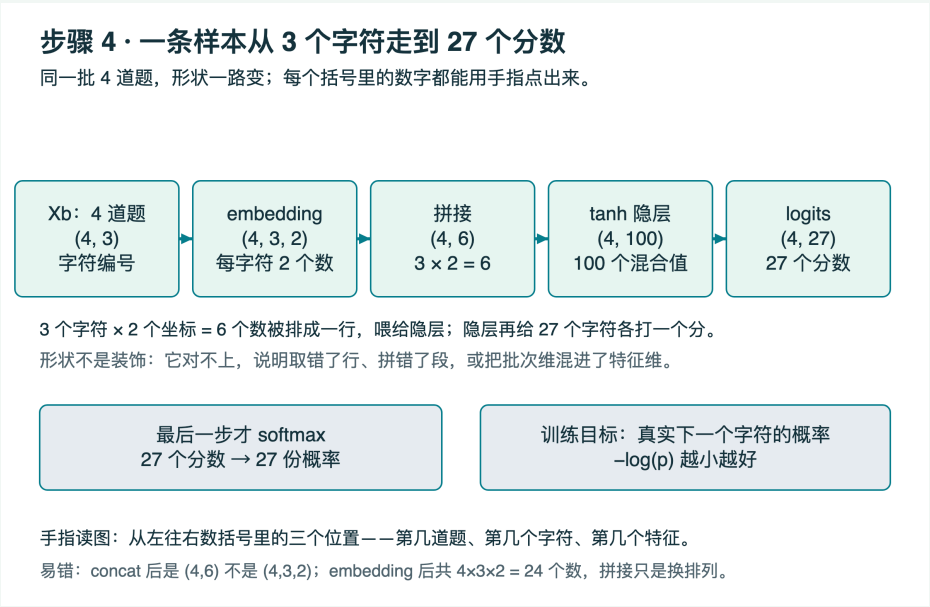

图注：助手绘制的教学示意，2026-11-10；形状对应正文教学脚本 N=4、D=2、H=100、V=27，数字只用于说明维度。

手指读图： 从左往右数括号里的三个位置——第几道题、第几个字符、第几个特征；数到最后一格，27 个分数还不是概率。

三、一个小追踪：一句话怎么变成 27 个分数

假设一条样本的 3 个字符编号是 `[5, 13, 13]`，嵌入维度 2：

1. 查表得 3 组坐标，拼成 6 个数；
2. 乘 `W1 (6,100)` 加偏置，得到 100 个数；
3. 过 tanh，仍在 `(−1, 1)`；
4. 乘 `W2 (100,27)` 加偏置，得到 27 个分数；
5. softmax 成 27 份概率，取真实下一个字符那一格算 `−log(p)`；

6. 反传更新 `W1`、`W2`（以及 embedding 和偏置）。

「过拟合一个批次」就是把这 6 步在 32 个样本上重复很多次：如果 loss 降不下去，先别换模型，先查第 5 步取的是不是真实答案那一格。

四、常见误解

1. **「embedding 的某一维代表元音」**：不保证。维度只是可学习坐标，人类含义要另做分析。
2. **「能背下一个批次就说明模型好」**：不。那只是管线自检，泛化要看验证集。
3. **「验证集可以随便用来挑最好的那次」**：挑得越多，它就越像训练集，最终要留一份没动过的测试集。
4. **「上下文越长越好」**：不一定。窗口变长会带来更多参数与计算，也可能学到更多噪声。

五、合上书前的两个自问

- 把 `block_size` 从 3 改成 5，`(N,6)` 会变成多少？`W1` 的第一维跟着变成多少？
- 训练 loss 一直降、验证 loss 开始升，先改哪一项？为什么不是先改学习率？

卡住时按这个顺序查

按现象列出先查什么、修好后怎么验。这些路径来自课程故障与代码整理，同一个报错不保证只有一个原因；先定位影响的是数据、数学、状态还是系统性能，再回到上面的操作，不靠同时换五个参数碰运气。

现象	先查什么	修好后怎么验
loss 每轮越来越奇怪	是否清梯度、是否重做前向	固定批次短跑并记录每步
概率行和不是 1	sum 的维度与 keepdim	各行和为 1，不只看总和

课程里出现过的一个真实案例

案例 2｜零概率名字

- 起点与做法：未见字符对带来 log(0)，加伪计数
- 讲者当时的结果：不再因零概率给无穷 NLL
- 可借鉴：平滑改变整体分布
- 出处：第2课 01:00:50 [O2]

这是课程演示，数字不是你在自己机器上的复现结果。

原课练习（官方英文原文）

下面是作者在视频说明里给学习者的练习指令，保留英文原文，不冒充聊天提示词。建议先独立完成，再看对应代码；中文只用于说明它落在本步骤的哪一段。

第 2 课原练习

[O2]

E01: train a trigram language model, i.e. take two characters as an input to predict the 3rd one. Feel free to use either counting or a neural net. Evaluate the loss; Did it improve over a bigram model?
E02: split up the dataset randomly into 80% train set, 10% dev set, 10% test set. Train the bigram and trigram models only on the training set. Evaluate them on dev and test splits. What can you see?
E03: use the dev set to tune the strength of smoothing (or regularization) for the trigram model - i.e. try many possibilities and see which one works best based on the dev set loss. What patterns can you see in the train and dev set loss as you tune this strength? Take the best setting of the smoothing and evaluate on the test set once and at the end. How good of a loss do you achieve?
E04: we saw that our 1-hot vectors merely select a row of W, so producing these vectors explicitly feels wasteful. Can you delete our use of F.one_hot in favor of simply indexing into rows of W?
E05: look up and use F.cross_entropy instead. You should achieve the same result. Can you think of why we'd prefer to use F.cross_entropy instead?
E06: meta-exercise! Think of a fun/interesting exercise and complete it.

中文对照

- E01：训练一个三元（trigram）语言模型，也就是用两个字符作输入预测第三个。计数法或神经网络都行。评估 loss——比 bigram 模型有改善吗?
- E02：把数据随机切成 80% 训练、10% 验证（dev）、10% 测试。bigram 和 trigram 只在训练集上训练，在 dev 和 test 上评估。你看到了什么?
- E03：用 dev 集调 trigram 的平滑（或正则化）强度——多试几种，看哪一种按 dev loss 最好。调这个强度时，训练集和 dev 集的 loss 各呈什么走势?取最优的平滑强度，最后只在测试集上评估一次。你能得到多好的 loss?
- E04：我们的 one-hot 向量其实只是选出 W 的一行，显式造这个向量显得浪费。你能删掉 F.one_hot，改成直接按行索引 W 吗?
- E05：查一下并改用 F.cross_entropy，结果应当相同。想一想：为什么我们更愿意用它?
- E06：元练习！想一个有趣的练习，并把它做完。

本步对应的课程章节与时间定位

第 2 课 | The spelled-out intro to language modeling: building makemore（手把手入门语言建模：搭出 makemore）

英文自动字幕约 19,445 词；逐字稿；主线步骤。

起点	原章节标题	视频定位
00:00:00	intro（开场介绍）	播放
00:03:03	reading and exploring the dataset（读取并探索数据集）	播放
00:06:24	exploring the bigrams in the dataset（查看数据集里的字符对（bigram））	播放
00:09:24	counting bigrams in a python dictionary（用 Python 字典统计字符对）	播放
00:12:45	counting bigrams in a 2D torch tensor ("training the model")（用二维 torch 张量统计字符对（“训练模型”））	播放
00:18:19	visualizing the bigram tensor（把字符对计数矩阵画出来）	播放
00:20:54	deleting spurious (S) and (E) tokens in favor of a single . token（去掉多余的开头/结束标记，统一用一个点号）	播放
00:24:02	sampling from the model（从模型里采样）	播放

起点	原章节标题	视频定位
00:36:17	efficiency! vectorized normalization of the rows, tensor broadcasting（效率：按行向量化归一化与张量广播）	播放
00:50:14	loss function (the negative log likelihood of the data under our model)（损失函数：模型下数据的负对数似然）	播放
01:00:50	model smoothing with fake counts（用假计数做模型平滑）	播放
01:02:57	PART 2: the neural network approach: intro（第二部分：神经网络做法（开场））	播放
01:05:26	creating the bigram dataset for the neural net（为神经网络准备字符对数据集）	播放
01:10:01	feeding integers into neural nets? one-hot encodings（整数怎么喂给神经网络？独热编码）	播放

起点	原章节标题	视频定位
01:13:53	the "neural net": one linear layer of neurons implemented with matrix multiplication（“神经网络”：用矩阵乘实现的一层线性神经元）	播放
01:18:46	transforming neural net outputs into probabilities: the softmax（把输出变成概率：softmax）	播放
01:26:17	summary, preview to next steps, reference to micrograd（小结、预告下一步、回看 micrograd）	播放
01:35:49	vectorized loss（向量化损失）	播放
01:38:36	backward and update, in PyTorch（在 PyTorch 里反传与更新）	播放
01:42:55	putting everything together（把各部分拼起来）	播放
01:47:49	note 1: one-hot encoding really just selects a row of the next Linear layer's weight matrix（注 1：独热编码其实只是取出下一层权重矩阵的一行）	播放

起点	原章节标题	视频定位
01:50:18	note 2: model smoothing as regularization loss（注 2：模型平滑就是正则化损失）	播放
01:54:31	sampling from the neural net（从神经网络采样）	播放
01:56:16	conclusion（结语）	播放

进入步骤 4 的操作正文 · 返回关键词导航

关键词拆解｜步骤 5：初始化、激活分布、饱和、BatchNorm

这一步像给一条很长的传话队伍做体检：不是听最后一个人说了什么，而是每一站都量一下「声音有多大、还听得清吗」。信号如果一开始就爆掉或缩成零，后面再调学习率也救不回来。

一、七个关键词，各对应体检里的哪一项

初始化（initialization）：训练前给权重设起始值。尺度合适的随机起点，既让神经元不完全一样，也避免信号经过多层后爆炸或消失。初始化错了，后面所有超参数都在补它的债。

激活值（activation）：某层前向算出来的数。看直方图能发现它是否挤在零附近、范围过宽，或集中在 tanh 的 ±1。它是「信号在这一站的音量」。

饱和（saturation）：tanh 输入很大时输出贴近 ±1，曲线几乎平、导数接近 0。像水阀拧到极限，再推输入也不改变出水量，反向信号便传不回去。

梯度尺度（gradient scale）：参数变化对 loss 的影响大小。梯度全接近零，更新像没踩油门；极大则可能一步冲过头。看梯度直方图比只盯最后 loss 更能说明内部发生了什么。

BatchNorm（批归一化）：按一个批次统计激活的均值和方差，再缩放平移，让中间信号落在可控范围。像每个接力区都重新校准刻度尺——但这把尺依赖当批数据。

运行统计量（running statistics）：训练时逐渐累计的均值和方差，评估时用它们代替当前批统计。它们是模型状态的一部分，存模型时要一起存；只保存权重，等于拿走了刻度表。

train/eval 模式：训练时 BN 用批次统计并更新累计值；评估时用累计值。忘了切模式，同一个输入会因「同批其他样本不同」而改变输出。

二、诊断顺序：先看信号，再改参数

现象	先看哪里	说明
激活全挤在 ±1	每层 tanh 输出直方图	饱和，反向斜率近 0
激活全是 0 附近	输入尺度、初始化	信号被压扁
梯度随层数迅速变小	各层梯度直方图	可能初始化过小或饱和
BN 前后差异巨大	归一化的轴与形状	轴选错，形状对但统计错
评估结果忽好忽坏	是否忘了 `eval()`	用了当批统计而不是累计值

一句话：**先定位信号在哪一层失真，再决定改初始化、改激活还是加归一化。**

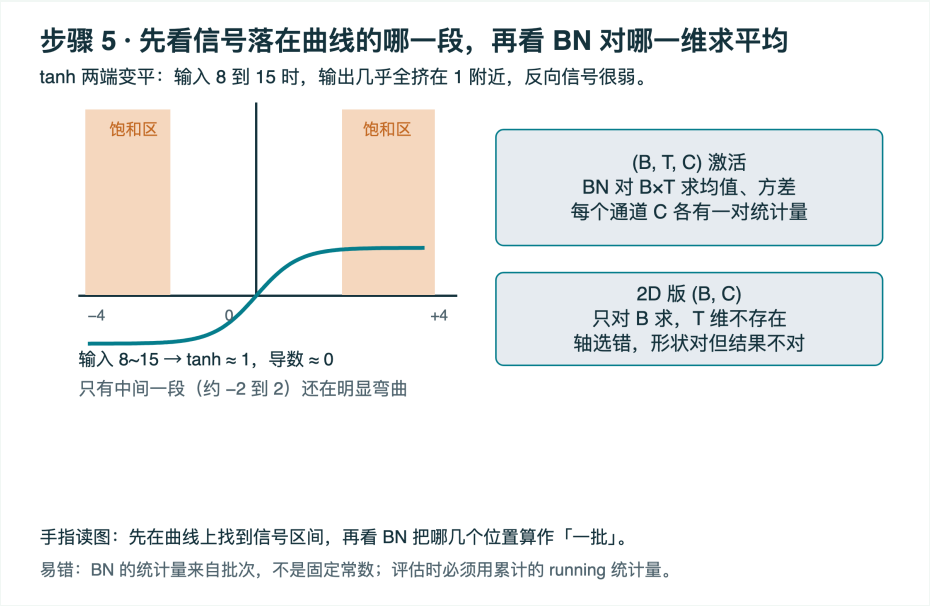

图注：助手绘制的教学示意，2026-11-10；tanh 曲线与饱和区间按标准函数绘制，8~15 的例子来自正文说明，不是实测分布。

手指读图： 先在横轴找到这一层的输入范围，竖直向上碰曲线读输出；再看右侧方框，确认 BN 把哪几个位置算作「一批」。

三、一个小例子：为什么 8 到 15 几乎没区别

`tanh(8) ≈ 0.99999977`，`tanh(15) ≈ 1.0`。两者输出几乎相同，导数分别约为 $1-\tanh^2(8) \approx 4.5\times10^{-7}$ 和更小。也就是说，输入从 8 变到 15，前向几乎看不出差别，反向收到的斜率近乎零。模型不是「学得慢」，而是这一站的信号已经传不回去了。

反过来，输入落在 −2 到 2 之间时，曲线还有明显弯曲，`tanh'(0)=1`，梯度更容易通过。初始化要做的，就是把大多数输入放进这段弯曲区。

四、常见误解

1. **「BN 让训练一定更好」**：不一定。它改变的是优化地貌，可能更快，也可能在小批次上引入噪声。
2. **「BN 的均值是固定常数」**：不是。训练时来自当批，评估时来自 running 统计。
3. **「只保存权重就够了」**：不够。running 统计量不恢复，评估结果会变。
4. **「激活范围越宽越有表达力」**：不是。超出非线性敏感区后，宽度不等于信息。

五、合上书前的两个自问

- 若把 3D 激活 `(B,T,C)` 的 BN 轴写成只对 B 求，结果形状还对吗？为什么数值不对？
- 训练时忘了 `model.eval()`，同一个验证样本的预测会变吗？为什么？

进入步骤 5 的操作正文 · 返回关键词导航

关键词拆解｜步骤 6：手写反传、张量雅可比、广播、梯度累积

自动求导器平时替你做了三件事：**局部求导、形状对齐、结果累加**。这一步把变速箱拆开，让每颗齿轮单独转给你看。写不出这四式，不代表不会用 PyTorch；但写得出，就再也不会被「形状对、结果错」的 bug 困住。

一、七个关键词，各对应拆开的哪颗齿轮

向量/矩阵梯度：标量只有一个数；张量有很多元素。对每个元素求导会形成雅可比矩阵，直接存通常很贵；反传用矩阵乘法一次性算出所需的那部分。

矩阵乘法反向：若 `Y = X @ W`，上游梯度为 `dY`，则 `dX = dY @ Wᵀ`、`dW = Xᵀ @ dY`。转置来自输入与权重在乘积中的角色互换：谁在前向里被「乘」，反向就用另一个人的转置去乘它。

广播（broadcasting）：把较小形状的数值逻辑上扩展到大张量。前向加偏置时，偏置被每一行重复；反向必须把这些重复位置的影响**求和**还给原偏置，不能只留一份。

归约（reduction）：`sum`/`mean` 把许多数压成较少数，反向把梯度扩回原形状。前向取平均，反向就要除以元素数量；漏除会让梯度整体偏大。

embedding 反传：查表前向只取出某些行，反向把每个位置的梯度散回被取出的行。同一个字符被多次查到，所有贡献必须累加到同一行。

梯度核对：同一批数据、同一参数、同一前向下，比手写和 autograd 的梯度；再用有限差分做第三方参照。比较最大绝对差与容差，而不是要求浮点逐位相同。

梯度累积：连续算若干小批次梯度后再更新一次。它改变的是「更新频率」，不是「模型容量」；每步的缩放要按累积次数处理。

二、反向四式，各自在哪个位置

式子	形状	手指走到哪
`Y = X @ W + b`	`(4,3)@(3,2)→(4,2)`	前向一行：两输入一输出
`dX = dY @ Wᵀ`	`(4,2)@(2,3)→(4,3)`	回到 X，用 W 的转置
`dW = Xᵀ @ dY`	`(3,4)@(4,2)→(3,2)`	回到 W，用 X 的转置
`db = dY.sum(0)`	`(4,2)→(2,)`	四行的贡献加成一个

记住一句话：**反向公式里，转置出现在「前向时被放在右边（或左边）的那个输入」上；广播的量，梯度要沿被复制的轴求和。**

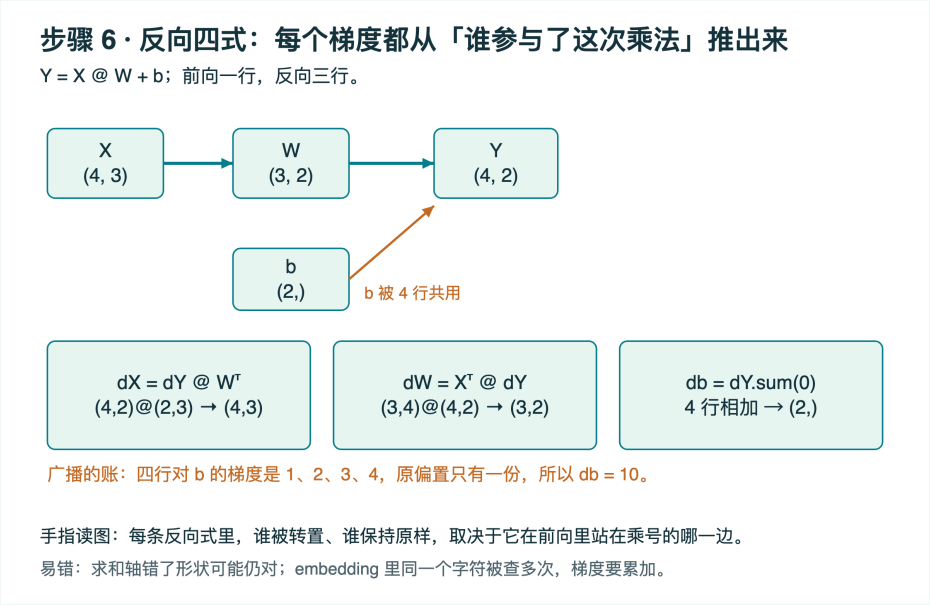

图注：助手绘制的教学示意，2026-11-10；形状取正文的 4×3、3×2 教学例子，不对应完整训练配置。

手指读图： 先沿前向箭头找到 Y，再沿反向箭头回到 X、W、b；每回到一个框，先对形状，再对数值。

三、手算一遍：广播的账为什么是 10

批大小 4，偏置 b 是 2 维，前向时同一份 b 被 4 行共用。设下游给这 4 行的梯度分别是 1、2、3、4：

- 每一行都觉得「b 应该动一点」，但 b 只有一份；
- 于是 b 的梯度是 `1+2+3+4 = 10`；
- 若只取最后一行（4），或保留成 4 个数，形状就与 b 不符。

embedding 同理：一个字符在一批里被查到 3 次，它的梯度要加 3 次，而不是覆盖 3 次。

四、常见误解

1. **「手写反传是重新发明梯度」**：不是，只是把自动求导的步骤显式写出来。
2. **「形状对就说明实现对」**：不对。求和轴、均值除数、广播还原错了，形状往往仍然对。
3. **「梯度核对要完全相等」**：不。浮点实现有误差，要比最大绝对差与容差。
4. **「梯度累积等于更大模型」**：不等于，它只改变更新频率与等效批大小。

五、合上书前的两个自问

- 若把 `db = dY.sum(0)` 写成 `sum(1)`，形状变成什么？哪一维被错误地合并了？
- 同一字符在一批中出现 3 次，若梯度只取最后一次，会偏大还是偏小？为什么？

进入步骤 6 的操作正文 · 返回关键词导航

关键词拆解｜步骤 7：层级分组、感受野、WaveNet 风格

固定窗口模型把所有历史字符一次性摊平，像把 8 张卡片并排铺在桌上；层级模型则先把相邻两张钉成一小叠，再把小叠合成大叠。信息没有变多，但**结构**变了：远距离的证据可以经过几站汇总，而不是一开始就挤在一层里。

一、六个关键词，各对应叠纸的哪一步

上下文长度 / 感受野（receptive field）：某个预测位置能影响到的最早输入范围。窗口越长，理论可用历史越多，但需要处理的信息也越多。感受野是「往下能碰到几个原始字符」，不是「模型理解了多少」。

分组与展平：把相邻字符的表示合并成更宽的向量。8 个字符先每 2 个一组，得到 4 组；(4,2) 的表示展平成 (4,2C) 再送进下一层。张量元素总数必须守恒，分组不能凭空丢字符或复制字符。

层级表示（hierarchical representation）：低层组合短片段，高层组合更长片段。可以类比音节组成词、词组成短语；这只是结构类比，不表示模型内部真有语言学模块。

参数共享：同一层变换应用到不同位置的小组，减少重复参数，也让局部模式能在多个位置复用。

WaveNet 风格：逐层扩大可见上下文的卷积式/分组式设计。这里的重点是「有组织地扩大视野」，不是把名字预测任务变成音频生成。

形状检查：若输入 `(B,T,C)`，分成小组时 T 下降、特征维通常增大；每次 reshape 前后元素数应一致，批维 B 不应被混进分组。

二、感受野是怎么一层层翻倍的

层	形状（单样本）	一个格子能看到几个原始字符
原始字符	8 个	1
两两成组	4 组	2
组再相合	2 个组合	4
顶层预测	1	8

一句话：**每上一层，一个格子的「视野」翻倍，格子的数量减半。**

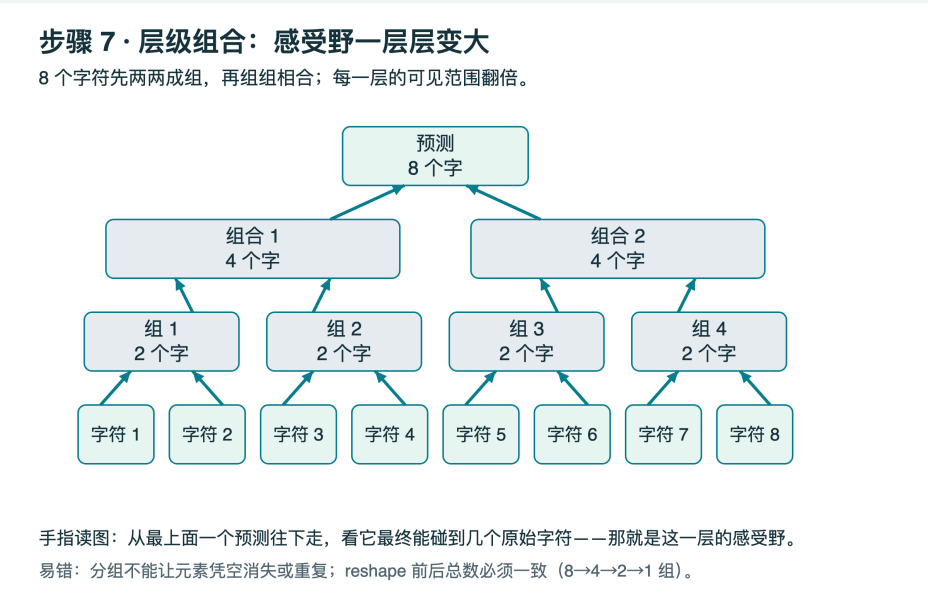

图注：助手绘制的教学示意，2026-11-10；8 个字符的教学例子对应本步 `block_size=8` 的设置，层级画法不代表课程代码的每一层细节。

手指读图： 从最上面的预测往下走，看它最终能碰到几个原始字符；每下一层，触点数量翻倍。

三、一个小追踪：abc 从哪来

字符 `a b c d e f g h` 要预测下一个：

1. 组 1 由 `a b` 合成，组 2 由 `c d` 合成；
2. 组合 1 由组 1、组 2 合成，此时已覆盖 `a b c d`；
3. 组合 2 覆盖 `e f g h`；
4. 顶层预测同时看到两个组合，感受野 = 8。

如果第 1 步把 `a b` 和 `b c` 都拿去合并，`b` 就被用了两次；元素总数会从 8 变成 9，后面所有形状都会错位。

四、常见误解

1. **「层级结构一定比固定窗口好」**：不一定。相近约 22,000 参数时，平铺与层级约 2.027 / 2.029，没有立刻改善；修好 BN 后约 2.022；扩到约 76,000 参数才到约 1.993。
2. **「感受野大就等于理解得深」**：不等于。能看到更多字符，不代表一定用得上。
3. **「reshape 只是换个看法」**：不是。顺序错位会把不同位置的数混到一起，形状却仍然合法。
4. **「分组越多越好」**：分组越深，层数越多，训练与调参成本也上升。

五、合上书前的两个自问

- 8 个字符两两分组后，为什么是 4 组而不是 8 组？元素总数变了吗？
- 若某一层 reshape 时把批维 B 也乘进去，形状会变成什么？为什么后续 loss 可能仍然「能算」？

卡住时按这个顺序查

按现象列出先查什么、修好后怎么验。这些路径来自课程故障与代码整理，同一个报错不保证只有一个原因；先定位影响的是数据、数学、状态还是系统性能，再回到上面的操作，不靠同时换五个参数碰运气。

现象	先查什么	修好后怎么验
三维 BN 不报错但结果怪	是否跨 B/T 统计	均值/方差形状与课程修正版对齐

课程里出现过的一个真实案例

案例 6｜层级模型

- 起点与做法：近似等参数比较，再修三维 BN
- 讲者当时的结果：约2.029→2.022；增容后约1.993
- 可借鉴：结构不一定立刻改善
- 出处：第6课后半 [O6]

这是课程演示，数字不是你在自己机器上的复现结果。

本步对应的课程章节与时间定位

第 6 课 | Building makemore Part 5: Building a WaveNet（搭 makemore 第 5 部分：搭一个 WaveNet）

英文自动字幕约 10,385 词；逐字稿；主线步骤。

起点	原章节标题	视频定位
00:00:00	intro（开场介绍）	播放
00:01:40	starter code walkthrough（通读起始代码）	播放
00:06:56	let's fix the learning rate plot（修一下学习率曲线）	播放
00:09:16	pytorchifying our code: layers, containers, torch.nn, fun bugs（把代码改成 PyTorch 风格：层、容器、torch.nn 与几个坑）	播放
00:17:11	overview: WaveNet（概览：WaveNet）	播放
00:19:33	dataset bump the context size to 8（数据集：把上下文长度提到 8）	播放
00:19:55	re-running baseline code on block_size 8（用 block_size 8 重跑基线）	播放
00:21:36	implementing WaveNet（实现 WaveNet）	播放
00:37:41	training the WaveNet: first pass（训练 WaveNet：第一遍）	播放

起点	原章节标题	视频定位
00:38:50	fixing batchnorm1d bug（修 BatchNorm1d 的 bug）	播放
00:45:21	re-training WaveNet with bug fix（修完后重新训练）	播放
00:46:07	scaling up our WaveNet（把 WaveNet 做大）	播放
00:46:58	experimental harness（实验记录框架）	播放
00:47:44	WaveNet but with “dilated causal convolutions”（换成“空洞因果卷积”的 WaveNet）	播放
00:51:34	torch.nn（torch.nn 模块）	播放
00:52:28	the development process of building deep neural nets（搭深度网络的实际开发过程）	播放
00:54:17	going forward（接下来怎么走）	播放
00:55:26	improve on my loss! how far can we improve a WaveNet on this data?（来超过我的损失！这份数据上 WaveNet 还能提升多少）	播放

进入步骤 7 的操作正文 · 返回关键词导航

关键词拆解｜步骤 8：语言模型、因果注意力、位置、残差、LayerNorm

字符 GPT 把「看前几个字符」升级成「看整段前文，并自己决定看谁」。注意力像一场只有举手才能发言的会：每个位置提出一个问题（Query），拿它去和所有可见位置的标签（Key）比对，按相似度分配注意力，再把那些位置的内容（Value）按比例混进来。因果规则保证没人能偷看还没发生的答案。

一、十二个关键词，各对应会场的哪一环

自回归（autoregressive）：一次预测一个下一个 token，再把刚生成的放回上下文继续。像接龙，每一步只能参考已经写出的内容。

token：模型处理的离散符号。本步是字符 token，之后 BPE 会把多个字节合成更大的 token。token 不等同于自然语言里的词。

注意力（attention）：每个位置为可见位置计算权重，再按权重混合信息。权重是学出来的，不是人类给定的解释。

Query / Key / Value：Q 是「我现在要找什么」，K 是「我这里有什么标签」，V 是「真正可取走的信息」。相似的 Q/K 得分高，随后用分数加权汇总 V。

因果掩码（causal mask）：把未来位置的分数设为不可用。训练时所有位置并行算，但第 t 个位置不能看 t+1 的真实字符。

缩放点积注意力：`softmax(QKᵀ/√d) V`。点积衡量匹配；除以 `√d` 控制维度变大时分数过大，避免 softmax 过早变成「只看一个」。

多头注意力（multi-head）：并行做几组不同的注意力再拼接。像多个角度同时查资料；不能直接声称某一头固定负责语法或指代，除非另做分析。

位置编码（positional embedding）：给 token 加上位置信息。否则注意力只看到一袋字符表示，分不清「猫追狗」和「狗追猫」。

前馈网络（MLP block）：每个位置独立经过的小型非线性层，加工已汇总的信息。

残差连接（residual）：把模块输入直接加回输出，给信息留一条绕过施工区的主路，让模块只学「要补什么」。

LayerNorm：对单个位置的特征维做尺度校准；与 BatchNorm 用批次统计不同，不依赖同批其他样本。

训练目标：给定前文预测下一个 token 的分布，用真实后继算交叉熵。目标是续写，不天然等于遵循指令或回答问题。

二、形状一路怎么走

阶段	形状（教学配置）	含义
输入	`(B, T)`	B=4，T=32 个字符位置
嵌入 + 位置	`(B, T, C)`	C=32 个特征
分头	`(B, H, T, C/H)`	H=4，每头 8 维
注意力分数	`(B, H, T, T)`	每个头、每个 query 看每个 key
混合后	`(B, T, C)`	各头拼回 32 维
输出	`(B, T, V)`	每个位置 V=65 个字符分数

`(B,H,T,T)` 是本步最值得用手指点的形状：**B 是几段文本，H 是几个角度，前一个 T 是「谁在问」，后一个 T 是「问谁」。**

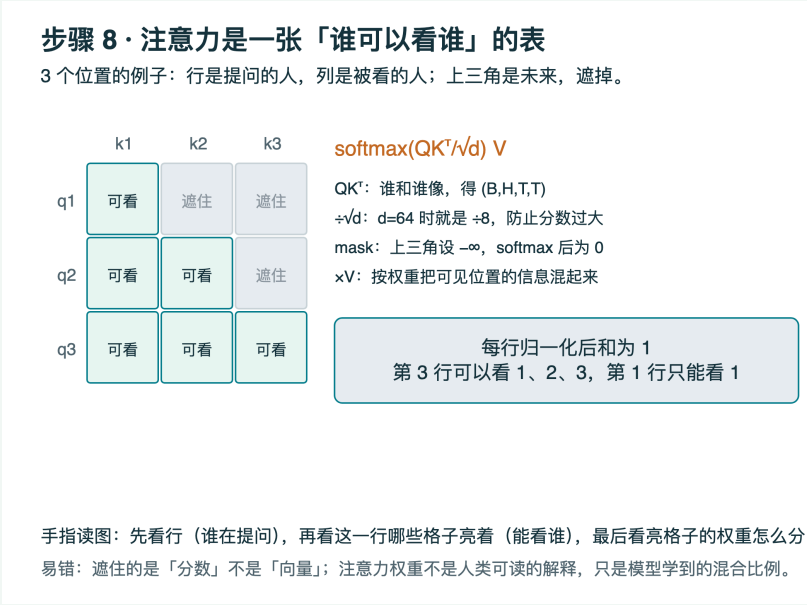

图注：助手绘制的教学示意，2026-11-10；3×3 表格只演示因果掩码的方向，真实模型是 T×T 且每个头各有一张。

手指读图： 先看行（谁在提问），再看这一行哪些格子亮着（能看谁），最后看亮格子的权重怎么分。

三、一个小例子：三个位置

序列 `a b c` 训练时同时建立 `a→b`、`ab→c` 两个目标：

- 预测 b 时，第 1 行只能看 a；
- 预测 c 时，第 2 行可以看 a、b；
- 把上三角遮住后，第 2 行的 softmax 只在 a、b 上分配，权重和为 1。

如果忘了遮，第 2 行会看到 c，训练 loss 会异常漂亮——因为答案被偷看了。

四、常见误解

1. **「注意力权重就是解释」**：不是。它只是混合比例，不能直接当成人能读的理由。
2. **「多头各自负责语法/指代」**：没有保证，需要专门分析。
3. **「残差和 LayerNorm 可以互相替代」**：不能。一个管信息通路，一个管尺度。
4. **「训练目标就是回答问题」**：不是，续写和指令遵循是两件事。

五、合上书前的两个自问

- 遮住的是分数还是向量？如果只把未来位置的 V 置零，softmax 的分母会怎样？
- 把 `√d` 去掉，d=64 时点积会大多少倍？softmax 会变得更平还是更尖？

进入步骤 8 的操作正文 · 返回关键词导航

关键词拆解 | 步骤 9：字节、UTF-8、BPE、预切分、词表

分词器是原始文字与整数输入之间的编解码器。它决定模型究竟把一句话切成哪些编号；模型只接收编号，不直接读 Unicode 字符。把它想成「打包员」：同样的货物，按不同规则装箱，箱子的数量和编号都会变。

一、十个关键词，各对应打包的哪一步

Unicode 字符与 UTF-8 字节：人眼看到的一个字符，可能由多个 UTF-8 字节组成。字节是 0–255 的整数，更底层、更通用；在字节中间切开再当独立字符解码，会得到损坏文本（常见是「�」）。

byte-level（字节级）：先把文本编码成字节，确保任何输入都有可表示的基础。纯字节词表最多 256 项，通用但序列可能很长。

BPE（Byte Pair Encoding）：反复寻找语料中最常见的相邻符号对，把它合并成新符号。像把常一起出现的两个零件装成一个组件，以后处理相似文本可以少走几步。

训练 tokenizer：统计当前序列里相邻对的频率，选最高者合并并记录规则，直到目标词表大小或没有可合并对。合并顺序本身就是规则，顺序不同，切分不同。

编码 encode：用已学规则把新文本转成 token ID。它按既定规则工作，不会因为新文本出现就临时扩充词表。

解码 decode：把 token ID 还原成字节，再按 UTF-8 解码。正确的往返应满足 `decode(encode(text)) == text`（在约定的特殊 token 规则内）。

预切分（pre-tokenization）：BPE 合并前先按规则划分边界，例如词、数字、标点片段。像规定零件不能跨某些隔板组合；不同正则会得到不同频率统计与词表。

特殊 token：tokenizer 明确定义的控制标记，例如文档边界。普通用户文字若被意外解释成特殊标记，语义可能改变，所以要区分转义与允许的特殊 token。

词表大小：可用 token ID 数量。词表越大，常见片段可能更短，但嵌入与输出层参数更大；换 tokenizer 后，旧模型的 token ID 含义不再兼容。

未知 token / 复杂字形：不同 tokenizer 对边缘字节序列处理不同。案例的作用是提醒测试真实边界，不能凭一两个例子推断所有模型的行为。

二、BPE 的每一步在空间里做什么

步骤	空间动作	结果
统计相邻对	沿序列相邻两格连线计数	`ab`、`ba` 各 2 次
选最高频	在所有对里挑一个	并列时按规则选，假设选 `ab`
合并	把两格压成一格	序列从 6 格变 4 格
记录规则	新编号入词表	词表大小 256 → 257
重复	回到第一步	直到达到目标词表

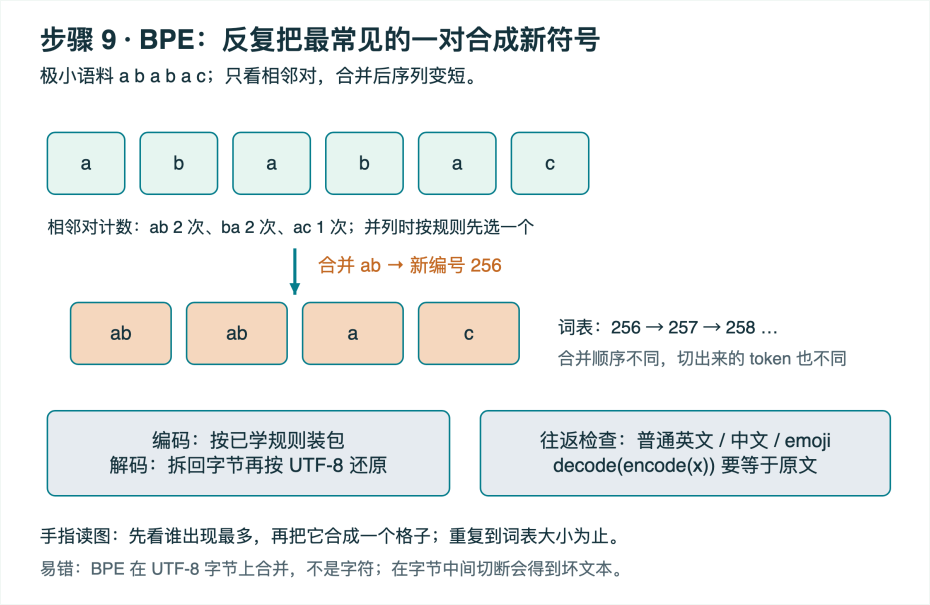

图注：助手绘制的教学示意，2026-11-10；极小语料 `ababac` 的合并顺序与计数为手工演算，实际实现还要处理切分规则与并列取舍。

手指读图： 先看谁出现最多，再把它压成一个格子；每压一次，序列短一格，词表多一个编号。

三、手算一遍：6 个字符的两次合并

序列 `a b a b a c`，相邻对是 `ab, ba, ab, ba, ac`：

1. `ab` 2 次、`ba` 2 次、`ac` 1 次（并列，按规则先选 `ab`）；
2. 合并 `ab` → 新编号 256（词表大小变成 257），序列变成 `[ab][ab]a c`，共 4 格；
3. 再统计：`[ab][ab]`、`[ab]a`、`a c` 各 1 次；
4. 继续合并，直到词表达到目标大小。

注意第 1 步的并列：如果规则先选 `ba`，后面切出来的 token 就完全不同。所以「BPE 词表」必须连同合并顺序一起保存，只存最终词表是不够的。

四、常见误解

1. **「一个 token 就是一个词」**：不是。token 可以是半个词、多个字节，甚至一个空格加字母。
2. **「词表越大越好」**：不一定。词表大、序列短，但嵌入与输出层参数也大。
3. **「换 tokenizer 可以直接复用旧模型」**：不能。同一串文字在新 tokenizer 下编号不同，模型学到的是旧编号。
4. **「在字节中间切开没关系」**：有关系。切坏的 UTF-8 序列解码会变乱码。

五、合上书前的两个自问

- 若语料里 `ab` 和 `ba` 并列最高频，先合并哪个？对最终切分有什么影响?
- 为什么 `decode(encode("你好"))` 必须等于原文，而 `encode(decode(ids))` 却不一定等于原来的 ids?

卡住时按这个顺序查

按现象列出先查什么、修好后怎么验。这些路径来自课程故障与代码整理，同一个报错不保证只有一个原因；先定位影响的是数据、数学、状态还是系统性能，再回到上面的操作，不靠同时换五个参数碰运气。

现象	先查什么	修好后怎么验
tokenizer 往返失败	字节/Unicode、merge rank、规范化	英文/中文/emoji/空串逐项

课程里出现过的一个真实案例

案例 8｜tokenization 异常

- 起点与做法：比较拼写、数字、空白和特殊符号
- 讲者当时的结果：许多异常与切分方式有关
- 可借鉴：保留原输入和 token
- 出处：第8课 [O8]

这是课程演示，数字不是你在自己机器上的复现结果。

原课练习（官方英文原文）

下面是作者在视频说明里给学习者的练习指令，保留英文原文，不冒充聊天提示词。建议先独立完成，再看对应代码；中文只用于说明它落在本步骤的哪一段。

第 8 课原练习

[O8]

```
- Advised flow: reference this document and try to
implement the steps before I give away the partial
solutions in the video. The full solutions if
you're getting stuck are in the minbpe code
https://github.com/karpathy/minbpe/blob/master/exe
rcise.md
```

中文对照：建议流程——先对照这份文档自己实现各步骤，再去看视频里给出的部分答案；卡住时的完整解答在 minbpe 仓库的 exercise.md。

第 8 课minbpe 分步练习

以下来自官方 exercise.md，保留原文。[O12]

```
# exercise

Build your own GPT-4 Tokenizer!

### Step 1

Write the `BasicTokenizer` class, with the
following three core functions:

- `def train(self, text, vocab_size,
verbose=False)`
- `def encode(self, text)`
- `def decode(self, ids)`

Train your tokenizer on whatever text you like and
visualize the merged tokens. Do they look
reasonable? One default test you may wish to use
is the text file `tests/taylorswift.txt`.

### Step 2

Convert you `BasicTokenizer` into a
`RegexTokenizer`, which takes a regex pattern and
splits the text exactly as GPT-4 would. Process
the parts separately as before, then concatenate
the results. Retrain your tokenizer and compare
the results before and after. You should see that
you will now have no tokens that go across
```

categories (numbers, letters, punctuation, more than one whitespace). Use the GPT-4 pattern:

~~~
GPT4_SPLIT_PATTERN = r"""'(?i:[sdmt]|ll|ve|re)|[^\r\n\p{L}\p{N}]?+\p{L}+|\p{N}{1,3}| ?[^\s\p{L}\p{N}]++[\r\n]*|\s*[\r\n]|\s+(?!\S)|\s+"""
~~~

Step 3

You're now ready to load the merges from the GPT-4 tokenizer and show that your tokenizer produces the identical results for both `encode` and `decode`, matching [tiktoken](https://github.com/openai/tiktoken).

~~~
# match this
import tiktoken
enc = tiktoken.get_encoding("cl100k_base") # this is the GPT-4 tokenizer
ids = enc.encode("hello world!!!? (안녕하세요!) lol123 😉")
text = enc.decode(ids) # get the same text back
~~~

Unfortunately, you will run into two issues:

1. It is not trivial to recover the raw merges from the GPT-4 tokenizer. You can easily recover what we call `vocab` here, and what they call and store under `enc._mergeable_ranks`. Feel free to copy paste the `recover_merges` function in `minbpe/gpt4.py`, which takes these ranks and returns the raw merges. If you wish to know how this function works, read [this](https://github.com/openai/tiktoken/issues/60) and [this](https://github.com/karpathy/minbpe/issues/11#issuecomment-1950805306). Basically, under some conditions it is enough to only store the parent nodes (and their rank) and get rid of the precise details of which children merged up to any parent.
2. Second, the GPT-4 tokenizer for some reason permutes its raw bytes. It stores this permutation in the first 256 elements of the mergeable ranks, so you can recover this byte shuffle relatively simply as `byte_shuffle = {i: enc._mergeable_ranks[bytes([i])] for i in range(256)}`. In both your encode and decode, you'll have to shuffle bytes around accordingly. If you're stuck, reference the minbpe/gpt4.py` file for hints.

Step 4

(Optional, irritating, not obviously useful) Add the ability to handle special tokens. You'll then be able to match the output of tiktoken even when special tokens are present, e.g.:

~~~
import tiktoken
enc = tiktoken.get_encoding("cl100k_base") # this is the GPT-4 tokenizer
ids = enc.encode("<|endoftext|>hello world", allowed_special="all")
~~~

Without `allowed_special` tiktoken will error.

Step 5

If you've made it this far, you're now a pro at LLM Tokenization! Sadly, you're not exactly done yet because a lot of LLMs outside of OpenAI (e.g. Llama, Mistral) use [sentencepiece](https://github.com/google/sentencepiece) instead. Primary difference being that sentencepiece runs BPE directly on Unicode code points instead of on UTF-8 encoded bytes. Feel free to explore sentencepiece on your own (good luck, it's not too pretty), and stretch goal if you really experience and suffer from the burden of time, re-write your

```
BPE to be on Unicode code points and match the
Llama 2 tokenizer.
```

中文要点

- 第 1 步：写 `BasicTokenizer`，实现 `train(text, vocab_size)`、`encode(text)`、`decode(ids)` 三个核心方法。在任意文本上训练并可视化合并后的 token，看是否合理；默认测试文件可用 `tests/taylorswift.txt`。
- 第 2 步：改成 `RegexTokenizer`，先按 GPT-4 的正则把文本切开，对每段分别做 BPE，再拼回。重新训练并比较前后结果：切分之后不会再出现跨类别的 token（数字、字母、标点、连续空白各自成段）。
- 第 3 步：加载 GPT-4 的合并规则，验证你的 encode/decode 与 tiktoken 完全一致。两个坑：合并规则不像词表那样直接给出，可用 `minbpe/gpt4.py` 的 `recover_merges` 还原；GPT-4 还对字节做了置换，存在可合并排名的前 256 项里。
- 第 4 步（可选、烦人、未必有用）：支持特殊 token，这样带 `<|endoftext|>` 的文本也能与 tiktoken 对齐；不加 `allowed_special` 时 tiktoken 会报错。
- 第 5 步：多数非 OpenAI 的模型（Llama、Mistral）用 sentencepiece，它直接在 Unicode 码点上跑 BPE，而不是在 UTF-8 字节上。可自行探索；进阶目标是把你的 BPE 改成按码点，并与 Llama 2 分词器对齐。

原文件中的代码围栏在本段外层展示时用 ~~~ 表示，代码内容未改；可复制的原文件见交付代码 `minbpe/exercise.md`。

本步对应的课程章节与时间定位

第 8 课｜Let's build the GPT Tokenizer（手写 GPT 分词器）

英文自动字幕约 24,679 词；逐字稿；主线步骤。

起点	原章节标题	视频定位
00:00:00	intro: Tokenization, GPT-2 paper, tokenization-related issues（开场：分词、GPT-2 论文与分词相关的毛病）	播放
00:05:50	tokenization by example in a Web UI (tiktokenizer)（在网页工具里看分词实例（tiktokenizer））	播放
00:14:56	strings in Python, Unicode code points（Python 的字符串与 Unicode 码点）	播放
00:18:15	Unicode byte encodings, ASCII, UTF-8, UTF-16, UTF-32（Unicode 字节编码：ASCII、UTF-8、UTF-16、UTF-32）	播放
00:22:47	daydreaming: deleting tokenization（畅想：如果不要分词）	播放
00:23:50	Byte Pair Encoding (BPE) algorithm walkthrough（过一遍 BPE 算法）	播放
00:27:02	starting the implementation（开始动手实现）	播放

起点	原章节标题	视频定位
00:28:35	counting consecutive pairs, finding most common pair（统计相邻对，找出最常见的一对）	播放
00:30:36	merging the most common pair（合并最常见的那一对）	播放
00:34:58	training the tokenizer: adding the while loop, compression ratio（训练分词器：加 while 循环，看压缩率）	播放
00:39:20	tokenizer/LLM diagram: it is a completely separate stage（分词器与 LLM 的关系图：它是完全独立的一步）	播放
00:42:47	decoding tokens to strings（把 token 解码回字符串）	播放
00:48:21	encoding strings to tokens（把字符串编码成 token）	播放
00:57:36	regex patterns to force splits across categories（用正则强制按类别切分）	播放

起点	原章节标题	视频定位
01:11:38	tiktoken library intro, differences between GPT-2/GPT-4 regex（tiktoken 库入门，GPT-2 与 GPT-4 正则的差别）	播放
01:14:59	GPT-2 encoder.py released by OpenAI walkthrough（通读 OpenAI 放出的 GPT-2 encoder.py）	播放
01:18:26	special tokens, tiktoken handling of, GPT-2/GPT-4 differences（特殊 token、tiktoken 的处理方式与两代差异）	播放
01:25:28	minbpe exercise time! write your own GPT-4 tokenizer（minbpe 练习时间：自己写一个 GPT-4 分词器）	播放
01:28:42	sentencepiece library intro, used to train Llama 2 vocabulary（sentencepiece 入门：Llama 2 的词表是怎么训的）	播放
01:43:27	how to set vocabulary set? revisiting gpt.py transformer（词表怎么定？回看 gpt.py 里的 Transformer）	播放

起点	原章节标题	视频定位
01:48:11	training new tokens, example of prompt compression（训练新 token，以及提示词压缩的例子）	播放
01:49:58	multimodal [image, video, audio] tokenization with vector quantization（用向量量化做图像/视频/音频的多模态分词）	播放
01:51:41	revisiting and explaining the quirks of LLM tokenization（回头解释 LLM 分词的种种怪现象）	播放
02:10:20	final recommendations（最后的建议）	播放

进入步骤 9 的操作正文 · 返回关键词导航

关键词拆解｜步骤 10：GPT-2 结构、参数量、权重绑定、生成

从字符 GPT 走到 GPT-2，不是换一个更聪明的公式，而是把 tokenizer、层数、宽度、上下文、初始化与训练配方合成一套互相匹配的系统。配置像建筑图纸，模型代码像施工方法，权重像已经装好的家具，tokenizer 像房间编号系统——图纸对、编号错，门牌号照样指错房间。

一、九个关键词，各对应图纸上的哪一处

模型配置（config）：层数、宽度、头数、上下文窗口、词表。结构参数与训练参数（学习率、批大小、步数）要分开记；混在一起，复现时就分不清是「盖错了楼」还是「装修错了」。

参数量（parameter count）：可学习数字的总数，像可调旋钮的数量。更多旋钮提供更大容量，也需要更多数据、算力和内存。

token embedding 与语言模型头：前者把 token ID 查成向量，末端线性层把向量映射回词表 logits。权重绑定时两处共享同一矩阵，省参数并建立输入/输出词向量的联系。

位置嵌入：把位置向量加进 token 表示。序列长度不能超过训练时支持的上限，除非另做扩展处理。

预训练续写：给一段前缀，让模型按分布继续生成。固定前缀便于比较；流畅不代表事实正确、指令遵循或问答能力。

单批次检查：先拿很小一批确认输出形状、loss 有限、梯度非零、更新后 loss 有合理变化。它是接线验收，不代表完整训练。

权重加载兼容性：参数名、张量形状、词表与位置定义必须匹配。某层 shape 对不上，通常说明结构或配置不同，不要靠随意 reshape 掩盖。

温度（temperature）：把 logits 除以温度再 softmax。温度低放大高分候选、输出更保守；温度高拉平分布、更随机。它改变采样行为，不改变已训练的参数与知识。

检查点（checkpoint）：参数、优化器状态、步数、随机状态与配置。只存权重可用于生成；要从断点续训，通常还需要优化器与进度。

二、124M 是从哪几项乘出来的

部件	算式	参数量
token 嵌入	50,257 × 768	38,597,376
位置嵌入	1,024 × 768	786,432
每个 Block	12 × 768² + 13 × 768	7,087,872
12 个 Block	7,087,872 × 12	85,054,464
末尾 LayerNorm	2 × 768	1,536
合计	—	**124,439,808**

一句话：**参数量不是「感觉很大」，而是几张矩阵的形状乘出来的；能手算，就能判断某个「小改动」到底加了多少参数。**

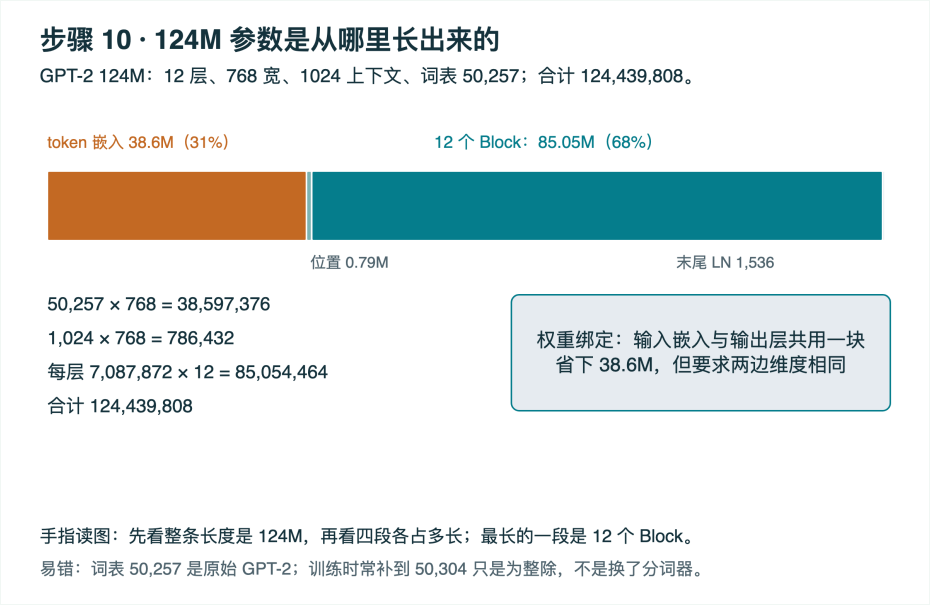

图注：助手绘制的教学示意，2026-11-10；四段长度按 GPT-2 124M 官方配置实算，百分比为四舍五入，不冒充训练实测。

手指读图： 先看整条长度是 124M，再看四段各占多长；最长的一段是 12 个 Block，而不是词表。

三、一个小追踪：权重绑定省了多少

若输入嵌入与输出层不共享，词表 50,257、宽 768 时，两处各有一块 `50,257×768`：

- 不绑定：38,597,376 × 2 ≈ 77.2M；
- 绑定：只留一份 38.6M，模型总量从约 163M 降到 124.4M；
- 代价：两边必须同维度，且输入/输出表示被强行拉到同一空间。

课程里还要区分三件事：结构是否正确、能否加载预训练权重、从零训练是否收敛。三件事的检查方法不同，不能用一个 loss 同时证明。

四、常见误解

1. **「参数量大就一定更强」**：不一定。容量要与数据、算力匹配。
2. **「词表 50,257 补到 50,304 是换了分词器」**：不是。补到 50,304 是为了整除等工程原因，token 含义不变。
3. **「生成流畅说明模型可靠」**：不。流畅只是概率分布的一个侧面。
4. **「权重绑定一定更好」**：不一定，它省参数也带来约束。

五、合上书前的两个自问

- 若把层数从 12 改成 24，参数量增加多少？哪一项翻倍、哪一项不变?
- 温度设成 0.1 和 1.5，同一个前缀的输出会有什么差别？参数变了吗?

进入步骤 10 的操作正文 · 返回关键词导航

关键词拆解｜步骤 11：吞吐、基准测试、融合算子、混合精度

优化是在**相同训练工作**下缩短时间或降低资源，不是只让计时数字变漂亮。像给一条生产线提速：先确认产品没变，再谈每分钟多出几件。

一、七个关键词，各对应生产线的哪一段

吞吐（throughput）：单位时间处理的 token 数，常写 tokens/second。它回答「跑得多快」，不直接回答「学得多好」。

基准测试（benchmark）：固定模型、输入、批次、精度、预热与计时方式，测可重复的速度。GPU 首次运行的编译、数据搬运与缓存会污染结果，所以要预热并多次测量。

端到端时间：不只前向和反向，还包括数据读取、CPU 到 GPU 搬运、优化器更新与评估。只优化一个 kernel，整体可能几乎不变。

融合（fusion）：把多个小操作合成较少的 GPU kernel，减少反复启动与中间结果搬运。像把流水线上几道紧邻工序放到一个工作站完成。

混合精度（mixed precision）：部分计算用较低精度以提高速度、节省显存，同时在关键处保留稳定精度。需要检查数值稳定性与硬件支持。

编译 / CUDA Graph 等路径：减少 Python 调度开销或提前固定执行图。首轮可能含编译成本，计时需区分冷启动与稳态。

正确性护栏：对照基线 loss、梯度、输出或少量训练步骤。速度提升若来自漏算、少训或不同输入，就不是等价加速。

二、怎么算、怎么报

量	算式	说明
每秒 token	`B × T × 步数 ÷ 秒数`	只算计时窗口内的步
每步时间	`总秒数 ÷ 步数`	多次测量取中位数
加速比	`旧每步时间 ÷ 新每步时间`	必须同口径
端到端	含数据加载、更新、评估	用户体感的那个数

例子：20 次更新 × 每次 2048 token，共 40,960 token；用时 10 秒，则约 4,096 tokens/s。这个例子只演示单位换算，不代表任何具体硬件。

图注：助手绘制的教学示意，2026-11-10；时间轴只表示计时边界，长度不代表真实耗时比例。

手指读图： 把灰色段（启动/预热）拿掉，只量中间青色段，再除以这段里的步数。

三、一次可信的测速要写清什么

1. 设备型号、CUDA/cuDNN 版本、PyTorch 版本；
2. 批次、序列长度、精度（fp32 / bf16 / fp16）；
3. 预热多少步、计时多少步、取均值还是中位数；
4. 是否含数据加载与评估；
5. 对照的基线 loss 与步数，证明「算的是同一件事」。

少写其中任何一项，「快了 2 倍」都无法复查。

四、常见误解

1. **「第一次跑得快就是优化有效」**：第一次往往最慢（编译、缓存冷），必须预热。
2. **「kernel 快了，训练就快了」**：不一定，瓶颈可能在数据加载或通信。
3. **「混合精度一定不掉点」**：不一定，要检查数值稳定性。
4. **「不同设备的 tokens/s 可以直接比」**：不能，口径不同。

五、合上书前的两个自问

- 若只测前向不测反向，吞吐会虚高多少？为什么不能这样报？
- 同一配置下，预热 10 步与不预热的结果差在哪？该信哪一个？

进入步骤 11 的操作正文 · 返回关键词导航

关键词拆解｜步骤 12：token 预算、梯度累积、数据分片、DDP、成本

扩大训练前先算三件事：**要做多少题、每次做多少、需要几台机器**。大训练的主要风险不是代码能否启动，而是预算估错、数据重复，或多卡进程根本没有并行干活。

一、七个关键词，各对应预算表的哪一行

token 预算（token budget）：训练总共让模型看过多少 token。每次全局更新处理 `B×T` 个 token，做 U 次更新约 `B×T×U`；有梯度累积 A、卡数 W 时，约 `B_micro×T×A×W×U`，但要对照脚本确认世界大小怎么计入。

梯度累积（gradient accumulation）：连续算若干小批次梯度后再更新一次，近似模拟更大批次，降低显存峰值。每个小批次通常要按累积次数缩放 loss；「更新次数」和「看过的样本量」不是一回事。

数据分片（sharding）：把数据切成多段供不同阶段读取，避免反复从头读或把全部数据塞进内存。要记录每片 token 数、顺序、是否重叠、验证集是否隔离。

DDP（DistributedDataParallel）：多卡各自算不同数据的梯度，再同步平均。像多个班同时做不同练习，统一汇总后再一起更新。启动多进程不等于有效并行。

world size / rank：参与训练的进程总数与各自编号。全局批次通常是单卡批次乘进程数（再考虑累积），但具体定义必须看源码。

每步时间与估时：目标 U 步、实测稳态每步 t 秒，纯训练约 `U×t` 秒，再加评估、检查点、启动与故障余量。小时数是估算，不是承诺。

成本上限与停止条件：开跑前写预算上限、预计结束时间、何时检查 loss、如何中止与保存。异常发散时停下来保留日志，不要为了「跑完」继续烧钱。

二、预算就是四层乘法

层	例子	结果
一次微批	8 × 1024	8,192 token
乘累积	× 8	65,536 token
乘卡数	× 8	524,288 token / 更新
乘更新次数	× 10,000	约 5.24B token

如果实测每步 0.8 秒，纯训练约 `10,000 × 0.8 = 8,000` 秒，约 2.22 小时，还不含评估、启动与保存。

图注：助手绘制的教学示意，2026-11-10；8×1024×8×8×10,000 为演算示例，不对应任何具体硬件的报价或实测。

手指读图： 顺着乘号从左走到右，每一步都问「这一维是谁决定的」：微批由显存定，长度由上下文定，卡数由机器定。

三、一个小检查：卡数增加，数据真的增加了吗

假设 8 张卡，每张都从同一个文件、同一偏移读同一批数据：

- 表面：8 张卡都在跑，GPU 利用率很高；
- 实际：8 份梯度几乎一样，有效数据仍是 1 份；
- 后果：token 预算表上写着 5.24B，模型实际只见过约 0.65B 不重复 token。

检查办法：打印每个 rank 的第一个 batch 索引，确认互不相同；再看 sampler 是否按 rank 切分。

四、常见误解

1. **「更新次数多就等于训练多」**：不一定，要看每次更新看了多少新 token。
2. **「卡多就一定快」**：不一定，通信与同步可能成为瓶颈。
3. **「token 预算可以事后补」**：补不回来，数据重复会改变有效训练量。
4. **「估时就是承诺」**：不是，它只是按当前实测外推的估计。

五、合上书前的两个自问

- 若把累积从 8 改成 4、其他不变，每次更新的 token 数变成多少？U 要不要跟着改?
- 8 张卡都读同一偏移，token 预算表上的数字和实际不重复 token 差几倍?

进入步骤 12 的操作正文 · 返回关键词导航

关键词拆解｜步骤 13：训练集 loss、验证 loss、基准评估、HellaSwag、样本审阅

评价模型像考试：训练时的练习分、留出的模拟考、统一标准化测试和人工抽查，各自回答不同问题。只挑最好看的一项，等于只看体检报告里最正常的那一栏。

一、八个关键词，各回答哪个问题

训练 loss：模型在用于更新参数的数据上的平均预测损失。下降说明它更贴合训练样本，不一定更会处理新样本。

验证 loss：在未参与梯度更新的数据上算的损失，用于观察泛化与选检查点。验证集被反复用于挑方案后，就不再是完全客观的最终考试。

检查点（checkpoint）：某一时刻的参数、优化器状态、步数、随机状态与配置。只存权重可用于生成；要从断点续训，通常还要优化器与进度。

HellaSwag：多选式常识推理基准：给定上下文和若干候选结尾，比较模型对候选的打分。评估代码必须按数据集规定只对续写部分计分，不能把上下文也算进答案长度。

多选评分：常见做法是对候选续写 token 的 log 概率求和或取平均。总和偏好短答案，平均又是另一种口径；报告时要写清公式、token 边界与版本。

基准分数：用于在相同数据、划分、预处理与评测实现下比较。不同版本或不同评分方式的分数不能直接排高低。

样本审阅（qualitative inspection）：随机看生成文本，检查乱码、重复、格式与明显退化。它能发现故障，但不能替代定量评测，也不能挑几段顺眼文本宣称成功。

困惑度（perplexity）：交叉熵的指数变换，可直觉理解为每一步面对的有效候选数量。只在相同 tokenizer、数据与口径下比较才有意义。

二、三种曲线的读法

曲线	正常形态	异常信号	先查什么
训练 loss	持续下降	不降或乱跳	标签、梯度、学习率
验证 loss	先降后平/微升	与训练背离很早	过拟合、切分、泄漏
HellaSwag	随能力缓慢上升、常与 loss 不同步	长期完全不动	评测实现、计分口径

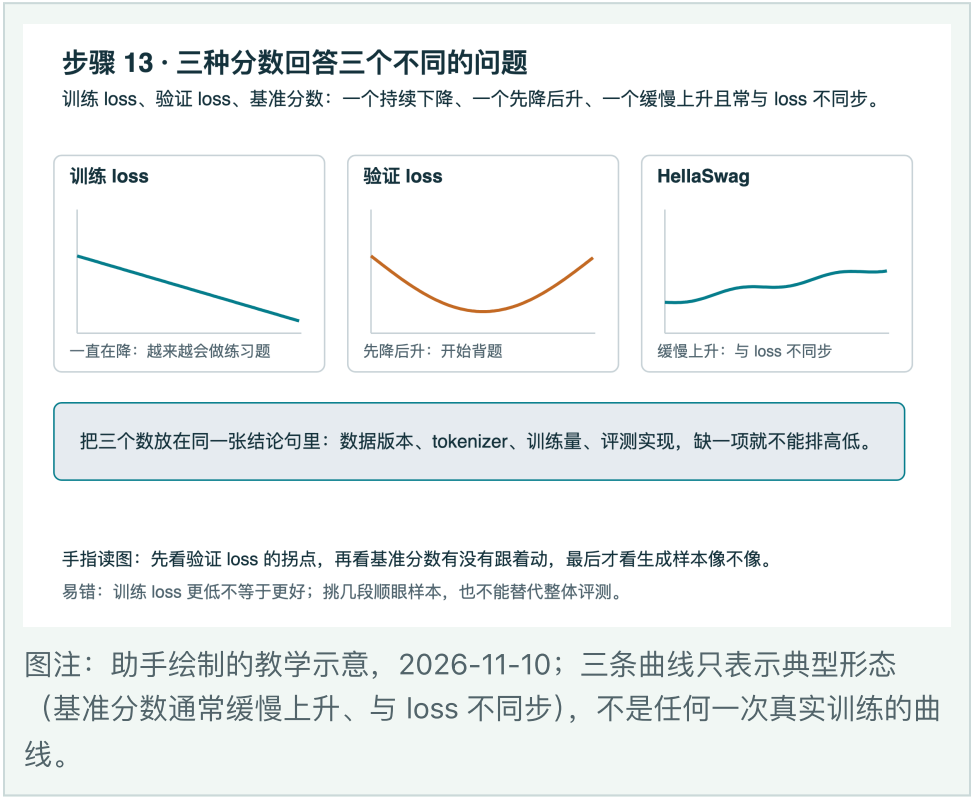

图注：助手绘制的教学示意，2026-11-10；三条曲线只表示典型形态（基准分数通常缓慢上升、与 loss 不同步），不是任何一次真实训练的曲线。

手指读图： 先看验证 loss 的拐点，再看基准分数有没有跟着动（它常常走得比 loss 慢），最后才看生成样本像不像。

三、同一句话里必须写清的六项

在〔数据版本与切分〕、〔tokenizer〕、〔训练 token 数/步数〕、〔评测实现〕条件下，训练 loss 为〔〕、验证 loss 为〔〕，在〔基准〕上得到〔分数/正确数〕；人工检查发现〔具体观察〕。缺少任何一项，结论都不可复查。

如果完整 124M 训练没有真实运行，就写「未完成/未测试」，不要用缩小模型的结果替代。

四、常见误解

1. **「训练 loss 最低的检查点最好」**：不一定，它在验证集上可能更差。
2. **「验证集可以一直用来调参」**：调得越多，它越像训练集，最后要留一份测试集。
3. **「HellaSwag 分数涨了，模型就全面变强」**：它只测一类多选常识推理。
4. **「生成样本好看就是成功」**：样本审阅只负责发现故障，不负责证明能力。

五、合上书前的两个自问

- 训练 loss 降、验证 loss 升，先怀疑过拟合还是实现错误？各看哪个证据？
- 两个 HellaSwag 分数差 2 分，能否直接说模型 B 更强？还缺哪些口径？

卡住时按这个顺序查

按现象列出先查什么、修好后怎么验。这些路径来自课程故障与代码整理，同一个报错不保证只有一个原因；先定位影响的是数据、数学、状态还是系统性能，再回到上面的操作，不靠同时换五个参数碰运气。

现象	先查什么	修好后怎么验
训练中断后恢复不一致	optimizer、RNG、数据指针是否存了	独立做中断/恢复对照

进入步骤 13 的操作正文 · 返回关键词导航

阅读说明

> 手册类型：定制版

这本手册带你从一个数的导数出发，写出自动求导、字符语言模型、Transformer、BPE 分词器，再走到 GPT-2 124M 的训练与评估。课程主线是 Karpathy 的 9 节技术视频，原始逐字稿按课独立保留，英文自动字幕中的错词没有被静默改成另一句话。

先看路线图，再逐步动手。来源 O1–O9 对应 9 节课，每一步末尾都附了该课全部章节的时间定位，可直接打开对应片段；O10 以后是讲者官方代码。字幕负责定位讲解，代码负责确认屏幕上的符号和实现。所有课程结果、训练耗时、吞吐与成本都是讲者当时的实验，不是你这台电脑的保证。

手册提供可复现的操作与判断标准；缩小版检查只证明局部路径可运行。真实读者完整试用、GPT-2 全量训练分别记录，不能拿小实验代替。助手建议、学习时间估算和自行补写的记录工具均明确标出。模板中的〔〕是待你填写的占位，不是课程原话。

“原提示词”指作者实际输入给模型的文字，按用途放在对应步骤（步骤 8、步骤 9、步骤 10），来源、核对说明与对应截图就放在那条提示词下面；普通训练代码、补全上下文、分词器测试输入各有类别，不把它们改写成一套并不存在的聊天提示词。截图均须有来源和时间；逐字稿不能替代屏幕上未念出的文字。

术语与形状速查

主线会反复用到下面这些词。遇到不熟的符号，先查这里的含义和形状，再回到代码里的运算；各步骤还会再解释一次它在当前语境下的具体样子。

术语	这本手册中的意思
token	分词器分出的离散单元，不一定是字或词
embedding	用整数 ID 查表得到的可训练向量
logits	softmax 之前的未归一化分数
NLL/交叉熵	对真实目标概率取负对数并聚合；本文默认自然对数
autograd	沿计算图自动计算梯度
batch	同时处理的多个例子；GPT 中每个例子是一段序列
B/T/C/V/H	批大小/序列长度/通道数/词表大小/单头宽度；按上下文核含义
train/val/test	参数更新/配置选择/最终独立评估的数据划分
residual	将模块结果与原输入相加的路径
causal mask	禁止当前位置读取未来位置
pre-norm	残差分支先归一化再做注意力或MLP
BPE	按训练得到的相邻对合并规则压缩字节序列
merge rank	编码时使用的合并优先级
special token	作为文档/对话等结构标记的预定义 ID
TF32/BF16	不同精度路径，适用硬件与操作不同
gradient accumulation	多个微批反传后才更新一次参数
DDP	多进程各持完整模型、分数据并同步梯度

术语	这本手册中的意思
checkpoint	模型及状态快照；保存哪些状态决定能否精确恢复

六阶段路线图

阶段	本阶段做什么	入口与产物
1：环境与梯度	建学习目录，写标量求导与计算图	步骤 1、步骤 2：可验证的梯度
2：语言建模	用名字数据训练 bigram 和 MLP	步骤 3、步骤 4：采样与独立验证 loss
3：稳定与加深	诊断激活，手写反传，构建层级模型	步骤 5至步骤 7：梯度对照与 WaveNet 风格模型
4：手写 GPT	从均匀聚合走到多头因果注意力	步骤 8：Tiny Shakespeare 文本生成
5：分词器	从 UTF-8 字节实现 train / encode / decode	步骤 9：BPE、正则切分与往返测试
6：GPT-2 复现	验结构、测速度、扩训练、做评估	步骤 10至步骤 13：可复核训练记录

这一阶段先不做：聊天微调、RLHF、RAG、上线产品；以后再看下面的范围与延伸。原课没有交付这些完整流程，不能把预训练模型当作 ChatGPT 成品。

这阶段先不做与后续延伸

主线完成的是预训练模型与分词器实验。下面区分课程预告、可选练习和真正需要另开任务的工作，避免读完后误判自己已经做完聊天系统。

先不做什么	依据	当前改为
一开始直接训练124M完整预算	结构/数据/梯度没核过，长跑会放大错误	单批次、短跑、再核费用
把课堂GPU耗时当本机承诺	硬件、精度、版本与预算不同	本机热身与稳态实测
用ChatGPT提示词代替训练实现	本课是权重与优化算法教程	对应步骤保留中英文输入与模板，训练实现照课做
把预训练模型称为聊天助手	第7/9课只解释后续微调	先评估续写、验证NLL与选择题
接上业务RAG或工具调用	不在9课实现范围	另开扩展，不改本课对象
仅凭架构名声称比基线强	第6课已有相近预算无改善案例	控制变量并保留失败结果
生成截图替代真实课程画面	截图要证明具体输入/输出与时间	实际视频抽帧，缺失项明确登记

可选后续：按第7课练习实现并行多头、算术任务、自有数据预训练后微调、读论文加入一个改动；按分词练习匹配 `cl100k_base`、探索 SentencePiece。SFT/RLHF、全量部署、更多模型尺寸和 llm.c 的优化需要单独资料与预算，不在本次实际训练验证范围内。 课程内部的六阶段路线到这里。下面这一节把整门课程放进更长的一年计划，属于助手整理的岗位扩展。

从课程到岗位：一年四阶段路线（扩展）

这一节不是 Karpathy 原课内容，而是助手根据你的微信读书划线《10.23 如何走理论和实践的闭环》整理的岗位转型扩展。原文用机器视觉转岗举例：先用三个月学完一部教程并完成大作业，再用三个月找实践机会做 Demo，再用三个月把 Demo 提升成公开文章，最后用三个月按反馈打磨成小规模应用。四段合起来一年，正好走两遍“理论—实践”的循环。

下面把这四步套到 LLM 岗位，并把整门 Karpathy 课程放进第一阶段。上面的六阶段路线图是课程内部的技术大纲，不替代这里的职业路线。

时间怎么分：四段三个月，理论实践交替

阶段	时间	类型	这一阶段解决的问题	必须产出
1. 理论课与大作业	第 1–3 月	理论	把 LLM 基础从“看过”变成“写过”	13 步课程、一份大作业、实验记录
2. 实践机会与 Demo	第 4–6 月	实践	把知识放进真实场景，做出能给别人看的东西	Demo、演示视频、真实用户反馈
3. 理论提升与公开发表	第 7–9 月	理论	把 Demo 背后的方法讲清楚，接受外部检验	公开文章、论文、仓库或演讲
4. 实践打磨与小规模应用	第 10–12 月	实践	按反馈改到别人能用，形成求职证据	小规模应用、评估报告、作品集

时间只是建议节奏，不是截止日期。手册默认每周 24 小时；按这个投入，13 步课程约 6 周完成，剩下的时间用于大作业、复跑和缓冲。每周时间更少，就把四段各自拉长，但不要打乱顺序，也不要删掉每段的必须产出。原文还建议找两三个自驱力强的人组成小组；一个人做也可以，小组只用于互相复跑和评审。

阶段 1（第 1–3 月）：理论课与大作业

这一阶段解决什么：先建立完整的技术底座。只把视频看完不算完成；你要能从空目录写出关键模块，并用实验数据说明它为什么工作。

课程怎么放进三个月：用现有的 13 步课程和六阶段路线图。课程本身约 6 周；第 7–12 周做大作业、复跑和补漏。大作业必须包含基线、指标和失败分析，不能只是把课程代码再跑一遍。

必须产出

产出	具体要求	放在哪里
课程实现	步骤 1–13 的代码或 notebook 都能从空环境跑通	自己的课程目录
实验记录	每次关键实验记录数据切分、seed、超参、设备、loss、耗时	实验记录表
大作业仓库	有 README、依赖、复现命令和结果	Git 仓库
大作业报告	目标、基线、方法、结果、失败案例、下一步	报告 Markdown 或 PDF
自评	已掌握什么、仍不懂什么、下一阶段补什么	一页笔记

大作业选一个

- 在预算内复现 GPT-2 124M 的短跑：记录 loss 曲线、吞吐、成本和失败情况。
- 用自选语料训练一个小 GPT，与 bigram 或 MLP 基线比较，报告验证 loss 和样本质量。
- 实现一个课程延伸（例如小型推理优化或分词器对比），在固定预算下评估。

任务清单

- ☐ 建好独立环境，记录 Python、PyTorch、设备和随机种子。
- ☐ 完成步骤 1–13，保存每一步可运行的代码或 notebook。
- ☐ 为每次关键实验填写实验记录：数据、参数、loss、耗时。

- [ ] 从三个大作业方向里选一个，写清基线和评价指标。
- [ ] 完成大作业代码，确保能从空目录按 README 跑通。
- [ ] 产出训练或评估报告，至少包含一张 loss 曲线和一组失败案例。
- [ ] 请一位同行按 README 复跑，记录他卡住的位置。
- [ ] 写一页自评：已掌握什么、仍不懂什么、下一阶段补什么。

过关检查：别人能按 README 复现主要结果；报告把实测结果和预期分开写；未解决的问题写下来，而不是藏起来。

阶段 2（第 4–6 月）：实践机会与 Demo

这一阶段解决什么：把课程里的能力放进一个真实场景。真实场景可以来自当前工作、开源项目、实验室、社区、朋友的小生意，或一个范围明确的自由职业任务；使用公司数据前先拿到授权。

必须产出

产出	具体要求	放在哪里
实践 brief	一页写清用户、问题、成功指标、约束、数据权限	项目文档
可运行 Demo	真实用户能亲手试一次	代码仓库或在线页面
演示视频	3–5 分钟，覆盖输入、过程、输出和失败情况	视频或录屏文件
反馈记录	至少 2 位真实用户或同行的原话和问题	反馈日志
问题清单	按影响排序，供第三阶段选用	项目看板或 Markdown

任务清单

- [ ] 列出 3 个可能的实践场景，标注数据权限和可接触的真实用户。
- [ ] 选定 1 个场景，写一页实践 brief：用户、问题、指标、约束。
- [ ] 确认数据与代码使用权限；需要公司批准的先拿到批准。
- [ ] 做出最小可用 Demo，能在真实场景跑通一次。
- [ ] 录一段 3–5 分钟演示视频，覆盖输入、过程、输出和失败情况。
- [ ] 找至少 2 位真实用户或同行试用，记录原话和问题。
- [ ] 把反馈整理成按影响排序的问题清单。
- [ ] 写半页复盘：哪些假设被现实推翻。

过关检查：至少一个不是你自己的人用过 Demo；反馈里写得出具体失败，而不是只有“挺好”；下一阶段有一个明确问题可以研究。

阶段 3（第 7–9 月）：理论提升与公开发表

这一阶段解决什么：把实践里的发现提升成可复用的方法，并接受外部检验。原文特别强调“不论老板是否认可”都要发表；这里的发表可以是技术文章、公开仓库、技术演讲或论文，不要求一定是同行评审论文。

必须产出

产出	具体要求	放在哪里
公开成果	技术文章、GitHub Release、workshop 论文或演讲视频，至少一种	博客、GitHub、arXiv 或社区
方法说明	问题、方法、基线、结果、局限、复现步骤	公开稿正文
外部反馈	至少 3 条评论、issue、评审或提问	评论区或 issue 记录
回应笔记	哪些反馈成立、哪些不成立、下一步改什么	半页 Markdown

任务清单

- ☐ 从阶段 2 的问题清单里选一个能在一篇文章里讲清的问题。
- ☐ 补读该问题相关的 3–5 篇论文或技术文档，做结构化笔记。
- ☐ 设计一个能回答该问题的对照实验或分析，固定预算和指标。

- [ ] 重跑实验，保存原始日志和结果表。
- [ ] 写公开稿：问题、方法、基线、结果、局限、复现步骤。
- [ ] 发布到博客、GitHub、arXiv 或技术社区，并保留版本号。
- [ ] 收集至少 3 条外部反馈，逐条记录。
- [ ] 写半页回应：哪些反馈成立、哪些不成立、下一步改什么。

过关检查：陌生人能按复现步骤跑通；公开稿写明什么没有成功；反馈用证据回应，而不是只做辩解。

阶段 4（第 10–12 月）：实践打磨与小规模应用

这一阶段解决什么：用第三阶段的反馈改到别人能用，形成求职时拿得出手的证据。目标是“小规模可用”，不是做一个生产级平台。

必须产出

产出	具体要求	放在哪里
小规模应用	CLI、Web 服务、Notebook 工具或内部工具，附安装说明	代码仓库
评估报告	改进前后的指标、用户反馈、已知局限	报告 Markdown 或 PDF
版本记录	改了什么、为什么改、还有什么没改	CHANGELOG
作品集页	项目简介、架构图、结果、链接	个人网站或 GitHub Pages
面试故事	一个技术决策、一个失败与修复	两页笔记

任务清单

- ☐ 从阶段 3 的反馈里选 1 个最影响可用性的问题。
- ☐ 设定改进指标和停止条件，避免无限打磨。
- ☐ 实现改进，补测试或回归检查。
- ☐ 重跑评估，记录改进前后的数据。
- ☐ 整理成可小规模使用的形态：CLI、Web 服务、Notebook 工具或内部工具。
- ☐ 写安装和使用说明，找 1 位新用户按说明独立跑通。
- ☐ 写评估报告：指标、用户反馈、已知局限。
- ☐ 更新作品集，准备“技术决策”和“失败与修复”两个面试故事。

- [ ] 决定是否跑第二轮四阶段循环，或开始投递。

过关检查：新用户不看你的操作也能安装并使用；改进前后有可比较的数据；你能讲清取舍和失败，不把没跑过的结果说成成绩。

三条岗位分支怎么选

四段的时间和必须产出不变，变的是每段学什么、做什么、发表什么。阶段 1 结束时选一条主分支；另一条只记成兴趣，不要求同时完成。

分支	理论重点	实践场景	发表形式	打磨目标
Harness / Agent 系统工程	agent loop、工具协议、状态与上下文、错误恢复、trace、eval	为真实工作流做一个小 harness	开源仓库 + 设计说明	降低失败率、延迟和成本
LLM 算法工程	优化、Transformer、训练数据、微调或推理算法	在真实数据上复现基线并做一个改动	实验报告或 workshop 论文	用对照实验决定保留或放弃
Researcher	数学、论文阅读、相关工作、窄研究问题	复现论文结果或小型 benchmark	论文式报告、workshop 或 arXiv	补消融、回应评审、公开代码

分支 A：Harness / Agent 系统工程

阶段	这一阶段做什么	必须产出
1. 理论课与大作业	在 Karpathy 课程之外补 agent loop、工具调用、状态管理、错误恢复、trace 和 eval；大作业做一个最小 harness	课程实现、harness 设计说明、可运行原型
2. 实践机会与 Demo	把 harness 接到一个真实工作流，例如代码审查、资料提取或报告生成	Demo、trace 样例、真实用户反馈
3. 理论提升与公开发表	开源 harness，写清架构、失败模式、评测方法和复现步骤	公开仓库、设计文章、评测表
4. 实践打磨与小规模应用	针对一个失败模式改进，补回归用例，报告成功率、延迟和成本	可用工具、回归测试、前后对比表

分支任务清单

- ☐ 读完并笔记：agent loop、tool calling、context/state、错误恢复、trace、eval。
- ☐ 写一页 harness 设计：模型接口、工具协议、状态、失败处理。
- ☐ 实现最小 harness，能跑通一个真实工作流。
- ☐ 记录成功、失败和重试的 trace。
- ☐ 找真实用户试用，收集失败案例。

- [ ] 公开仓库和设计说明，附复现步骤。
- [ ] 针对一个失败模式做改进，补回归测试。
- [ ] 产出任务成功率、延迟、成本对比表。

分支 B：LLM 算法工程

阶段	这一阶段做什么	必须产出
1. 理论课与大作业	在课程之外补优化、Transformer、数据处理、微调或推理算法；大作业复现一个基线	基线仓库、实验配置、课程实验记录
2. 实践机会与 Demo	在真实数据或任务上跑基线，只改一个变量做对照	基线结果、改动结果、失败分析
3. 理论提升与公开发表	写实验报告或 workshop 风格论文，交代基线、改动、结果和算力	公开报告、配置、结果表
4. 实践打磨与小规模应用	根据证据保留、修改或放弃改动，整理成可复跑的流水线	可复跑流水线、评估报告、成本说明

分支任务清单

- [ ] 选定一个具体算法问题，写清基线、指标和算力预算。
- [ ] 复现基线，结果与公开数字或课程结果对齐。
- [ ] 只改一个变量，跑对照实验。
- [ ] 记录质量、算力、显存和耗时。

- [ ] 写实验报告：假设、方法、结果、失败原因。
- [ ] 公开发布报告和配置，保证他人可复跑。
- [ ] 根据反馈决定保留、修改或放弃该改动。
- [ ] 整理成可复用的训练或推理流水线。

分支 C：Researcher

阶段	这一阶段做什么	必须产出
1. 理论课与大作业	补数学和相关论文，把课程实现当作研究工具；大作业复现一个论文结果或小 benchmark	结构化论文笔记、复现代码、差异记录
2. 实践机会与 Demo	在一个窄问题上做可证伪的实验，记录与原文的差异	实验设计、原始日志、初步结果
3. 理论提升与公开发表	写论文式报告：相关工作、方法、实验、消融、局限；视情况投 workshop 或 arXiv	论文式报告、投稿或公开稿
4. 实践打磨与小规模应用	按评审意见补消融和对照，公开代码与数据	修订稿、代码和数据发布、回应说明

分支任务清单

- [ ] 选定一个窄问题，写一页研究问题和可证伪的假设。
- [ ] 精读 5–8 篇相关论文，做结构化笔记和对比表。

- [ ] 复现一篇论文的关键结果，记录与原文的差异。
- [ ] 设计对照实验和消融实验，固定预算。
- [ ] 跑实验并保存原始日志、配置和随机种子。
- [ ] 写论文式报告：相关工作、方法、结果、消融、局限。
- [ ] 投 workshop、arXiv 或公开技术报告，收集评审意见。
- [ ] 根据意见补实验，公开代码和数据。

这套路线的边界

- 这一节是助手整理的职业扩展，不是 Karpathy 原课内容，也不代表任何公司的招聘标准。
- 完成路线只能证明你有相应的工作证据，不保证拿到 offer。
- 三个月是建议节奏，不是硬截止；可以拉长，但不要跳过必须产出。
- “发表”可以是博客、公开仓库或技术演讲；同行评审论文是可选目标，不是硬性要求。
- 公司实践必须先拿到数据和代码授权；不能把保密数据带进公开项目。
- 完整 GPT-2 124M 训练取决于设备和预算；跑不了完整训练时，用有界实验并写清边界，不能声称已经复现。
- 没有实际跑过的结果、没有收到的反馈、没有发生的发表，都不写进简历或作品集。

现在从这里开始

- [ ] 先完成阶段 1 的课程和大作业，不急着选分支。
- [ ] 阶段 1 结束时，根据自己愿意持续做一年的问题，选一条主分支。
- [ ] 把四个阶段的必须产出抄进自己的任务管理工具，按周检查。
- [ ] 每段结束写半页复盘：产出了什么、卡在哪里、下一段改什么。

本次条件与完成结果

条件	对这次学习的影响
已有 Python、uv、AI 工具开发基础	省去通用编程入门，补张量形状、梯度与训练实验习惯
一个人学习，项目默认周一至周三每天 8 小时	按每周 24 小时安排建议日程；保持每次实验可恢复
偏好可照做的命令、原提示词与真实截图	保留原始材料、可复制代码与逐项验收，图下注明时间
GPU 型号与云 GPU 预算尚未确认	先做 CPU 小实验；完整训练前核算力与费用，不默认启动付费资源

条件不同时怎么调：每周只有 6 小时，按同一顺序分四倍周数，不删第 5 课梯度练习；已经会反向传播，可先做步骤 6 的对照，再决定跳过哪些基础；只有普通电脑时，完成步骤 1–9 和 GPT-2 缩小结构实验，保留完整训练配置，不声称已复现训练质量。

做完后留下什么	数量/范围	所在位置
独立原始逐字稿	9 课，每课 Markdown + SRT	deliver/transcripts/
实验记录	每种模型/改动至少 1 条真实记录	步骤 1 的实验表
语言模型实现	bigram、MLP、层级模型、字符 GPT、GPT-2	步骤 3–13
分词器	train / encode / decode 与测试	步骤 9
原提示词及对应画面	按实际发现的条目逐条登记；步骤内含中英文与模板	步骤内提示词（原文、译文、模板与截图同处）
完整训练证明	仅在实际运行后填写	loss、吞吐、预算、检查点与评估日志

动手前的缺口

G1：GPU 与预算未知，影响完整 GPT-2 训练；不阻碍前 9 步及小规模验证。先测每步耗时，再用“总步数 × 实测单步时间”估时。

G2：自动字幕可能把 tanh、BatchNorm、GPT、张量维数识别错。以对应代码和实际画面核对关键符号；不要把英文识别错词当作数学结论。

G3：基础模型只续写文本，不承诺问答能力。完整训练质量依赖数据、token 预算和评估口径，不能只看生成的一段流畅文字。

建议日程与实验节奏

下面是助手估算的 6 周学习安排，按项目默认每周 3 天、每天 8 小时，共 144 小时。包含约 18 小时 38 分钟视频和 125 小时 22 分钟阅读、编码、诊断与复盘；长训练的无人值守等待单列，不按视频时长推算。

周	周一：8 小时	周二：8 小时	周三：8 小时
1	环境 2h、微分与 Value 6h	链式法则/反传 6h、对照 2h	bigram 计数 5h、采样与 NLL 3h
2	bigram 神经网络 4h、广播 4h	MLP 数据与前向 5h、单批次检查 3h	学习率/切分 5h、验证与记录 3h
3	初始化与饱和 4h、BatchNorm 4h	激活/梯度图 4h、手写 CE 4h	手写 BN/embedding 梯度 6h、对照 2h
4	层级模型 5h、BN 维度修复 3h	字符 GPT 数据/基线 4h、注意力 4h	多头/残差/LayerNorm 5h、采样 3h
5	BPE 训练 4h、编解码 4h	正则/特殊 token 4h、案例核对 4h	GPT-2 结构 5h、权重与单批次 3h
6	速度逐项测量 5h、配置 3h	梯度累积/DDP/数据 5h、短跑 3h	验证/HellaSwag 4h、结果与归档 4h

每个学习日先用 15 分钟回读上次记录，再完成表中的任务；结束前 30 分钟保存代码、参数、结果和下一步，这些时间计入表内。若某步未通过，使用下一时段继续排错；144 小时是计划预算，不是学会或跑完的保证。

步骤 1 建立环境与课程工作目录

先把“视频里运行的文件”和“你自己的练习”分开。这样能反复从空白实现，又能随时对照作者代码，避免把所有版本覆盖成最后一次尝试。

目标：准备独立环境、数据和可恢复的实验目录。

先认符号：∂、x^n、tanh 分别是什么？

下面是助手根据你的提问整理的入门解释。先能读出来、指到具体数字，再继续后面的公式；不需要一开始就背求导规则。

∂：读作“偏”，这次只检查一个旋钮

`∂z/∂x` 整体读作“z 对 x 的偏导数”。意思是：**其他输入先不动，只把 x 调大一点，看看 z 会改变多少。** 这里讨论的是当前位置的变化率，不是把 ∂ 当作一个普通数字做除法。

例如 `z=x+y`，当前 x=2、y=3，所以 z=5：

只改哪个输入	输出怎么变	变化比例
x 从 2 变成 2.01，y 不动	z 从 5 变成 5.01	0.01÷0.01=1
y 从 3 变成 3.01，x 不动	z 从 5 变成 5.01	0.01÷0.01=1

所以 `∂z/∂x=1` 和 `∂z/∂y=1`：两个旋钮分别轻推，屏幕都会等量变化。“偏”提醒你这次只检查其中一个旋钮。换个公式，导数可能就不同；导数为 1 不表示 z 的值为 1。在一般曲线上，小距离比较只是估计，偏导数描述距离趋近零时的变化率。

$z=x^n$：读作“z 等于 x 的 n 次方”

x 叫底数，右上角的 n 叫指数，z 是结果。**当 n 是正整数时，x^n 就是 n 个 x 连着相乘。**

写法	x=2 时展开	结果
x^2，x 的平方	2×2	4
x^3，x 的立方	2×2×2	8
x^4，x 的四次方	2×2×2×2	16

x^3 不是 x×3。 x=2 时，前者是 8，后者是 6。Python 用 `x ** 3` 表示 x^3；`x * 3` 才是 x×3。

空间转化：乘方是重复乘同一个底数，不是把同样的数排队相加

先画一个装着 1 的盒子，让它连续经过三道“乘以 2”的门：1、2、4、8。门数是指数 3，每道门的倍率是底数 2。换成四道门，就再从 8 变成 16。

也可以把 2^2 想成边长为 2 的正方形，里面有 2×2=4 个单位小方格；把 2^3 想成三条边都为 2 的立方体，里面有 2×2×2=8 个单位小方块。计数例子用的是整数边长；正方形的面积单位与立方体的体积单位不同。

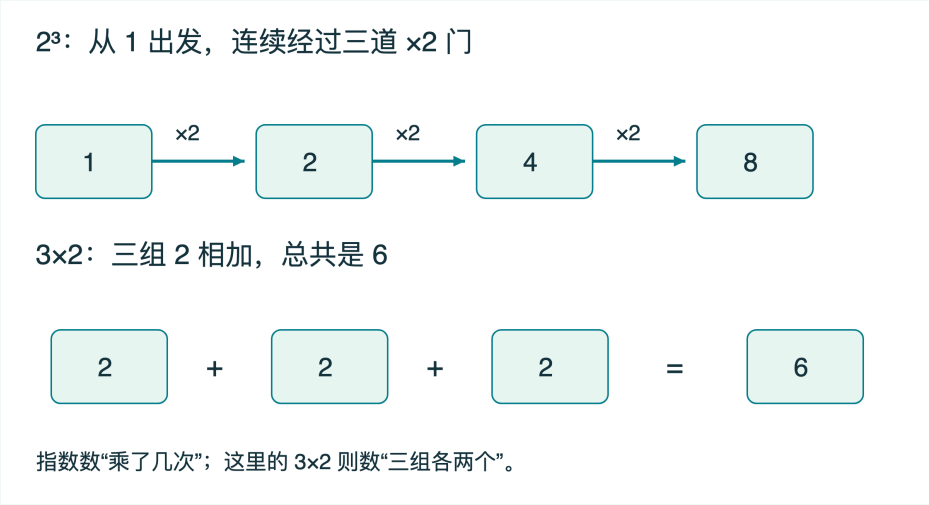

图注：助手绘制的教学示意，正整数指数示例；上方从 1 连续乘三次 2 得到 8，下方把三个 2 相加得到 6。帮助区分 2^3 与 3×2，不是实测图。

读图自问： 再加一道 ×2 门，会从 8 变成多少？16。下方只再添一组 2，又是多少？8。这两种“多加一个”的规则不同。这里的连续相乘只直接解释正整数指数；零、负数与小数指数要用相应的扩展定义。

正切 tan：把角度变成“升高 ÷ 水平前进”的比例

先想一段直坡。你从左下角出发，沿坡到右上角。坡与水平地面的夹角叫 θ，θ 是希腊字母，常读作“西塔”。

正切 tan 是一个根据角度算比例的函数。 在下面这个直角三角形里，`tan(θ)=对边÷邻边=升高的高度÷水平前进的距离`。读作“西塔的正切”。这里先讨论 0° 到 90° 之间的锐角。

三角形里的名字	这张坡道图里的对应物	具体数字
角 θ	坡面与水平地面之间的角	约 36.87°
对边	对着 θ 的竖直高度	3 米
邻边	紧贴 θ 的水平直角边，不包括斜边	4 米
斜边	沿坡实际走的距离	5 米
tan(θ)	升高 ÷ 水平距离	3÷4=0.75，无单位

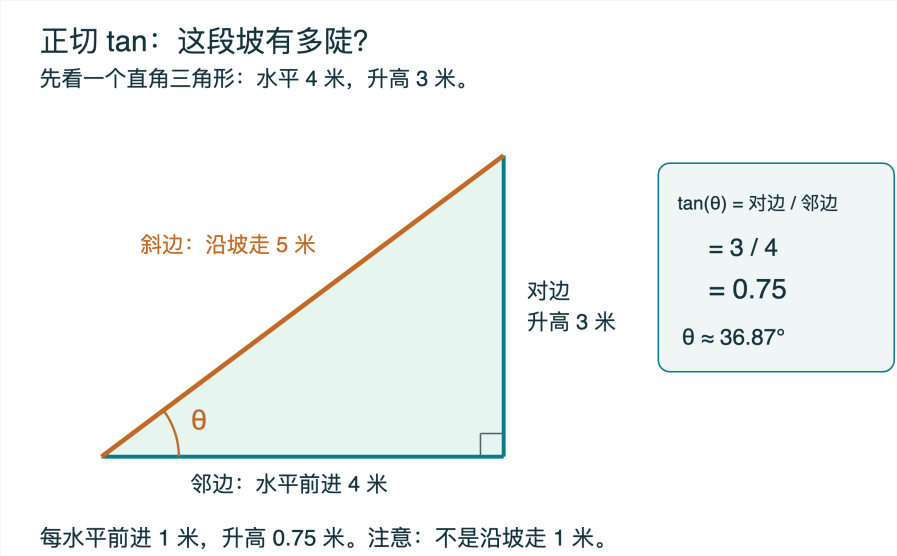

图注：助手绘制的 3–4–5 直角三角形教学示意；正切用竖直高度除以水平距离，不用斜坡长度作分母。θ 约 36.87°。

像给小朋友讲： 在这种笔直的坡上，每水平往前 1 米，会升高 0.75 米。数越大，坡越陡。这里“水平往前 1 米”不是沿坡走 1 米；两种距离不同。

用手指读图： 先指左下角的 θ，再指对面的竖边 3，最后指贴着角的水平边 4。用 3 除以 4。不要拿斜边 5 来除：3÷5 对应这里的正弦，不是正切。

放大不改变比例： 把整张图扩大两倍，高变 6、水平距离变 8，仍有 6÷8=0.75，坡角不变。正切描述的是角度对应的比例，不是三角形有多大。

换一个坡试试： 高 1、水平 1 时，角度是 45°，正切是 1。θ 越接近 90°，正切越大；恰好 90° 时分母为零，正切没有定义，不能把它当成一个普通的有限数。

别把三个东西混起来： θ 是角度，tan(θ) 是比例，θ 的大小通常不等于这个比例。上图不是“角度等于 0.75°”，而是“约 36.87° 的正切等于 0.75”。

tan 与 tanh 是不同函数。 tan 叫正切，可用直角三角形理解；tanh 叫双曲正切，它的名字来自双曲函数。不要把 tanh(x) 当作图里这段坡的正切，也不要以为它就是 tan(x) 后面乘一个 h。理解网络时，可以先掌握下节的平滑压缩曲线，不必先掌握双曲线。

t=tanh(x)：读作“t 等于 x 的双曲正切”

`tanh` 是一个完整的函数名，叫“双曲正切函数”，不是 t、a、n、h 四个字母相乘。括号表示把 x 交给这个函数，左边的 t 是给输出起的名字。口头也常直接称它为“tanh 函数”。

给小朋友讲：一台柔和的数字压缩器。 把 x 送进去，机器按固定规则吐出 t。它把任意实数压到 −1 和 1 之间：负数的输出仍是负数，0 还是 0，正数的输出仍是正数。

输入 x	输出 tanh(x)，约值	可以怎样理解
−3	−0.995	很靠近 −1
−1	−0.762	负数被压进范围
0	0	处在中间
1	0.762	正数被压进范围
3	0.995	很靠近 1

它不是硬剪刀。 不是“超过 1 就全部改成 1”；tanh(1) 本身也不是 1。它是一条平滑的 S 形曲线，中间变化明显，两端越来越平。对于有限实数输入，数学输出严格介于 −1 与 1 之间；计算机精度有限，极大输入有时会显示为 1 或 −1。

空间转化： 把 x 放在横轴，t 放在纵轴。从中间沿曲线向右走，曲线先上升较快，后来越来越靠近高度 1；向左则靠近 −1。步骤 5 的曲线图 展示的正是这条关系，旁边还标出变化率。

网络为什么用它？ 神经元先算 `s=w1*x1+w2*x2+…+b`，再算 `t=tanh(s)`。例如先算出 s=1，就输出约 0.762。tanh 给计算加入非线性的弯曲；如果多层都只有线性变换与偏置，整体仍可合成一次这样的变换。它不是给模型装上“思想”。

```
import math                          # 导入标准库里的数学
函数
for x in [-3, -1, 0, 1, 3]:          # 依次取五个输入
    t = math.tanh(x)                 # 算出双曲正切
    print(x, round(t, 3))            # 打印输入和保留三位
小数的输出
```

你实际做的事： Python 标准库按同一个函数规则算五次，并打印输入与输出。这里没有训练参数，运行它也没有训练网络。

停一下： x 从 3 变成 4，输出会从约 0.995 变成 1.995 吗？不会；tanh(4) 约为 0.9993。两端越来越不容易变化，这就是后面解释梯度变小时要用到的直觉。

双曲正切的空间转化：一张曲线图，先看懂输入怎样变成输出

把它想成坡路，但要从侧面看。 不是从天空俯瞰一条左右拐弯的 S 形公路，而是在旁边看路面从低处升到高处、然后逐渐变平。这里的高低是相对于图中零刻度，不是现实海拔。

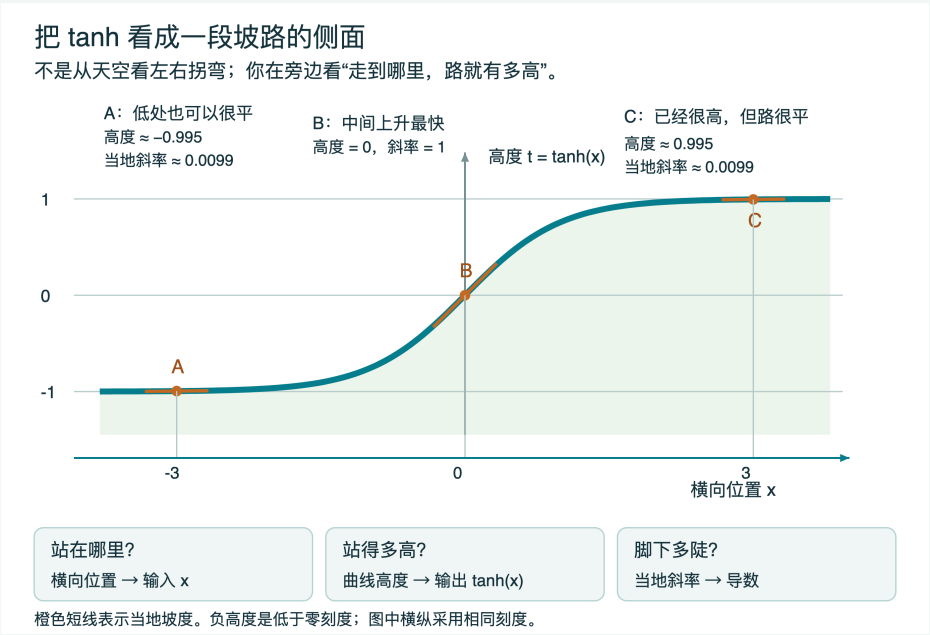

图注：助手绘制的数学侧视类比，横纵采用相同刻度。A、B、C 对应 x=-3、0、3；高度约为 -0.995、0、0.995，局部导数约为 0.0099、1、0.0099。橙色短线是各点的切线片段，示意当地坡度。

用手指沿路走一遍：A 在低处，但路很平；B 高度在中间，坡最陡；C 已经很高，但路又变平了。 因此，站得高与脚下陡是两件事。

你在问什么	数学上对应什么	看图哪里
我走到哪里了?	输入 x	下方横向位置刻度
我站得多高?	输出 tanh(x)	路面相对零线的高度
脚下的路有多陡?	tanh 在此处的导数	橙色短线的斜率

记住 C 点：输出已经接近 1，导数却接近 0。 它帮助你区分“激活值大”和“局部梯度大”。图里的路只是数学类比，不代表真实地形。

把它想成一条带高度的路线。 横向位置是输入 x，曲线在那个位置的高度就是输出 t。想求 tanh(1)，先在横轴找到 1，向上走到曲线上，再水平看纵轴：高度约为 0.762。这不是沿曲线走了多远，也不是曲线的斜率。

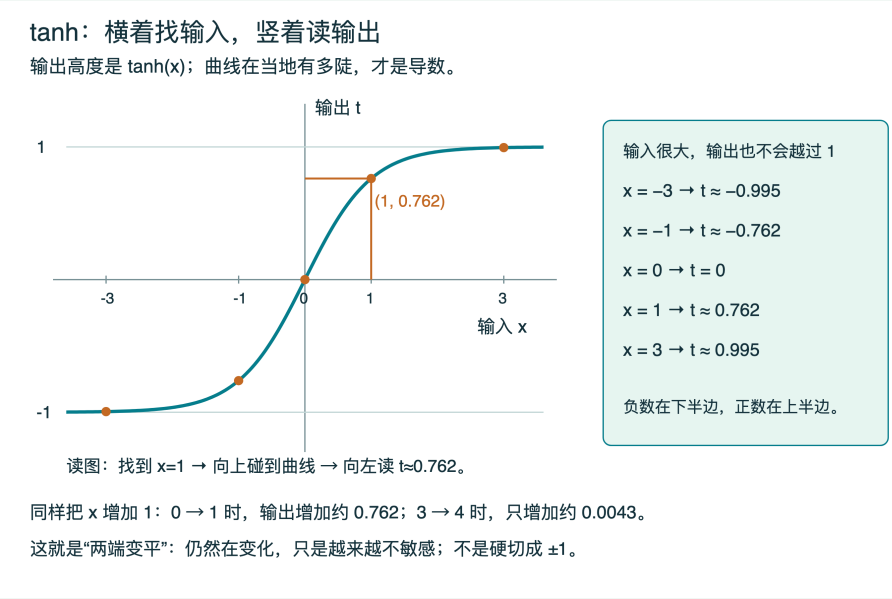

图注：助手绘制的 tanh 函数图，数值由标准数学函数计算并四舍五入。橙色折线示范 x=1 时怎样读出 t≈0.762；灰色水平线标出输出趋近的 ±1。

看见三件事就够了。 第一，中间穿过原点，所以输入 0 得到 0。第二，往右走时输出升高，但越来越靠近 1；往左则靠近 –1。第三，两端逐渐变平，所以继续改变输入，输出只改变很少。

做同样大小的输入变化	输出变化，约值	你在图上会看到什么
x 从 0 变成 1	0 → 0.7616，增加 0.7616	中间上升明显
x 从 3 变成 4	0.9951 → 0.9993，增加约 0.0043	右端已经很平

表中变化量由未四舍五入的数计算后再取约值。这是在比较两段长度为 1 的区间，不是直接把变化量叫作某一点的导数。**曲线高度告诉你输出是多少；当地的斜率才告诉你输入轻推一下时，输出有多敏感。**

换成神经元的场景。 前面加权求和得到一个数 s，tanh 把它映射成输出 t。若 s=1，t≈0.762；若 s=3，t≈0.995。反传时的局部导数是 `1−t∗t`：s=0 时等于 1，s=3 时约 0.0099。因此“输出已经很大”和“梯度很大”不是一回事，两端输出接近 ±1 时，局部梯度反而很小。

小练习： 指出输入 −1 的位置，预测输出在 0 上面还是下面；答案是下面，约 −0.762。再指出输入 3 的位置：它的输出不是 3，也不是 1.5，而是约 0.995。

想知道为什么名字里有“双曲”？再看另一张图

前面的 S 形线是“x 与 tanh(x) 的对应图”，**它本身不是双曲线**。名字来自下面这个几何关系：在 $U^2-V^2=1$ 的右支双曲线上取一个点 P，它的坐标可以写成 $U=\cosh(x)$、$V=\sinh(x)$，那么 $\tanh(x)=V/U$。

这里暂时把 cosh、sinh 当作“根据参数 x 确定点的横、纵坐标”的两个函数名字即可；不必为了运行神经网络先推导它们。U、V 是这张图的坐标；参数 x 决定点在哪里，**x 不是普通的三角形夹角，也不是这里的横坐标 U**。

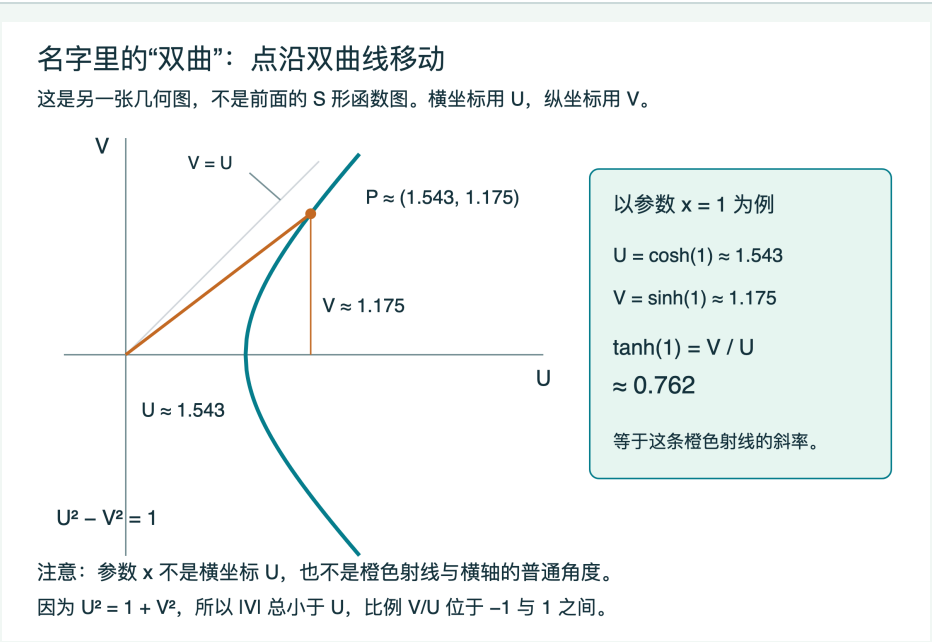

图注：助手绘制的单位双曲线右支示意。参数 x=1 时，P≈(1.543,1.175)，橙色射线斜率 V/U≈0.762，等于 tanh(1)。坐标轴与前一张函数图不同，不可混读。

用手指读图： 从原点指向 P；看它横向走了约 1.543，竖向升高约 1.175，两者相除约为 0.762。双曲线上满足 $U^2=1+V^2$，所以 U 比 |V| 大，V/U 不会越过 −1 或 1。点向右上移动时，射线逐渐靠近斜率为 1 的方向，但不会在有限参数处达到它。

与正切的衔接： 上一张坡道图的 tan(θ) 是按普通角度 θ 来算高/水平距离；这里 tanh(x) 用的是双曲参数 x。虽然最后都能表示成一个几何比值，它们对输入的解释不同，不能把 tanh(1) 当成 tan(1°)，也不能当成 tan(1 弧度)。

1. 下载或打开交付目录中的代码快照，记录对应提交。基础 6 课看 `nn-zero-to-hero/lectures/`；第 7 课看 ng-video-lecture 的 bigram.py/gpt.py，nanoGPT 用于进阶对照；分词看 minbpe；GPT-2 看 build-nanogpt。[O10、O11、O12、O13]
2. 使用下方助手提供的本地命令建环境，先执行 import 检查，不直接跑 200000 次训练。包版本以你实际安装结果保存。[O1、O3]
3. 在 makemore 笔记本运行目录放 `names.txt`；第 7 课使用 Tiny Shakespeare。先打印前几条、总量和字符集合，确认文件不是网页错误文本。[O2、O7、O16]
4. 每次实验记录 seed、数据切分、模型维数、步数、学习率、设备、训练与验证 loss。不要用换模型同时换数据的结果声称架构改进。[O3、O6]

下面是助手整理的安装入口，不是讲者原命令。先切到自己的学习目录，保持课程原始快照不变。

```
uv venv --python 3.11          # 用 Python 3.11 新建虚拟环境，生成 .venv 目录
source .venv/bin/activate      # 激活虚拟环境，之后装的包都进这里
uv pip install torch numpy matplotlib jupyterlab graphviz regex tiktoken transformers datasets tqdm requests   # 装课程要用的库：张量、绘图、笔记本、图、分词、模型与数据加载
python -c "import torch; print(torch.__version__); print('CUDA:', torch.cuda.is_available())"   # 自检：打印 torch 版本，并报告 CUDA（显卡加速）是否可用
uv pip freeze > requirements-installed.txt   # 把这次实际装上的版本存成清单，方便复现
jupyter lab                    # 启动 Jupyter，浏览器里打开笔记本界面
```

课程的 Python `graphviz`（图描述生成包）负责生成图描述；本地渲染还需要 Graphviz 的 `dot`（画图程序）。缺它时先用数值梯度对照，画图报错不代表自动求导错误。下载依赖失败时先记录具体包与错误，不改成另一门课。

> **做完的标准**：能打开课程笔记本并导入 torch；能读到名字与 Shakespeare 数据；第一条实验记录写明设备和版本。

白话说明：先给自己准备一张能反复使用的实验桌

你现在要做的是让代码、数据和运行环境都能找到彼此。终端负责启动程序；Jupyter 把程序分成一个个可单独运行的单元格。你在单元格里输入代码，按 Shift+Enter（运行并跳到下一格），结果显示在下面。它适合逐段观察数字如何变化。

先看这些词指什么：Python 是执行代码的语言；PyTorch 是做张量计算和自动求导的工具；Notebook 是把代码、文字和输出放在一起的 `.ipynb` 文件；kernel（内核）是正在运行这本 Notebook 的 Python 进程。关掉网页不等于清空 kernel；乱序执行单元格会让旧变量残留。

操作 A：在自己的目录留一份练习副本

在终端执行下面命令。`cp -R` 复制官方代码，`cd` 改变当前工作目录。此处 `~/karpathy-learning` 是助手建议的练习目录；若你已经在这里做过练习，不再复制覆盖，直接进入已有目录。

```
mkdir -p ~/karpathy-learning        # 建学习目录（已存在也不报错）
cp -R /Users/ziye/Documents/wiki/system/roadmap/structure/2026-10-29-karpathy-llm-zero-to-hero/deliver/code ~/karpathy-learning/   # 把课程代码整份复制进学习目录
cd ~/karpathy-learning              # 进入学习目录
```

操作 B：准备 Python，并确认用的是哪一个解释器

首次使用时执行原步骤的 `uv venv --python 3.11` 和安装命令。以后每次新开终端，进入学习目录后先执行 `source .venv/bin/activate`（在当前终端里激活虚拟环境）。然后运行：

```
python -c "import sys; print(sys.executable)"
# 打印当前 Python 解释器路径，确认用的是 .venv 里那个
python -c "import torch; print(torch.__version__);
print(torch.rand(2, 3))" # 打印 torch 版本和一个 2 行
3 列的随机数表
jupyter lab
# 启动 Notebook 界面
```

第一条应显示学习目录下 `.venv` 中的 Python；第二条应输出版本和一个 2 行 3 列的随机数表。数字每次可以不同。步骤 2 的教学脚本只用 Python 标准库，即使 PyTorch 尚未安装也可以先做。

操作 C：确认数据和 Notebook 在同一层

在 Jupyter 左侧依次打开 `code/nn-zero-to-hero/lectures/makemore/`。这里有 `names.txt` 和五个课程笔记本。新建一个 Notebook，在第一格运行：

```
from pathlib import Path                                    #
用 pathlib 处理文件路径
print(Path.cwd())                                           #
打印当前工作目录，先确认自己在哪
text = Path('names.txt').read_text()                        #
读入 names.txt 全文
print(text.splitlines()[:5])                                #
打印前 5 行名字
print('名字条数：', len(text.splitlines()))                  #
打印总行数，确认不是空文件或网页报错文本
```

结果怎么看：应看到若干名字和大于零的条数。`FileNotFoundError`（找不到文件的报错）通常表示当前目录不对；先看 `Path.cwd()`，不要反复安装库。`ModuleNotFoundError: torch`（找不到 torch 模块的报错）表示当前 kernel 的环境里没有 torch；在 Notebook 中查看 `sys.executable`，与终端输出比较。

本步停在哪里：保存这个 Notebook，记下 Python 路径与 PyTorch 版本。你不需要先理解神经网络；能启动代码、能读到数据就进入下一步。

说明与衔接：本段是助手基于本步骤课程与代码整理的动手导读；微型例子只解释相应局部机制。继续按下面原有课程讲解、截图与验收要求完成该步。

空间转化：把步骤 1 摆到一张图里

把学习环境想成工作台：左边是你复制出来的代码与数据，中间是实际执行它们的 Python 环境，右边是输出、图和日志。Jupyter 像工作纸的编辑台，内核负责执行并记住变量。找到某个文件夹不等于已经选对 Python 环境；先确认路径和内核，再运行一格。

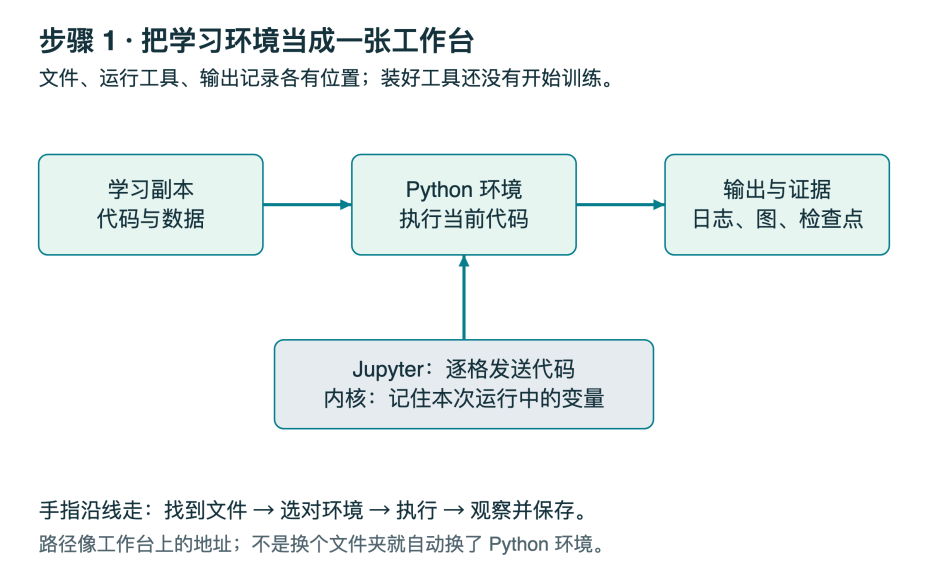

图注：助手绘制的教学示意，2026-11-09；帮助理解本步的计算关系与操作顺序。图中教学数字与简化结构不冒充课程截图、模型实测性能或完整实现。

试着用手指读图： 先指出输入或起点，再沿依赖找到中间处理，最后指出输出或结果记录。停在每一站，说出“这里放的是什么、对它做了什么、什么东西会改变”。如果遇到反向箭头，要说明它传回的是梯度，还是图中另有注明的流程。

再用一句话检查自己： 遮住正文，只看图，解释这一节与上一步相比新增加了什么；然后回到本步的小实验核对。会复述图并不代替实际运行和数值验收。

Task（任务）｜本机环境准备

- ☐ 启动 Jupyter，并打开第 1 课练习笔记本。
- ☐ 运行环境与数据检查，确认输出通过。

本机 setup：两步直接照做

以下提示词由助手按本机实际目录整理，可复制给有本地终端能力的助手；不是讲者原提示词。也可以自行在终端执行对应命令。目录移动后，请替换命令与提示词中的完整路径。

Setup 1（准备工作 1）：启动 Jupyter，打开第一课练习

适用前提：本机的 practice 目录、.venv 环境和启动脚本已经准备好。日常学习从这里开始，无需重复运行上面的安装命令。

复制给助手的准确提示词：

```
请在目录
/Users/ziye/Documents/wiki/system/roadmap/structur
e/2026-10-29-karpathy-llm-zero-to-hero/practice 中
执行 ./start-jupyter.sh，启动 Jupyter Lab 并打开浏览
器。如果这个练习目录的 Jupyter 已经运行，请复用已有服务。告
诉我如何打开 experiments/01-microgradattempt-
001.ipynb，并选择 Python（Karpathy practice）
（Karpathy 练习环境）内核。不要运行训练单元格。
```

自己在终端执行：

```
cd
"/Users/ziye/Documents/wiki/system/roadmap/structu
re/2026-10-29-karpathy-llm-zero-to-hero/practice"
# 进入练习目录
./start-jupyter.sh
# 运行启动脚本，起 Jupyter 并打开浏览器
```

浏览器打开 Jupyter 后，在左侧依次打开 experiments → 01-micrograd → attempt-001.ipynb，选择 Python (Karpathy practice) 内核。启动命令会持续占用当前终端；保持它运行。浏览器未自动打开时，使用终端输出的本机链接。

Setup 2（准备工作 2）：激活环境，运行环境与数据检查

如果 Jupyter 正在前一个终端运行，请新开一个终端窗口或标签页执行以下命令。source（在当前终端里执行脚本的命令）只对当前终端生效，所以新终端需要重新激活环境。

复制给助手的准确提示词：

```
请在目录
/Users/ziye/Documents/wiki/system/roadmap/structure/2026-10-29-karpathy-llm-zero-to-hero/practice 中依次执行 source .venv/bin/activate 和 python scripts/check_environment.py。检查依赖导入、CPU/MPS/CUDA 状态、names.txt 与 Tiny Shakespeare 的数据内容，并告诉我检查是否通过。如果报错，记录具体包名与错误后修复，再重新检查。不要启动模型训练。
```

自己在终端执行：

```
cd
"/Users/ziye/Documents/wiki/system/roadmap/structure/2026-10-29-karpathy-llm-zero-to-hero/practice"
# 进入练习目录
source .venv/bin/activate          # 激活虚拟环境（只对当前终端生效）
python scripts/check_environment.py   # 跑环境与数据检查脚本，输出会写到 records/
```

做完的标准：命令退出码为 0，输出包含包版本、设备状态、数据预览、总量和字符集合；结果保存到 records/environment-check.json。2026-11-09 本机实测：CPU/MPS 检查通过，CUDA 为 false；名字共 32,033 个，Shakespeare 共 1,115,394 字符、65 种字符。dot 为 null 表示尚未安装系统 Graphviz 渲染程序，不代表 PyTorch 检查失败。

可以直接填写的实验表（T1–T3）

这些表把运行条件、结果和判断一起留下。它们是助手根据课程实验习惯制作的记录工具，不是讲者输入过的原提示词；〔〕只是填写占位。

T1 实验卡

```
实验编号：〔唯一编号〕
课程/时间点：〔第几课，HH:MM:SS〕
代码提交/文件：〔commit，文件〕
问题：〔只写这次要验证的一件事〕
数据与切分：〔数据版本，train/val/test〕
设备/框架版本：〔真实环境〕
seed：〔真实值〕
模型：〔上下文，embedding，层数，头数，参数量〕
训练：〔batch，梯度累积，token 预算，步数，学习率〕
只改了什么：〔对照变量〕
结果：〔train/val loss，评估正确数/总数，吞吐〕
样本文件/截图：〔路径与时间〕
判断：〔继续/停止/回退，理由〕
下一步：〔一个具体动作〕
```

T2 形状与梯度检查

张量/参数	前向形状	反向形状	与参考最大差	判定与依据
〔名称〕	〔真实形状〕	〔真实形状〕	〔实测〕	〔容差/原因〕

T3 吞吐与费用估算

项	填真实值
设备、卡数、dtype、B、T、A	〔〕
热身次数、是否含编译/验证	〔〕
稳态 update 秒数 s	〔〕
token/update	B×T×A×W
tok/s	token/update ÷ s
预计训练小时	目标 update 数 × s ÷ 3600
当前实际 GPU 单价与计费单位	〔查询日期与订单页面〕
预算上限/停止时间/停止方式	〔〕

另提供 CSV 空表，位于交付目录 `templates/`。不要把示例占位写成实际跑过的数据。

后面每一步末尾的排错表

从步骤 2 起，每一步末尾都有一张「卡住时按这个顺序查」的小表，按现象列出先查什么、修好后怎么验；它们和上面的实验表一样，是助手根据课程故障与代码整理的检查路径，不是讲者原话，同一个报错也不保证只有一个原因。

步骤 2 从导数实现 micrograd

看不懂代码？ 先跳到本节中段的「三岁小孩版」白话重讲，那里用五幕把这几个格子重新说了一遍。

神经网络的训练可以拆成可求导的数学运算。这里先让一个小计算图的梯度完全可见，再把这些零件组成神经元和多层网络。

目标：实现标量 `Value`、图级反向传播和一次参数更新。

1. 从 `f(x)=3*x**2-4*x+5` 做有限差分：计算 `(f(x+h)-f(x))/h`，缩小 h 并与解析导数对照。随后对 `d=a*b+c` 分别扰动 a、b、c。定位第 1 课 00:08:08–00:19:09。[O1]
2. 给 `Value` 保存 `data`、`grad`、父节点与运算；先实现加法、乘法，再给每个运算保存局部 `_backward`。从输出梯度 1 开始，用链式法则向后传递。定位 00:19:09–01:17:32。[O1]
3. 用拓扑排序收集图，再逆序调用局部反传；测试 `a+a` 和 `a*a`，确认同一节点被多条路径使用时梯度累加，不能覆盖。定位 01:17:32–01:27:05。[O1]
4. 实现 tanh、幂、负数、减法与除法；再实现 Neuron、Layer、MLP、parameters。构造课程中的四组小样本，用平方误差训练。每轮重做前向、清梯度、反传、沿负梯度更新。与 PyTorch 的相同计算图逐个数对照。[O1、O14]

> **做完的标准：** `a+a` 的导数为 2；乘法、tanh 的手算/自动/有限差分大致一致；四组样本 loss 经更新下降；能解释清梯度和拓扑顺序。

白话说明：你正在造一台“会告诉你该拧哪个旋钮”的计算器

先不想大语言模型。想象一个公式里有一个可以调的数字 `w`：输入 2，希望输出 4，当前计算方式是 `预测值=w×2`。如果 w=0，就预测 0；如果 w=2，就预测 4。训练就是让程序根据误差，自动把 w 往合适的位置移动。

micrograd 处理这个过程中的关键问题：**最终误差变大或变小，与每个可调数字有什么关系？** 它先记住计算经过了哪些加法、乘法等操作，再沿着这些操作倒推导数。你将亲手实现这套记录和倒推机制。

先坐下来：刚才电脑到底替你做了什么？

先只记一句话：我们在做一个“猜错以后，知道该怎样调”的小机器。 这一节还没有教电脑说话。我们先造一个很小的零件，日后训练更大的网络会用到同一种方法。

下面是助手编写的教学类比，不是课程里的真实机器。想象桌上放着一台玩具果汁机：你输入“2 杯”，机器有个可以转动的旋钮 `w`。我们人为规定它的显示屏显示 `2*w`，希望显示 4。现在旋钮在 0，屏幕便显示 0。问题是：**怎样让程序自己把旋钮往正确方向转一点？**

这里“杯子”只帮你记住输入，屏幕数字只是公式的结果；真实果汁机并不按这段程序工作。输入 2、希望得到的 4 都由我们给定，允许程序调整的只有旋钮 `w`。

你在屏幕上看到的动作	像在做什么	实际发生的事情
在 Jupyter 的格子里输入代码	给机器写一张工作纸	文字暂时放在编辑框里，还没有计算
按 Shift+Enter	让机器照工作纸做一遍	Python 执行这一格，结果显示在下面
出现 `8.3、8.03…`	试着轻推旋钮，量屏幕变化	用小幅输入变化估计导数
执行 `class Value`，没有很多数字出现	按图纸造好一种“带记录卡的盒子”	定义一种对象的行为，尚未训练网络
出现 `3、2、1`	给三个旋钮分别贴上灵敏度标签	程序算出了最终结果对三个输入的导数
出现 `16 → 0.64`	调了一下旋钮，离目标近了	一次参数更新后，重新计算的误差变小
出现 200 次训练和一条下降曲线	重复“猜、量差距、调一点”	同一批四个样本反复参与参数更新

你现在不用背完整代码。 先看下面每一小节的故事，再看数字，最后才看代码。每节只需回答最后的一个小问题。任何一节还说不出来，就先停在那里，不用急着运行下一格。

先翻译原步骤里那些看不懂的词

原文里的词	用具体东西理解	在本练习中长什么样
标量	单独一个数字	`2.0`；还不是一整排或一整张表
Value	带着计算履历的小数字盒子	装着当前数值、梯度和产生它的运算
data	盒子里当前的数	`a.data=2.0`
grad	最终输出对这个数的局部敏感度	`a.grad=3` 意味着 a 小幅增大 δ，输出约增加 3δ
父节点	直接产生这个结果的输入盒子	`d=a*b` 的父节点是 a、b
前向传播	按公式从输入算出结果	先算乘积，再算加法，最后算误差
loss	衡量预测偏离目标的一个数	`(预测值-目标值)**2`；越小越好
`_backward`	某一个运算自己的反传规则	乘法知道怎样把输出梯度分给两个输入
`backward()`	安排整张图反传的总调度	先排顺序，再逐个调用局部规则
参数	允许被训练改变的数字	权重 w 和偏置 b；输入数据和目标通常固定
学习率	每次沿梯度移动多少	`w -= 0.1 * w.grad` 中的 0.1

这里的“影响”是数学上的局部变化率，不是道德责任或因果解释。梯度描述的是这次前向、这个参数位置下的关系。

操作 A：先运行四行代码，亲眼看见“导数”

给小朋友讲：轻轻推一下，看看动了多少。 想象你沿着一小段斜坡往前挪。你想知道脚下有多陡，就量“往前挪的距离”和“升高的距离”。导数讲的正是这种当前位置的变化比例。

把故事放回公式。 `f` 是一台按固定规则算数的机器；`x` 是送进去的数；`f(x)` 是吐出来的数。`**2` 表示自己乘自己，`*` 表示乘法。输入 2 时，机器算 `3*2*2-4*2+5=9`。输入 2.1 时，输出 9.83。我们只多输入了 0.1，输出却多了 0.83，所以这一小段的变化比例是 `0.83/0.1=8.3`。

`h` 就是“这次轻推多少”。有限差分是先实际试两次，再比较结果；解析导数则是根据公式推导出斜率。在这里，缩小轻推距离后，估计值靠近 8。**8 不是机器的输出：输出在 x=2 时是 9；8 是当前位置的变化比例。**

你该操作什么： 先只运行本小节这一格，找到输出里的第一列 h 和第二列斜率。不要先改整段代码。然后把输入 2 换成 3，观察结果靠近 14。

停一下，自己说一句： “我刚才轻推的是输入，观察的是输出改变了多少。”如果只能记住一个区别，就记住“结果”和“结果变化的快慢”是两件事。

在 Jupyter 新建 `my_micrograd.ipynb`，第一格输入下面代码。也可以保存为 `.py` 文件后在终端运行。这里不需要 torch。

```
def f(x):                              # 定义要研究的函数
    return 3 * x ** 2 - 4 * x + 5   # 3x² - 4x + 5

for h in [0.1, 0.01, 0.001, 0.0001]:   # 依次取越来越小的步长 h
    print(h, (f(2 + h) - f(2)) / h)    # 打印 h 和 (f(2+h)-f(2))/h，即差分估计的斜率
```

你在干什么：先计算 x=2 的结果，再把 x 轻轻推大一点 h，比较输出变化了多少，最后除以推的距离。就像测量“向前走一厘米，坡面升高多少”。

会看到什么：结果约为 8.3、8.03、8.003、8.0003，越来越靠近 8。手算导数是 `f'(x)=6x-4`，在 x=2 时等于 8。最后一位有浮点误差属于正常现象，不要把 h 无限缩小。

自己改一下：把 `f(2 + h)` 和 `f(2)` 中的输入 `2` 改成 `3`，保留 `x ** 2` 的指数 `2`，结果应趋近 14。能解释这两组结果，就知道导数是“当前位置的斜率”，不是函数永远不变的属性。

操作 B：把一个大公式拆成两道小工序

给小朋友讲：算总价，先算一堆，再加一份。 想象每份点心的价格是 a=2 元，买 b=3 份，再加固定包装费 c=4 元。先算点心钱 `u=a*b=6`，再算总价 `d=u+c=10`。字母只是给数字起的小名字，u 是中途的小票，d 是最后的小票。

三个旋钮要分开试。 只把每份价格加 0.01，三份的总价就加 0.03；只把包装费加 0.01，总价就加 0.01。于是 a 的灵敏度是 3，c 的灵敏度是 1。为了计算 b 的导数，我们把“份数”看成可以连续变化的数学量；现实里的整块点心不能买 0.01 块，所以类比只用于理解乘法。

链式法则像两段放大器接在一起。 第一段把 a 的微小变化放大 3 倍。如果最后又规定 `L=2*d`，第二段再放大 2 倍，那么 a 对 L 的变化比例就是 `3*2=6`。这不是把两个数字随便相乘，而是后一段接收了前一段已经发生的变化。

你该操作什么： 用纸写下“2×3=6，6+4=10”，再只把 2 改成 2.01。看到 10.03 就对了。先理解这个变化，再看下面的计算图。

停一下： 包装费增大一点时，为什么不乘 3？因为包装费走的是直接相加的那条路，不经过点心数量的乘法。

取 `a=2, b=3, c=4`，把 `d=a*b+c` 拆成：

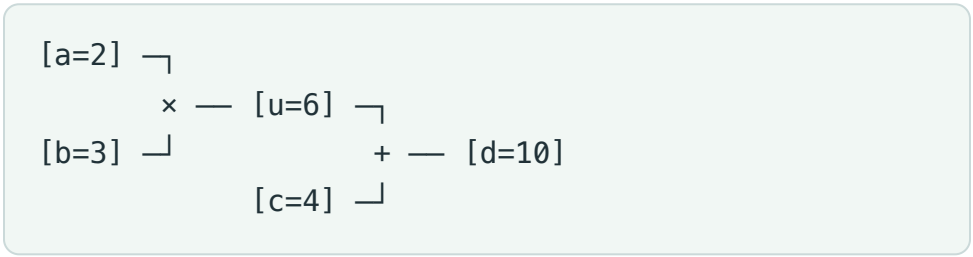

从 d 往回想：c 增加 0.01，d 也增加 0.01，因此 `∂d/∂c=1`。a 增加 0.01，乘上固定的 b=3 后，d 增加 0.03，因此 `∂d/∂a=3`。同理 `∂d/∂b=2`。这种只动一个输入、保持其他输入不变的导数叫偏导数。

再接一层 `L=2*d`，a 对 L 的影响变为 `3×2=6`。前一站的影响乘上后一站的影响，就是链式法则。你不需要一次对整个复杂公式求导，只要给每种小运算写好局部规则。

操作 C：运行完整教学版，再回来看每个部件

给小朋友讲：先拿到一整盒积木，再一块一块认识。 下面的大段程序是一整套可以运行的积木。运行它，只证明这些积木能拼起来；不意味着你已经知道每块的用途。

零基础的读法： 暂时不要从第一行一路硬读到最后。先运行，认出五组输出：测斜率、算三个梯度、检查重复使用、调一个参数、训练一个小网络。然后按 D、E、F、G 的顺序回来看代码。一口气贴进去是为了得到可观察的对象，真正的理解发生在后面的逐块拆解。

Jupyter 操作小抄： 点进代码格，粘贴代码，按 Shift+Enter。格子左侧出现 `[*]` 表示还在运行；出现编号表示执行已结束，但仍要看下面是否有错误信息。输出通常显示在格子下方。单独执行后面的格子时，如果提示 `NameError`，可能是前面的定义格还没运行。定义 `class` 相当于先准备图纸，创建对象才是照图纸做盒子。

停一下： “把代码贴上去”和“运行代码”有什么区别？前者是写工作纸，后者是让 Python 照着做。

我已把下面完整代码保存到交付目录 `code/learning/step02_micrograd_walkthrough.py`。无需安装第三方库，在终端直接运行：

```
python3
/Users/ziye/Documents/wiki/system/roadmap/structur
e/2026-10-29-karpathy-llm-zero-to-
hero/deliver/code/learning/step02_micrograd_walkth
rough.py   # 直接运行教学脚本，它会依次打印五组对照结果
```

若步骤 1 已复制过代码，使用 `~/karpathy-learning/code/learning/step02_micrograd_walkthrough.py` 前先确认这次新增文件也已复制过去。上面的交付目录绝对路径始终指向本次文件。

下面是**助手编写的完整教学脚本**，用于拆解课程机制，不冒充作者原文件。可以复制整段保存成自己的 `.py` 文件。先看输出，再回到 `Value` 中按加法、乘法、反传顺序阅读。

```
"""助手编写的教学版：纯 Python 标量求导与四样本训练，不是官方源码。"""
import math  # 数学函数：tanh 与乘方
import random  # 随机数：初始化权重

# ── 核心一：Value 保存一个数字、它的梯度，以及它由谁算出来 ──
class Value:  # 定义 Value 类

    def __init__(self, data, parents=(), op=""):  # 构造方法
        self.data = float(data)  # 保存这个节点的数值
        self.grad = 0.0  # 梯度初始为 0
        self.parents = parents  # 记下产生它的上游节点
        self.op = op  # 记下用了哪种运算
        self._backward = lambda: None  # 局部反传函数，默认为空

    def __add__(self, other):  # 定义 + 运算
        other = other if isinstance(other, Value) else Value(other)  # 右边是普通数字时先包成 Value
        out = Value(self.data + other.data, (self, other), "+")  # 建输出节点，并记住两个父节点

        def backward():  # 定义加法的局部反传
            self.grad += out.grad  # x 的梯度累加 z 的梯度
            other.grad += out.grad  # y 的梯度累加 z
```

```
的梯度
        out._backward = backward  # 把反传函数挂到输
出节点上
        return out  # 返回输出节点

    def __mul__(self, other):  # 定义 * 运算
        other = other if isinstance(other, Value)
else Value(other)  # 数字先包成 Value
        out = Value(self.data * other.data, (self,
other), "*")  # 建输出节点

        def backward():  # 定义乘法的局部反传
            self.grad += other.data * out.grad  #
x 的梯度 += y × 下游梯度
            other.grad += self.data * out.grad  #
y 的梯度 += x × 下游梯度
        out._backward = backward  # 挂上反传
        return out  # 返回输出节点

    def __pow__(self, exponent):  # 定义 ** 运算
        assert isinstance(exponent, (int, float))
# 只支持整数或浮点指数
        out = Value(self.data ** exponent,
(self,), f"**{exponent}")  # 建输出节点

        def backward():  # 定义乘方的局部反传
            if exponent != 0:  # 指数为 0 时导数为
0，跳过
                self.grad += exponent * self.data
```

```
** (exponent - 1) * out.grad  # 梯度 += n·x^(n-1)·
下游梯度
        out._backward = backward  # 挂上反传
        return out  # 返回输出节点

    def tanh(self):  # 定义 tanh
        t = math.tanh(self.data)  # 先算出 tanh 的值
t
        out = Value(t, (self,), "tanh")  # 建输出节
点

        def backward():  # 定义 tanh 的局部反传
            self.grad += (1 - t * t) * out.grad  #
梯度 += (1-t²)·下游梯度
        out._backward = backward  # 挂上反传
        return out  # 返回输出节点

    def __neg__(self):  # 取负：-a
        return self * -1  # 等于乘 -1

    def __sub__(self, other):  # 减法：a-b
        return self + (-other)  # 等于加上 b 的相反数

    def __rsub__(self, other):  # 反向减法：数字 - a
        return other + (-self)  # 等于 other + (-a)

    def __truediv__(self, other):  # 除法：a/b
        return self * other ** -1  # 等于乘 b 的 -1
次方
```

```
    def __rtruediv__(self, other):  # 反向除法：数字 / a
        return other * self ** -1  # 等于 other × a⁻¹

    __radd__ = __add__  # 数字 + Value 也走加法
    __rmul__ = __mul__  # 数字 × Value 也走乘法

    def backward(self):  # 定义 backward
        order, visited = [], set()  # 拓扑序表与已访问集合

        def visit(node):  # 递归收集所有上游节点
            if node not in visited:  # 没访问过才处理
                visited.add(node)  # 标记为已访问
                for parent in node.parents:  # 遍历它的全部上游
                    visit(parent)  # 递归上游
                order.append(node)  # 上游都排完，再把自己放进序列
        visit(self)  # 从输出节点开始收集整张图
        self.grad = 1.0  # 输出对自己的梯度记为 1
        for node in reversed(order):  # 按逆拓扑序逐个执行
            node._backward()  # 调用该节点的局部反传

# ── 核心二：一个神经元 = 若干权重 + 一个偏置 + tanh ──
class Neuron:  # 定义 Neuron
```

```
    def __init__(self, input_count):  # 构造：输入个数
        self.w = [Value(random.uniform(-1, 1)) for _ in range(input_count)]  # 每个输入一个 -1 到 1 的随机权重
        self.b = Value(0)  # 偏置从 0 开始

    def __call__(self, x):  # 前向：被调用时
        return sum((w * xi for w, xi in zip(self.w, x)), self.b).tanh()  # 加权和 Σwᵢxᵢ + b，再过 tanh

    def parameters(self):  # 返回参数列表
        return self.w + [self.b]  # 权重加偏置

# ── 核心三：一层 = 若干个神经元并排 ──
class Layer:  # 定义 Layer
    def __init__(self, input_count, output_count):  # 构造：输入维度、神经元个数
        self.neurons = [Neuron(input_count) for _ in range(output_count)]  # 建 output_count 个神经元

    def __call__(self, x):  # 前向
        return [neuron(x) for neuron in self.neurons]  # 每个神经元各算一个输出

    def parameters(self):  # 返回参数列表
        return [p for neuron in self.neurons for p in neuron.parameters()]  # 把各神经元参数摊平
```

```
# ── 核心四：多层感知机 = 若干层叠起来 ──
class MLP:  # 定义 MLP
    def __init__(self, input_count, widths):  # 构造：输入维度与各层宽度
        sizes = [input_count] + widths  # 尺寸表：输入 + 每层输出
        self.layers = [Layer(a, b) for a, b in zip(sizes, sizes[1:])]  # 相邻两项配对建层

    def __call__(self, x):  # 前向
        for layer in self.layers:  # 逐层往下传
            x = layer(x)  # 过一层
        return x[0] if len(x) == 1 else x  # 单输出时拆掉列表

    def parameters(self):  # 返回参数列表
        return [p for layer in self.layers for p in layer.parameters()]  # 各层参数汇总

# 五组对照：有限差分、计算图、重复节点、一次更新、四样本训练
def main():  # 定义 main
    print("1. 有限差分：目标导数为 8")  # 第 1 组标题：有限差分
    f = lambda x: 3 * x ** 2 - 4 * x + 5  # 被求导的函数 f(x)=3x²−4x+5
    for h in (0.1, 0.01, 0.001, 0.0001):  # 依次取四个步长 h
        print(h, (f(2 + h) - f(2)) / h)  # 打印差分
```

```
估计 (f(2+h)-f(2))/h

    print("2. 计算图：d=2*3+4，梯度应为 3、2、1")  # 第 2 组标题：计算图
    a, b, c = Value(2), Value(3), Value(4)  # 三个输入节点
    d = a * b + c  # 先乘后加，得到输出 d
    d.backward()  # 从输出反传
    print(d.data, a.grad, b.grad, c.grad)  # 打印 d 与 a、b、c 的梯度（应为 10、3、2、1）

    print("3. 重复节点：a+a 和 a*a 分别建新图")  # 第 3 组标题：同一节点被用两次
    a = Value(3)  # 新建 a=3
    (a + a).backward()  # a+a 反传
    print("a+a:", a.grad)  # 应得 2
    a = Value(3)  # 重新新建 a=3
    (a * a).backward()  # a*a 反传
    print("a*a:", a.grad)  # 应得 2a=6

    print("4. 一个参数的一次更新")  # 第 4 组标题：一次参数更新
    w = Value(0)  # 参数 w 从 0 开始
    loss = (w * 2 - 4) ** 2  # 损失 (2w-4)²
    loss.backward()  # 反传
    before = loss.data  # 更新前的 loss
    w.data -= 0.1 * w.grad  # 沿负梯度走一步，学习率 0.1
    after = (w * 2 - 4) ** 2  # 更新后重新算 loss
```

```
    print("loss before/after:", before,
after.data, "w:", w.data)  # 打印更新前后 loss 与 w

    print("5. 四样本小网络：200 次更新，打印重新计算的
loss")  # 第 5 组标题：四样本训练
    random.seed(42)  # 固定随机种子 42
    model = MLP(3, [4, 4, 1])  # 3 维输入，两个 4 宽
隐层，1 个输出
    xs = [[2, 3, -1], [3, -1, 0.5], [0.5, 1, 1],
[1, 1, -1]]  # 四组输入
    ys = [1, -1, -1, 1]  # 四个目标值

    def current_loss():  # 定义当前 loss
        return sum((model(x) - y) ** 2 for x, y in
zip(xs, ys)) / len(xs)  # 四组平方误差取平均

    print("parameters:", len(model.parameters()))
# 打印参数量
    print("step 0:", current_loss().data)  # 打印第
0 步 loss
    for step in range(200):  # 训练 200 轮
        loss = current_loss()  # 每轮重新前向，建新计
算图
        for p in model.parameters():  # 遍历所有参数
            p.grad = 0.0  # 清掉上一轮梯度
        loss.backward()  # 反向传播
        for p in model.parameters():  # 再遍历所有参
数
            p.data -= 0.05 * p.grad  # 沿负梯度更新，
```

```
学习率 0.05
        if (step + 1) % 50 == 0:  # 每 50 轮
            print("step", step + 1, "loss:",
current_loss().data)  # 打印这一轮的 loss
    print("predictions:", [round(model(x).data, 4)
for x in xs])  # 打印四个预测值
    print("targets:", ys)  # 打印目标值

if __name__ == "__main__":  # 作为脚本直接运行时
    main()  # 执行 main
```

操作 D：读懂 Value 的四个零件

给小朋友讲：普通数字只有号码；Value 数字还有一张来历卡。 例如一个盒子正面写 6，背面写“我是 2 号盒子和 3 号盒子相乘得到的”。这样我们既能看答案，又能回头找到答案从哪里来。

盒子上的部件	一句话故事	代码里真正的含义
`data`	正面写当前数字	例如乘法结果 6
`parents`	背面记录输入盒子	保留 a、b 对象的引用；不是复制两份独立的 a、b
`op`	记录刚才用了哪种工具	`*` 或 `+` 等运算标记
`grad`	贴上“最终输出对我有多敏感”的标签	反传后保存最终标量输出对该节点的导数
`_backward`	每道工序的小纸条	知道拿到下游梯度后，如何给输入累加贡献
`backward()`	按正确次序分发小纸条的调度员	安排整张计算图的反向传播

为什么要倒着走？ 先有最后的目标，才能知道中途每一站对这个目标的影响。对 `d=a*b+c`，先处理最后的加法，再处理前面的乘法。如果乘法还没收到来自后面的梯度就提前执行，会用到尚未收齐的信息。

拓扑排序这四个字先不用怕。 正向算数时，“材料必须先准备好，才能算成品”。排序先记下满足这个条件的顺序；反传再把顺序倒过来。不同支路之间可能有多种正确排列，关键是不能颠倒依赖。一个节点被几条下游路径使用时，要等这些贡献都传回来，再把它的梯度继续向前面的输入传。

为什么最末端填 1？ 把最终输出自身增加 0.01，它自身当然增加 0.01，比值就是 1。因此 `d.grad=1` 是“d 对 d 的导数为 1”，并不是说 d 的值变成了 1。

停一下： 盒子上的 `data=10` 和 `grad=1` 可以同时存在吗？可以，一个记数值，一个记变化比例。

第一件：保存数值。 `Value(2)` 创建一个盒子；`.data` 里面是 2，`.grad` 先设为 0，因为此时还没计算“最终输出受它影响多少”。

第二件：运算时留履历。 `out=Value(self.data*other.data, (self, other), '*')` 做了三件事：算出新数字，记住输入盒子，标记这是一道乘法。普通 Python 数字算完就只留下结果；Value 还留下从哪里来的信息。

第三件：给乘法写反传小纸条。 内部 `backward` 函数记住 `self`、`other` 和 `out`，以后真正反传时再读取 `out.grad`。这种函数保留外层变量引用的写法叫闭包。
`out._backward=backward` 只是在保存规则，没有马上执行。

第四件：统一倒序调用。 外面的 `backward()` 从输出追溯父节点，把“输入先、结果后”的顺序记在 order 里，再反过来执行。“从输出梯度 1 开始”表示输出对它自己的导数是 1，即 `dL/dL=1`；它不表示 loss 的数值为 1。

操作 E：为什么同一个节点不能覆盖梯度

给小朋友讲：同一个旋钮，连着两盏计数牌。 两块牌都显示 a，总显示是 `a+a`。把旋钮从 3 调到 3.01，两块牌各多 0.01，总数就多 0.02。这是同一个旋钮被用了两次，不是两个互不相干的旋钮。

`+=` 像往同一个篮子里继续放东西。 第一条路贡献 1，第二条路再贡献 1，篮子里就有 2。`=` 则像把原来的东西倒掉再放新的，最后只剩 1。去重的是“这只盒子安排几次反传”，不能去掉同一个盒子参与运算的两份贡献。

清梯度又是什么？ 这一轮收完所有路的贡献以后，就能更新参数。下一轮重新计算时，先把记录篮子倒空，才能收这一轮的新贡献。它不清空参数的 `data`，也不把学到的权重归零。

你该观察什么： `a=3` 时，`a+a` 的输出是 6、导数是 2；`a*a` 的输出是 9、导数是 6。两个实验各用一个新建的 a，避免把上次篮子里的记录混进来。

停一下： “一轮内部要累加”和“下一轮开始前要清空”为什么不矛盾？因为一个是收齐这一次的结果，一个是准备下一次。

把 a 看成同一个旋钮。`b=a+a` 用了两次这个旋钮。a 增大 0.01，左边贡献 0.01，右边再贡献 0.01，b 总共增加 0.02。因此梯度要把 1 和 1 加起来。

脚本分别用新 a 测 `a+a` 和 `a*a`。a=3 时，前者导数是 2，后者是 `2a=6`。拓扑遍历只访问 a 一次，但加法或乘法的局部规则仍向 a 累加两次。这是“节点不重复执行”和“贡献不能丢”的区别。

每轮训练前清空参数 `.grad`，是为了开始计算这一批的新梯度；一次反向传播内部使用 `+=`，是为了汇总同一参数的所有路径。两件事发生在不同层级，不矛盾。此教学实现不支持在同一旧计算图上直接反复调用 backward 来得到独立答案；练习中重建图最清楚。

操作 F：用一个旋钮亲手跟踪一次训练

给小朋友讲：猜一个数，差太远就转一下旋钮，再猜。 我们要求输入 2 时得到 4，机器的规则是 `预测=2*w`。w=0 时预测 0，离 4 差了 4。把差平方，得到误差分数 16；正差和负差平方后都不会是负数。

反传没有直接把答案 2 塞进旋钮。 它只告诉我们：当前位置 `w.grad=-16`。这表示 w 很小幅增加时，误差在局部会下降。我们按照自己选的步长 0.1，把 w 从 0 调到 1.6。此时预测 3.2，离目标只差 0.8，新的平方误差是 0.64。

为什么叫学习率？ 它像每次肯走多大的步子。方向对不代表步子越大越好。例如此处若用 1，w 一下变成 16，预测 32，误差反而变成 784。梯度是当前位置的指示，并不承诺任意距离都能降低误差。

旧小票不会自己重印。 原来的 `loss` 保存的是更新前算出的 16。旋钮改了以后，必须再做一次预测、再计算误差，才能得到 0.64。打印旧小票只会继续看到 16。

停一下： 我们让什么变了？只有允许训练的参数 w。输入 2、目标 4 没变；预测和误差因为重新计算才变。

时刻	具体计算	结果
当前参数	w=0	旋钮还没调
前向预测	`w*2`	0
计算误差	`(0-4)**2`	loss=16
反传	`2*(w*2-4)*2`	w.grad=-16
更新	`w = 0 - 0.1*(-16)`	w=1.6
重新前向	`(1.6*2-4)**2`	新 loss=0.64

负梯度意味着往增加 w 的方向移动会在局部降低 loss。因此减去负数，w 反而增大。学习率过大时可能跨过最优点；这次选 0.1 只是为了给你一个能手算的例子。

这里的关键动作：更新 w 以后重新计算 loss。旧的 loss 盒子还存着 16，它不会自动感知参数已经变了。训练循环每轮重新前向，就是为新参数生成新的计算图和新的误差。

操作 G：把旋钮组成一个神经元，再组成网络

给小朋友讲：一个小工位算一次，许多小工位接起来就能算复杂一点。 一个神经元先收几个输入。每个输入都有一个“音量旋钮” w，决定这个输入乘多少；再加一个整体偏移 b。最后经过 tanh 这道弯曲处理。

先看只有一个输入的工位。 输入 x=2、权重 w=0.5、偏置 b=0，先得到 `0.5*2+0=1`；经过 tanh，输出约 0.7616。tanh 可以想象成把过大的数字压进 -1 到 1 之间的软弯道；它不是生硬截断，所以越靠两端，输出越不容易继续变化。导数 `1-tanh(x)**2` 描述这种局部变化率。这里 x 指 tanh 收到的输入。

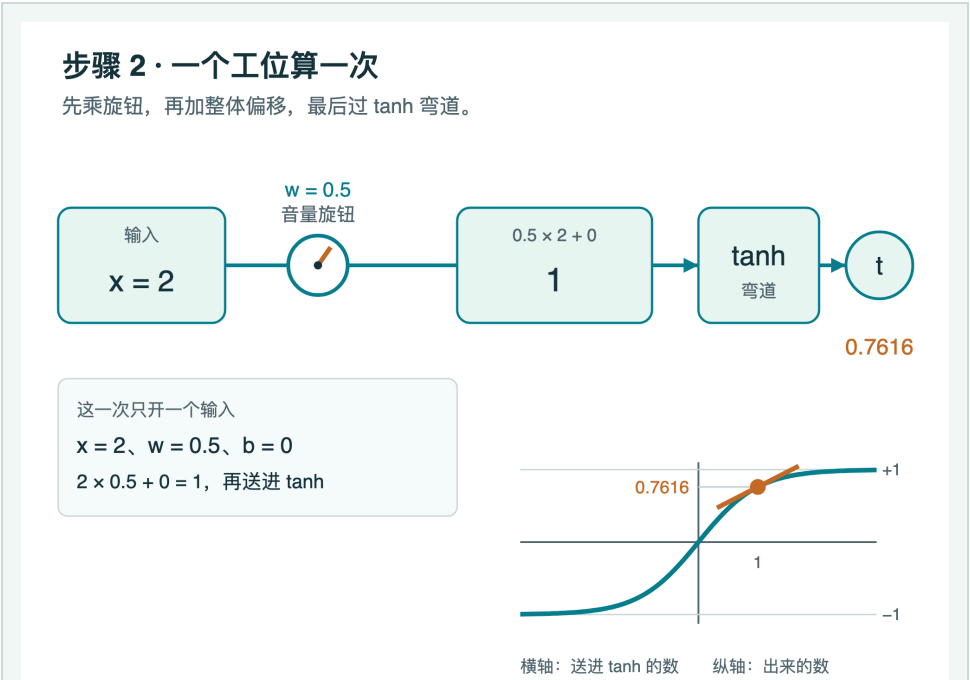

图注：助手绘制的教学示意，2026-11-10；x=2 先过音量旋钮 w=0.5，乘出 1，加 b=0 仍是 1，过 tanh 得约 0.7616。右侧曲线上橙点是 t≈0.7616，橙色短线是那一点的斜率。数值由标准函数计算后取约值。

用手指读图： 从 x=2 那个盒子出发，指着旋钮说“这个输入乘 0.5”；到 tanh 说“把 1 弯成 0.7616”；最后在曲线上找到高度约 0.7616 的橙点。

并排是层，串接是网络。 一层里的多个工位各自看同一组输入，但有自己的权重；下一层接收上一层产生的一组输出。`MLP(3, [4,4,1])` 可以读成“先输入三个数，经过四个工位，再经过四个工位，最后经过一个工位”。画在纸上的位置只是帮助理解，不是脑细胞真的排在那里。

一份样本里的 3 个数

↓ 每个工位都接收这一组输入

[工位] [工位] [工位] [工位]　　第一层，输出 4 个数

↓ 下一层接收这 4 个数

[工位] [工位] [工位] [工位]　　第二层，输出 4 个数

↓

[工位]　　最后一层，输出 1 个预测

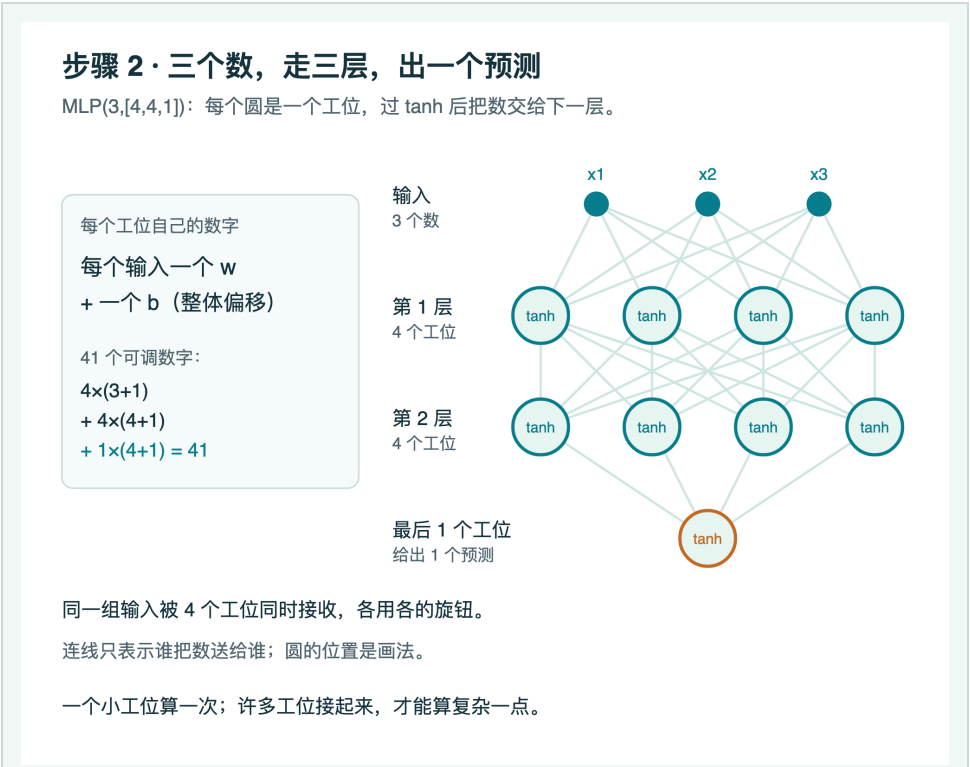

图注：助手绘制的教学示意，2026-11-10；三个输入 x1 至 x3 被第一层 4 个 tanh 工位同时接收，第二层再收第一层的 4 个输出，最后 1 个工位也是 tanh 工位，给出预测。方框里的 41 是全部可调数字；连线只表示送数方向，圆的位置是画法。

用手指读图： 先数每一层的圆：3、4、4、1；再随便点一条线，说出它把哪个数送给下一层的哪个工位。图中只画往前送数，没有画反传。

四组样本是四张练习卡。 每张卡正面写三个输入数，背面写目标 +1 或 -1。这里网络逐张计算预测，把四张卡的平方误差取平均，然后统一调整所有 41 个参数。重复 200 轮表示反复练同四张卡，不是看了 200 份新资料。

你该观察什么： 先看 loss 是否总体变小，再看四个预测是否接近各自目标。即使都接近，也只说明会做这四张练习卡；还没有证明换一张没见过的卡也能答对。

停一下： `parameters()` 为什么不返回所有中间数字？因为只要收集允许调整的旋钮；中间数字是旋钮和输入共同算出的结果。

一个神经元计算 `tanh(w1*x1+w2*x2+...+b)`。各个 w 调节某个输入的分量，b 调节整体偏移；tanh 把线性结果经过一条弯曲函数，输出落在 -1 到 1 之间。其局部导数为 `1-tanh(x)**2`。

一层 Layer 是多个神经元并排接收同一组输入；MLP 把多层串起来，上一层的输出成为下一层的输入。`MLP(3,[4,4,1])` 表示 3 个输入，依次经过 4、4、1 个神经元。可训练数字共 `4*(3+1)+4*(4+1)+1*(4+1)=41` 个。

`parameters()` 把这 41 个权重和偏置收集成列表。训练循环遍历列表清梯度、更新数值；它不会把所有中间计算结果都当作可训练参数。

教学脚本用四组输入和 ±1 目标，计算四个平方误差的平均值，再做 200 次更新。本次实际运行中，初始平均 loss 约 1.3197，200 次更新后约 0.00685；四个预测约为 `[0.9467,-0.9026,-0.9269,0.9012]`。这是该小脚本的演示结果，说明它能拟合这四个点，尚不能证明泛化或语言能力。

操作 H：拿 PyTorch 对一个小公式的答案

给小朋友讲：自己算完，再请另一台计算器验算。 你的 Value 是亲手做的小计算器；PyTorch 是现成的计算工具。我们给两边完全一样的 a、b、c 和公式，检查结果以及导数是否一致。

`torch.tensor(2.0, requires_grad=True)` 的意思是"准备一个值为 2 的数，并要求跟踪有关它的求导计算"。`d.backward()` 让 PyTorch 倒推梯度；`.item()` 只是把单个数取出来方便打印。

不是看到没报错就算验证成功。 对 `2*3+4`，必须看到结果 10，三个梯度 3、2、1；再换一组输入也要对应。对照一个公式能增加我们对这个机制的信心，但不能证明程序对所有公式都没有错误。

停一下： 两边的随机网络不一样时，为什么不能要求输出完全一样？因为参数不同，相当于旋钮位置不同，计算的就不是同一个具体函数。

完成步骤 1 的 torch 安装后，在新单元格执行：

```
import torch
# 导入 PyTorch
a = torch.tensor(2.0, requires_grad=True)
# 输入 a，要求记录梯度
b = torch.tensor(3.0, requires_grad=True)
# 输入 b
c = torch.tensor(4.0, requires_grad=True)
# 输入 c
d = a * b + c
# 前向：d = a×b + c
d.backward()
# 反向：自动算出三个输入的梯度
print(d.item(), a.grad.item(), b.grad.item(),
c.grad.item())   # 打印 d 与 a、b、c 的梯度
```

输出应约为 `10.0 3.0 2.0 1.0`，与教学版相同。再把输入换成 1.5、-2、0.3，先手算，后跑两套代码。对照的是同一个数学计算，不是随机初始化不同的两张网络。

卡住时按症状找位置

现象	先检查什么
输出值对，但所有 grad 都是 0	是否调用输出的 `backward()`；输出种子梯度是否为1
a+a 的梯度只有1	局部规则是否写成了赋值 `=`，或丢了一条贡献
a*a 的梯度只得3	两个输入引用同一对象时，是否执行了两次累加
第一轮正常，下一轮梯度异常累加	新一轮前是否清参数梯度；是否复用了旧计算图
更新后打印的 loss 一直不变	是否只打印旧 loss，没有重新前向
loss 爆大或变成非有限数	更新符号是否写反；学习率是否过大；数据是否异常
与官方 engine.py 找不到相同 tanh 方法	本脚本展示 tanh 教学版本，官方快照主要使用 ReLU；对照共同的加法、乘法、拓扑遍历机制

今天可以先停在这里：你能运行完整脚本，手算出 `3、2、1` 和更新后 loss=0.64，并说出“清梯度、反传、更新、重新前向”各自的作用。然后再尝试删去加法或乘法的反传实现，从空白补回来；最后继续课程笔记本中的其他运算与练习。

说明与衔接：本段是助手基于本步骤课程与代码整理的动手导读；微型例子只解释相应局部机制。继续按下面原有课程讲解、截图与验收要求完成该步。

空间转化：把步骤 2 摆到一张图里

把公式摆在桌上：a、b 两个数字盒子先进入乘法站，得到 u；u 与 c 再进入加法站，得到 d。正向从左读到右，得到 10；反向先给最终 d 的梯度标 1，再往回传出 3、2、1。框中的 data 是数值，grad 是最终输出对该值的变化率；位置只是帮助看依赖，不是硬件里的真实坐标。

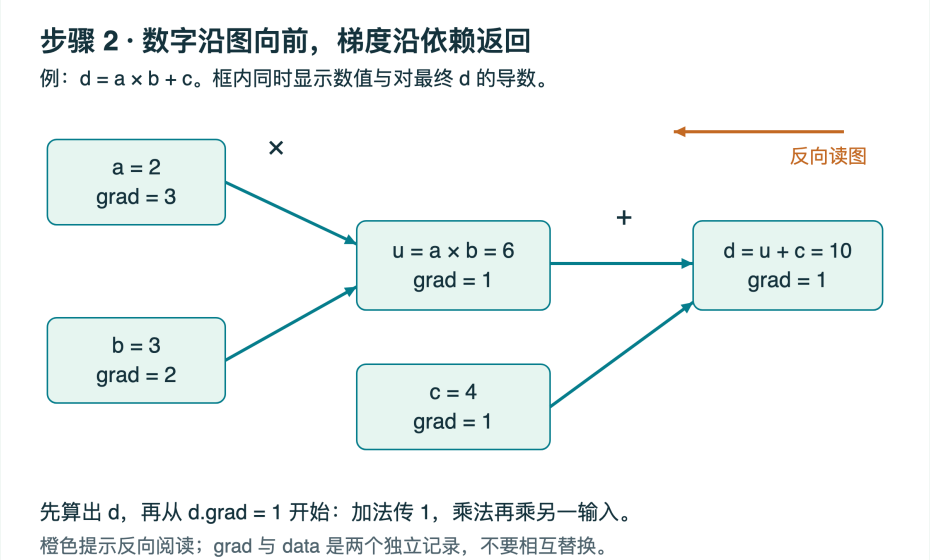

图注：助手绘制的教学示意，2026-11-09；帮助理解本步的计算关系与操作顺序。图中教学数字与简化结构不冒充课程截图、模型实测性能或完整实现。

试着用手指读图： 先指出输入或起点，再沿依赖找到中间处理，最后指出输出或结果记录。停在每一站，说出“这里放的是什么、对它做了什么、什么东西会改变”。如果遇到反向箭头，要说明它传回的是梯度，还是图中另有注明的流程。

再用一句话检查自己： 遮住正文，只看图，解释这一节与上一步相比新增加了什么；然后回到本步的小实验核对。会复述图并不代替实际运行和数值验收。

看不懂？用三岁小孩的说法重讲一遍（本机实跑版）

上面讲的是「为什么」；这一节只讲「刚才那几个格子到底干了什么」，用更小的词再说一遍。数字来自本机 `practice/my_micrograd.ipynb` 在 2026-11-10 的实际输出，不是另编的例子。

一句话：**算数值 → 寄责任信 → 拧旋钮 → 对答案。**

第一幕：先量滑梯有多陡（第 1、2 格）

先写一个函数 `f(x) = 3x² − 4x + 5`，在 x=2 旁边挪一小步 h，算「高度变了多少 ÷ 往前走了多少」。h 从 0.1 缩到 0.0001，量到 **8.3 → 8.03 → 8.003 → 8.0003**：脚步越小，越靠近 **8**。为什么正好是 8？因为导数是 `6x − 4`，x=2 代进去就是 8；换 x=3 量到 14，也正好对上。

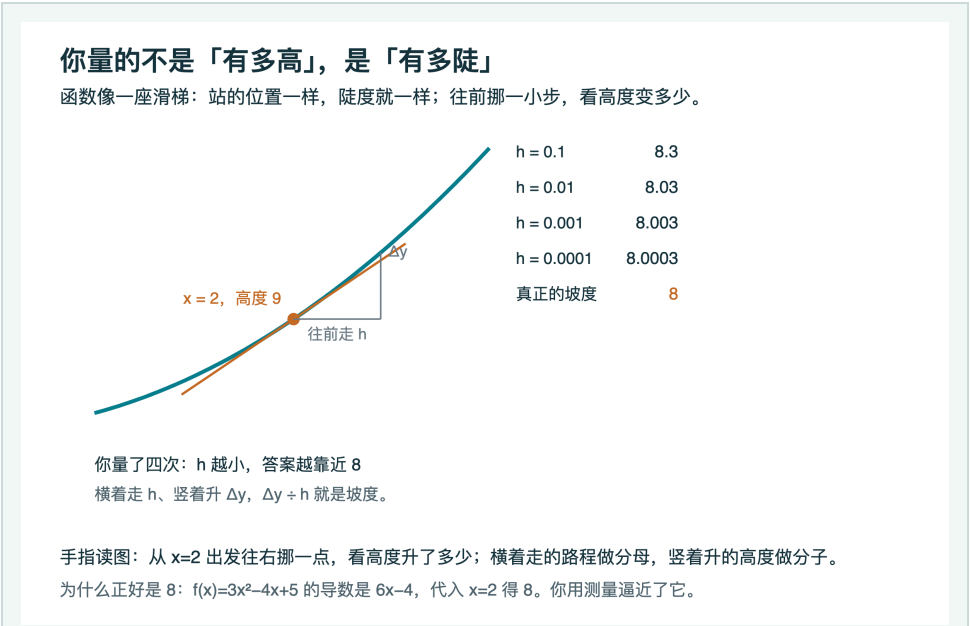

图注：助手绘制的教学示意，2026-11-10；曲线为 `f(x)=3x²−4x+5` 的真实形状，四组 h 的读数取自本机 notebook 输出。

手指读图： 从 x=2 出发往右挪一点，看高度升了多少；横着走的路程做分母，竖着升的高度做分子。步子越小，越接近真正的陡度。

第二幕：每个数字自带一封「责任信」（第 3 格前半）

每换一个函数都手量一次太累，于是写一个 `Value` 类，让每个数字带两样东西：**数值**（`data`）和**责任信**（`grad`）。信有三条规矩：加法原样递回；乘法乘上「另一个人」；最后一个数先收到「1 号信」，再倒着走一遍。拿 `d = a×b + c` 试：a=2、b=3、c=4，d=10，三封信分别是 **3**、**2**、**1**。两个小陷阱：`a+a` 让 a 收两封，得 2；`a×a` 在 a=3 时得 6。

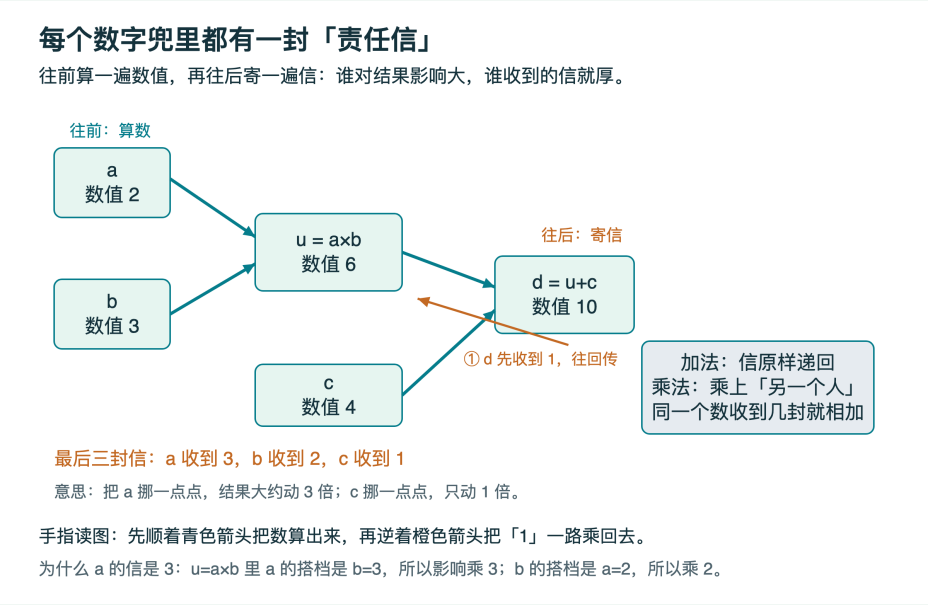

图注：助手绘制的教学示意，2026-11-10；数值与梯度对应 d=a×b+c 的手算例子，不冒充课程原图。

手指读图： 先顺着青色箭头把数算出来，再逆着橙色箭头把「1」一路乘回去；a 的搭档是 b=3，所以 a 收到 3。

第三幕：让旋钮自己转一下（第 3 格中间）

让 `w` 从 0 开始，把「错了多少」定义成 `(2w − 4)²`：

动作	数字	意思
一开始	w = 0，错 16	离答案很远
算坡度	−16	往哪边拧能少错
拧一小步	w = 1.6	0 − 0.1 × (−16)
再算一次	错 0.64	一次就少错 25 倍

这就是训练的全部秘密：**算错多少 → 算往哪拧 → 拧一小步 → 再来一次。**

第四幕：41 个旋钮的小脑袋（第 3 格后半）

搭一个小网络：3 个输入 → 4 个 → 4 个 → 1 个输出，共 **41 个旋钮**。给它 4 道题：`[2,3,−1]→+1`、`[3,−1,0.5]→−1`、`[0.5,1,1]→−1`、`[1,1,−1]→+1`。练 200 次，错误从 **1.32** 掉到 **0.0069**；最后四道题的答案 0.95、−0.90、−0.93、0.90，已经很接近 +1、−1、−1、+1。

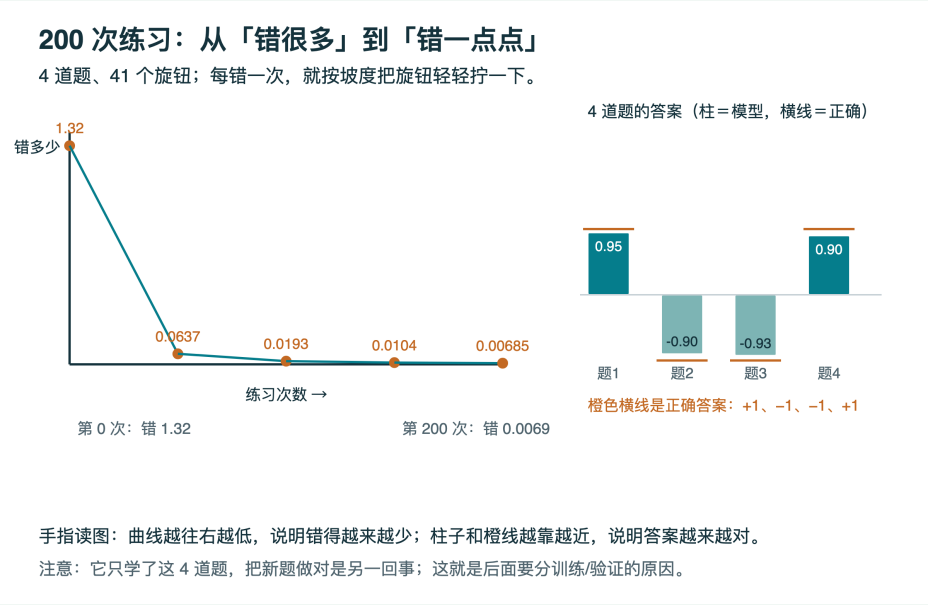

图注：助手绘制的教学示意，2026-11-10；曲线五个点与四道题的预测值均取自本机 notebook 输出。

手指读图： 曲线越往右越低，说明错得越来越少；柱子和橙线越靠越近，说明答案越来越对。

但要记住：它只是把这 4 道题做熟了。 换新题会不会，是另一回事——所以后面要分训练集和验证集。

第五幕：和 PyTorch 对答案（第 4、5 格）

自己写的机器和 PyTorch 算出来几乎一样：d 的三个梯度都是 3、2、1；`tanh(0.7)` 是 0.6043677771 对 0.6043677926；tanh 梯度 0.6347395900 对 0.6347395778；单神经元预测 0.2354957495 对 0.2354957610，loss 0.1328633486 对 0.1328633726。差的那一点点是「小数位不够长」（双精度对单精度），**不是算错**。

把五个词换成人话

你看到的词	人话
导数 / 梯度	滑梯有多陡：挪一点，结果动几倍
反向传播	从结果往回寄「责任信」
loss	错了多少；越小越好
参数 / 权重	可以拧的旋钮
tanh	把任何数压到 −1 到 1 之间的「压扁机」
学习率	每次拧旋钮的幅度

三个自问

- 为什么 h 越小，量出来的坡度越靠近 8?
- `d = a×b + c` 里，为什么 a 收到 3、b 收到 2、c 收到 1?
- 训练一次，为什么要先「清空旧信」再「往回寄」？

☐ 环境与数据已确认，未直接启动长训练。

本步末尾有可直接填写的实验表 T1–T3。

把链式法则落实到代码

设 `z=x*y`。来自下游的梯度是 `z.grad`，则 x 收到 `y.data*z.grad`，y 收到 `x.data*z.grad`。设 `z=x+y`，两个输入都收到 `z.grad`。局部导数只描述当前运算，乘上下游梯度后才是对最终 loss 的影响。

```
# 教学核心片段；位于 Value 运算的 _backward 闭包内
self.grad += other.data * out.grad    # 自己对上游的贡献：另一个数 × 下游梯度
other.grad += self.data * out.grad    # 另一个数同理
```

当 `b=a+a` 时，a 的两条贡献都必须留下；导数应为 2。如果赋值写成 `=`，最后一次调用会抹掉前一次结果。拓扑遍历避免重复执行同一个节点，但不能删除数学上的两条贡献。

`tanh(x)` 的局部导数可写成 `1-tanh(x)**2`。用 exp、加法、除法拆开同一个 tanh 后，应得到相同结果；这说明不同计算图能实现同一函数。有限差分有数值误差，不要求所有 h 的结果完全相等。

真正的训练循环

```
# 教学整理片段：parameters() 来自你自己的网络对象 n
for p in n.parameters():
    p.grad = 0.0                    # 1) 清空上一轮梯度
loss.backward()                     # 2) 反向传播，累加
这一轮的梯度
for p in n.parameters():
    p.data += -0.05 * p.grad        # 3) 沿负梯度更新，
0.05 是学习率
```

学习率 0.05 在此只是演示更新，不是所有任务的推荐值。不要在清梯度后忘记调用 backward，也不要在参数更新后拿旧 loss 冒充新 loss；更新后的结果必须重新前向计算。

课程最后对照 PyTorch 的 tensor 与 micrograd 标量对象，再到官方源码找 tanh 的反传。生产框架以张量为基础，不会真的用 Python 标量节点训练大模型。官方 micrograd 当前使用 ReLU 等实现，与视频临时写的 tanh 版本可能不同，先比数学行为，再比文件是否逐行相同。

- [ ] 保存梯度对照和训练前后 loss，没有只凭计算图截图判断正确。

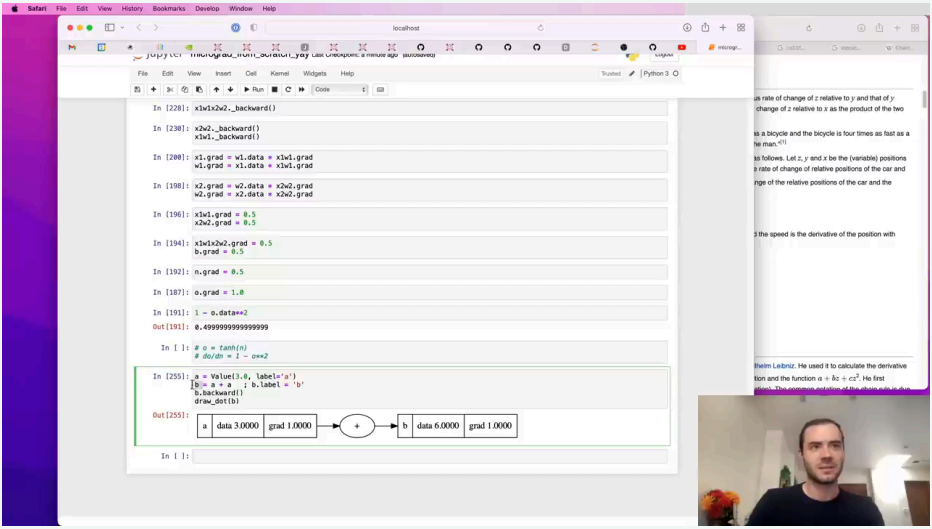

图注：真实课程截图，2026-10-29 提取，第1课 01:23:20；用于对照本节讲解，不替代代码和梯度核验。[O1]

卡住时按这个顺序查

按现象列出先查什么、修好后怎么验。这些路径来自课程故障与代码整理，同一个报错不保证只有一个原因；先定位影响的是数据、数学、状态还是系统性能，再回到上面的操作，不靠同时换五个参数碰运气。

现象	先查什么	修好后怎么验
micrograd 的 a+a 梯度只有 1	局部反传是否累加	a+a 导数 2，a*a 导数 2a

课程里出现过的一个真实案例

案例 1 | 多路径反传

- 起点与做法：a+a 只赋值梯度，改为累加
- 讲者当时的结果：修复单节点多次使用错误
- 可借鉴：最小反例优先
- 出处：第1课 01:22:28 [O1]

这是课程演示，数字不是你在自己机器上的复现结果。

原课练习（官方英文原文）

下面是作者在视频说明里给学习者的练习指令，保留英文原文，不冒充聊天提示词。建议先独立完成，再看对应代码；中文只用于说明它落在本步骤的哪一段。

第 1 课原练习

[O1]

```
you should now be able to complete the following
google collab, good luck!:
https://colab.research.google.com/drive/1FPTx1RXtB
fc4MaTkf7viZZD4U2F9gtKN?usp=sharing
```

中文对照：第 1 课没有列文字练习，作者只给了一个 Colab 链接——现在你应该能完成下面这个 Colab，祝好运。

本步对应的课程章节与时间定位

第 1 课｜The spelled-out intro to neural networks and backpropagation: building micrograd（手把手入门神经网络与反向传播：搭出 micrograd）

英文自动字幕约 24,352 词；逐字稿；主线步骤。

起点	原章节标题	视频定位
00:00:00	intro（开场介绍）	播放
00:00:25	micrograd overview（micrograd 概览）	播放
00:08:08	derivative of a simple function with one input（单输入简单函数的导数）	播放
00:14:12	derivative of a function with multiple inputs（多输入函数的导数）	播放
00:19:09	starting the core Value object of micrograd and its visualization（开始写 micrograd 的核心 Value 对象及其可视化）	播放
00:32:10	manual backpropagation example #1: simple expression（手算反传例 1：简单表达式）	播放
00:51:10	preview of a single optimization step（预览一次优化步骤）	播放
00:52:52	manual backpropagation example #2: a neuron（手算反传例 2：一个神经元）	播放
01:09:02	implementing the backward function for each operation（为每种运算实现 backward）	播放

起点	原章节标题	视频定位
01:17:32	implementing the backward function for a whole expression graph（为整张表达式图实现 backward）	播放
01:22:28	fixing a backprop bug when one node is used multiple times（修一个反传 bug：同一节点被多次使用）	播放
01:27:05	breaking up a tanh, exercising with more operations（拆开 tanh，再练更多运算）	播放
01:39:31	doing the same thing but in PyTorch: comparison（换成 PyTorch 做同样的事并对照）	播放
01:43:55	building out a neural net library (multi-layer perceptron) in micrograd（在 micrograd 里搭神经网络库（多层感知机））	播放
01:51:04	creating a tiny dataset, writing the loss function（造一个小数据集，写损失函数）	播放

起点	原章节标题	视频定位
01:57:56	collecting all of the parameters of the neural net（收集网络的全部参数）	播放
02:01:12	doing gradient descent optimization manually, training the network（手写梯度下降，训练网络）	播放
02:14:03	summary of what we learned, how to go towards modern neural nets（总结：我们学到了什么，怎样走向现代神经网络）	播放
02:16:46	walkthrough of the full code of micrograd on github（通读 GitHub 上 micrograd 的完整代码）	播放
02:21:10	real stuff: diving into PyTorch, finding their backward pass for tanh（实战：进 PyTorch 源码找 tanh 的反传）	播放
02:24:39	conclusion（结语）	播放
02:25:20	outtakes :)（花絮）	播放

我的自学笔记：关于导数、反向传播与下坡的十一个问题

这一段是我自己学步骤 2 时的提问记录：问题是我问的，图和解释是助手按我的要求整理的。留在这里，方便以后回头查。全部用图讲，不写公式。

问 1：「责任信」那张图里，a 收到 3、b 收到 2、c 收到 1，凭什么？

凭的是“倍数”。《Value》那张 d = a×b + c 的图里，乘法那一段的倍数是“旁边那个人”：a 旁边站着 b=3，所以 a 的信是 3；加法不改倍数，所以 c 只拿 1。倍数是量出来的，不是规定的。

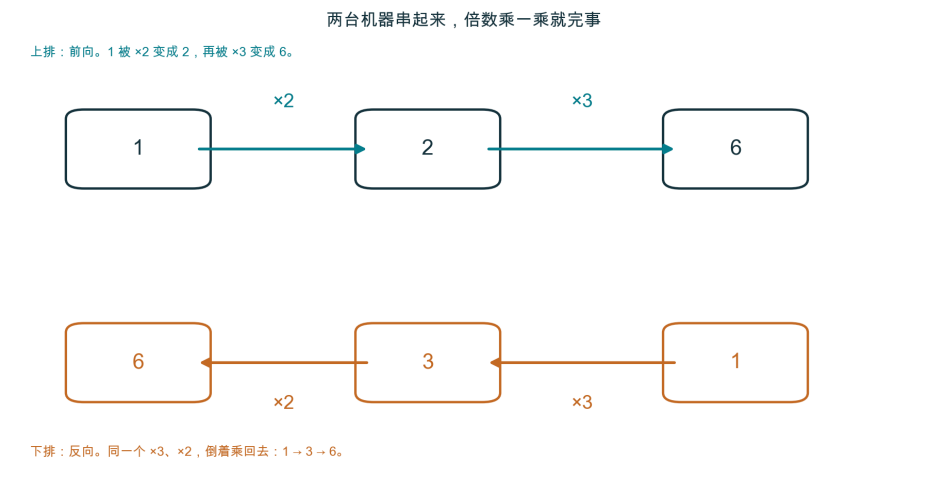

图注：助手绘制的教学示意，2026-11-10；两台机器 ×2 与 ×4 的串联例子，倍数为教学数字。

问 2：为什么要求导数？不算行不行？

不算就只能瞎试。高度（损失）只告诉你“现在多糟”，不告诉你往哪走；坡度才给方向。你要往下走，就必须知道脚下哪边低。

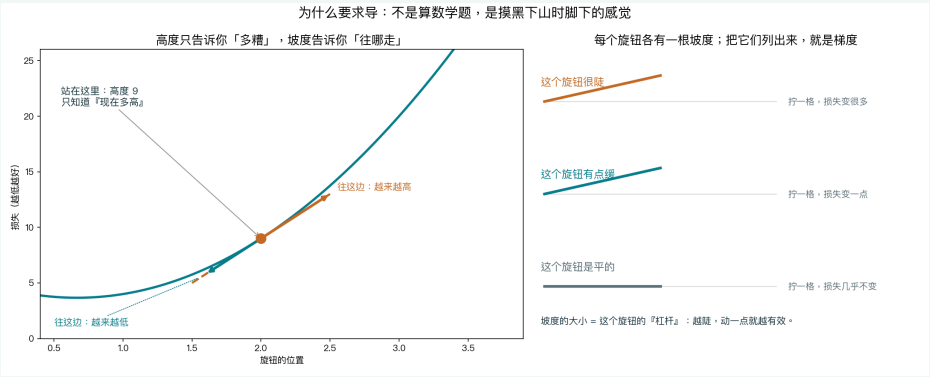

图注：助手绘制的教学示意，2026-11-10；山坡、切线与两个方向；9 与 8 取自 $f(x)=3x^2-4x+5$ 在 $x=2$ 的例子。

问 3：损失越大，是不是下降得越快？

不是。损失是高度，梯度是坡度。高原上损失很大却没有坡，悬崖边损失不大却很陡。每步走多远只看坡度，不看高度。

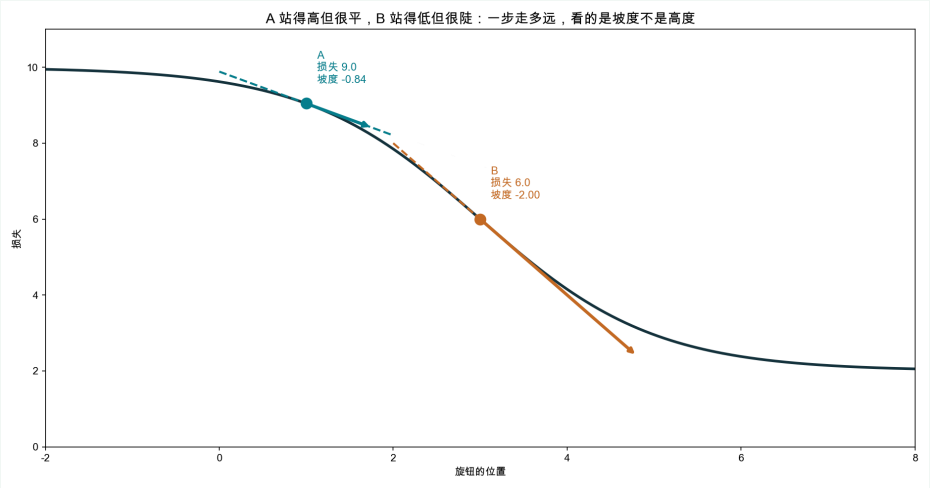

图注：助手绘制的教学示意，2026-11-10；两条切线来自同一函数上的两个位置。

问 4：能不能像线性回归那样理解——人往线上靠？

能理解一半。数据（人）是不动的，动的是线（参数）。训练就是线在平面上挪，直到穿过或贴近那些点；点不会自己走向线。

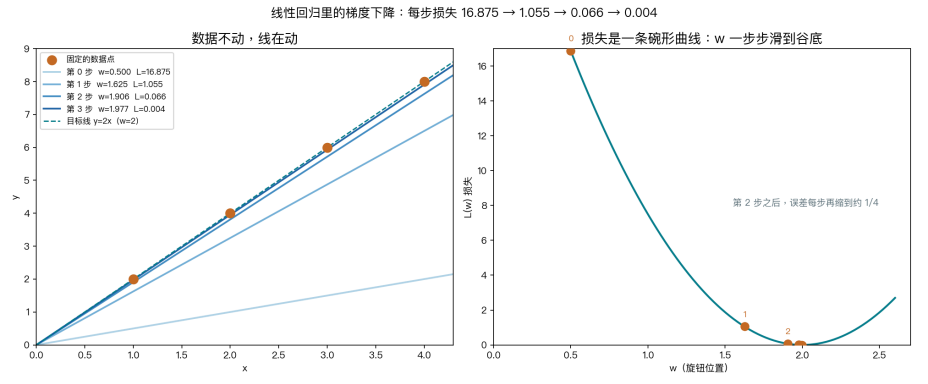

图注：助手绘制的教学示意，2026-11-10；四点取 y=2x，w 从 0.5 走到 2，损失 16.9→0.004。

问 5：回归之外另一种是什么？w、b 又是什么？

另一种是分类：回归预测一个连续的数，分类预测“哪一类”。w 是每个特征的发言权（每多一个，加几分或减几分），b 是底分，决定门槛落在哪。详细解释在步骤 3 开头的「先补一课：分类到底在干什么」。

问 6：一张图里同一个节点，上面写 64、下面写 1，损失怎么从 64 变成 1 了？

没变。上面是“值”（现在的损失 64），下面是“信”（这个节点变 1，损失变几）。信的起点恒等于 1，因为“损失变 1，损失变几”就是 1，和损失多大无关。

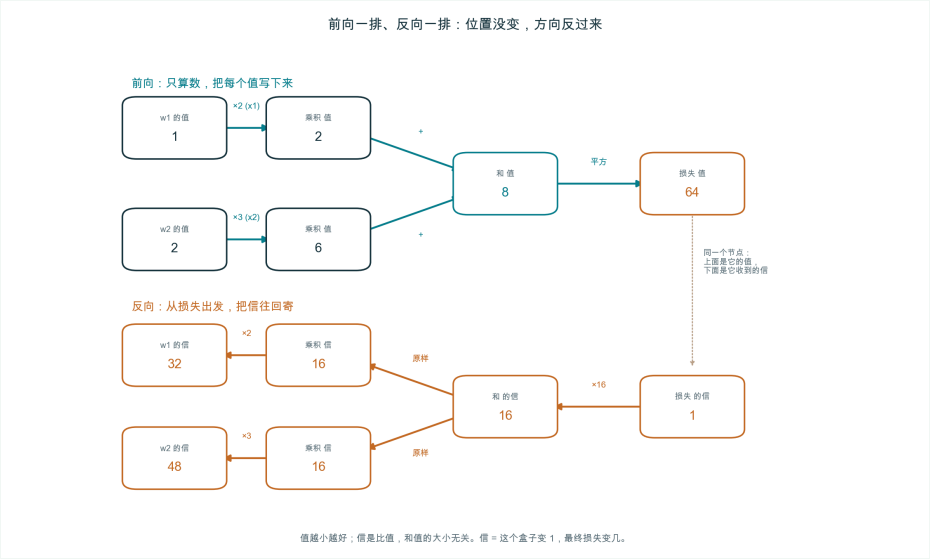

图注：助手绘制的教学示意，2026-11-10；w1=1、w2=2、x1=2、x2=3 的手算例子。

问 7：反向传播为什么要走 41 次测量，不能一次算完吗？

根本不用测 41 次。前向把中间数存下来，反向从损失出发把“信”分给上游每条边，每条边做一次乘法。41 个旋钮就是 41 次乘法，信只算一次。

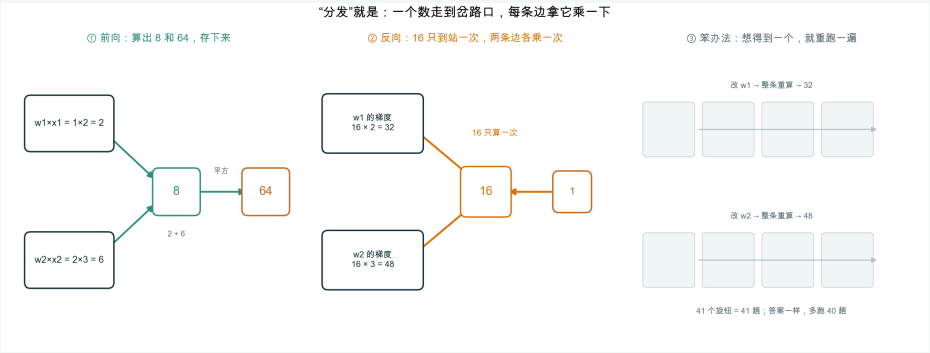

图注：助手绘制的教学示意，2026-11-10；两个旋钮的例子；16 是平方在 8 处的倍数。

代价对比：笨办法 41 个参数要重跑 41 趟；反向传播只要一趟前向加一趟反向。前提是前向时把中间数存下来（显存换时间）。

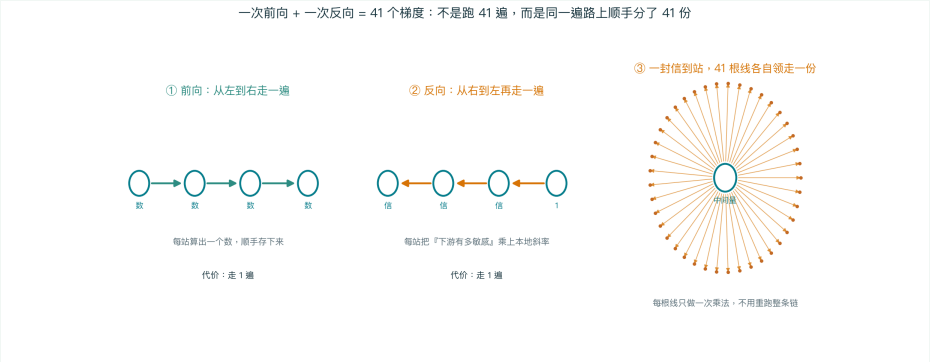

图注：助手绘制的教学示意，2026-11-10；三联画：前向存值、反向传信、到分叉点一次分发；41 为示意数量。

问 8：分发和"下山"怎么接上？

它们是同一个循环的两步：反向负责"量出 41 个坡度"，梯度下降负责"按坡度走一步"。量完就走，走完再量。

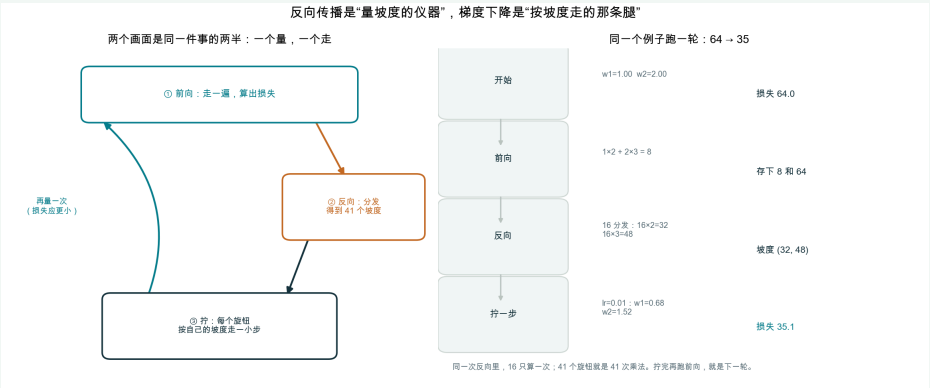

图注：助手绘制的教学示意，2026-11-10；右侧一轮数字：w=(1,2) 起，学习率 0.01，损失 64→35.1。

问 9：反向是不是要“除回去”？从 8 走回 1？

不是。除回去只把输入还原出来（你本来就知道是 1）；乘回去才回答“输入变 1，最后变几”。反向传播做的是后者，所以一路是乘，不是除。

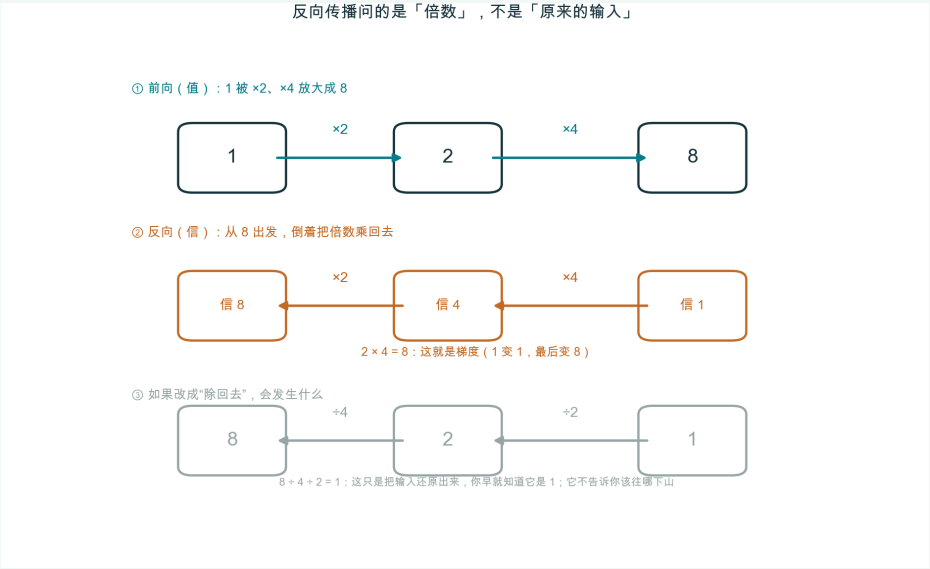

图注：助手绘制的教学示意，2026-11-10；三行分别是前向、反向与除法对照。

问 10：41 维根本感受不到，怎么往下走?

画不出来，但动作一样：量出 41 个数（每个旋钮的坡度），同时拧。左边是 41 维真跑一次：按坡度走损失降到接近 0，随机走则原地打转。

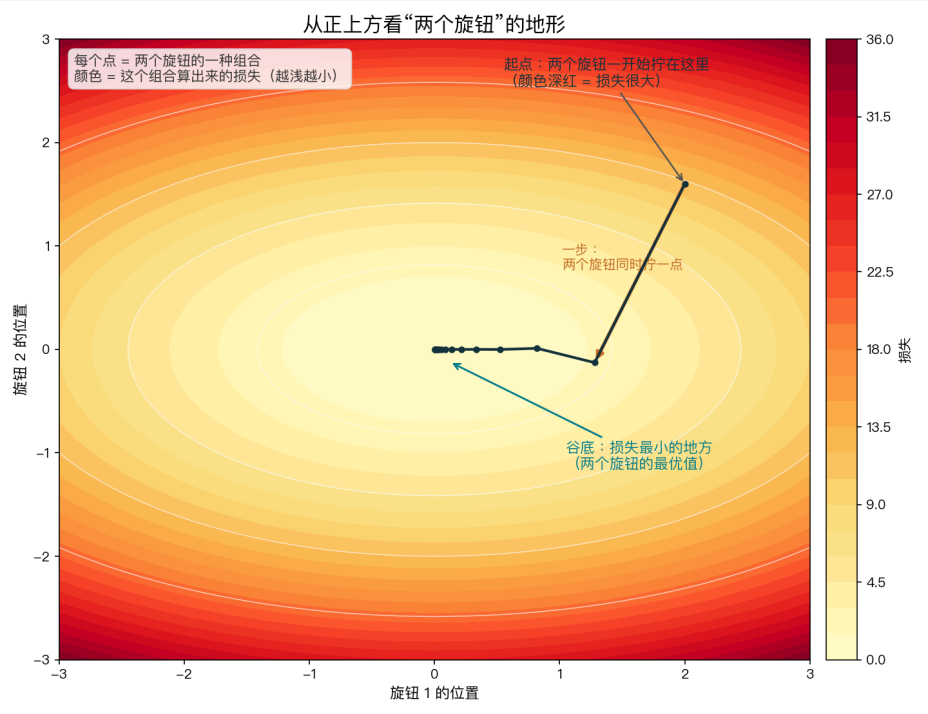

图注：助手绘制的教学示意，2026-11-10；地形为教学用的碗形函数，路径为梯度下降轨迹。

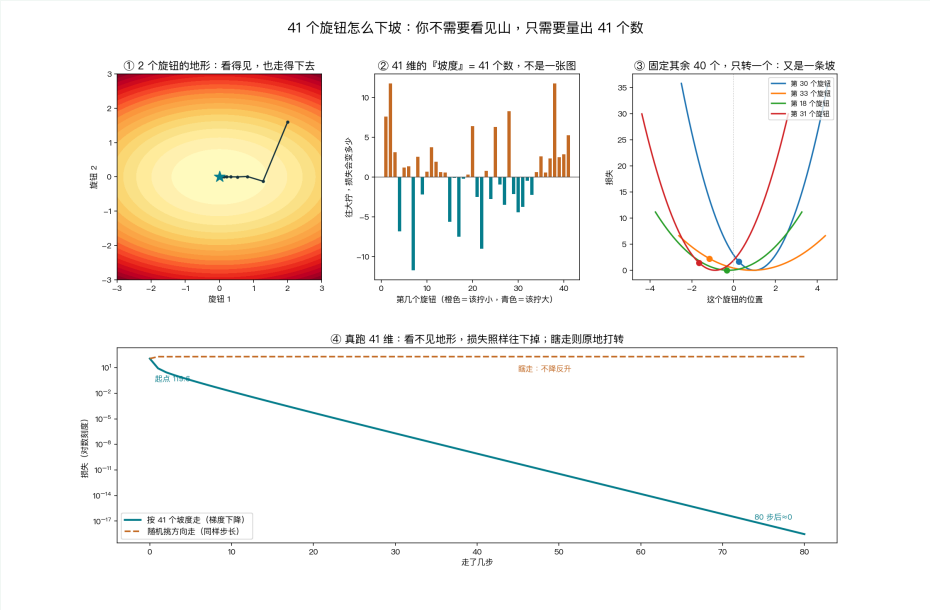

图注：助手绘制的教学示意，2026-11-10；41 维二次函数上的真跑结果；随机对照用同样步长、随机方向。

问 11：步子该多大？怎么判断走对了？

梯度给方向，学习率给每步走多远。损失稳稳下降说明合适；几乎不动说明太小或已经到底；来回跳或越来越大说明太大。判断只看损失，不看梯度大小。

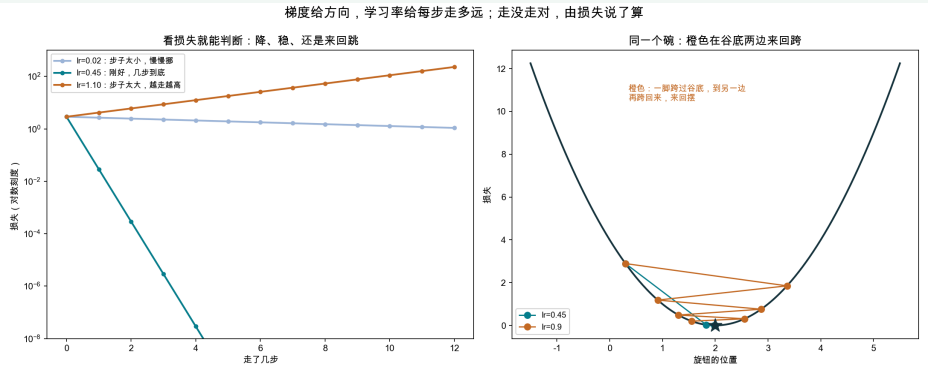

图注：助手绘制的教学示意，2026-11-10；同一个碗形损失上的三条轨迹，学习率取 0.02、0.45、1.10。

步骤 3 用名字数据构建 bigram 语言模型

bigram 只根据前一个字符预测下一个字符。先用计数得到概率，再用一个神经网络学相同的关系，能把“训练、loss、采样”这三个概念连起来。

目标：得到可评估、可采样的字符级基线。

1. 读取 `names.txt`，按行拆名字，建立字符到整数的映射。用同一个 `.` 表示开始/结束，遍历 `'.'+w+'.'` 的相邻字符对。第 2 课 00:03:03–00:24:02。[O2]
2. 在 27×27 计数表 N 中累加 `N[ix1,ix2]`，做平滑后逐行归一化成 P。检查每行之和为 1；先看一行，确认行是当前字符、列是后继字符。[O2]

3. 从索引 0 开始按 `P[ix]` 采样下一个字符，遇到 0 结束；保存 20 个输出。再用真实字符对计算平均负对数似然，不能只凭生成的名字“像不像”判断。定位 00:24:02–01:02:57。[O2]
4. 把每个输入字符做 one-hot，与 27×27 权重 W 相乘得到 logits，softmax 后计算交叉熵，反传并更新 W；比较神经网络与计数法的结果，保留正则化强度。[O2]

> **做完的标准**：概率各行和为 1；能解释 `-log(p)`；计数和神经网络两条路径都能生成名字；训练 loss 与相同数据口径的基线可比较。

先补一课：分类到底在干什么（w、b、概率）

给小朋友讲：判断一封邮件是不是骗子，先给每条线索打分，再把总分翻译成“有多大把握”。这一节没有代码，只把三个零件摆清楚。

只看两件事：`x1` 是“免费”出现几次，`x2` 是链接个数。手写一条第一版规则：

分数 = 1×x1 − 2×x2 + 0.5

`1` 和 `−2` 是 **w（权重）**：每多一次“免费”加 1 分，每多一个链接减 2 分；绝对值越大，这个特征说话越响。`0.5` 是 **b（偏置）**：不随输入变的底分，它决定“门槛”落在哪。代入 `x1=3`、`x2=2`，分数 = 3 − 4 + 0.5 = **−0.5**。

为什么必须有 b：没有它，分界线必须正好穿过原点，等于规定“免费 0 次、链接 0 个”刚好卡在线上。现实的门槛在别处，b 就是用来把整条线平移的。

分数还不是概率：−0.5 分说不清“有几分把握”。sigmoid 把任何分数压成 0–100%：−2 分 → 12%，0 分 → 50%，2 分 → 88%。

为什么不用“大于 0 就判垃圾”：台阶太硬，差一点没反应，也报不出把握；sigmoid 是台阶的软版本，而且处处可导，梯度才传得回去。

答错怎么罚：交叉熵。答对且自信罚得少（p=0.9 → 0.10）；答错还自信罚得狠（p=0.1 → 2.30）。这条规则专门治“嘴硬”。

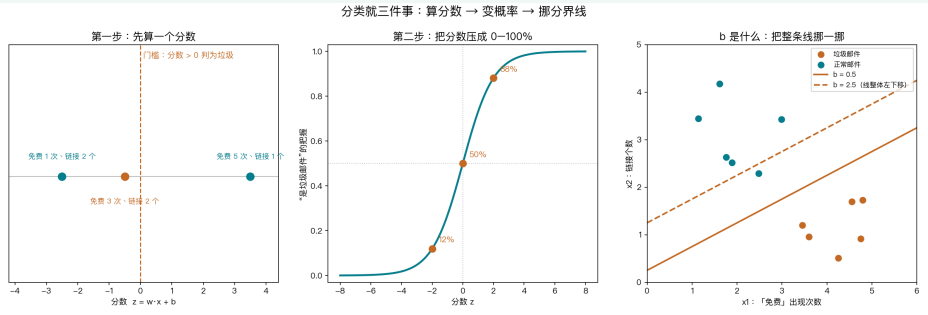

图注：助手绘制的教学示意，2026-11-10；邮件与数字均为手算例子，用来解释分数、sigmoid 与偏置，不冒充课程截图或实测。

Andrew Ng 为什么按这个顺序讲：任何监督学习都只有三个零件——打分公式、罚分规则、拧旋钮的方法。他的课每次只换一个零件：

模型	打分	换成概率	罚分
线性回归	w·x+b	不换，直接当答案	平方误差
逻辑回归	同一个 w·x+b	sigmoid	交叉熵
神经网络	许多个逻辑回归叠起来	最后一层 sigmoid 或 softmax	交叉熵

拧旋钮的方法（梯度下降）从头到尾没变。所以每次只需要理解一个新零件，不会被三样新东西同时砸中。

和 bigram 的关系：27 个候选字符 = 算 27 个分数 → softmax 摊成 27 个百分比 → 交叉熵罚分。邮件是 2 选 1，名字是 27 选 1，是同一件事。

自检三问：

1. 把 b 从 0.5 改成 2.5，分界线往哪边移？更容易判成垃圾，还是更容易判成正常？
2. 分数 −2 和 +2，把握差多少？
3. 模型说“99% 是垃圾”，结果不是，罚多少？（−log 0.01 ≈ 4.6，很重）

白话说明：先做一张“下一个字母接什么”的统计表

假设你只看一个名字的上一个字符，预测下一个字符。你先观察很多真实名字，把每种接法出现的次数记下来，再按比例抽签生成新名字。这就是最简单的字符语言模型。

先打开：学习副本里的 `code/nn-zero-to-hero/lectures/makemore/makemore_part1_bigrams.ipynb`。`names.txt` 应在同一目录。运行代码前把 Notebook 另存为自己的版本。

先把这一步想成一个生活场景

想象你在玩名字接龙。你不知道接下来写什么，就翻一本记录簿："以前看到 m 时，后面通常接什么？"本步先做这本记录簿，再让电脑按记录里的比例抽签。电脑没有理解名字的含义；它只学字符相邻的规律。

怎么读这一节： 先读每个操作前的故事与具体数字，再运行原有代码。代码成功只是程序完成了动作；能回答"停一下"的问题，才说明你知道它在做什么。下面的场景和小数字是助手编写的教学例子。

先把关键词翻成看得见的东西

关键词	白话意思	本步的具体样子
字符	一个字母或符号	emma 中有四个字符
bigram	相邻的两个字符	e 后面接 m
词表	所有允许使用的字符名单	26 个字母加点号，共 27 个
计数矩阵 N	行列交叉的次数表	行是当前字符，列是下一个字符
概率 P	这一行抽签时各选项的份额	一整行加起来等于 1
平滑	给每个选项先放一张基础签	N+1 避免从未出现的接法概率为零
one-hot	只有一个位置亮着的指示牌	指出当前字符是哪一行
logits / softmax	先打分，再变成概率	分数可以为负，概率不能为负

操作 A：只拿一个名字，列出模型看见的题目

场景：把一条项链拆成相邻两颗珠子。 在 emma 两端放点号，就像放“开始”和“结束”两块牌。窗口每次往右移一格，得到五道接龙题。这里不是把名字打乱，也不是列所有字符组合。

你实际做的事： `zip(chars, chars[1:])` 把原列表和右移一位的列表配对。先在纸上圈出 e→m、m→m，再去输出里找它们。

停一下： 为什么四个字母产生五对？因为还要学“怎样开始”和“何时结束”。

在新单元格运行：

```
word = 'emma'                                  # 一个例子名字
chars = ['.'] + list(word) + ['.']             # 前后各加一个点，表示开始与结束
print(list(zip(chars, chars[1:])))             # 两两配对，得到 （左, 右） 的相邻字符对
```

结果是 `('.', 'e'), ('e','m'), ('m','m'), ('m','a'), ('a','.')`。点号是开始/结束标记；`m,m` 是合法重复，不能删。每一对都相当于一道“看到左边，猜右边”的题。

操作 B：把同样的记录方式用到整个文件

场景：每种接法都有一个收票格。 看到 m 后面接 a，就往“m 行、a 列”放一张票；所有名字都看完，再数票。假设某行只允许三种结尾，票数是 2、1、0；各加一后为 3、2、1，除以总数 6，概率变成 1/2、1/3、1/6。这个三选项例子只是为了手算，课程词表是 27 类。

你实际做的事： 第一个索引找行，第二个索引找列；`sum(dim=1, keepdim=True)` 对每一行求和并保留可广播的形状。

停一下： 为什么不是让整张表总和为 1？因为每一个“当前字符”都要有自己的一整套下一字符概率。

```
from pathlib import Path
import torch                                          #
用张量存计数表
words = Path('names.txt').read_text().splitlines()
# 一行一个名字
letters = sorted(set(''.join(words)))                 #
全部出现过的字符，去重并排序
stoi = {ch: i + 1 for i, ch in enumerate(letters)}
# 字符 → 编号（从 1 开始）
stoi['.'] = 0                                         #
点号固定编号 0，表示开始/结束
itos = {i: ch for ch, i in stoi.items()}              #
编号 → 字符，解码时用
V = len(stoi)                                         #
词表大小
N = torch.zeros((V, V), dtype=torch.int64)            #
V×V 的计数表，行是当前字符，列是下一个字符
for word in words:                                    #
遍历每个名字
    seq = ['.'] + list(word) + ['.']                  #
前后补点，变成可切相邻对的序列
    for left, right in zip(seq, seq[1:]):             #
每次取相邻两个字符
        N[stoi[left], stoi[right]] += 1               #
在对应格子里记一票
P = (N + 1).float()                                   #
加一平滑，并把整数转成小数
P = P / P.sum(dim=1, keepdim=True)                    #
```

```
每一行各自归一化，得到概率
print(N.shape, P.sum(dim=1))                    #
打印表的形状与每行的和，检查归一化
```

每行之和应接近 1；行数等于词表大小。看 `P[stoi['m']]` 就是在问“m 后面各种字符的机会有多大”。如果维数正确但行和不对，先检查归一化方向。

操作 C：按表抽签生成一个名字

场景：按袋子里的签抽下一颗珠子。 如果 m 这一袋里 a 的份额大，它容易被抽到，但不是每次一定抽到。抽到 a 后，下一轮换成 a 的袋子；抽到点号就收工。

你实际做的事： `multinomial` 按概率抽编号，`itos` 把编号翻回字符。seed 像固定一次抽签的起始状态，帮助复现；它没有把模型训练得更聪明。

停一下： 为什么同一张概率表可以生成不同名字？因为生成包含抽样，不是永远挑最大概率。

```
g = torch.Generator().manual_seed(42)          # 固
定随机种子，方便复现
ix, output = 0, []                             # 从
点号（编号 0）开始，输出为空
for _ in range(30):                            # 最
多生成 30 个字符
    ix = torch.multinomial(P[ix], 1,
generator=g).item()   # 按当前字符那一行的概率抽下一个
    if ix == 0:                                # 抽
到点号就表示名字结束
        break
    output.append(itos[ix])                    # 把
编号换回字符
print(''.join(output))                         # 拼
成一个名字打印出来
```

30 是助手设置的长度上限，防止异常实现一直生成。随机名字可能古怪；此模型只记得一个字符，输出怪并不自动表示程序错。重复运行并保存20个结果，同时计算真实字符对的平均 `-log(p)`。

操作 D：再用神经网络重做同一件事

场景：先用点票得到答案，再学会调整一块分数板。 统计版直接把次数换成概率；神经网络版把每个格子的分数当作可调数字。one-hot 乘 W，相当于按当前字符取出 W 的一行；softmax 把这行分数变成概率。

具体数字： 正确答案概率是 0.1 时，负对数损失约 2.303；提高到 0.5 时约 0.693。正确答案被分到更多概率，惩罚就更小。

停一下： 这一步在调什么？神经网络版调 W 的分数，不是在改训练名单里的真实名字。

回到课程的 one-hot、权重矩阵 W、softmax 与 loss 单元格。每次先打印中间形状，确认 one-hot 乘 W 实际取出了对应行。这里开始用步骤 2 的“前向—算误差—反传—更新”，训练 W 里的数字。

判断是否完成：你可以从一对字符指到计数表的一个格子，再指到概率表的一个数；能生成名字，也能解释真实答案概率从0.1升到0.5时，损失为什么从约2.303降到0.693。训练集得分和独立验证得分分别记录。

卡住时先找哪一站

看到的现象	先检查什么
所有行加在一起才等于 1	归一化维度错了；应分别检查每行
生成没有停下来	检查点号编号和结束分支；保留长度上限
名字很奇怪	先看概率/损失是否正确；只记一个字符本来就有限

说明与衔接：本段是助手基于本步骤课程与代码整理的动手导读；微型例子只解释相应局部机制。继续按下面原有课程讲解、截图与验收要求完成该步。

空间转化：把步骤 3 摆到一张图里

把概率表画成棋盘：左侧行标签是“现在是谁”，上方列标签是“下一个是谁”。手指先停在 m 行，再横着看这一行的抽签份额。抽到 a 后，把手指移到 a 行，再抽一次。棋盘的上下位置没有字母意义，只是查表地址。

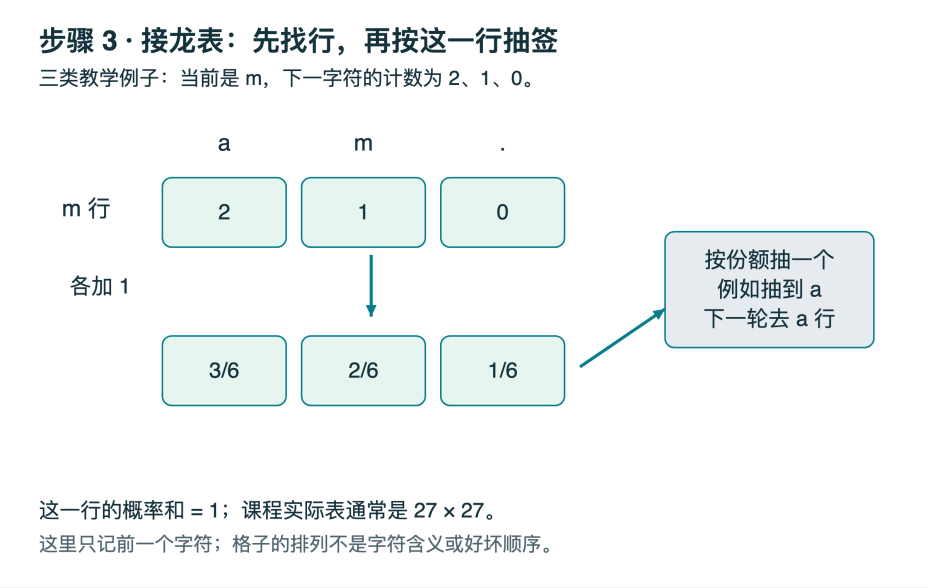

图注：助手绘制的教学示意，2026-11-09；帮助理解本步的计算关系与操作顺序。图中教学数字与简化结构不冒充课程截图、模型实测性能或完整实现。

试着用手指读图： 先指出输入或起点，再沿依赖找到中间处理，最后指出输出或结果记录。停在每一站，说出“这里放的是什么、对它做了什么、什么东西会改变”。如果遇到反向箭头，要说明它传回的是梯度，还是图中另有注明的流程。

再用一句话检查自己： 遮住正文，只看图，解释这一节与上一步相比新增加了什么；然后回到本步的小实验核对。会复述图并不代替实际运行和数值验收。

把 emma 从字符串一路走到概率：两次空间转换

上面那张图画的是“查表—抽签”的关系；这里把同一个过程按数据形状拆开，看清每一步手里拿的到底是什么。下面所有数字都来自 `names.txt` 的 32,033 个名字，是本机现场统计的，不是估的。

第一次转换把字符串变成矩阵。`emma` 不是一颗珠子，而是 `e`、`m`、`m`、`a` 四颗，前后再各加一个点号，一共六颗。查 27 格词表得到编号 `[0, 5, 13, 13, 1, 0]`，形状是 `(6,)`；每个编号再摊成一行 27 位的 one-hot，形状变成 `(6, 27)`。编号本身没有大小含义：m 是 13 号，只表示它放在第 13 格，不代表 m 比 a “大”。

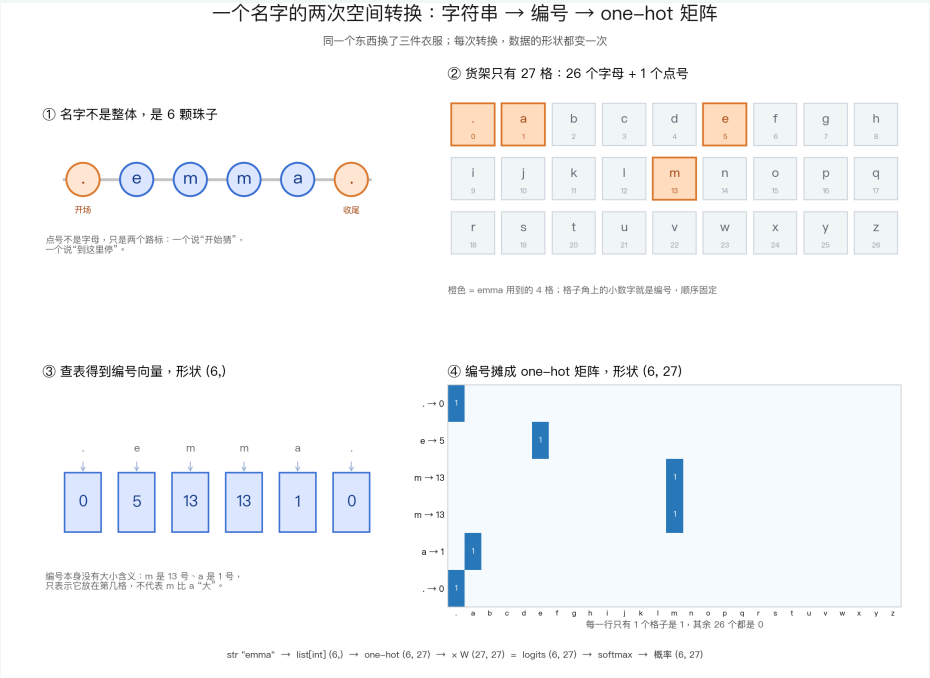

图注：助手绘制的教学示意，2026-11-10；词表、编号与 one-hot 由本机 `names.txt` 现场计算，只说明形状变化，不冒充课程截图。

第二次转换把矩阵变成概率和样本。27×27 的计数表，行是"现在是谁"，列是"下一个是谁"；取出一行、除以这一行总和，就得到下一个字符的概率。点号后面接 e 的概率只有 4.78%，m 后面再接 m 只有 2.53%，`emma` 恰好踩中两个不常见的分支。整个名字的概率是 3.48e-06，取负对数约 12.57，这就是它在 bigram 模型下的"惊讶程度"。

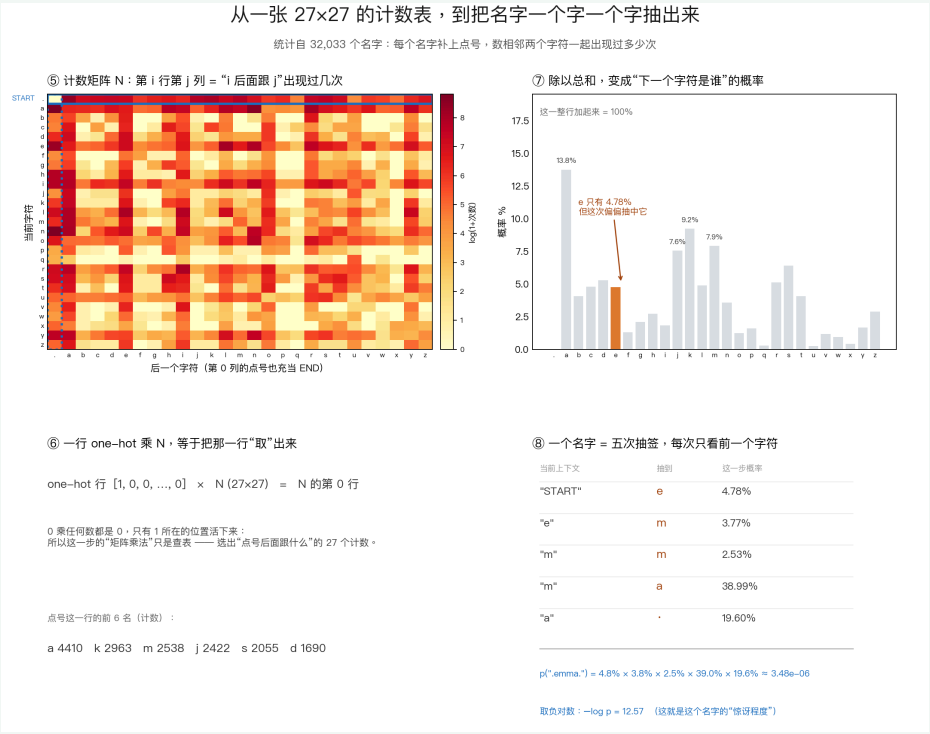

图注：助手绘制的教学示意，2026-11-10；计数、概率与抽样结果均由 `names.txt` 现场统计，数字是真实统计，不是课程截图。

形状账本：每一步只盯形状，就知道自己在哪个空间。

手里拿的东西	形状	含义
名字字符串	1 个	`emma`
加边界后的字符序列	(6,)	`. e m m a .`
编号	(6,)	0、5、13、13、1、0
one-hot	(6, 27)	每行只有一个 1
logits / 概率	(6, 27)	每一行是“下一个字符”的分数或概率
采样结果	1 个字符串	例如 `emma`

读这张账本只需要回答一句：形状从哪来、到哪去，中间那一步做了什么。27 始终是词表大小，6 始终是“名字长度加 2”；两者混在一起时，先分清哪个轴是“位置”、哪个轴是“候选字符”。

最容易错的是广播方向

```
# N 为已累加好的计数矩阵；1 是本实验的加一平滑
P = (N + 1).float()                                  # 每个格子加 1，避免零概率
P = P / P.sum(1, keepdim=True)                       # 按行归一化：每行加起来是 1
assert torch.allclose(P.sum(1), torch.ones(P.shape[0]))   # 断言每行和都为 1
```

`P.sum(1)` 的形状是 `(27,)`，直接相除会按末尾维度广播，可能把本想做的逐行归一化变成按列缩放。`keepdim=True` 保留 `(27,1)` 才能明确逐行除。张量形状正确、程序没有报错，都不足以证明数学意思正确。

损失和零概率

单个真实下一个字符概率为 p，损失是 `-log(p)`；整批取平均。概率越接近 1 损失越小，p=0 会得到无穷大。加一平滑让未见过的字符对也有非零概率，但会改变原来概率的分配；平滑强度是取舍，不是“永远加一就最好”。

神经网络的 one-hot 输入乘 W，等价于取出 W 对应行。后续 embedding 的查表并不是全新魔法，而是相同索引思想的更紧凑实现。`W**2` 的惩罚会把 logits 拉向较平缓分布，与计数平滑的效果相似，但两者不等同于同一个算法。

采样时保留实验条件

同一个模型用不同随机种子会给不同名字。比较改动时固定采样数量、种子和最大长度；最大长度是防止自己的错误实现无限循环的助手建议。输出十个好名字并不能说明全体分布改善。

- [ ] 保存计数表、概率检查、模型参数和 20 个原始样本。

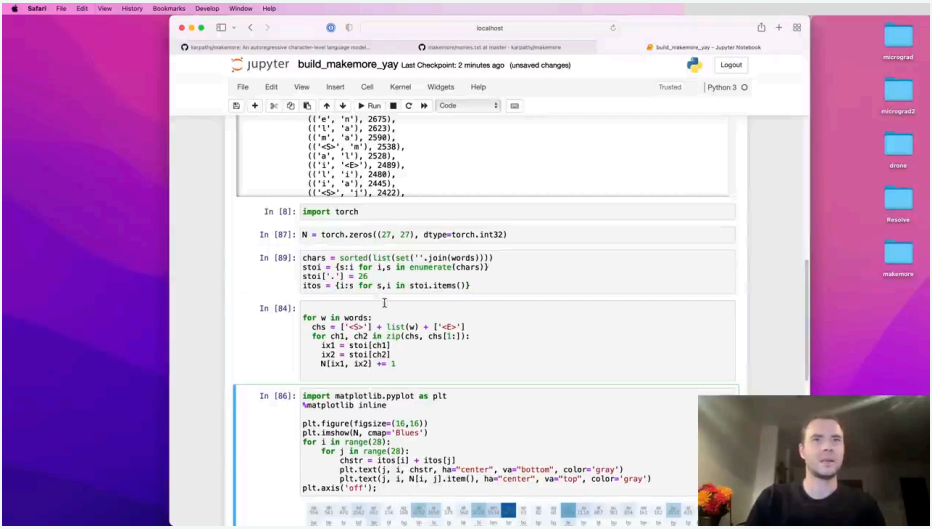

图注：真实课程截图，2026-10-29 提取，第2课 00:22:30；用于对照本节讲解，不替代代码和梯度核验。[O2]

步骤 4 从字符窗口训练 MLP

前一节只记住一个字符的后继。MLP 将多个历史字符映射成向量，再一起预测下一个字符；这里开始需要真正区分训练表现和对新数据的表现。

目标：实现固定上下文的 MLP，建立独立验证流程。

1. 在 `makemore_part2_mlp.ipynb` 中先只取少数名字，`block_size=3`。每个名字前补三个 0，每产生一个目标字符就把窗口左移一位；确认 X 是 `(N,3)`，Y 是 `(N,)`。定位第 3 课 00:09:03。[O3、O10]

2. 建 embedding 表 C，先用 2 维便于观察。`C[X]` 得到 `(N,3,2)`，拼成 `(N,6)` 后接隐层、tanh 和输出层，输出 27 个 logits。逐层写出形状。[O3]
3. 先在一个固定小批次上反复训练，确认 loss 可以明显降下去；再用随机 minibatch 训练全集。每轮清梯度后再 backward，更新后重新前向。学习率从小范围试起，观察太小、适中与发散三种情况。[O3]
4. 按名字打乱后分 80%/10%/10%，再分别展开字符窗口。训练集调参数，验证集选配置，测试集留到最后；增加隐层或 embedding 后只比较相同切分下的验证 loss。[O3]

> **做完的标准**：能打印每层形状；能降低固定批次 loss；能在未参与更新的名字上计算验证 loss；生成 20 个名字并登记全部参数。

白话说明：让模型同时看前三个字母，再决定接什么

上一步只看一个字母，能利用的信息太少。这里让三个历史字符共同参与预测。embedding 是给字符配一组可调整的数字；MLP 把三组数字混合后给下一个字符打分。

先打开：`code/nn-zero-to-hero/lectures/makemore/makemore_part2_mlp.ipynb`。继续使用同目录 `names.txt`。

先把这一步想成一个生活场景

上一步像只听到一个字就猜下一字。现在给机器一张能看见前三个字符的观察卡。每个字符先换成一张数字名牌，再把三张名牌交给一个小网络一起判断。名牌不是人工写好的“元音”“辅音”标签，而是会随训练改变的数字。

怎么读这一节： 先读每个操作前的故事与具体数字，再运行原有代码。代码成功只是程序完成了动作；能回答“停一下”的问题，才说明你知道它在做什么。下面的场景和小数字是助手编写的教学例子。

先把关键词翻成看得见的东西

关键词	白话意思	本步的具体样子
上下文窗口	每次允许看的历史范围	本练习看前三个字符
embedding C	字符编号到数字名牌的查找表	27 行，每行 D 个可调数字
维度 D	一张名牌上写几个数	D=2 就写两个数
batch / B	同时处理几张练习卡	B=4 表示四条样本
reshape / 拼接	把名牌排成一长条	3 张两格名牌变成 6 格
隐藏层 H	中间加工后的数字个数	示例每条变成 100 个数
验证集	不参与参数更新的新练习卡	用来选配置

操作 A：手工展开 emma，先检查输入和答案是否错位

场景：拿一块能露出三个位置的纸板，沿名字滑动。 开头没有历史，就用三个点号补齐；看到 ... 猜 e，看到 ..e 猜 m。正确答案永远在窗口的后面，不能先放到输入里。

你实际做的事： X 保存观察卡，Y 保存背面的答案。先把前五行编号翻成字符，确认纸板位置。只看形状相同无法发现答案错位。

停一下： 输入 emm 时，为什么答案是 a，而不是最后那个 m？因为任务是猜还没看到的下一个字符。

```
输入 ...，答案 e
输入 ..e，答案 m
输入 .em，答案 m
输入 emm，答案 a
输入 mma，答案 .
```

点号编码为0。构建数据后打印前五行 X 和 Y，并把整数翻回字符核对。不要只看形状；X 与 Y 错位一格，模型也能运行，但它学的是错误任务。

操作 B：运行一个只看形状的小实验

场景：每个字母取一张两格名牌。 假设 e 的名牌是 [0.2,-0.1]，m 的是 [0.7,0.4]，那么 emm 查表后得到三张名牌，再排成 [0.2,-0.1,0.7,0.4,0.7,0.4]。这些数字是教学假设，正负数本身不代表好坏。

你实际做的事： `(4,3,2)` 读成“四张卡、每张三个字符、每个字符两个数”；`(4,6)` 是每张卡合并成六个数。最后 `(4,27)` 是每张卡对 27 种下一字符分别打分。

停一下： reshape 有没有学到新知识？没有，它只是重新排格子；参数更新才会改变名牌和加工规则。

下面数值仅用于展示接口，不是训练好的字符表示。

```
import torch
N, D, H, V = 4, 2, 100, 27          # 批大小 4、嵌入
2 维、隐层 100、词表 27
Xb = torch.randint(V, (N, 3))       # 4 条样本，每条
3 个字符编号
C = torch.randn(V, D)               # 27×2 的字符嵌
入表
emb = C[Xb]                         # 查表：得到
(4,3,2)
flat = emb.reshape(N, 3 * D)        # 3 个字符拼成 6
维 (4,6)
W1 = torch.randn(3 * D, H)          # 第一层权重
(6,100)
b1 = torch.zeros(H)                 # 第一层偏置
(100)
W2 = torch.randn(H, V)              # 输出层权重
(100,27)
b2 = torch.zeros(V)                 # 输出层偏置
(27)
h = torch.tanh(flat @ W1 + b1)      # 隐层：线性 +
tanh
logits = h @ W2 + b2                # 输出 27 个分
数，还没归一化
print(emb.shape, flat.shape, h.shape,
logits.shape)   # 打印四步的形状
```

应依次看到 `(4,3,2)`、`(4,6)`、`(4,100)`、`(4,27)`。这段随机初始化只用来观察维度；正式训练用课程的可求导参数与初始化方式。

操作 C：只训练同一小批，确认网络真的会改变

场景：先让学生反复做同一小叠题，检查笔和答案本能不能用。 固定 32 个样本，只是一个排错实验。若连这叠题都很难降低误差，先检查梯度和更新链路，再谈大数据效果。

你实际做的事： 抽样语句放在循环外，确保每轮确实是同一批。记录第一轮和后续 loss，而不只是看程序有没有报错。中间张量默认不一定保留 `.grad`，`retain_grad()` 是请框架留下这份检查记录。

停一下： 记住 32 道练习题是否等于会做新题？不等于，所以还要下一步。

在课程笔记本初始化参数后，固定抽取32个样本，把 `Xb/Yb` 放在训练循环外面。先做几百次更新，记录前后 loss；每轮都清参数梯度、重新前向、backward、更新。若需要获取非叶子中间张量的 `.grad`，先调用它的 `retain_grad()`。

怎么看：loss 应有明显下降趋势。若没有，先看参数是否 `requires_grad=True`、学习率是否非零、更新是否真的作用于本次前向使用的参数，再考虑模型太小。

操作 D：换成完整学习任务

场景：先按整本作业分练习册和考试册，再拆成小题。 先分名字、后展开窗口，是为了避免同一个名字的相似窗口同时进入训练和验证。之后每轮从训练册抽一小批，验证册只负责打分。

你实际做的事： 一次只改一个设置，并保留同一切分。训练分数下降而验证分数上升，可能是在更用力记住旧题，不能直接宣布模型更好。

停一下： 增加 H 后分数变好，是否一定因为 H？只有其他条件基本一致，比较才有解释力。

按名字分出训练、验证、测试集，然后分别展开窗口。将随机抽取 minibatch 的语句放回循环内，训练集用于更新，验证集用于比较配置。一次只改 D、H、学习率或上下文长度中的一项，保存两条 loss 曲线。

别混淆两种成功：固定小批次能记住，只证明计算链路有效；没见过的名字上 loss 改善，才开始体现泛化。做完保留数据切分、形状打印、固定批次结果和独立验证结果。

卡住时先找哪一站

看到的现象	先检查什么
维度对但 loss 异常	把编号翻回字符，先检查 X/Y 配对
固定小批 loss 不变	检查 requires_grad、清梯度与参数更新
训练好、验证差	检查数据切分与过拟合，不只继续加宽网络

说明与衔接：本段是助手基于本步骤课程与代码整理的动手导读；微型例子只解释相应局部机制。继续按下面原有课程讲解、截图与验收要求完成该步。

空间转化：把步骤 4 摆到一张图里

从左往右看：三个编号各到同一张 C 表取一行；三行数字横着拼成一条；隐藏层把它加工成 H 个数；末端给 V 种字符打分。每张样本都有自己的这一条流水线，但共享 C 和权重。二维名牌图只是教学例子，不能把某一坐标擅自命名为“性别”或“含义”。

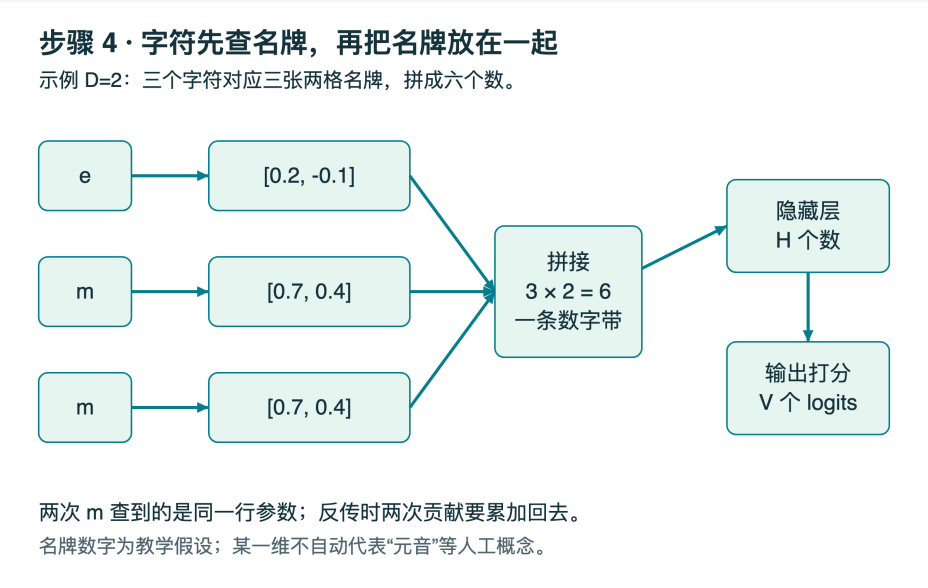

图注：助手绘制的教学示意，2026-11-09；帮助理解本步的计算关系与操作顺序。图中教学数字与简化结构不冒充课程截图、模型实测性能或完整实现。

试着用手指读图： 先指出输入或起点，再沿依赖找到中间处理，最后指出输出或结果记录。停在每一站，说出“这里放的是什么、对它做了什么、什么东西会改变”。如果遇到反向箭头，要说明它传回的是梯度，还是图中另有注明的流程。

再用一句话检查自己： 遮住正文，只看图，解释这一节与上一步相比新增加了什么；然后回到本步的小实验核对。会复述图并不代替实际运行和数值验收。

形状阶梯：从 3 个编号走到 27 个分数

这张阶梯把四个形状并排放在一起：批维 4 一直在最外层，位置轴从 3 压成 1，特征轴从 2 涨到 100，最后落到 27 个分数。走到哪一格，都能回答“这一格里有多少个数、哪个轴刚变过”。

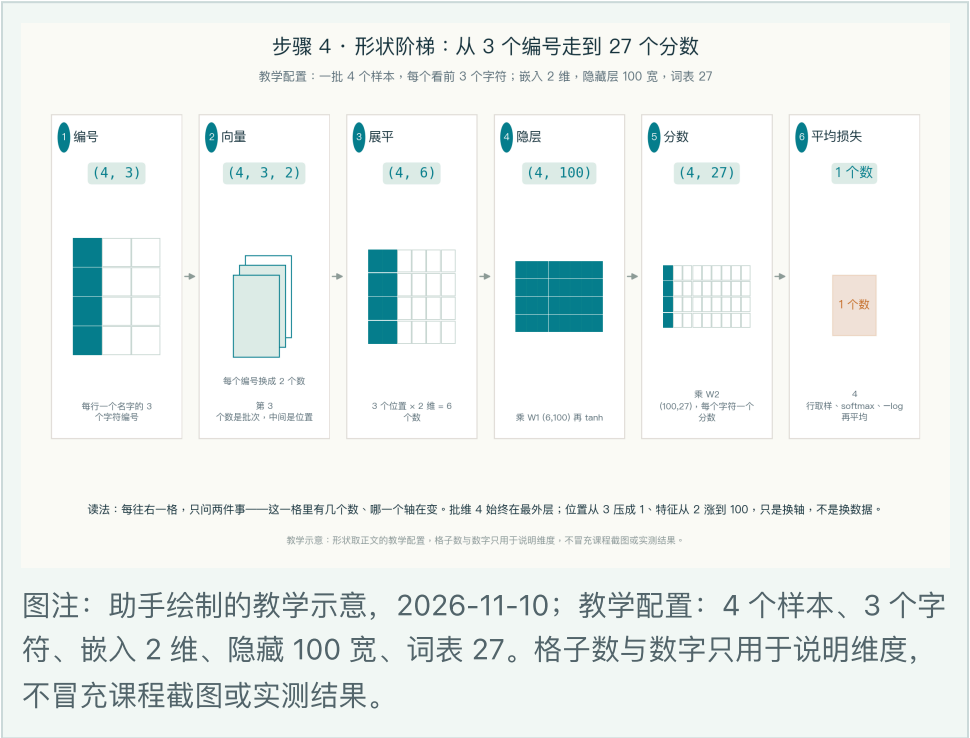

图注：助手绘制的教学示意，2026-11-10；教学配置：4 个样本、3 个字符、嵌入 2 维、隐藏 100 宽、词表 27。格子数与数字只用于说明维度，不冒充课程截图或实测结果。

检查点：把 (4, 6) 读成“4 个样本各 6 个数”，不是“6 个样本”。

一次前向应当长什么样

```
# C: (27, D), W1: (3*D, H), b1: (H,), W2: (H, 27),
b2: (27,)
emb = C[Xb]
# 查嵌入表
h = torch.tanh(emb.view(emb.shape[0], -1) @ W1 +
b1) # 展平成一行再做线性+tanh
logits = h @ W2 + b2
# 输出层分数
loss = F.cross_entropy(logits, Yb)
# 交叉熵：把分数和正确答案比
```

`view` 改的是解释数据形状的方式，通常复用底层存储，不等于复制每个数。reshape 前后元素数必须一样；之后遇到 transpose 导致非连续内存时，不要机械套用 view，可先检查 stride 或 contiguous。

`F.cross_entropy` 接收未归一化的 logits，内部以稳定方式组合 log-softmax 和 NLL。若先手写 `exp()`，很大的 logits 会溢出；先减每行最大值不改变 softmax 概率。正式训练用稳定函数；手工展开留给理解与梯度练习。

为什么先过拟合一个批次

它检查模型、loss、梯度和更新路径是否连通。固定几十个例子都记不住时，直接扩大数据会让问题更难定位。它通过以后才能换到新批次和独立验证集；这个诊断通过不能当作模型泛化证据。

调参顺序与比较边界

课程逐步尝试了更大的隐层、10 维 embedding、约 200000 步训练，并在前后阶段使用 0.1 与 0.01 学习率；讲者报告验证 loss 约 2.17。这些是课程当时的实验设置与结果，短跑、不同 seed、不同版本不应强行对齐最后一位。

先固定切分、batch size 和训练预算，只改一项：embedding 维数、隐层宽度、上下文长度或学习率。绘制训练与验证曲线；训练改善而验证变差提示过拟合。不要不停看测试集来选最好一次。

生成时从全 0 上下文开始，经 C 查表、隐层、softmax 后采样，再滚动窗口。二维 embedding 可画散点观察字符关系；十维 embedding 不能再直接拿前两个数当作完整语义图。

- [ ] 比较表包含 train/val，测试集没有用于选超参数。

参见步骤 1 的实验表 T1。

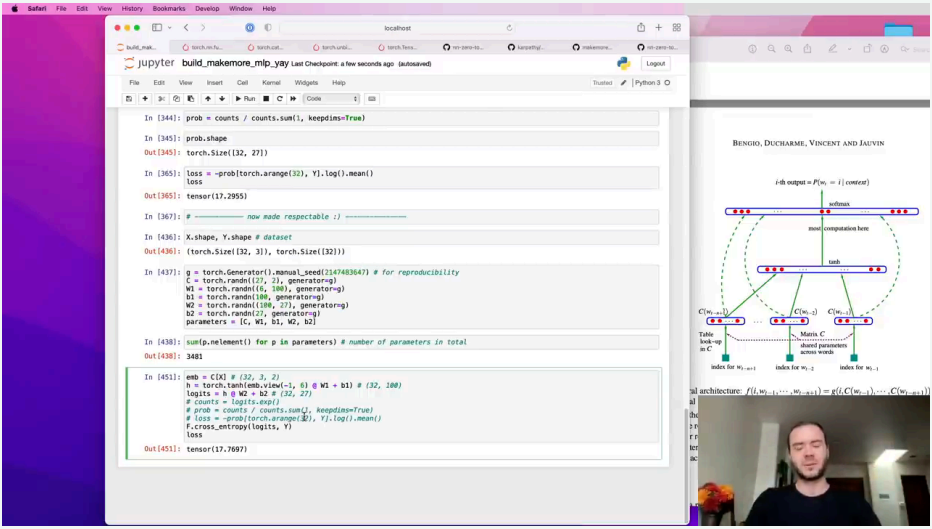

图注：真实课程截图，2026-10-29 提取，第3课 00:34:10；用于对照本节讲解，不替代代码和梯度核验。[O3]

卡住时按这个顺序查

按现象列出先查什么、修好后怎么验。这些路径来自课程故障与代码整理，同一个报错不保证只有一个原因；先定位影响的是数据、数学、状态还是系统性能，再回到上面的操作，不靠同时换五个参数碰运气。

现象	先查什么	修好后怎么验
loss 一开始几十甚至无穷	logits 尺度、零概率、手写 exp 溢出	均匀基线与稳定 CE

课程里出现过的一个真实案例

案例 3 | MLP 增容

- 起点与做法：改 hidden/embedding 与学习率
- 讲者当时的结果：讲者验证 loss 约2.17
- 可借鉴：看验证而非只看训练
- 出处：第3课 01:11:46 [O3]

这是课程演示，数字不是你在自己机器上的复现结果。

原课练习（官方英文原文）

下面是作者在视频说明里给学习者的练习指令，保留英文原文，不冒充聊天提示词。建议先独立完成，再看对应代码；中文只用于说明它落在本步骤的哪一段。

第 3 课原练习

[O3]

```
- E01: Tune the hyperparameters of the training to
beat my best validation loss of 2.2
- E02: I was not careful with the intialization of
the network in this video. (1) What is the loss
you'd get if the predicted probabilities at
initialization were perfectly uniform? What loss
do we achieve? (2) Can you tune the initialization
to get a starting loss that is much more similar
to (1)?
- E03: Read the Bengio et al 2003 paper (link
above), implement and try any idea from the paper.
Did it work?
```

中文对照

- E01：调训练超参数，超过我（讲者）最好的验证 loss 2.2。
- E02：这个视频里我没仔细处理初始化。(1) 如果初始化时预测概率完全均匀，会得到多少 loss？我们实际是多少？(2) 你能调初始化，让起始 loss 更接近 (1) 吗？
- E03：读 Bengio 等 2003 年的论文（链接见上），实现并尝试论文里任意一个想法。有用吗？

本步对应的课程章节与时间定位

第 3 课 | Building makemore Part 2: MLP（搭 makemore 第 2 部分：多层感知机）

英文自动字幕约 12,731 词；逐字稿；主线步骤。

起点	原章节标题	视频定位
00:00:00	intro（开场介绍）	播放
00:01:48	Bengio et al. 2003 (MLP language model) paper walkthrough（通读 Bengio 等 2003 年 MLP 语言模型论文）	播放
00:09:03	(re-)building our training dataset（重建训练数据集）	播放
00:12:19	implementing the embedding lookup table（实现嵌入查表）	播放
00:18:35	implementing the hidden layer + internals of torch.Tensor: storage, views（实现隐层，并讲 torch.Tensor 内部：存储与视图）	播放
00:29:15	implementing the output layer（实现输出层）	播放
00:29:53	implementing the negative log likelihood loss（实现负对数似然损失）	播放
00:32:17	summary of the full network（整个网络小结）	播放

起点	原章节标题	视频定位
00:32:49	introducing F.cross_entropy and why（介绍 F.cross_entropy 及为什么用它）	播放
00:37:56	implementing the training loop, overfitting one batch（写训练循环：先过拟合一个批次）	播放
00:41:25	training on the full dataset, minibatches（在全量数据上训练，用小批次）	播放
00:45:40	finding a good initial learning rate（寻找合适的初始学习率）	播放
00:53:20	splitting up the dataset into train/val/test splits and why（划分训练/验证/测试集，以及为什么）	播放
01:00:49	experiment: larger hidden layer（实验：加大隐层）	播放
01:05:27	visualizing the character embeddings（把字符嵌入可视化）	播放
01:07:16	experiment: larger embedding size（实验：加大嵌入维度）	播放

起点	原章节标题	视频定位
01:11:46	summary of our final code, conclusion（最终代码小结与结语）	播放
01:13:24	sampling from the model（从模型里采样）	播放
01:14:55	google collab (new!!) notebook advertisement（Colab 笔记本广告（新））	播放

步骤 4–5 问答记录：把这几页真正读懂

> 2026-11-11 围绕步骤 4 的一轮问答整理，按问题归类。图都是当场为了解释而画的示意图，不是课程截图；图里的数字来自本次实跑（seed 42、block 3、D=2、H=100、1200 步），loss 与 notebook 打印的 2.863 / 2.861 / 2.865 一致。

一、这一步到底在干什么

一句话：**给最近 3 个字符，给 27 个候选各打一个分数；训练就是调这 3,481 个数字，让正确答案的分数变高。**代码里的 `forward` 就是这条流水线，一共五站。

站	形状	在干什么	一句话
① 输入	`(N,3)`	3 个字符换成 3 个编号	编号只是座位号，`e=5`、`m=13` 没有大小含义
② 查表	`(N,3,2)`	每个编号去 C 表取一行	表是 27×2、可训练；两个 `m` 取到完全一样的数字
③ 拼接	`(N,6)`	3 组坐标横着排成一条	顺序是信息，所以并排而不是相加
④ 隐层	`(N,100)`	6 个数变 100 个数，过 tanh	100 个“加权提问”，每个单元一种问法
⑤ 输出	`(N,27)`	100 个数变 27 个分数	还不是概率，softmax 之后才是

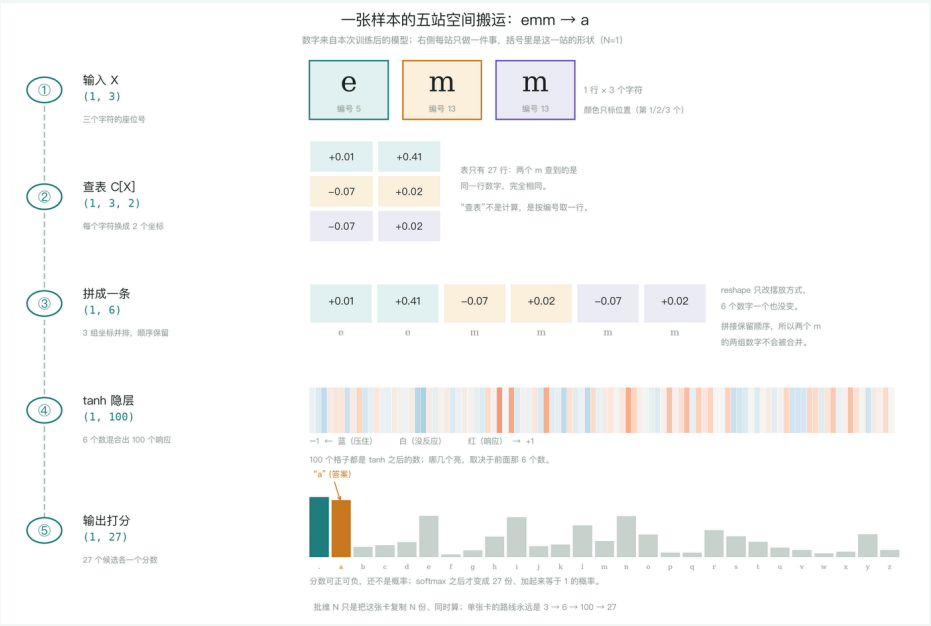

图注：用本次实跑的数字走一遍 `emm → a`。每站只做一件事，括号里是这一站的形状（N=1）。

三个最容易误读的地方：

1. **train 和 dev 两条线重合，不是好消息。**1200 步 × 32 条 = 38,400 次看题，而训练集有 182,625 道题，平均每道题只看了 0.21 遍。这叫欠拟合，不是泛化好。
2. **固定 32 条能压到 0.86，只证明“管线通了”。**那是前向、反向、更新连起来的自检。
3. **`N` 不是模型的一部分。**`(4,3)` 与 `(182625,3)` 只是同时算几张卡。

参数量 3,481 = 54（C 表）+ 600（W1）+ 100（b1）+ 2,700（W2）+ 27（b2）。

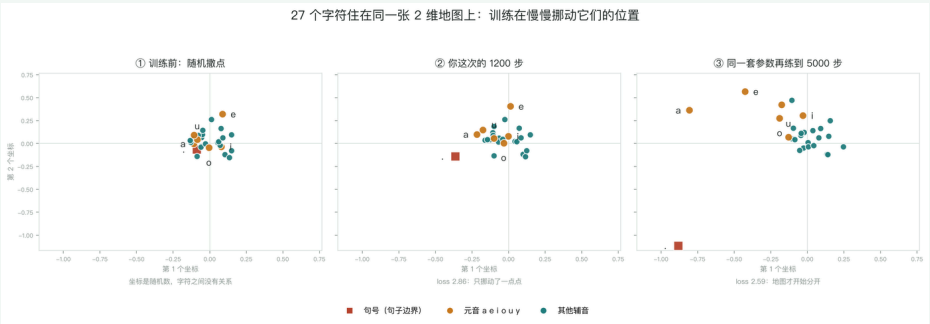

图注：D=2 是唯一能直接画出来的情况。1200 步只挪动了一点；练到 5000 步（loss 2.59）才明显分开。

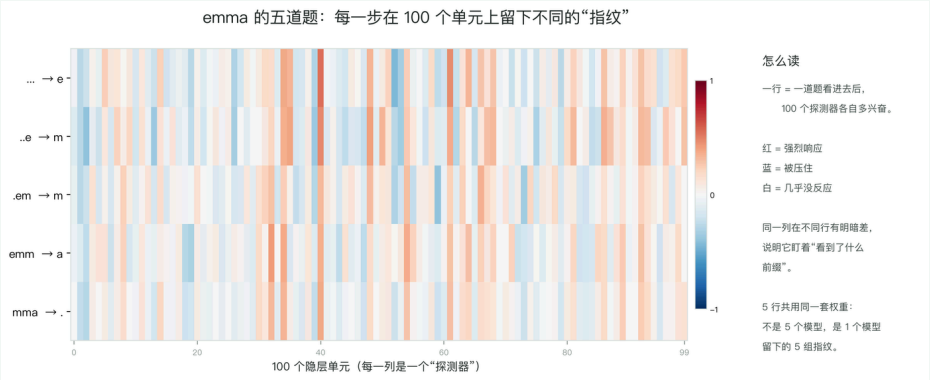

图注：同一列在不同行亮度不同，说明这些单元对“前缀”敏感，而不是只看最后一个字符。

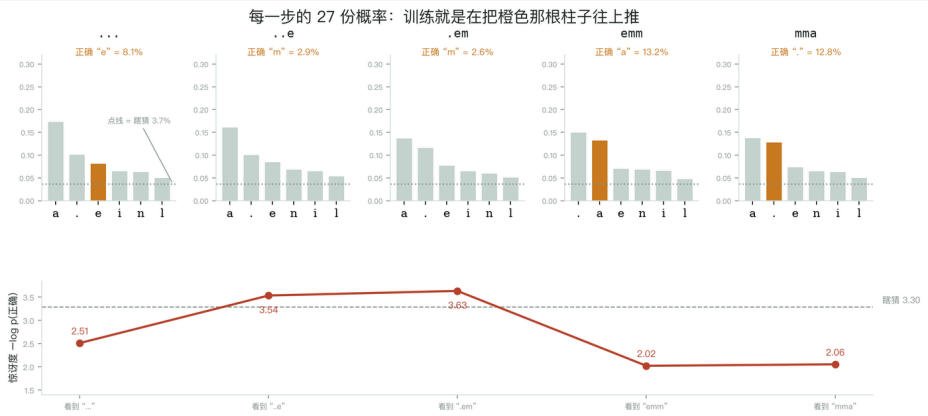

图注：`..e → m` 与 `.em → m` 的惊讶度 3.54、3.63 比瞎猜的 3.30 还差——平均降了，不代表每步都好。

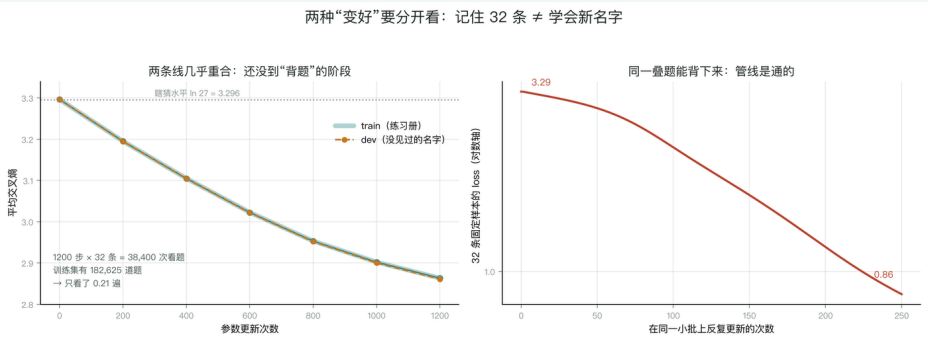

图注：左图是全集 train/dev，右图是 32 条固定样本的自检。

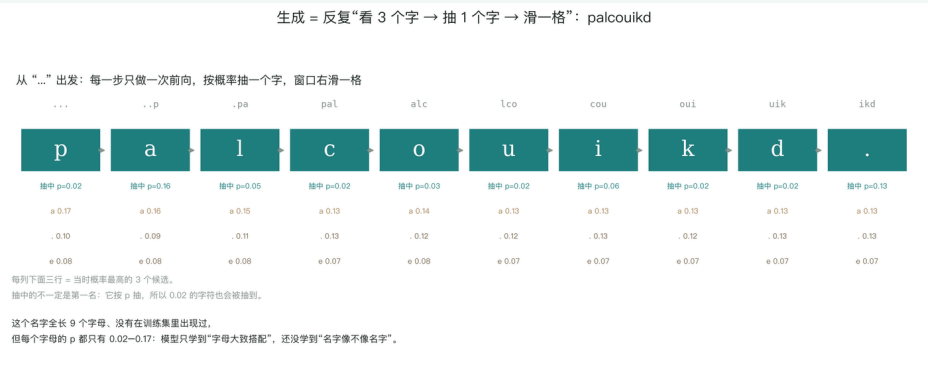

图注：看 3 个字 → 按概率抽 1 个 → 滑一格，抽到句号就停。每步概率只有 0.02–0.17。

二、loss 曲线、下山与盆底

为什么看曲线？ 因为曲线是唯一能看见“过程”的窗口：平着不降（学习率太小）、剧烈抖动（太大）、突然掉一截（衰减）、train 降而 dev 升（背题）。只看终点，这些信息全丢。

为什么像下山、为什么是盆底？ 没有解析解，只能迭代；而任何光滑函数在极小点附近都能写成二次型，开口向上就是碗——这是泰勒展开的必然。

为什么越小越好？ 这是记账方向：把“错”记成正数（`-log p`），所以越少越好。反过来记“对”也对，图会翻转。但最小值不是 0，而是数据本身的熵。

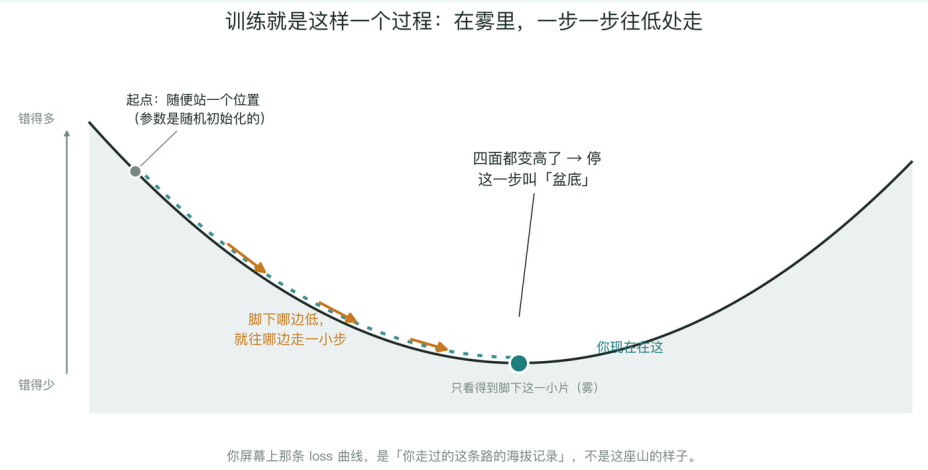

图注：高度是“错多少”，雾是“看不到整座山”，盆底是“四面都更高”。

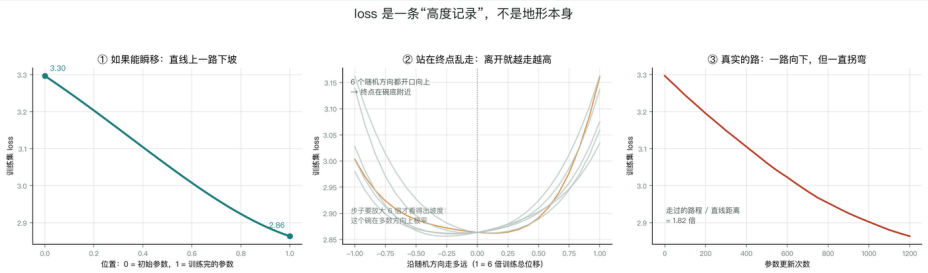

图注：左：起点到终点的直线；中：终点附近 6 个随机方向；右：真实的高度记录（路程是直线的 1.82 倍）。

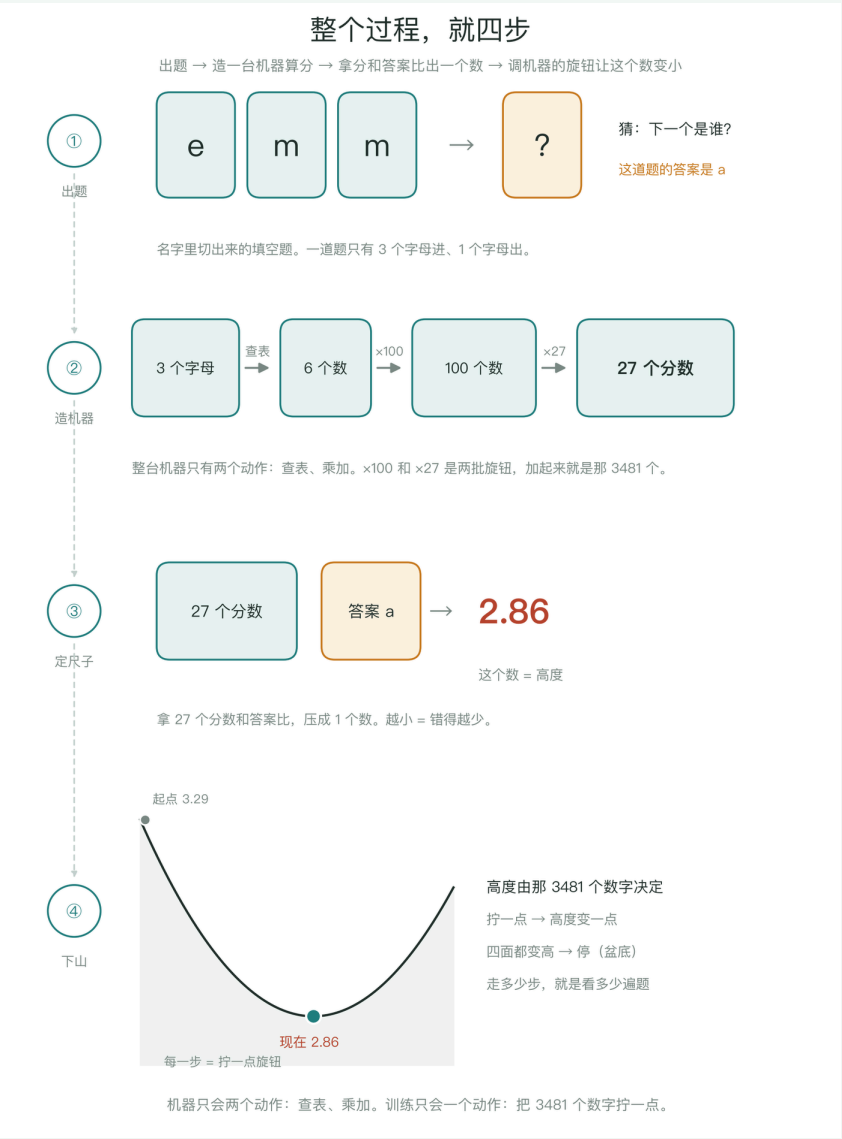

图注：出题 → 造机器算分 → 拿分和答案比出一个数 → 调旋钮让这个数变小。

三、100 个数到底是什么

100 个数，是 100 个评委各喊了一声。一个评委只能学一条死规矩，而真实情况要靠几条线索凑一起，所以放 100 个，每人只盯一个角度。每个评委用自己那 6 个旋钮，对着 6 个数算出一个数喊出来。

27 个候选人各听这 100 声，但他不是全听——他手里也有 100 个旋钮，决定“多信谁、少信谁”。**组合就发生在“挑着听”这一步。**

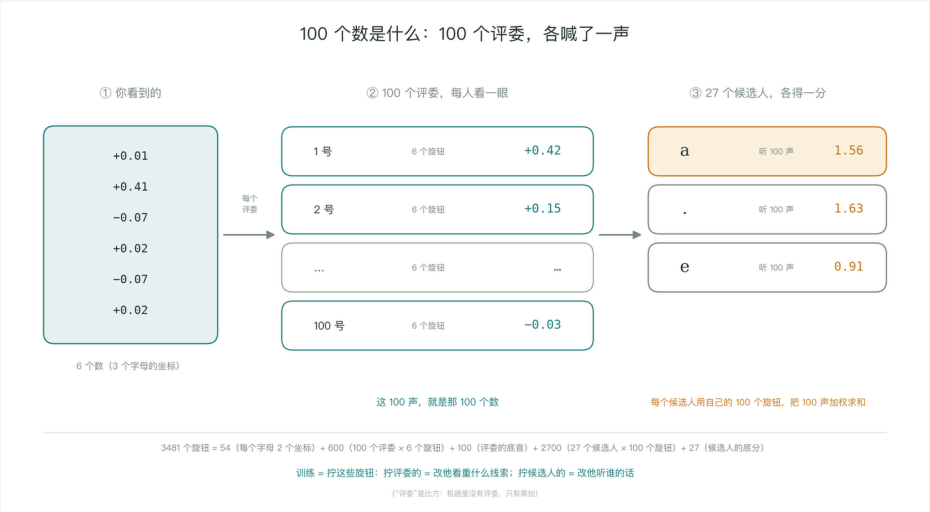

图注：3481 = 54 + 600 + 100 + 2700 + 27；600 是 100 个评委 × 6 个旋钮，2700 是 27 个候选人 × 100 个旋钮。

中间那 100 个数没有人类可读的含义。有含义的只有最后 27 个。

四、导数：从「多买一袋」到「斜率」

`c = a×b`、`a=2，b=3`，`a` 加 1，`c` 加 3——乘法里一个因子天然就是另一个因子的兑换率。画成面积更直观：宽加 1 格，多出来的竖条正好 3 格，因为高是 3。

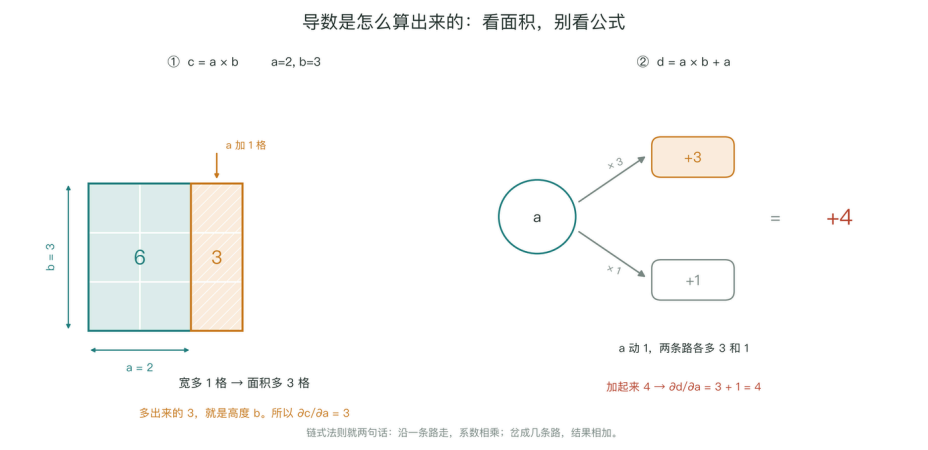

图注：右图是 `d = a×b + a` 的两条路：沿一条路系数相乘，岔成几条路结果相加。

但导数本身是**除法**：多出来多少 ÷ 你动了多少。面积只是乘法的画法。换成加法，`a` 加 1，`c` 多 1，`1÷1=1`，用不上面积。

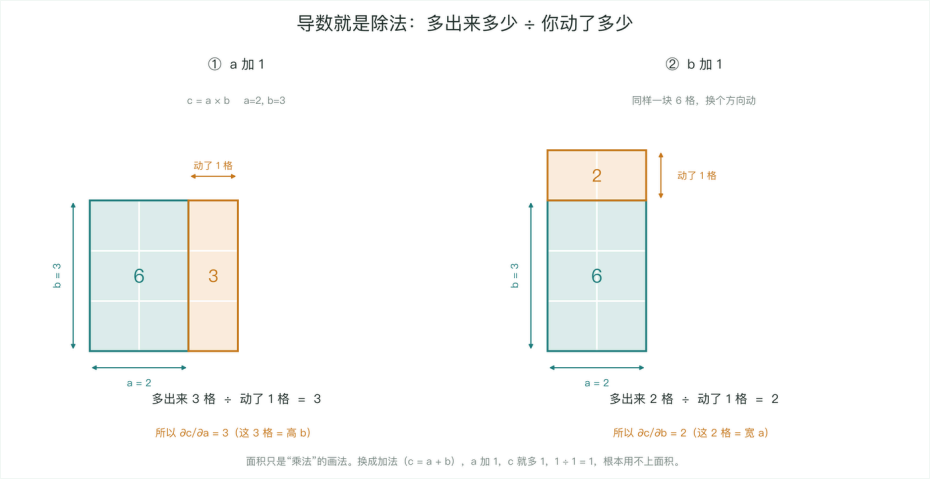

图注：左图动 a（多 3 格），右图动 b（多 2 格）。两个方向各量一次，就是两个导数。

换成买菜：**a = 买几斤，b = 每斤几块，c = 一共多少钱。**多买 1 斤多花 3 块（单价）；每斤涨 1 块多花 2 块（买了 2 斤）。

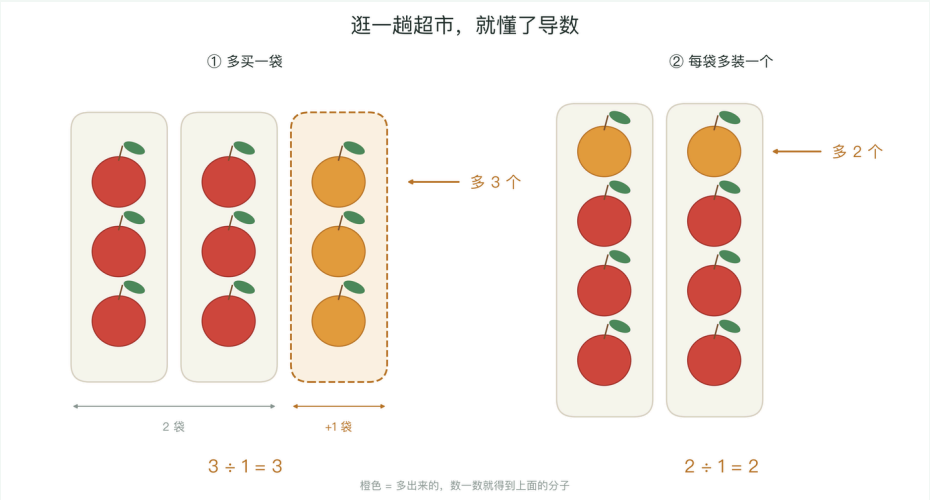

图注：左多买一袋数出 3，右每袋多装一个数出 2。橙色的就是分子。

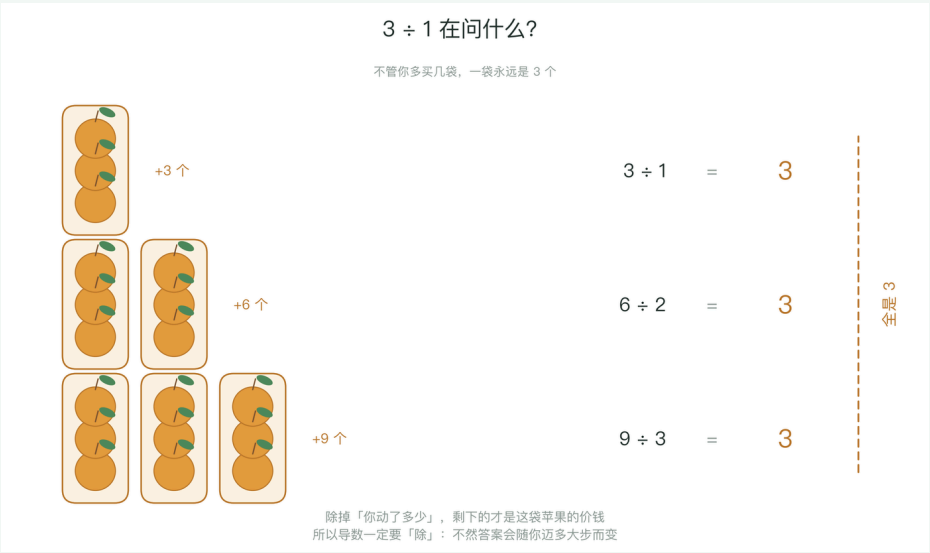

图注：买 1 袋、2 袋、3 袋，除掉买的数量之后都是 3——一袋永远是 3 个。

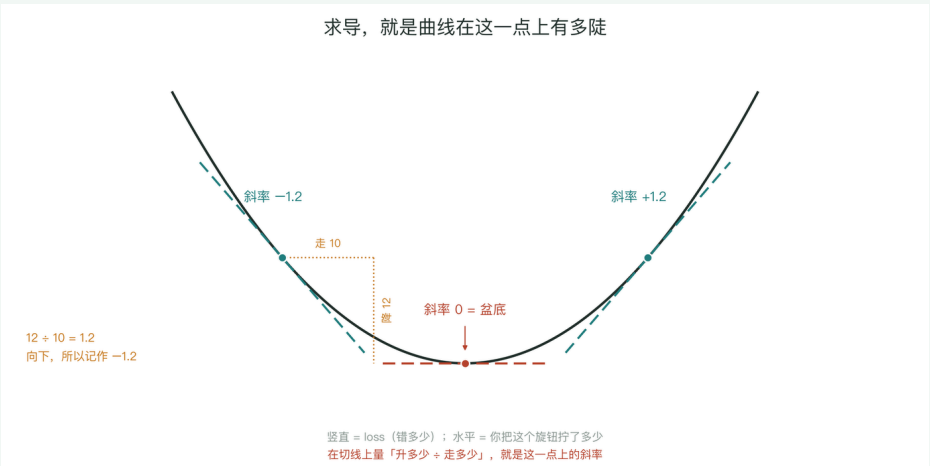

图注：竖直是 loss，水平是你拧了多少；斜率 = 升 ÷ 走。顶点斜率 0 就是盆底。

五、loss 是怎么变成 27 个导数的

loss 把 3,481 个旋钮的表现合成 1 个数；导数正好相反，把它拆成 3,481 份责任。

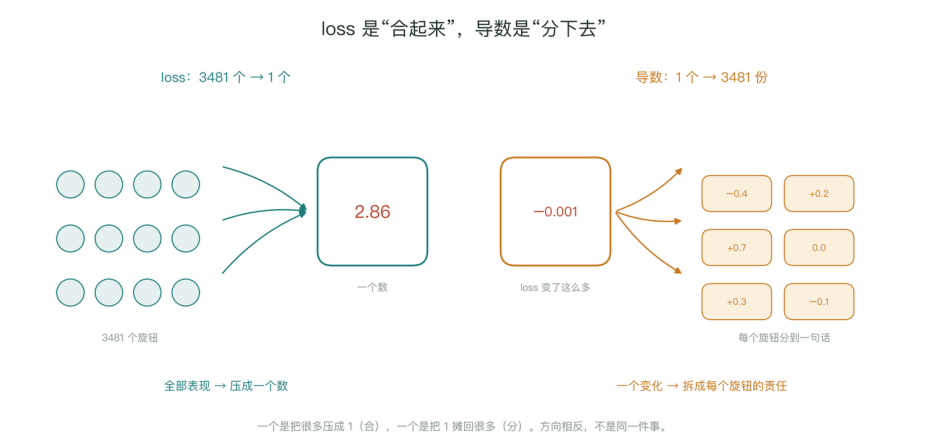

图注：左边把很多压成 1，右边把 1 摊回很多。

结论一行：**导数 = 概率 − 答案**。因为 `loss = −log(p[答案])`，而 p 是 softmax 出来的；log 和 exp 互相对消，只剩“预测减真相”。

账本版：**27 个孩子分 100 个苹果**。答案那个孩子 a 本该拿 100，实际拿 13，差 −87（要补）；其他孩子多拿的 15+7+65 正好 87（要退）。

图注：缺口 87 = 其他人多拿的 15+7+65，所以 27 个导数加起来等于 0。

为什么干净？因为 `loss = logsumexp − 答案那一格` 本身就是减法；求导时减号原样传下来。左边摊开按 `e^z` 的比例分，这个比例就是 softmax；右边只有一格是 1。

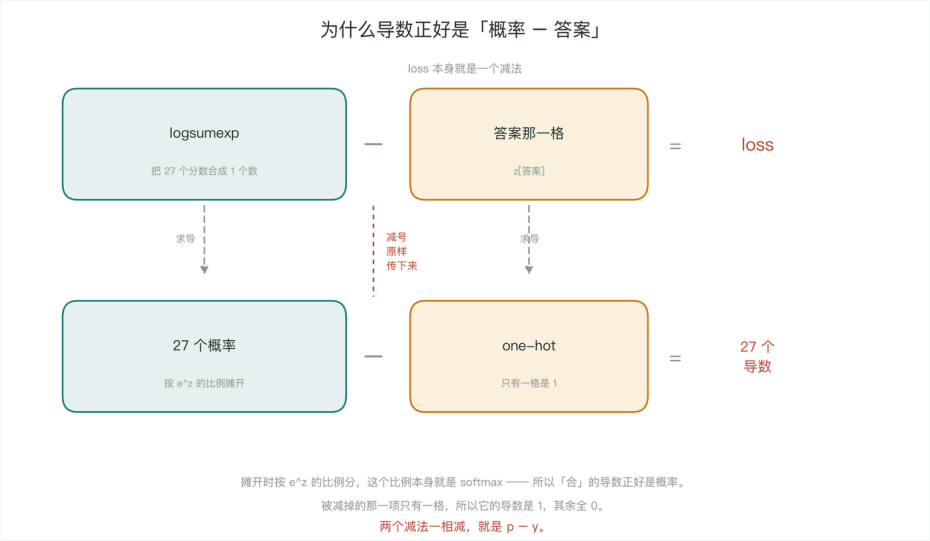

图注：loss 是个减法，所以导数也是个减法——照抄下来的。

求导这个动作是什么？就是“提前试一下”：抬 0.01，重算 loss（2.0241 → 2.0154），少 0.00867，÷0.01 = 0.867；`backward()` 直接给 0.868。区别只是：自己试要对 3,481 个旋钮各做一次，求导一次全给。

图注：抬一下 → 重算 → 除一下；求导直接给结果，差别只是速度和规模。

六、为什么是 27 个分数

27 不是从“3 个字母”来的，是**答案有多少种可能**：`27 = 1 个句号 + 26 个字母`。（3×3×3 也等于 27，那只是巧合。）

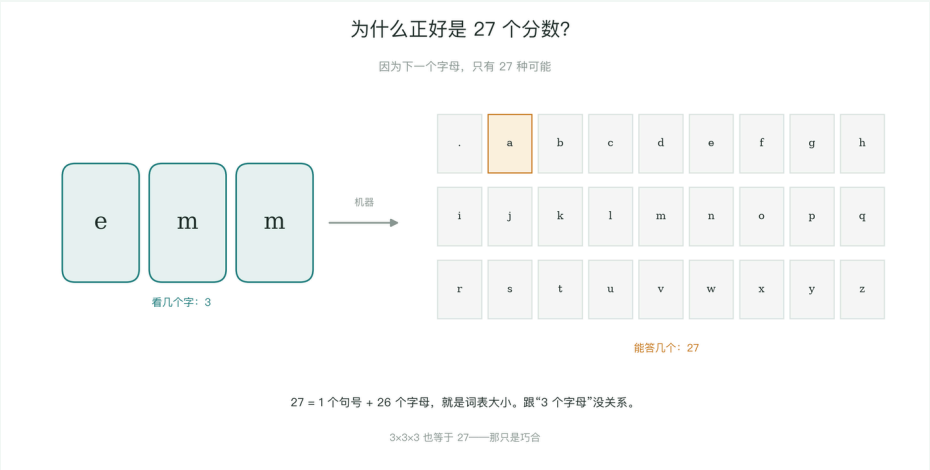

图注：左边是“看几个字”，右边是“能答几个”。

两头独立：窗口 3→5，输入从 6 个数变 10 个数，输出仍是 27；词表加 10 个数字，输出变 37，输入不变。

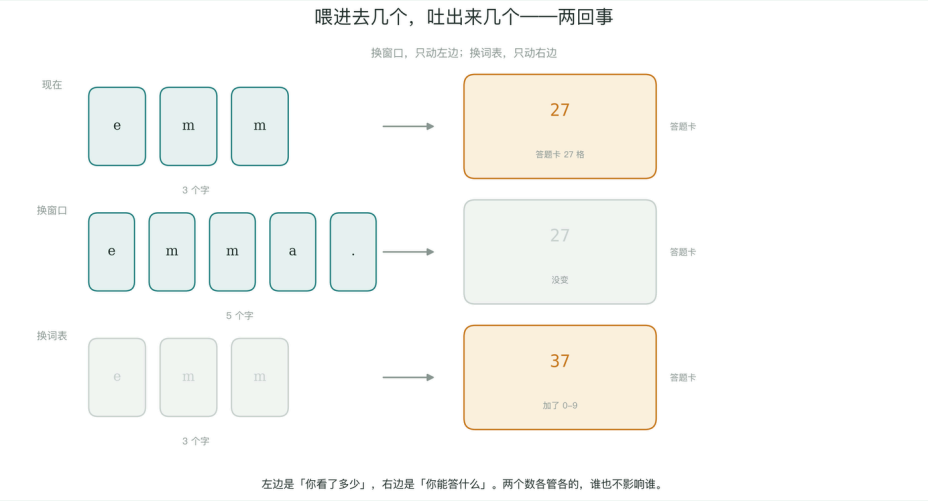

图注：换窗口只动左边，换词表只动右边。

窗口决定模型能看多远：只看 1 个字，猜不准；看 3 个字，`emm` 后面几乎只接 `a`。代价是组合变多（3 个字约 2 万种，5 个字约 1,400 万种）、算得更慢。现实里它叫“上下文长度”。

换词表是因为表里没有的字模型永远写不出来：名字里有 `O'Brien`，而词表里没有撇号，它就既读不懂也写不出。

七、micrograd、训练的一步、容量

micrograd 不“知道”斜率，它只知道“怎么算”斜率。斜率的大小、山的形状，是步骤 4 造出来的。记成：micrograd 是计算器，步骤 4 是你按计算器算的那道题。

有了导数不等于模型变了。`loss.backward()` 只把 3,481 个斜率写进 `p.grad`；真正改模型的是 `p -= lr * p.grad`。训练一步 = 量高度 → 问方向 → 迈一步。

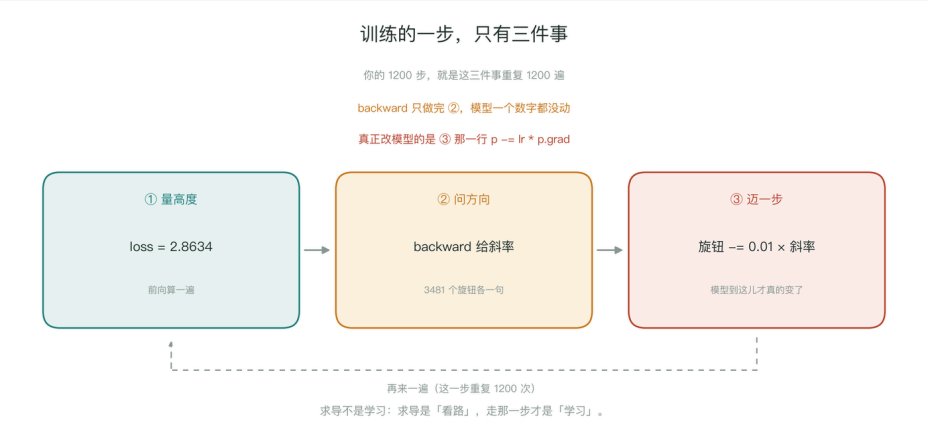

图注：backward 只做完 ②，模型一个数字都没动；③ 才是“学习”。

按钮越多就越准吗? 训练 loss 变低几乎是必然（小模型是大模型的特殊情况）；但新数据上的表现先降后升——按钮太多就开始背题。你这次 3,481 个按钮、只看了 0.21 遍数据，还在“没学够”那一头。

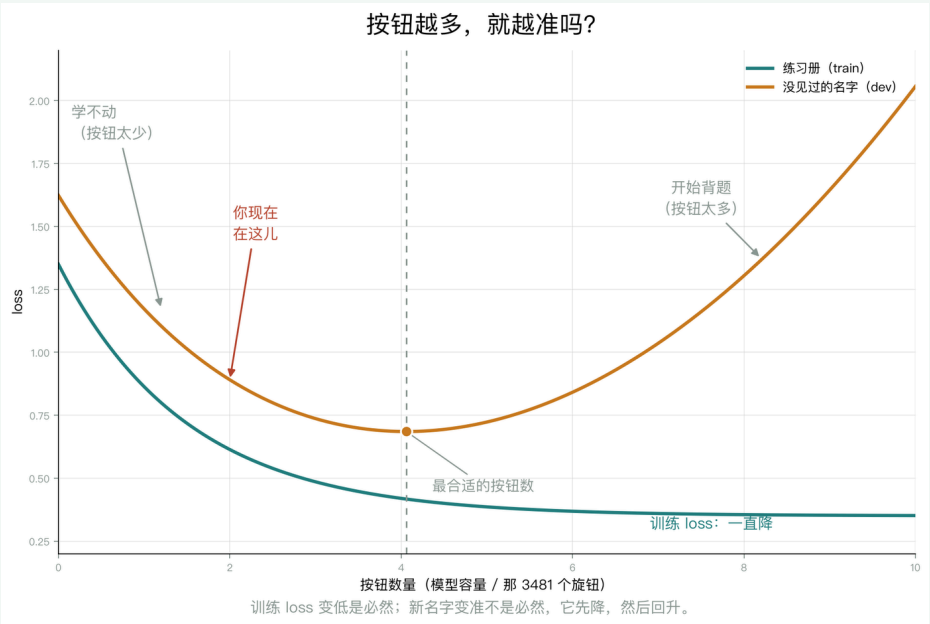

图注：训练 loss 一直降；新数据先降后升，虚线是最合适的按钮数。

八、几个容易混的概念

“组合”不是组合数学。组合数学（combinatorics）数“有多少种”；这里的“组合线索”是把几样东西揉成一个判断。确实有一处是组合数学：100 个评委“挑着听”有 2^100 种。但模型不枚举，它给每个评委一个权重，全听，只是程度不同——这是线性组合，用“加权”绕开“枚举”正是神经网络能工作的原因之一。

“对”是谁定的？不是模型，也不是数学，是数据和人。给 `emm`，答案是 `a`，来自“emma”这个名字本身；大模型预测下一个词，答案就是文本里的下一个词。而判分不是“猜对没猜对”：两个模型都答对 `a`，一个给 0.90、一个给 0.11，loss 是 0.1 和 2.2——它奖励的是“把信心放在对的地方”。

没有“目标值”，只有停止条件。你设的从来不是“loss 等于几”，而是用哪份数据、用什么公式罚、什么时候停。训到 0 意味着背题，而且 0 在物理上也不可达——数据本身带随机性。

九、把这条链连起来

1. **出题**：名字切成“看 3 个、猜 1 个”。
2. **造机器**：3 个字母 → 6 个数 → 100 个数 → 27 个分数，只有查表和乘加。
3. **定尺子**：27 个分数和答案比，压成一个数（loss）。
4. **看路**：backward 给 3,481 个斜率（= 概率 − 答案，一层层往回乘）。
5. **迈步**：`p -= lr * p.grad`，然后重复。

一句话：loss 是尺子，导数是斜率，迈步才是学习。你这次 1,200 步只把尺子从 3.29 挪到 2.86，因为题只看了 0.21 遍——不是方法不行，是还没走几步。

2026-11-12 续：从 MLP 到 BatchNorm 的追问

> 这一轮从「MLP 到底是什么」问到「为什么层数多了反而传不准」，最后落到「层级贝叶斯为什么小样本更准」。下面的数字来自本机实跑（seed 42、names 数据、4 层 × 64）；示意图是当场为了解释而画的，不是课程截图。

一、先把步骤 5 拍成一张 X 光

步骤 5 不是训练一个更好的模型，而是**训练之前先体检**：把一个样本喂进去，在每一站记录「信号长什么样、梯度还剩多少」。

看三个量就够了：

量	在哪看	说明什么
σ（标准差）	每一站的 64 个值	这站的值有多散。太大 → 全撞墙；太小 → 样本挤成一团，分不开
饱和率	tanh 输出绝对值 > 0.97 的比例	多少样本已经贴到 ±1。贴住的样本，回传时斜率只剩 0.01–0.07
梯度 σ	`∂L/∂h` 、`∂L/∂z`	反传回到这一站时，还有多少话语权

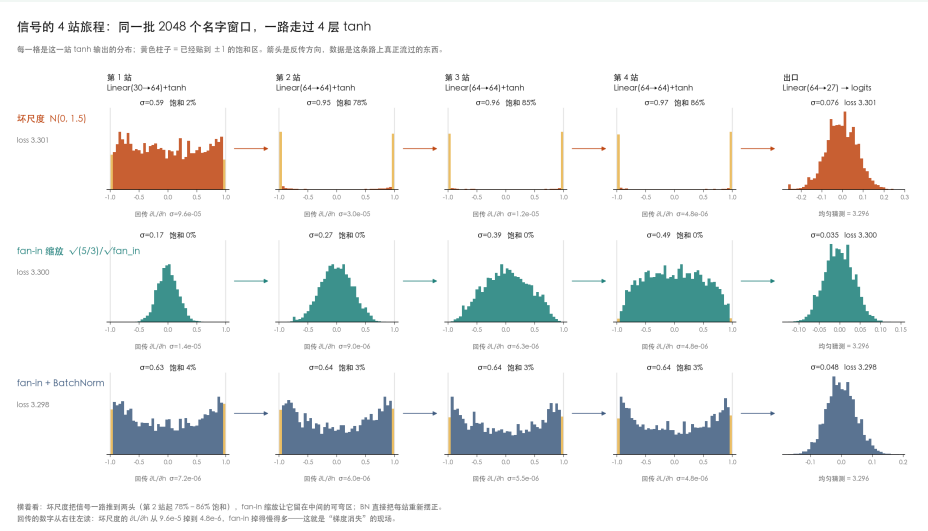

图注：助手绘制的诊断图，2026-11-12 本机实跑；2048 个训练窗口做一次前向 + 一次反向，seed 42。黄色柱子表示已进入 ±1 的饱和区。

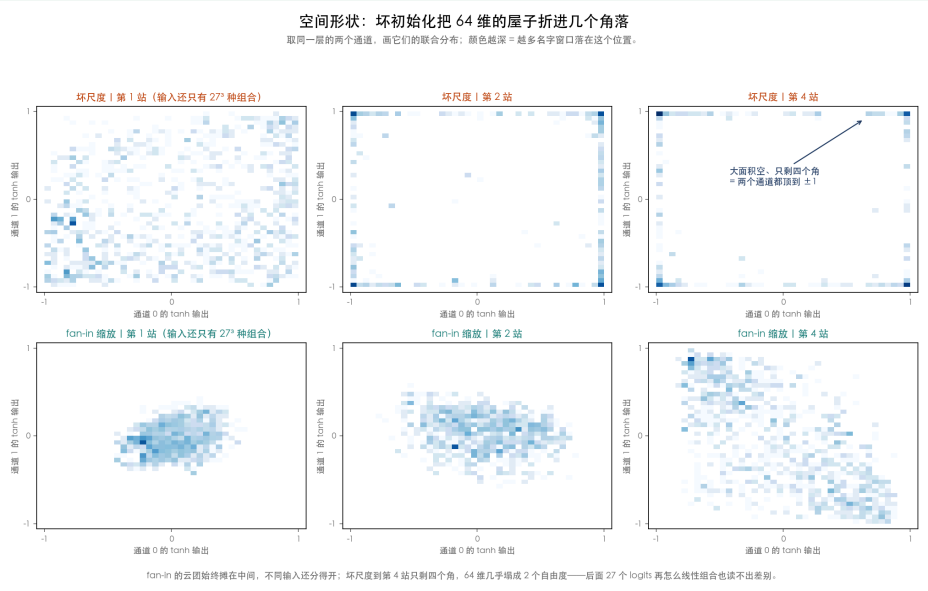

图注：同上一次实跑；取同一层的两个通道画联合分布，颜色越深表示越多窗口落在这个位置。第 1 站像格子，是因为输入只有 27^3 种组合，本来就离散。

三组条件，只改初始化（输出层都保持小尺度）：

条件	第 1 站 σ	第 4 站 σ	第 4 站饱和率	∂L/∂z 衰减	初始 loss
坏尺度 N(0,1.5)	0.88	11.2	86%	68×	3.301
fan-in 缩放	0.18	0.64	0.2%	3.5×	3.300
fan-in + BatchNorm	0.18 → BN 后 1.00	1.07 → BN 后 1.00	3%	1.5×	3.298

三种条件的初始 loss 都是 3.30，看上去一模一样，内部状态却完全不同。**只看 loss 会漏掉全部问题**，这正是本步骤验收标准要求的那件事。

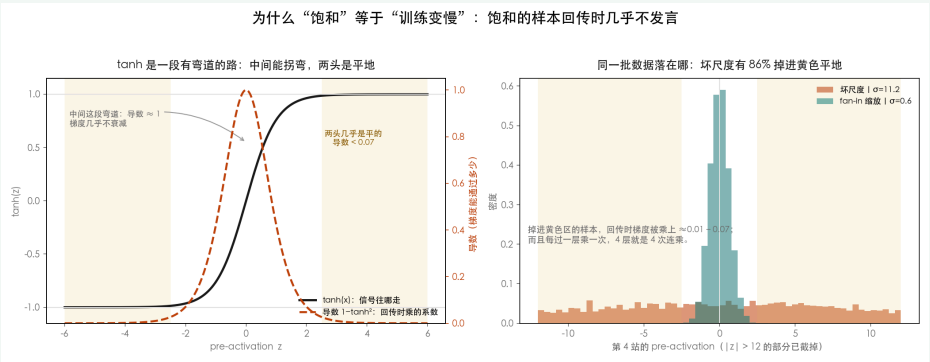

图注：助手绘制的教学示意，2026-11-12；左图曲线与导数来自 tanh 本身，右图直方图取自同一次实跑的第 4 站 pre-activation。

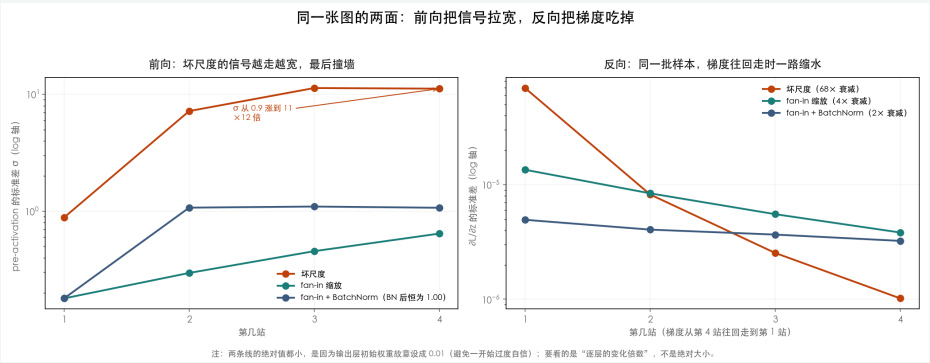

图注：同一次实跑的逐层统计；纵轴为 log 轴。绝对值小是因为输出层初始权重设为 0.01，要看的是逐层变化倍数。

BatchNorm 做的是三件事，其中第 2、3 件常被混在一起：

1. **抹平尺度**：初始权重差 6–9 倍，训练 300 步后 dev loss 只差 0.01（2.526 与 2.541）；
2. **积累标尺**：`running_mean = 0.9×旧 + 0.1×这一批`；
3. **切换用法**：`train()` 用当前批统计，`eval()` 用累计标尺；`train()` 只喂一条样本会直接报错（`Expected more than 1 value per channel`），`eval()` 才能一条一条预测。

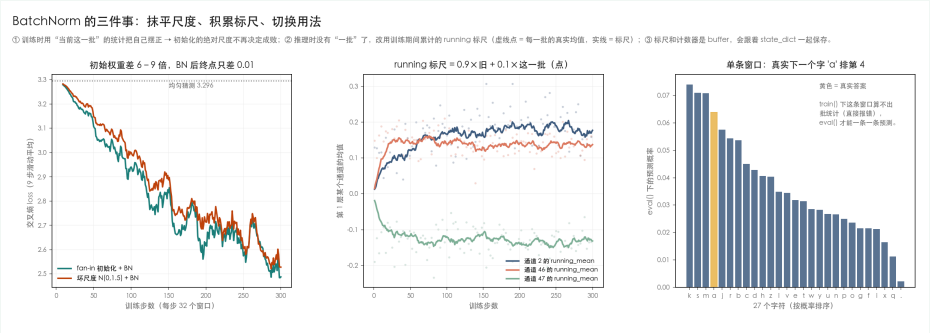

图注：助手绘制的诊断图，2026-11-12 本机实跑；300 个 minibatch、batch 32、Adam lr 1e-3。左图两条曲线的差别来自初始化，不是训练配置。

二、MLP 到底是什么

一句话：**把「加权求和 → 折一下」重复 N 次，最后接一个投票层。**没有别的零件。

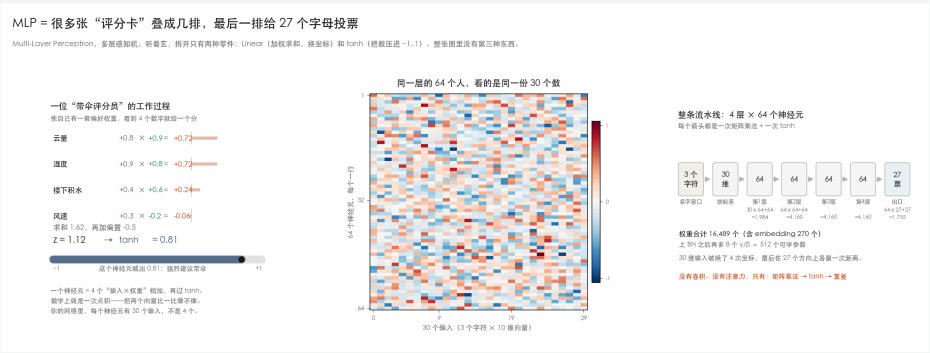

图注：助手绘制的教学示意，2026-11-12；左图用「带伞评分员」手算一个神经元（4 个输入、4 个权重、tanh 之后 0.81），中图热力图取自步骤 5 存档的第一层权重（64×30），右图为该网络的实际形状与参数量。

一个神经元就是一张评分卡：权重是「他关心什么、关心多少」，相加是打分，tanh 是把分数压成强度。一层 64 个神经元，就是 64 张卡同时看同一份 30 个数——矩阵乘法的每一行就是一张卡。

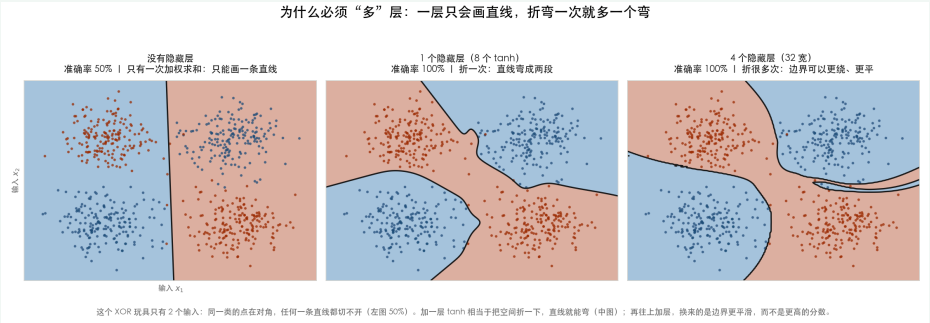

图注：助手绘制的教学示意，2026-11-12；XOR 玩具数据（2 个输入、4 个象限），三个模型同样训练 1500 步，准确率分别为 50%、100%、100%。这一张说明「深」换来的是能弯，不是更准。

如果没有 tanh，4 层线性层和 1 层线性层完全等价——矩阵乘矩阵还是矩阵。深度只有在中间夹了非线性时才有意义。

三、tanh(1.12)=0.81：把公式还原成空间

这个式子不是算术题，是「把数轴弯一下」。

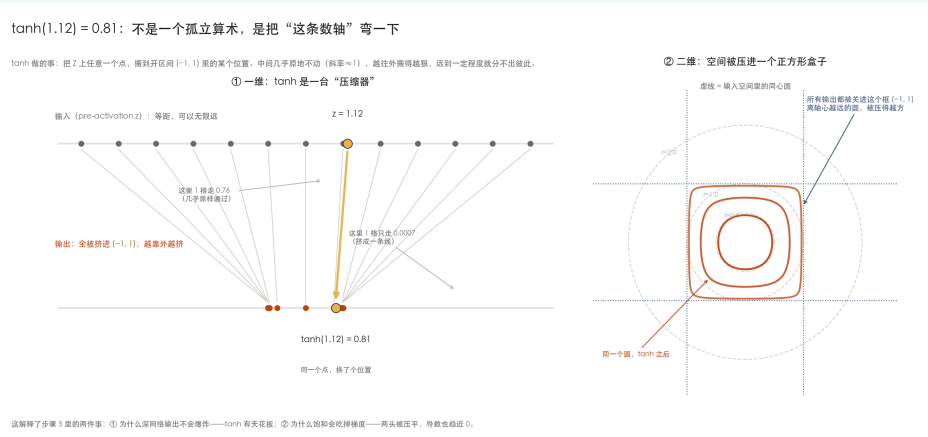

图注：助手绘制的教学示意，2026-11-12；左图把等距刻度映射到 (−1,1)，金色高亮为 1.12 → 0.81；右图为同一映射作用在同心圆上的结果。

中间几乎原地不动（斜率≈1），越往外压得越狠：`z` 处 1 格 → 0.76 格；4 处 1 格 → 0.0007 格。而 1.12 处的导数是 $1-0.807^2 = 0.348$ ——**梯度路过这一点，只剩 35% 能过去**。

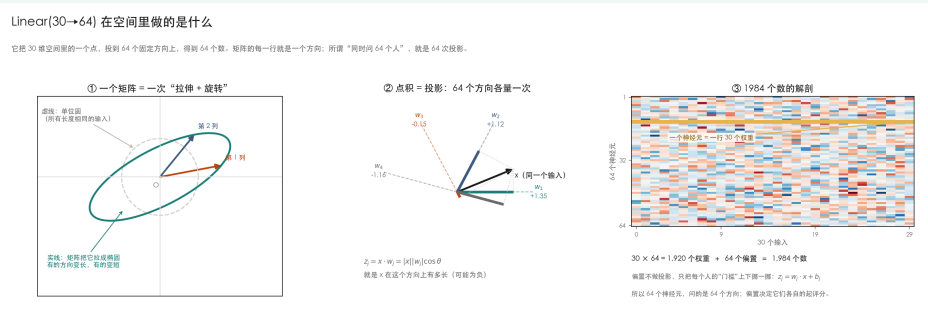

图注：助手绘制的教学示意，2026-11-12；左图为 2×2 矩阵把单位圆拉成椭圆，中图为点积即投影，右图热度矩阵取自步骤 5 存档的第一层权重。

`Linear(30→64)` 在几何上是同一件事：64 行就是 64 个方向，每个 `z` 是输入在这条方向上的影子。1,920 个权重加 64 个偏置等于 1,984；偏置不参与投影，只决定每个人的起评分。

四、换成人话：2 米宽的地铁门

如果公式还是绕，就看这一张：

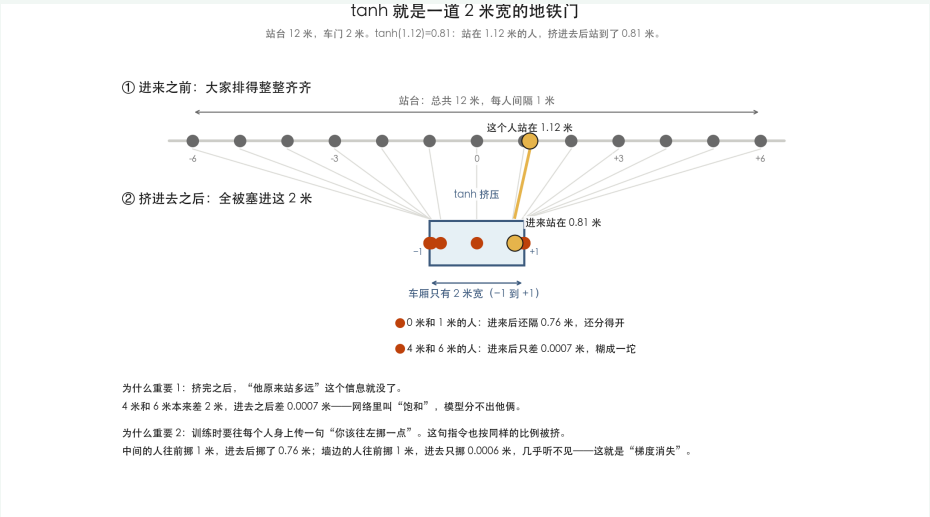

图注：助手绘制的教学示意，2026-11-12；站台 12 米、车门 2 米，`tanh(1.12)=0.81` 读作「站在 1.12 米的人，挤进去后站到 0.81 米」。

挤完之后的两个后果：4 米和 6 米的人只差 0.0007 米，**分不出谁是谁**（饱和）；墙边的人往前挪 1 米，进去只挪 0.0006 米，**几乎挪不动**（梯度消失）。

五、和「爬山」怎么接上

爬山说的是优化：站在 loss 山上，沿坡往下走。门说的是激活函数：每层把数压一次。两者的接点在**梯度要沿原路传回山脚**。

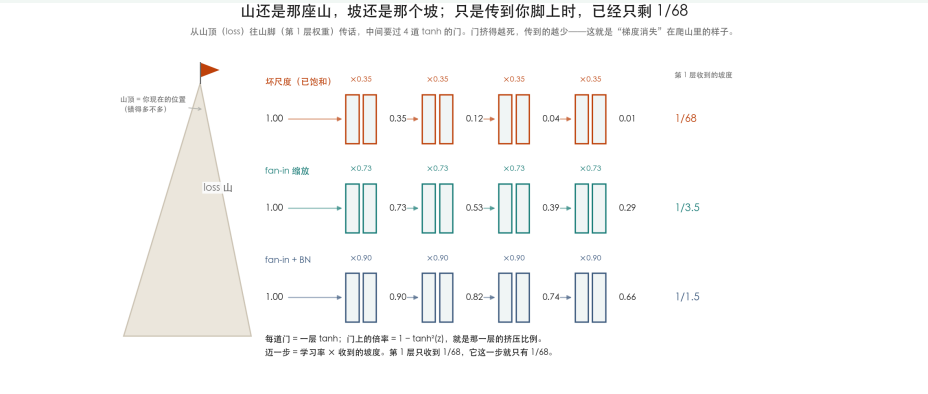

图注：助手绘制的教学示意，2026-11-12；每道门上的倍率是该层实测的每层保留比例（68.3、3.5、1.5 开四次方），不是人为设定。

山上的指令是 1.00，过四道门之后：坏尺度只剩 0.01（1/68），fan-in 还剩 0.29，BN 还剩 0.66。**山还是那座山，坡还是那个坡，只是传到脚上时已经打折。**

爬山里的东西	网络里的东西
山的高度	loss
你站的位置	当前参数
脚下的坡度	梯度
迈一步的距离	学习率 × 梯度
一道闸机	一层 tanh
闸机挤死	饱和（导数≈0）
走到山脚时听不见	梯度消失
换成自动感应的闸机	BatchNorm

六、更熟的场景：调淋浴水温

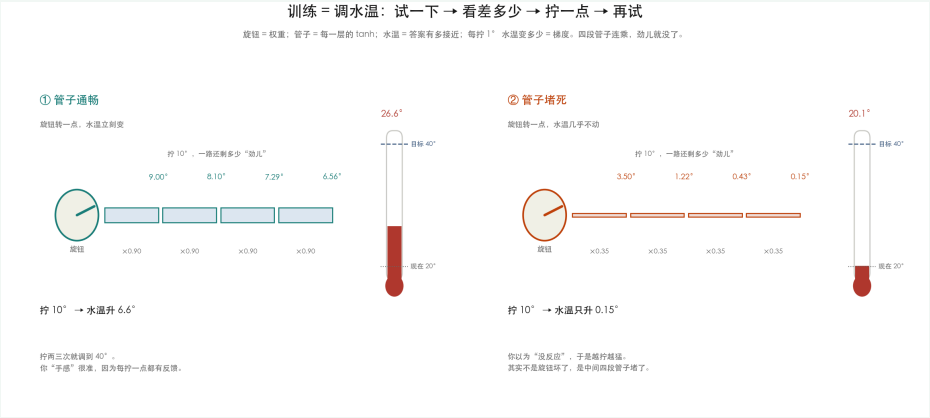

图注：助手绘制的教学示意，2026-11-12；左图每段 ×0.90，右图每段 ×0.35，数字由乘法逐段算出，用于对比「有反馈」与「没反馈」。

训练就是一个循环：试一下 → 看水温 → 还差多少 → 拧一点 → 再试。**每拧 1° 水温变多少，就是梯度**；管子越堵，拧了越没反应。

七、三种「修管子」，以及层数到底买到了什么

图注：助手绘制的教学示意与实测数字，2026-11-12 本机实跑（4 层与 8 层、600 步）；每层保留比例由实测梯度衰减开四次方得到。

做法	它在修什么	每层保留	8 层 600 步 dev
不修（坏尺度 tanh）	—	0.35	2.84
换初始化（fan-in）	装管子时按管径配水压	0.73	2.45
加 BatchNorm	每段装个稳压泵	0.90	2.43
换 ReLU	换成单向阀，正向不打折	0.90	2.42

代价也要写清楚：BN 让训练与推理行为不同、批太小时不稳；ReLU 会关掉约一半神经元（本次初始化下约 47% 输出为 0）；初始化单独用，网络很深时仍会失真。

层数呢？层数不是「更准」。同一份数据、同样 600 步、都加 BN：

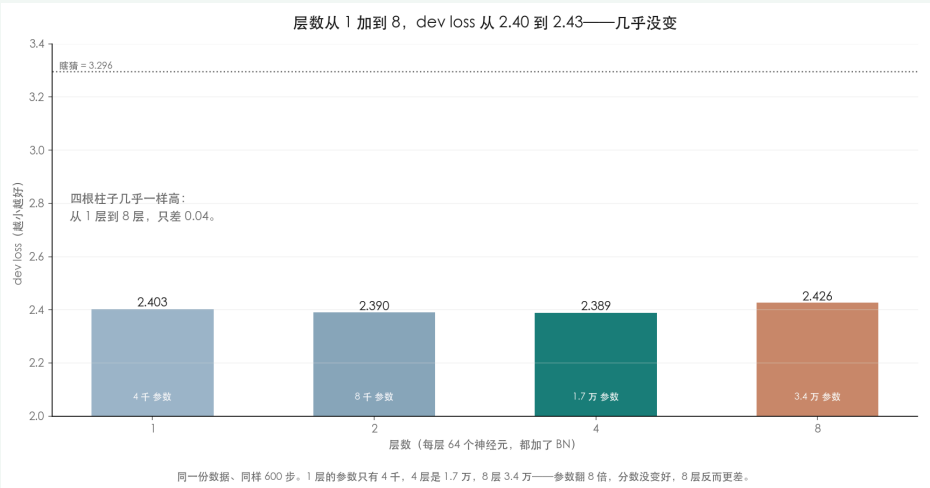

图注：助手绘制的诊断图，2026-11-12 本机实跑；1/2/4/8 层，每层 64 个神经元，600 步；纵轴包含「瞎猜 3.296」作为背景参照。

层数	参数	dev loss
1 层	4 千	2.403
2 层	8 千	2.390
4 层	1.7 万	2.389
8 层	3.4 万	2.426（更差）

参数翻 8 倍，分数只动 0.04。层数换来的是**组合能力**（XOR 那张图），不是精度；而且在难任务上，层越多数越难训。

八、「每个人有自己的权重、层层过滤更准」：哪半对

对的一半：每个神经元确实有一组自己的权重；层与层之间确实是「把上一层的结论再组合一次」。

错的一半：**它不是过滤，是换坐标**。过滤意味着筛掉不合格的，MLP 每层是把整批数乘一个矩阵、再弯一下，没有人被淘汰（ReLU 除外）。「越深越准」被上表直接否定：8 层 3.4 万参数没有赢过 1 层 4 千参数。而「每个人负责一个特征」是结果不是设计——同一层里常有大量冗余神经元，剪掉一大半分数几乎不掉。

九、加工链与传达链

「多层」其实是两种完全不同的东西，混在一起就会出现你那个矛盾。

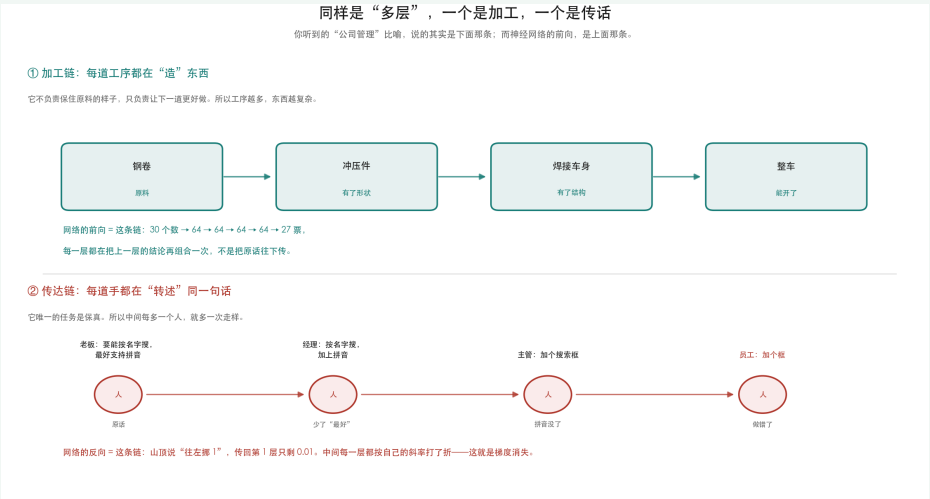

图注：助手绘制的教学示意，2026-11-12；上半是流水线（每层在造），下半是汇报链（每层在传），两者的区别是「重造」与「转述」。

	加工链	传达链
每层在干嘛	重造：把原料变成零件	转述：把同一句话往下传
目标	让下一步更好做	一字不差地保住原话
层数变多	东西越复杂	越走样
例子	钢卷→冲压→焊装→整车	老板→经理→主管→员工

网络的前向是加工链，反向传播是传达链。所以「层数越多越能做复杂的事」说的是前向，「层数越多越传不准」说的是反向，两者都不假。

公司管理里两种链同时存在，只是大家统称「层级」。汇报链确实是层多必失真；流水线则是工序越多越精细。神经网络像流水线，不像汇报链——因为每一层不对「原话」负责，只对最终的 loss 负责。公司里的「层层质检」属于第三种：冗余判断，靠多双眼睛提高精度，也不是靠传递。

十、科学里的同类：层级为什么可能更准

- **视觉皮层**：V1 对边缘与朝向敏感，V2 组合成轮廓，V4 组合成形状，IT 才认得出「这是什么」。层越深，感受野越大、对位置越不敏感，但对「是什么」越确定。这是加工链的生物学证据。
- **层级贝叶斯**：小样本的单位向大样本借力，估计更稳（见下一节）。这是严格意义上「多层换精度」的例子，但机制是「上层约束下层」，不是传递。

- **重整化群**：物理研究相变时一层层粗粒化，每层丢掉短程细节、保留长程结构。有研究（Mehta & Schwab, 2014）指出深度网络的前向与变分重整化群有对应；这仍是一个研究方向，不是定论。
- **多片镜头**：单片镜片有球差、色差，十几片玻璃各修一种像差，最后成像才锐利。它也不是「传光」，是逐片改造光路。

三种方向可以并列：加工（下→上重造）、传达（上→下衰减）、**约束（上→下修正）**。层级贝叶斯属于第三种。

十一、45 次打击够不够：向均值收缩

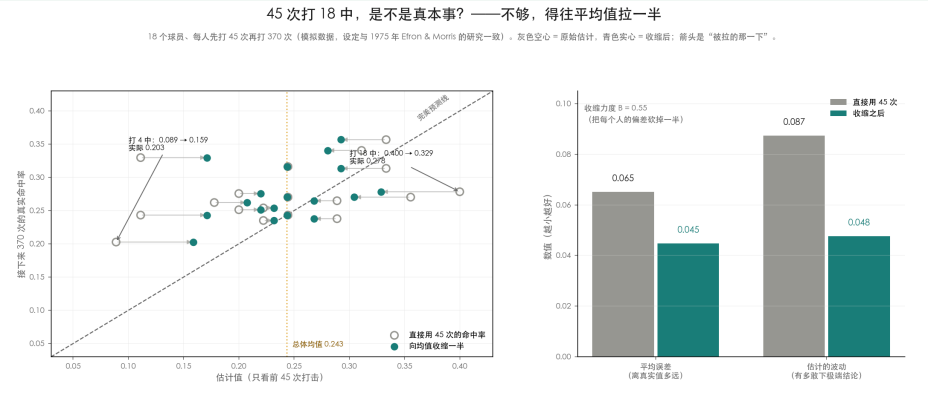

图注：助手用与 1975 年 Efron & Morris 研究相同的设定做的模拟（18 人、先 45 次再 370 次、真实水平围绕 .265 波动），2026-11-12；数字为本次模拟计算，不是原文数据。

45 次打 18 中，命中率 .400。但若真实水平是 .265，45 次的命中率会在 .13–.40 之间随机晃（标准差约 .066），而球员之间的真实差距只有约 .03——**噪声是信号的两倍**。

于是把每个人往总体均值拉一半（B=0.55）：.400 → .329，.089 → .159。结果平均误差从 0.065 降到 0.045，估计的波动从 0.087 降到 0.048。收缩引入了偏差，却大幅降了方差；当噪声大于信号时，这是净赚。

这个思路在训练里天天出现：**L2 正则化（weight decay）就是把权重往 0 拉**，0 就是权重的总体均值。dropout、早停、小样本的交叉验证是同一族：证据不足时，别装作很有把握。

十二、这一轮的三句话

1. **看网络要看分布，不要只看 loss**：初始 loss 都是 3.30，内部可以从「每层 σ≈1」走到「86% 贴墙」。
2. **层数买的是组合能力，不是精度**；能不能训得动，取决于每层的门有没有挤死。
3. **同一个「多层」有两条链**：前向在加工，反向在传话；前者越深越强，后者越深越糊。

步骤 5 诊断初始化、激活与 BatchNorm

loss 能下降仍可能浪费大量训练。这里通过输出分布、tanh 饱和和更新幅度，检查梯度有没有顺利穿过更深的网络。

目标：让初始化和层间统计可解释，而不是靠碰运气试常数。

1. 在训练前先看初始 loss。27 类近似均匀预测应接近 `log(27)≈3.296`；若远高于这个数，先检查最后一层 logits 的尺度与偏置，不急着延长训练。定位第 4 课 00:04:19。[O4]

2. 绘制 tanh 输入与输出的直方图，统计输出绝对值大于 0.97 的比例。若大量落到 ±1，导数 `1-h*h` 接近 0。按 fan-in 缩放权重，比较合理和不合理尺度下的前向与反向统计。[O4]
3. 在 Linear 后、tanh 前加入 BatchNorm，保存 gamma、beta、running mean/variance；分清可训练参数与缓冲区。训练时使用批统计，验证与生成时切到固定运行统计。[O4]
4. 将 Linear、BatchNorm、Tanh 封装成模块，观察每层激活、梯度、权重及 `std(lr*grad)/std(parameter)` 随时间的变化。保留一次异常与修复后的对照。[O4、O10]

> **做完的标准**：能解释初始 loss；能展示一次饱和及修复；训练与推理模式切换后生成正常；运行统计与可训练参数分别保存。

白话说明：检查网络里的信号是不是太大、太小或被压扁了

你已经有能训练的网络。现在像检查录音设备：音量太大削顶，太小听不清；只听最后成品不足以判断是哪一段出了问题，要逐段查看信号。

先打开：`makemore_part3_bn.ipynb`，仍在 `lectures/makemore/` 目录。先运行数据和初始化，停在第一次参数更新之前。

先把这一步想成一个生活场景

想象一排传话筒。前面声音太小，后面听不清；声音太大，设备把它挤到极限，再调一点也听不出差别。我们现在给网络装“观察仪表”，看看每一站的数字与梯度，而不是只盯最后的分数。这个声音类比帮助理解尺度，并不是网络真的在处理音量。

怎么读这一节： 先读每个操作前的故事与具体数字，再运行原有代码。代码成功只是程序完成了动作；能回答“停一下”的问题，才说明你知道它在做什么。下面的场景和小数字是助手编写的教学例子。

先把关键词翻成看得见的东西

关键词	白话意思	本步的具体样子
激活值	一个工位算出的中间数字	tanh 的输出 h
饱和	已经到曲线很平的位置	输入再变，输出变化很小
均值 / 标准差	大致中心 / 波动大小	用来观察一批信号的尺度
fan-in	一个神经元接收多少输入	求和项的个数
初始化	开始训练前摆放旋钮	不是训练后的权重
BatchNorm	按批统计调整每个通道的尺度	通常还带可学习的缩放与平移
运行统计	训练时积累的均值与方差记录	验证/生成时使用

操作 A：看还没训练时，模型有多“自信”

场景：刚进教室，还不会做题，却大声说“我百分之百确定”。 如果模型在随机初始化时就把大量概率给了错误字符，损失会很高。27 个选项平均分时，每个概率 1/27，正确答案的负对数损失约 3.296。

你实际做的事： 在训练前打印 logits 的分布和 loss。这个参照用于发现异常自信，不要求每个随机网络精确等于 3.296。

停一下： logits 大意味着正确吗？不意味着；它只是分数大小，仍要看高分给了谁。

打印 logits 的均值、标准差和初始 loss。27类完全均匀分布的 loss 是 `log(27)≈3.296`。随机初始化不保证完全均匀；这个数字是参照，不是强制精确相等的断言。远高于此值时，检查最后一层是否给错误答案极高信心。

操作 B：亲眼看见 tanh 饱和

场景：把软海绵压到快压不动。 tanh 中间变化明显，两端趋于平坦。输入 0 时导数为 1；输入 3 时 tanh 约 0.995，导数约 0.0099，传回的梯度会被这一站缩小很多。

你实际做的事： 在两条曲线上同时找 x=0 和 x=3，再看网络里有多少激活接近两端。阈值 0.97 是观察用的标线，不是“超过就判失败”的法律。

停一下： 为什么前向还能输出数字，反向却可能很难学？因为有值不代表局部变化率足够大。

```
import torch
import matplotlib.pyplot as plt
x = torch.linspace(-6, 6, 200)      # 在 -6 到 6 之
间取 200 个点
y = torch.tanh(x)                   # 对应的 tanh 输
出
plt.plot(x, y, label='tanh')        # 画 tanh 曲线
plt.plot(x, 1-y*y, label='local derivative')   # 画
局部导数 1-t²（中文：局部导数）
plt.legend()                        # 显示图例
plt.show()                          # 显示图像
```

你会看到 tanh 在左右两端变平，导数接近0。回到自己的网络，对 tanh 输出 h 算 `((h.abs()>0.97).float().mean())`，它表示有多大比例的值靠近饱和区域。高比例是排查线索，不单凭它宣布网络失败。

操作 C：做一组只有初始化不同的对照

场景：做同一锅汤，只改变一次盐的起始量。 要判断初始化尺度的作用，数据、随机种子、网络尺寸和训练预算都应保持可比。输入项多时，随意相加通常会增大波动，因此初始化要考虑 fan-in。

你实际做的事： 两种配置都从头开始，保存更新前的激活与梯度直方图。直方图横轴是数值区间，柱高表示有多少数落进去；不要把柱高当成梯度大小。

停一下： 已训练过的网络换初始化再比较公平吗？不公平，应各自重建同样起点。

保持同一 seed、数据和网络尺寸，分别用较大权重尺度与课程的 fan-in 缩放初始化，从头运行。记录第一次前向的 loss、饱和比例及反向后的梯度分布。`fan_in` 就是一位神经元接收的输入数；输入项越多，未经控制的求和波动通常越大。

操作 D：接入 BatchNorm 后检查训练与生成两种状态

场景：排队量身高时先看这一队的中心与分散程度。 BN 对每个通道减去批均值，再按方差调整尺度，还可用学习到的参数缩放和平移。它不是把所有人变成同一个数。

你实际做的事： 训练时可以借当前一批估计统计；验证时用积累的统计，避免同一个样本因同批伙伴变化而随意换标尺。保存权重时，也要保存这些统计记录。

停一下： `eval()` 会把权重重新训练一遍吗？不会，它切换某些层的行为；是否记录梯度是另一件事。

按课程把 BN 放在线性输出和 tanh 之间。训练用当前批均值/方差，生成和验证用训练阶段积累的统计。课程自写模块可能使用 `layer.training=False`；PyTorch 的 `nn.Module` 用 `model.eval()`。先确认你拿的是哪一种类，不混用接口。

做完留下什么：一组修复前后的直方图；同样预算的 loss 对照；保存模型时，除权重与偏置，还保存 BN 的运行统计。生成时一批只有1个例子就出错，优先检查是否还在按当前批估计方差。

卡住时先找哪一站

看到的现象	先检查什么
初始 loss 极大	先看最后一层分数是否过大
多数 tanh 接近 ±1	查看输入尺度和初始化
单样本生成不稳定	检查训练/评估状态和 BN 运行统计

说明与衔接：本段是助手基于本步骤课程与代码整理的动手导读；微型例子只解释相应局部机制。继续按下面原有课程讲解、截图与验收要求完成该步。

空间转化：把步骤 5 摆到一张图里

画一条带软弯道的管线：线性层输出先进入 BN 标尺，再进入 tanh。旁边放两块仪表，一块看前向数值分布，一块看反向梯度分布。图上弯道越平，表示该处的局部导数越小；不是有真的液体堵住，也不是所有小梯度都错误。

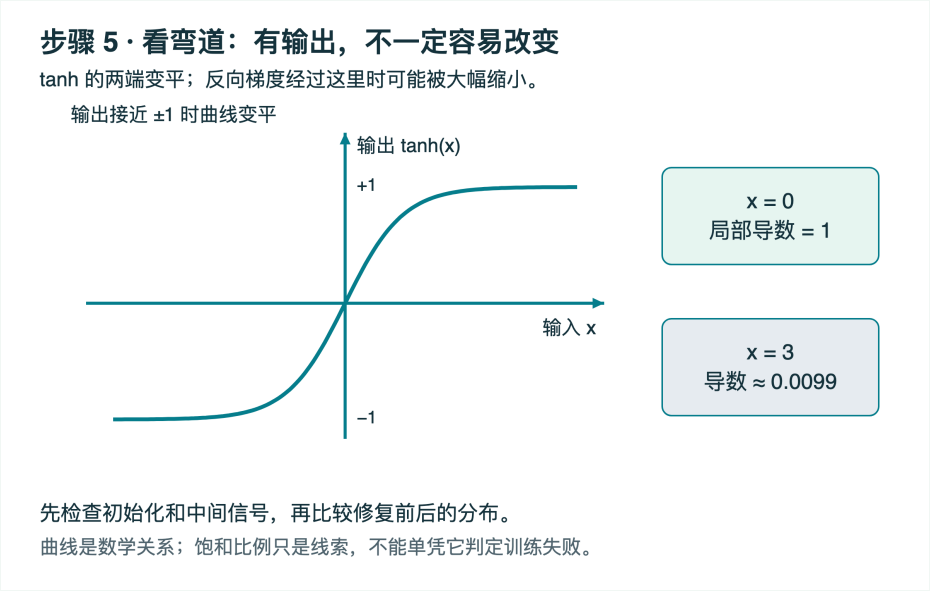

图注：助手绘制的教学示意，2026-11-09；帮助理解本步的计算关系与操作顺序。图中教学数字与简化结构不冒充课程截图、模型实测性能或完整实现。

试着用手指读图： 先指出输入或起点，再沿依赖找到中间处理，最后指出输出或结果记录。停在每一站，说出“这里放的是什么、对它做了什么、什么东西会改变”。如果遇到反向箭头，要说明它传回的是梯度，还是图中另有注明的流程。

再用一句话检查自己： 遮住正文，只看图，解释这一节与上一步相比新增加了什么；然后回到本步的小实验核对。会复述图并不代替实际运行和数值验收。

形状阶梯：BN 不改形状，只改每一列的位置和宽度

左边是 (32,100) 的激活，中间两个格子是沿批维算出的 (100,) 均值与方差，右边还是 (32,100)，但每一列已经被摆到均值 0、方差 1 附近，再乘 γ 加 β。形状一行没变，变的是每一列的刻度和位置。

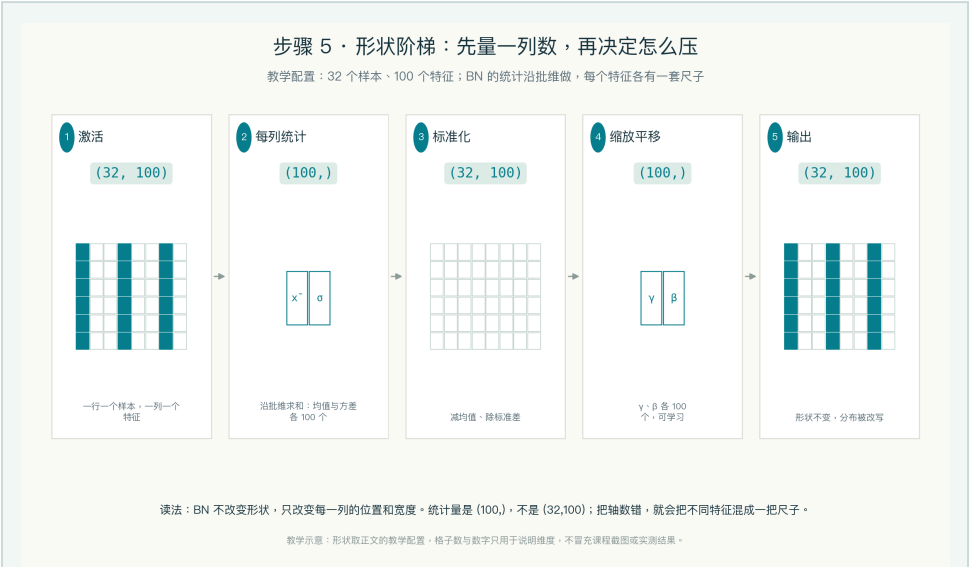

图注：助手绘制的教学示意，2026-11-10；教学配置：32 个样本、100 个特征，统计沿批维做。格子数与数字只用于说明维度，不冒充课程截图或实测结果。

检查点：统计量是 (100,)；代码里若出现 (32,1)，多半是把统计轴选错了。

初始化解决什么问题

若一层有 fan-in 个独立输入，直接乘大量未缩放的随机权重可能把方差放大。课程从 `1/sqrt(fan_in)` 入手，再讨论 tanh 的增益约 5/3。它依赖具体激活和网络结构，不能把 tanh 的系数抄到所有激活上。

最后一层较小的权重可以让初始概率接近均匀；不宜把所有层都初始化成零，否则同层神经元可能保持对称。初始化参数改变后，要重新初始化整套模型再比较，而不是接着已经训练过的权重往下跑。

BatchNorm 的状态必须跟着模型保存

```
# 示意：二维输入 (batch, features)，本段用于说明数学操作
mean = x.mean(0, keepdim=True)                # 每个特征在批内的均值
var = x.var(0, keepdim=True)                  # 每个特征在批内的方差
xhat = (x - mean) / torch.sqrt(var + 1e-5)  # 减均值、除标准差（加 eps 防除零）
out = gamma * xhat + beta                     # 再乘可学习的缩放与平移
```

这是课程自写层的思路。方差究竟除以 n 还是 n−1 必须与对应实现一致；原生 PyTorch 的训练与运行统计也有各自约定，不能只因为名字一样就宣称数值逐位相同。第 5 课会专门展开 Bessel 校正。

batch 里不同例子通过均值和方差耦合。若生成单个例子时仍算批统计，结果会改变甚至无法得到合理方差；生成不应依赖恰好一起生成了哪些其他名字。测试时要关掉自写层的 `training`，并使用训练期累计的统计量。

四组诊断图的读法

看什么	异常线索	下一步检查
tanh 输出分布	多数输出接近 ±1 或全挤在 0	输入尺度、初始化增益、归一化
各层梯度分布	越往前越小或越大	链式乘积、饱和、尺度
参数与梯度尺度	某层比其他层异常突出	参数初始化与层的角色
更新/参数比	更新几乎没有或一步改得过大	学习率与优化方式

课程把大约 10^{-3} 级的更新/参数比作为经验观察，不是必须达到的通用验收线；不同优化器、偏置和归一化参数不能一刀切。线性层叠加但没有非线性，仍等价于一个线性变换，不能靠堆层得到同样表达能力。

课程还展示了 ResNet50 中 Linear/Conv、BatchNorm、残差等模块的使用，目的是认识稳定深网络的方法，不要求在这一节重写图像分类系统。主实验继续用名字数据。

- [ ] 保存四类诊断记录，不以一张平滑 loss 图替代内部检查。

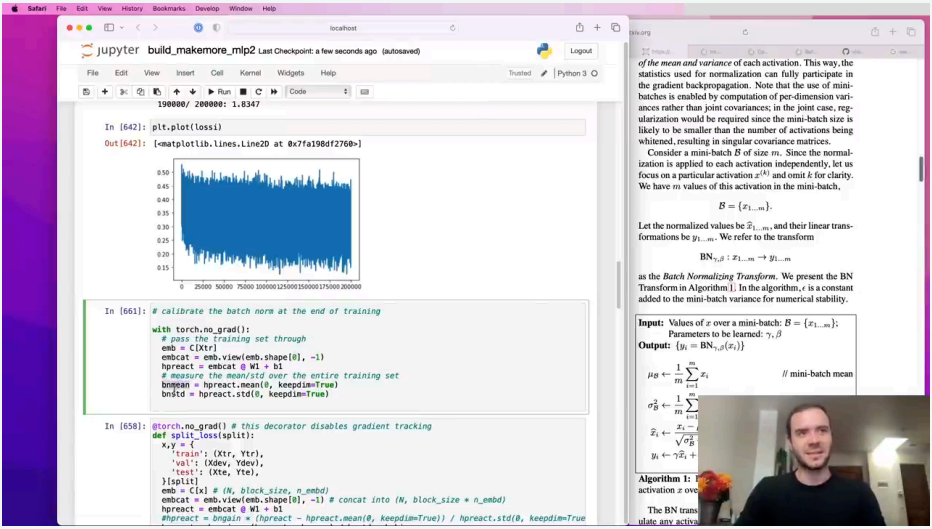

图注：真实课程截图，2026-10-29 提取，第4课 00:56:00；用于对照本节讲解，不替代代码和梯度核验。[O4]

卡住时按这个顺序查

按现象列出先查什么、修好后怎么验。这些路径来自课程故障与代码整理，同一个报错不保证只有一个原因；先定位影响的是数据、数学、状态还是系统性能，再回到上面的操作，不靠同时换五个参数碰运气。

现象	先查什么	修好后怎么验
tanh 大多为 ±1	初始化尺度、输入方差	饱和率与层间梯度
BN 单样本生成出错	training 标记、running stats	eval 后单个和批量行为合理

课程里出现过的一个真实案例

案例 4｜tanh 饱和

- 起点与做法：初始 loss 约27且隐层饱和，调尺度
- 讲者当时的结果：减少浪费的早期优化
- 可借鉴：先诊断分布
- 出处：第4课 00:04:19 起 [O4]

这是课程演示，数字不是你在自己机器上的复现结果。

原课练习（官方英文原文）

下面是作者在视频说明里给学习者的练习指令，保留英文原文，不冒充聊天提示词。建议先独立完成，再看对应代码；中文只用于说明它落在本步骤的哪一段。

第 4 课原练习

[O4]

- E01: I did not get around to seeing what happens when you initialize all weights and biases to zero. Try this and train the neural net. You might think either that 1) the network trains just fine or 2) the network doesn't train at all, but actually it is 3) the network trains but only partially, and achieves a pretty bad final performance. Inspect the gradients and activations to figure out what is happening and why the network is only partially training, and what part is being trained exactly.
- E02: BatchNorm, unlike other normalization layers like LayerNorm/GroupNorm etc. has the big advantage that after training, the batchnorm gamma/beta can be "folded into" the weights of the preceeding Linear layers, effectively erasing the need to forward it at test time. Set up a small 3-layer MLP with batchnorms, train the network, then "fold" the batchnorm gamma/beta into the preceeding Linear layer's W,b by creating a new W2, b2 and erasing the batch norm. Verify that this gives the same forward pass during inference. i.e. we see that the batchnorm is there just for stabilizing the training, and can be thrown out after training is done! pretty cool.

中文对照

- E01：这个视频里我没来得及看“把所有权重和偏置都初始化为零”会怎样。试一下并训练网络。你可能以为 1) 网络正常训练，或 2) 完全不训练；实际上是 3) 网络会训练，但只部分训练，最终效果很差。检查梯度和激活，弄清发生了什么、为什么只部分训练、究竟哪一部分在被训练。
- E02：BatchNorm 与 LayerNorm/GroupNorm 等归一化层不同，它的一大优势是：训练完之后 gamma/beta 可以“折叠进”前面 Linear 层的权重，测试时就不必再前向 BatchNorm。搭一个带 BatchNorm 的小型 3 层 MLP，训练后新建 W2、b2，把 gamma/beta 折叠进前一层 Linear 的 W、b，并去掉 BatchNorm，验证推理时前向结果完全相同。也就是：BatchNorm 只是为了稳定训练，训练完就能扔掉——挺酷。

本步对应的课程章节与时间定位

第 4 课 | Building makemore Part 3: Activations & Gradients, BatchNorm
（搭 makemore 第 3 部分：激活、梯度与 BatchNorm）

英文自动字幕约 21,386 词；逐字稿；主线步骤。

起点	原章节标题	视频定位
00:00:00	intro（开场介绍）	播放
00:01:22	starter code（起始代码）	播放
00:04:19	fixing the initial loss（修初始损失）	播放
00:12:59	fixing the saturated tanh（修 tanh 饱和）	播放
00:27:53	calculating the init scale: “Kaiming init”（计算初始化尺度：Kaiming 初始化）	播放
00:40:40	batch normalization（批归一化）	播放
01:03:07	batch normalization: summary（批归一化小结）	播放
01:04:50	real example: resnet50 walkthrough（真实例子：过一遍 ResNet50）	播放
01:14:10	summary of the lecture（本节小结）	播放
01:18:35	just kidding: part2: PyTorch-ifying the code（开个玩笑：第二部分，把代码改成 PyTorch 写法）	播放
01:26:51	viz #1: forward pass activations statistics（图 1：前向激活统计）	播放

起点	原章节标题	视频定位
01:30:54	viz #2: backward pass gradient statistics（图 2：反向梯度统计）	播放
01:32:07	the fully linear case of no non-linearities（完全没有非线性的纯线性情形）	播放
01:36:15	viz #3: parameter activation and gradient statistics（图 3：参数的激活与梯度统计）	播放
01:39:55	viz #4: update:data ratio over time（图 4：更新量与参数值之比随时间变化）	播放
01:46:04	bringing back batchnorm, looking at the visualizations（加回 BatchNorm，再看这些图）	播放
01:51:34	summary of the lecture for real this time（这次真的小结）	播放

步骤 6 不用 autograd 写完整 MLP 反向传播

这一课的练习是亲手算出 tensor 的梯度。先让每个中间变量都对上，再把公式合并；跳到最后一行公式容易把广播与求和方向背反。

目标：手算 CE、Linear、tanh、BatchNorm、embedding 的梯度，并与 PyTorch 逐项对照。

1. 打开 `makemore_part4_backprop.ipynb`，运行数据与初始化，保留拆开的前向变量。给中间张量 `retain_grad()`，只用一次 autograd 建参考答案；先不看后面的手写实现。第 5 课 00:07:26–00:13:01。[O5、O10]
2. 从 `loss=-logprobs[range(n),Yb].mean()` 倒推 log、归一化、exp、减最大值各步。被选中的真实类别初始梯度为 `-1/n`，其他位置为 0；每次做完用 `cmp` 看形状、近似一致和最大差值。[O5]
3. 穿过第二线性层、tanh、BatchNorm、第一线性层。广播在反向中要沿被扩展的维度求和；BN 的均值、方差两条路径都贡献梯度，不能只对单个元素求导。[O5]
4. 反传到 embedding 表时，把同一个字符在多个位置收到的贡献累加。逐项通过后，用合并的 CE 与 BN 公式替换冗长实现，最后在 `torch.no_grad()` 中训练，仅用自己算出的梯度更新。[O5]

> **做完的标准**：全部参与计算的参数与关键中间量梯度形状正确；与 autograd 在说明的容差内接近；去掉 `loss.backward()` 后训练仍能下降。

白话说明：暂时关掉自动挡，自己把每层的梯度算出来

步骤 2 处理单个数；这里一次处理一整批矩阵。你仍在应用同样的链式法则，但要处理转置、广播和重复索引。先拿 autograd 做参考答案，再独立计算；最后才把训练里的自动反传撤掉。

先打开：`makemore_part4_backprop.ipynb`。从头运行到拆开的前向计算，先不执行答案区。保留课程中的中间量名称，不急着把长公式压成一行。

先把这一步想成一个生活场景

之前用自动洗衣机洗衣服，现在打开透明盖子，亲手跟踪每道工序怎样影响最终结果。这里仍然是步骤 2 的链式法则，只是一个数字变成整张表。我们保留自动求导作为参考答案，再检验自己的逐层计算。

怎么读这一节： 先读每个操作前的故事与具体数字，再运行原有代码。代码成功只是程序完成了动作；能回答“停一下”的问题，才说明你知道它在做什么。下面的场景和小数字是助手编写的教学例子。

先把关键词翻成看得见的东西

关键词	白话意思	本步的具体样子
张量	有形状的一组数	这里常见二维矩阵
转置 .T	把行与列互换	3×2 变成 2×3
广播	一份数被重复用于多处计算	偏置 b 加到每一行
上游梯度 G	来自后面工序的敏感度	告诉本层输出各格怎样影响 loss
dW / dX	最终 loss 对 W / X 的导数	不是 W 或 X 的当前值
容差	允许的微小数值差	浮点数顺序不同可能有微小误差
scatter 累加	把多次使用的贡献送回同一行	同一字符名牌被查了多次

操作 A：先对最简单的线性层练一次

场景：四个顾客共用一张收费规则表。 X 有四行，每行三个输入；W 把三个输入混成两个输出；同一个偏置 b 被每位顾客都使用。后面传回的 G 告诉我们四行两列的输出各有多敏感。

先缩成单个数： 如果 `Y=2*w+b`，来自后面的梯度是 3，那么 w 收到 `2*3=6`，b 收到 3。矩阵公式只是同时处理很多这样的乘法和累加。

停一下： 为什么 db 要沿四行求和？因为同一份 b 在四条路径里都参与了计算。

下面代码完整演示“自动答案”和“手算答案”怎样放在一起比：

```
import torch
torch.manual_seed(42)
# 固定随机种子，结果可复现
X = torch.randn(4, 3, dtype=torch.float64,
requires_grad=True)   # 输入，双精度更便于比对
W = torch.randn(3, 2, dtype=torch.float64,
requires_grad=True)   # 权重
b = torch.randn(2, dtype=torch.float64,
requires_grad=True)      # 偏置
Y = X @ W + b
# 前向：Y = XW + b
G = torch.randn_like(Y)
# 假造的上游梯度
loss = (Y * G).sum()
# 造一个标量 loss
loss.backward()  # 参考答案，仅此处使用
# 让 PyTorch 算一遍梯度
with torch.no_grad():
# 下面自己算，不记录梯度
    dX = G @ W.T
# 手算 dX = G·Wᵀ
    dW = X.T @ G
# 手算 dW = Xᵀ·G
    db = G.sum(0)
# 手算 db = G 按列求和
    for name, manual, auto in [('X',dX,X.grad),
('W',dW,W.grad),('b',db,b.grad)]:
```

```
        print(name, manual.shape, (manual-
auto).abs().max().item())   # 比形状与最大差
```

`loss=(Y*G).sum()` 让 Y 收到的梯度恰好是 G，方便单独考核这一层。结果应接近0差异。db 对批维求和，因为同一份偏置在4行都被使用。

操作 B：回课程，从 loss 开始往回走

场景：按工序倒查一张总账。 从最终 loss 开始，先核最后一道工序，再核它的输入，逐站往前。手算值第一次与自动答案明显不一致的位置，就是优先检查的地方。

你实际做的事： 比较形状，再比较最大绝对误差。例如期望 `(3,2)` 却得到 `(2,3)`，先看转置；形状一样但都差 32 倍，先看有没有忘记批平均。

停一下： 最后一个权重梯度错了，是否一定是它自己的公式错？不一定，后面某站传来的 G 也可能已经错了。

先给需要比较的中间张量 `retain_grad()`，运行一次自动反传并保留参考结果。每手算一个中间量，就用课程的 `cmp` 比较形状和最大绝对差。最先出现明显偏差的那一步，比最后参数错多少更能定位问题。

顺序是交叉熵、输出线性层、tanh、BN、输入线性层、embedding。前向 mean 在反向中会带来除数；广播在反向中变成求和；重复字符索引在反向中必须累加。

操作 C：重点拆 BN，别直接背压缩公式

场景：一个人的身高变了，不仅改变他自己，也会改变全班平均身高。 BN 中一个输入参与自己的输出，也参与整批均值和方差，所以不能只走“自己那一条路”。各条路径贡献必须加起来。

你实际做的事： 先拆均值、减法、平方、求和、开方、除法。课程方差用 n−1，就要对那一个具体前向公式求导；换分母后参考答案也会变。

停一下： 为什么不能凭记忆抄一条 BN 反传公式？因为具体定义和归一化约定可能不同。

同一个输入既影响自己的标准化结果，也影响整批的均值和方差，因此有多条路径。课程前向方差采用 n−1 分母，手写反向必须匹配；改成 n 分母就不能沿用同一答案。先通过原子运算版本，再比较合并版本。

操作 D：手写梯度驱动训练

场景：验算通过后，才把自动挡换成手动挡。 自动答案是对照，不应又额外参与一次梯度更新。训练副本用你算出的梯度更新对应参数，保持每轮重新前向和正确清零。

你实际做的事： 先让一个小批完成一次更新，再观察多次更新的损失。参数变动并不自动证明导数正确，必须和前面局部对照一起看。

停一下： 梯度是手写的，是否就不需要验证集？仍然需要；求导正确与泛化良好是两种不同检验。

全部局部对齐后，才在训练副本去掉 `loss.backward()`，用自己计算的 dC、dW 等更新对应参数。训练完成后按原步骤用训练集校准 BN 统计，再进行验证和采样。

遇到差异怎么办：形状不对先查转置和 sum 维度；差一个固定倍数先查 batch 平均与 n−1；只有重复字符出错先查累加。浮点误差很小但逐位不同，记录容差与运算顺序，不盲目追求 `exact=True`。

卡住时先找哪一站

看到的现象	先检查什么
形状不对	检查转置、广播及求和轴
差一个固定倍数	检查平均、batch 大小与 n−1
仅重复字符时出错	检查是否覆盖了本应累加的梯度

说明与衔接：本段是助手基于本步骤课程与代码整理的动手导读；微型例子只解释相应局部机制。继续按下面原有课程讲解、截图与验收要求完成该步。

空间转化：把步骤 6 摆到一张图里

把前向画成左到右的矩阵管线，反向从右到左返回同形状的梯度。共享偏置像多条支路连到一个共同盒子，回程要汇总；embedding 重复索引也是多条支路回到同一行。箭头代表计算依赖，不代表数据在真实硬件上的物理路线。

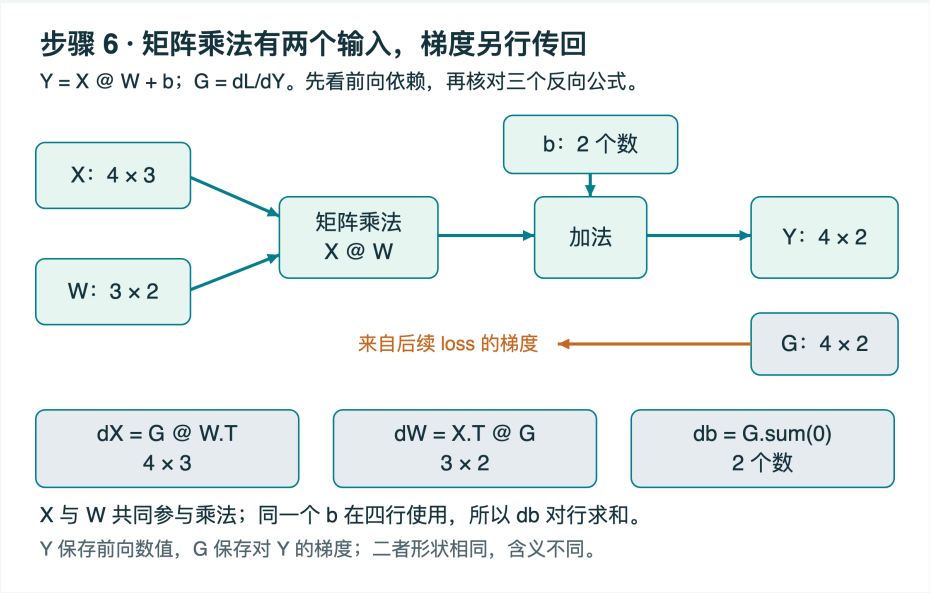

图注：助手绘制的教学示意，2026-11-09；帮助理解本步的计算关系与操作顺序。图中教学数字与简化结构不冒充课程截图、模型实测性能或完整实现。

试着用手指读图： 先指出输入或起点，再沿依赖找到中间处理，最后指出输出或结果记录。停在每一站，说出“这里放的是什么、对它做了什么、什么东西会改变”。如果遇到反向箭头，要说明它传回的是梯度，还是图中另有注明的流程。

再用一句话检查自己： 遮住正文，只看图，解释这一节与上一步相比新增加了什么；然后回到本步的小实验核对。会复述图并不代替实际运行和数值验收。

形状阶梯：前向多大，反向就多大

前向从左走到右，反向沿同一条路回来；每一站拿到的梯度与那一站的输出同形状。dW 与 W 同形、db 与 b 同形；广播过的地方反向要求和，重复索引过的地方反向要累加。

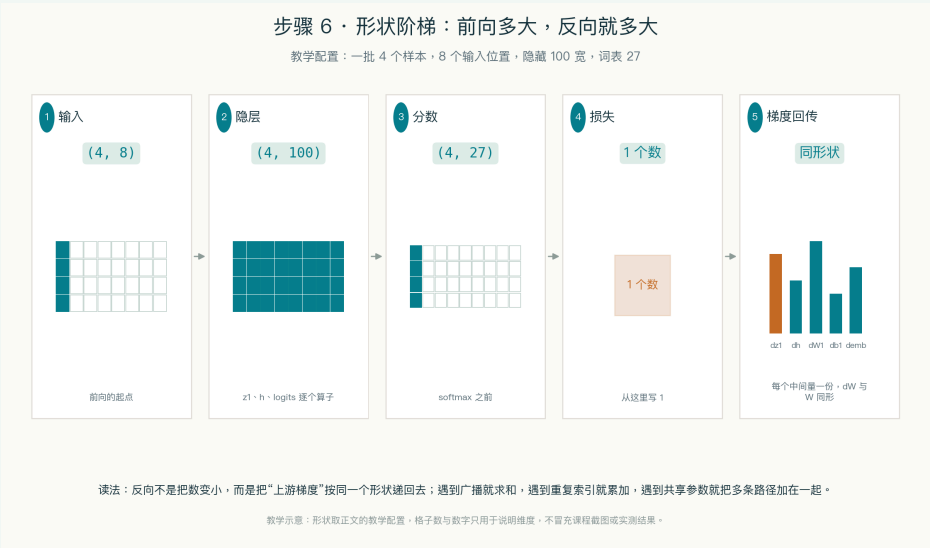

图注：助手绘制的教学示意，2026-11-10；教学配置：4 个样本、8 个位置、隐藏 100 宽、词表 27。格子数与数字只用于说明维度，不冒充课程截图或实测结果。

检查点：写出任意一层的参数形状，再写出它梯度的形状，两者应当一致。

先记住两个矩阵关系

对 `Y=X@W+b`，给定上游梯度 G：`dX=G@W.T`，`dW=X.T@G`，`db=G.sum(0)`。先检查维数能否回到原参数形状，再检查数值；形状相同仍可能把 n 与 n−1 混用。

```
# 合并的 softmax + 交叉熵反传；n 是 batch 大小
# 此段操作独立张量，不覆盖随后还要使用的概率引用

dlogits = F.softmax(logits, dim=1)      # 先算概率
dlogits[range(n), Yb] -= 1              # 正确类别那一格减 1（交叉熵的导数）
dlogits /= n                            # 平均损失，所以要除以 n
```

这来自平均 CE 的梯度。若 loss 使用 sum，不能再除以 n。若对同一 probs 对象原地减 1 后还用来绘图或计算其他梯度，会污染后续计算。

BN 必须与同一个前向配对

课程这一练习的方差使用 `1/(n-1)`，不是 `1/n`。对应压缩形式包含 `n/(n-1)`；如果前向改了定义，反向也必须重新推导。小常数 eps 在倒数平方根里面，反传时不能漏掉。

```
# 对应课程 n-1 方差版本；上游 dhpreact 与前向 bnraw、
bnvar_inv 已存在

dhprebn = bngain * bnvar_inv / n * (   # 先过缩放、
再乘 1/√方差
    n * dhpreact - dhpreact.sum(0)     # 均值那条路
径：减掉批内总和
    - n / (n - 1) * bnraw * (dhpreact *
bnraw).sum(0)   # 方差那条路径：n-1 校正
)
```

`exact=True` 需要运算顺序和浮点舍入也一致。课程的合并 CE/BN 公式可能只有 `approximate=True`，差值很小；先以误差量级判断，再查是否因运算重排造成。不要为了追逐逐位相同，改掉数学上正确的公式。

全手写训练后先校准 BN，再验证与采样

这一课的手写训练循环没有维护 running mean/variance，不能在结束时直接使用最后一个微批次的统计。作者在训练结束后用全部训练集做一次前向，固定隐层线性输出的均值与方差，再将同一组 bnmean/bnvar 用于验证、测试与生成。对应官方笔记本 cell 24–27。[O5、O10]

```
# 在手写训练完成之后执行；只使用训练集估计，不读取验证集
with torch.no_grad():                          # 只是
统计，不建计算图
    emb = C[Xtr]                               # 训练
集查表
    embcat = emb.view(emb.shape[0], -1)        # 展平
    hpreact = embcat @ W1 + b1                 # BN 之
前的那一层输出
    bnmean = hpreact.mean(0, keepdim=True)  # 用整
个训练集估计均值
    bnvar = hpreact.var(0, keepdim=True,
unbiased=True)   # 估计方差（n-1 校正）
```

随后使用 `(hpreact-bnmean)/sqrt(bnvar+1e-5)` 及训练得到的 bngain/bnbias 做验证/采样。保存这组校准统计；复评同一验证集时不要再随新batch改变它们。这是本课手写版本的做法，与上一课持续累计运行统计的版本分开。

embedding 是散回去的累加

`emb=C[Xb]` 的反向不是把 dC 直接赋成 demb；Xb 中同一字符可以重复出现。先用双循环 `dC[ix] += demb[k,j]` 写对，再考虑向量化。这个问题与 micrograd 的 `a+a` 是同一种“多路径累加”。

完成原子图练习后，再做合并 CE、合并 BN、全手写训练四个练习。已有参考梯度不等于已经学会；建议关掉答案从空白再写一次，把第一次出错的维数和修改原因记入记录。

- [ ] 保存逐项 cmp 输出和自写梯度训练曲线。

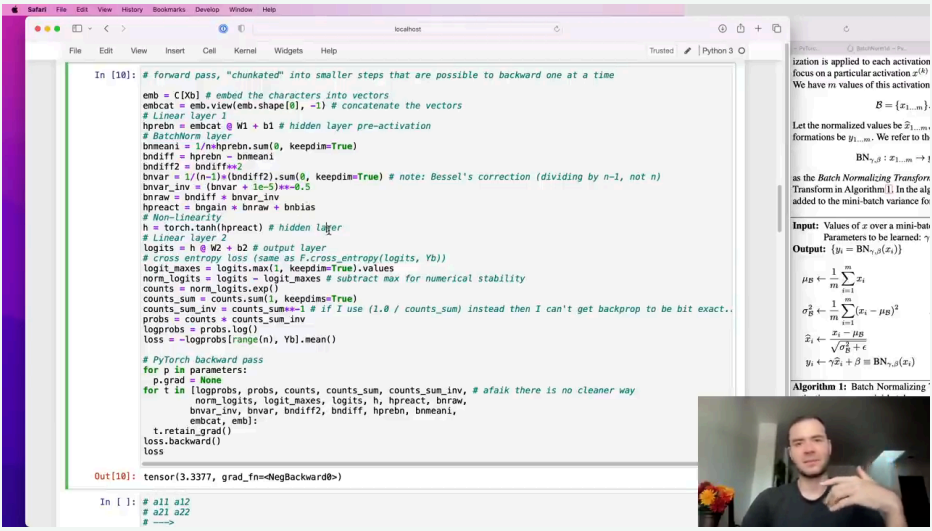

图注：真实课程截图，2026-10-29 提取，第5课 01:09:40；用于对照本节讲解，不替代代码和梯度核验。[O5]

卡住时按这个顺序查

按现象列出先查什么、修好后怎么验。这些路径来自课程故障与代码整理，同一个报错不保证只有一个原因；先定位影响的是数据、数学、状态还是系统性能，再回到上面的操作，不靠同时换五个参数碰运气。

现象	先查什么	修好后怎么验
手写梯度不一致	广播反向求和、mean 的 n、BN 的 n−1	从第一个差异变量向上游查
embedding 梯度丢失	同一个 ID 是否多次出现、是否 +=	重复字符累加后对照 autograd

课程里出现过的一个真实案例

案例 5｜手写 CE/BN

- 起点与做法：拆开算再合并，对照 autograd
- 讲者当时的结果：近似可一致，不必逐位一致
- 可借鉴：数学与浮点顺序分开
- 出处：第5课练习 [O5]

这是课程演示，数字不是你在自己机器上的复现结果。

本步对应的课程章节与时间定位

第 5 课｜Building makemore Part 4: Becoming a Backprop Ninja（搭 makemore 第 4 部分：成为反传忍者）

英文自动字幕约 20,776 词；逐字稿；主线步骤。

起点	原章节标题	视频定位
00:00:00	intro: why you should care & fun history（开场：为什么值得关心，以及一段有趣的历史）	播放
00:07:26	starter code（起始代码）	播放
00:13:01	exercise 1: backproping the atomic compute graph（练习 1：对原子计算图做反传）	播放
01:05:17	brief digression: bessel's correction in batchnorm（插一段：BatchNorm 里的贝塞尔校正）	播放
01:26:31	exercise 2: cross entropy loss backward pass（练习 2：交叉熵损失的反传）	播放
01:36:37	exercise 3: batch norm layer backward pass（练习 3：BatchNorm 层的反传）	播放
01:50:02	exercise 4: putting it all together（练习 4：全部串起来）	播放
01:54:24	outro（收尾）	播放

步骤 7 用层级结构扩大上下文

把更多字符一次性压进一层会很快失去结构。这里让相邻字符先成组，再逐层融合，观察“参数数量相近”和“结构不同”到底带来什么变化。

目标：实现 WaveNet 风格层级模型，并修复三维 BatchNorm 的隐性错误。

1. 回到第 4 课的自写层代码，封装 Embedding、FlattenConsecutive 和 Sequential。把所有参数通过统一接口收集；确认中间张量保留方法不会忘掉某层。第 6 课 00:01:40–00:17:11。[O6]
2. 把上下文从 3 改为 8，先跑平铺 MLP 基线。然后每次合并相邻两个位置，序列长度从 8 到 4、2、1；记录每层 `(B,T,C)` 的变化。[O6]
3. 检查 BN 在三维输入上按哪些维度求统计。若 x 为 `(B,T,C)`，该课程实现应跨 B 与 T 统计每个通道，即 `dim=(0,1)`；不能因广播没报错就沿用二维的 `dim=0`。[O6、O10]
4. 在近似相同参数量下比较平铺与层级结构，再单独增大 embedding 与隐层。平滑曲线用于阅读，同时保留原始 train/val 数据，不把一次略好的结果当作统计结论。[O6]

> **做完的标准**：能画出 8→4→2→1 形状；三维 BN 的统计方向正确；保存相同预算下的基线与层级对比，结果不佳也如实登记。

白话说明：把八个字符两两分组，再逐层汇总

这一步在改变“信息怎样组合”。你可以想成八个人先两两讨论，再让小组汇报继续合并。每一层都用同样的局部规则加工各组，最终汇总全部八个位置的信息。

先打开：`makemore_part5_cnn1.ipynb`。先保留一个上下文长度为8的平铺 MLP，作为比较对象。

先把这一步想成一个生活场景

八个人一起汇报很乱，于是先两人一组，再让两组的汇报合并，最后得到整体汇报。网络也可以先组合近邻字符，再逐层扩大能看到的范围。这里学的是一种信息组合结构，不是把人真的派来讨论。

怎么读这一节： 先读每个操作前的故事与具体数字，再运行原有代码。代码成功只是程序完成了动作；能回答“停一下”的问题，才说明你知道它在做什么。下面的场景和小数字是助手编写的教学例子。

先把关键词翻成看得见的东西

关键词	白话意思	本步的具体样子
B / T / C	样本数 / 位置数 / 通道数	三维张量的三个方向
分组拼接	把相邻位置的数字放在一起	两个 D 维位置拼成 2D 维
层级表示	先处理小片段，再处理大片段	8 个位置逐层变 4、2、1
共享权重	各组用同一套加工规则	不是每组各造一套参数
感受野	一个输出能受到哪些输入影响	逐层覆盖更多历史位置
统计轴	沿哪些方向收集 BN 统计	此处同时沿 B 和 T

操作 A：先用序号演示分组，确认没把不同名字混在一起

场景：两张桌子各有八张号码卡。 第一桌从 0 到 7，第二桌从 8 到 15。每桌自己两两分组，不能拿第一桌最后一张和第二桌第一张凑一对。B 这个维度就是分清桌子。

你实际做的事： 运行 reshape 后逐组读数字。如果出现 [7,8]，说明你让两条样本混了。此处用序号而非随机数字，是为了让错误一眼可见。

停一下： reshape 有没有求平均？没有，它只是重新组织相同的数字。

```
import torch
x = torch.arange(16).reshape(2, 8, 1)   # 2 条样本、每条 8 个位置、1 维
print('原始: ', x)
grouped = x.reshape(2, 4, 2)            # 每两个相邻位置拼成一个 2 维
print('两两分组: ', grouped)
```

第一条样本应组成 `[0,1] [2,3] [4,5] [6,7]`；第二条是 `[8,9] [10,11] [12,13] [14,15]`。跨样本的7与8不能成为一组。

操作 B：换成可学习的字符表示

场景：先把两份笔记夹在一起，再请一个加工工位写新摘要。 拼接保留两边全部数字，线性层和非线性才负责学怎样混合。第一轮 8 个位置变成 4 组，第二轮变 2 组，第三轮变 1 组。

你实际做的事： 每层打印 B、T、C，观察 B 不变，T 变小，拼接瞬间 C 变大。经过线性层后 C 可以被投影成设定的 H。

停一下： 只连续 reshape 三次是否已经学到高级特征？没有，必须有可训练的加工和训练数据。

把整数序号换成 embedding 后，形状是 `(B,8,D)`。第一次拼接成为 `(B,4,2D)`，线性层加工为 `(B,4,H)`；第二次分组为 `(B,2,2H)`，再加工；第三次合并到单个位置。每层都打印 shape，追踪 T 如何从8到4、2、1。

这里的“分组”本身只是重排；真正学习信息怎样组合的是后面的线性层和非线性。不要只 reshape 几次就以为已经训练了层级表示。

操作 C：修正三维 BatchNorm 的统计轴

场景：统计一种仪表读数，要收集所有桌子、所有座位上的这种仪表。 C 表示不同通道，B 和 T 表示同种通道出现在哪些样本与位置。按课程设计，BN 对每个通道收集 B×T 个数。

你实际做的事： 检查 `dim=(0,1)`，并确认结果可以广播回原张量。不要把通道轴一起平均掉，否则不同通道就共用了一把错误标尺。

停一下： 为什么三维输入不能盲目沿用二维时的统计代码？因为多出来的位置轴也参与了这次统计设计。

在 `(B,T,C)` 上，按课程设计对 `dim=(0,1)` 求每个通道的均值/方差。打印统计量形状并检查它是否对所有样本和位置共享，而不是为每个位置分别保留一套意外统计。

操作 D：比较模型，保留不成功的结果

场景：两种学习方法比赛，题目和练习时间要相近。 层级结构听起来合理，但未必立即优于平铺网络。先固定切分和预算，再比较验证 loss。

你实际做的事： 把结构、参数量、训练量写在结果旁边。更大的网络得分更好时，不能全归功于“分组”；需要单独控制规模继续比较。

停一下： 没有变好是不是白做了？不是；保存失败结果能说明这个设置下没有得到预期改善。

固定名字切分、token/样本预算与近似参数量，比较平铺与分组版本的验证 loss。再单独尝试增大 embedding 或隐层。层级更清楚并不保证在这份数据上立即更好；以记录为准。

本步的交付物：带每层形状的网络草图、三维 BN 的统计代码、两种模型的配置和验证结果。只有画出了8→4→2→1而没有训练/比较，算理解结构，还没完成实验。

卡住时先找哪一站

看到的现象	先检查什么
出现跨样本分组	检查 reshape 是否保留 B
通道维乘法报错	拼接后输入宽度应翻倍
图画对了但效果差	检查训练与公平对照，结构图不是效果证明

说明与衔接：本段是助手基于本步骤课程与代码整理的动手导读；微型例子只解释相应局部机制。继续按下面原有课程讲解、截图与验收要求完成该步。

空间转化：把步骤 7 摆到一张图里

把八个位置画成一排八片叶子，向上两两连接成四个节点，再连成两个、一个。每一层横着看的是组数，竖着看的是处理深度。这个树只表示依赖范围，并不证明每个节点真的学到了人类语言的词、短语或句法。

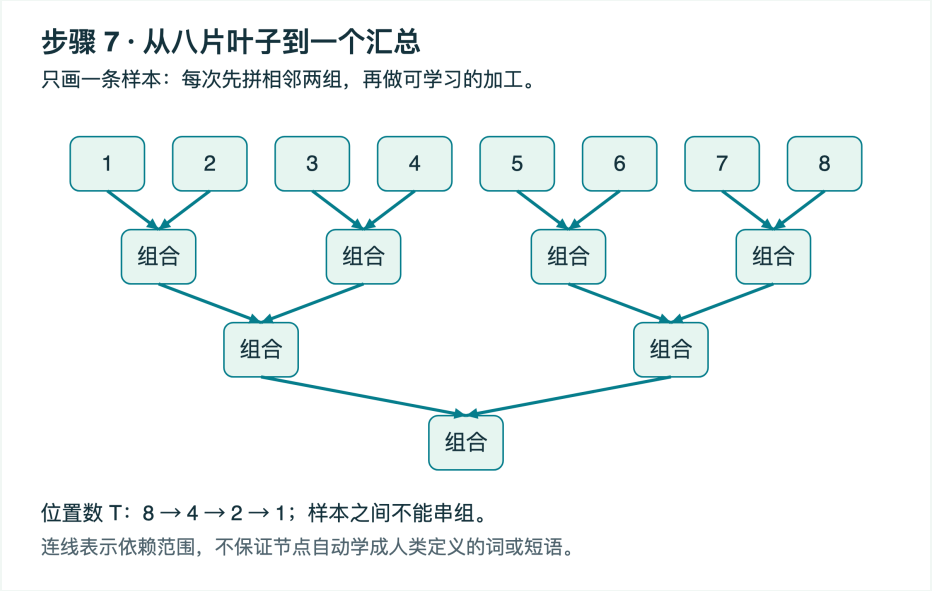

图注：助手绘制的教学示意，2026-11-09；帮助理解本步的计算关系与操作顺序。图中教学数字与简化结构不冒充课程截图、模型实测性能或完整实现。

试着用手指读图： 先指出输入或起点，再沿依赖找到中间处理，最后指出输出或结果记录。停在每一站，说出“这里放的是什么、对它做了什么、什么东西会改变”。如果遇到反向箭头，要说明它传回的是梯度，还是图中另有注明的流程。

再用一句话检查自己： 遮住正文，只看图，解释这一节与上一步相比新增加了什么；然后回到本步的小实验核对。会复述图并不代替实际运行和数值验收。

形状阶梯：两两分组，让每个格子看到更多字

分组只改摆法，不改元素总数：(4,8,2) 是 64 个数，(4,4,4) 还是 64 个；(4,4,100) 与 (4,2,200) 都是 1600 个。组数减半时宽度翻倍，信息没有被丢掉，只是换了排列。

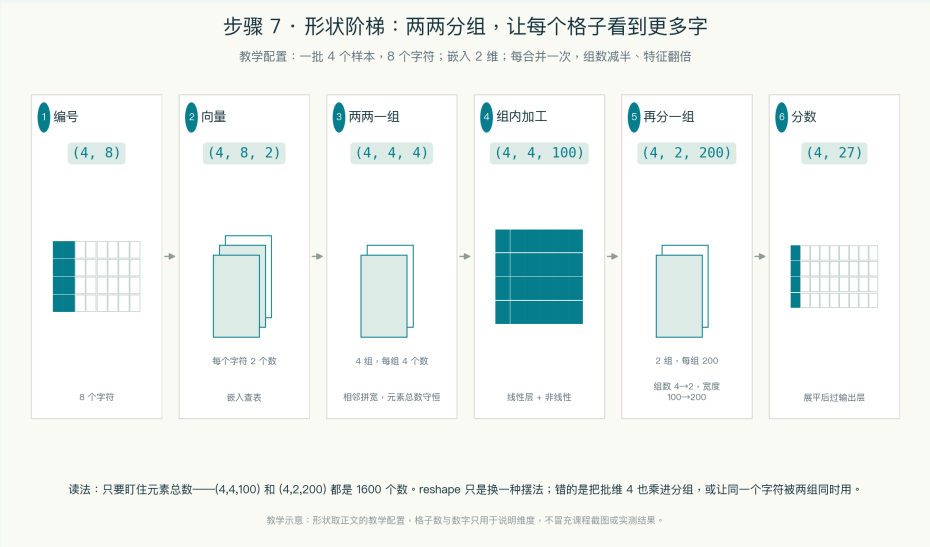

图注：助手绘制的教学示意，2026-11-10；教学配置：4 个样本、8 个字符、嵌入 2 维；每合并一次，组数减半、宽度翻倍。格子数与数字只用于说明维度，不冒充课程截图或实测结果。

检查点：每次 reshape 前后把元素数乘一遍，不相等就是错位了。

分组展平的核心

```
B, T, C = x.shape              # 批大小、序列长度、通道数
x = x.view(B, T // 2, C * 2) # 每两个时间步拼到通道维，长度减半、通道加倍
if x.shape[1] == 1:
    x = x.squeeze(1)           # 只剩一个时间步时去掉这一维，回到 (B, C)
```

前提是 T 可以被 2 整除，且数据排列符合相邻位置拼接。不能把 batch 也混进一个大向量，否则不同名字之间会互相污染。最后 squeeze 明确指定位置维，不要用无参数 squeeze 把 B=1 的 batch 维也删掉。

课程中的真实对比

讲者在相近约 22000 参数下，平铺与层级模型验证 loss 约 2.027、2.029，并没有立刻改善；修 BN 后约 2.022，扩大到约 76000 参数后约 1.993。差异来自课程当时的实验，讲者也保留了是否显著的疑问。这张对比应教你记录控制变量，而不是抄一个“必定提升”的结论。

这一节实现的是树状层级结构。原 WaveNet 中的门控、残差、skip connection 和高效 dilated causal convolution 并未完整实现；课程只预告了卷积如何避免相邻窗口重复计算。你不需要在这一阶段把视频的名字模型改成音频 WaveNet。

实验开始变慢后，要补实验框架：每次运行有参数、seed、训练/验证曲线和结果；不是在同一个笔记本里不断覆盖变量再凭记忆挑最好的图。

- ☐ 记录修复前后的 BN 维数与验证 loss。

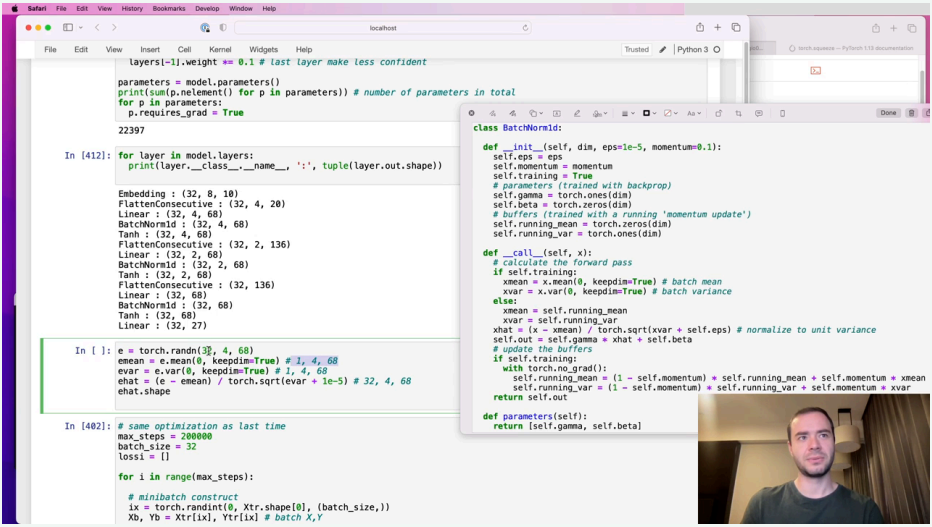

图注：真实课程截图，2026-10-29 提取，第6课 00:40:00；用于对照本节讲解，不替代代码和梯度核验。[O6]

步骤 8 从均匀聚合写到字符级 GPT

这一节把固定窗口 MLP 换成可以按内容选择历史信息的网络。重点是每个位置能看什么、信息如何混合；模型变大放在正确性之后。

目标：实现 decoder-only Transformer，在 Tiny Shakespeare 上训练与生成。

1. 在 `ng-video-lecture/gpt.py` 对照实现（视频 Colab 用于笔记本式推导），读取 Tiny Shakespeare，建立字符映射与 90%/10% 的连续文本切分。构造 `(B,T)` 输入及右移一位的目标；每个时间位置都是一个预测问题。第 7 课 00:07:52–00:38:00。[O7、O15]
2. 先写循环平均历史位置，再用下三角矩阵乘法实现等价聚合，最后用 masked softmax 得到相同结果。通过数值对照后，才引入可学习的 Q、K、V。[O7]
3. 用 token embedding 加 position embedding，写单头因果注意力，再并行多个头、拼接并投影。检查分数除以 `sqrt(head_size)`；只允许当前与过去位置，禁止看到未来目标。[O7]
4. 将注意力与逐位置 MLP 放进残差块，使用 pre-norm、LayerNorm 和 dropout。先用小配置训练/验证，再增大宽度、层数、上下文与迭代数；生成时只取最后位置 logits，采样后追加一个 token。[O7]

> **做完的标准**：三种均匀聚合数值一致；未来位置注意力为 0；训练与验证 loss 可记录；模型能持续生成；能说明为何它属于 decoder-only。

白话说明：让每个位置从过去挑选相关信息，再猜下一个字符

之前的网络靠固定组合方式处理上下文；注意力允许当前位置根据内容，给过去不同位置分配不同权重。因果限制要求只能看过去和自己，不能偷看未来答案。

先打开：学习副本 `code/ng-video-lecture/` 中的 `bigram.py`、`gpt.py` 和 `input.txt`。前者是较简单基线，后者是完整字符 GPT。二者顶层会启动训练，先编辑副本，再执行。

先把这一步想成一个生活场景

想象你在写故事，写到某个位置时，可以翻前面的笔记，挑有用的信息，但不能翻到尚未写出的后文。注意力就是给可见笔记分配不同份额，再把其中的信息合起来。这里的“注意”不是人的意识，而是一组可学习的数值运算。

怎么读这一节： 先读每个操作前的故事与具体数字，再运行原有代码。代码成功只是程序完成了动作；能回答“停一下”的问题，才说明你知道它在做什么。下面的场景和小数字是助手编写的教学例子。

先把关键词翻成看得见的东西

关键词	白话意思	本步的具体样子
token / 位置	本步的字符编号 / 它排在哪里	同一字符可以出现在不同位置
Q / K / V	查询 / 用于匹配的键 / 被汇总的内容	均由输入表示线性变换得到
注意力权重	各可见位置贡献多少的份额	每个查询位置的一行概率
因果 mask	挡住未来位置的遮板	未来分数设为负无穷后概率为零
head	一套独立的匹配与汇总通道	多个头可以学习不同模式
residual	保留输入并加上新处理结果	x + 新结果
LayerNorm	按单个位置的特征归一化	与 BN 依赖批统计不同

操作 A：只观察输入与目标错开一个位置

场景：盖住故事后半段，一字一字出题。 编号 [10,20,30,40,50] 可以产生四道题：看到 10 猜 20；看到 10、20 猜 30，依此类推。训练时四题一起算，但每题的遮板位置不同。

你实际做的事： 对齐输入 x 和右移一位的答案 y。先读打印结果，再读模型代码。x 和 y 一样会变成抄自己，不是续写。

停一下： 同时算四道题为什么不等于能偷看后文？因为每个位置的注意力都受到自己的 mask 限制。

```
ids = [10, 20, 30, 40, 50]      # 假想的 token 序列
x, y = ids[:-1], ids[1:]        # 输入是前 n-1 个，目
标是后 n-1 个
for t in range(len(x)):         # 逐个位置看：能看到多
少，要猜什么
    print('可见前文：', x[:t+1], '要猜：', y[t])   #
第 t 个位置只能看到前 t+1 个
```

数字只是假想字符编号。训练时可以同时计算四个位置的损失，但每个位置可见的前文长度不同。把 y 和 x 写成相同序列，会把续写题误写成抄写题。

操作 B：先看最简单的因果汇总

场景：先让所有可见笔记平分发言时间。 第一位置只能看自己，份额为 1；第二位置看两个，各分 1/2。随后让 Q 和 K 的匹配分数决定谁说得多，再用这些份额汇总 V。

具体数字： 若两个可见位置权重为 0.25、0.75，值分别为 2、6，则汇总结果是 5。实际 V 通常是一组数，这个加权过程对各维进行。

停一下： 权重是最终要输出的词吗？不是，它告诉我们怎样混合过去位置的信息。

```
import torch
scores = torch.zeros(4, 4)
# 4×4 的“注意力分数”，先全设 0
allowed = torch.tril(torch.ones(4, 4,
dtype=torch.bool))    # 下三角为 True：允许看自己和过去
weights = scores.masked_fill(~allowed, float('-
inf')).softmax(dim=-1)   # 未来位置填 -∞，再归一化
print(weights)
# 打印每行权重
```

四行分别近似为 `[1,0,0,0]`、`[1/2,1/2,0,0]`、`[1/3,1/3,1/3,0]`、`[1/4,1/4,1/4,1/4]`。矩阵上三角必须为0。接下来把原来全是0的 scores 换成 `Q@K.T/sqrt(head_size)`，模型就能学不同的权重。

操作 C：先跑 CPU 小版本，观察流程

场景：先用玩具轨道试车，再考虑长途运输。 小模型和 100 次更新用来发现数据、形状、训练循环是否接通。它可能输出乱字符，这时不能凭“不像人话”直接判整个实现错。

你实际做的事： 在副本里改小配置，核对每头宽度是 32/4=8，保存运行范围和 loss。先确认 CPU 路线可执行，不把课程的大训练预算默认搬到本机。

停一下： 小实验能运行是否证明完整模型已训练成功？只能证明这次小配置的路径跑通。

在 `gpt.py` 的副本中将配置改为：batch_size=4、block_size=32、max_iters=100、eval_interval=50、eval_iters=5、n_embd=32、n_head=4、n_layer=2、dropout=0.0、device='cpu'。32能被4整除，因此每头8维。末尾生成先改为 `max_new_tokens=100`。

在已激活环境的终端进入该目录运行 `python gpt.py`。这些是助手给的起步配置，只用来确认流程；100次更新后文字仍可能杂乱。保存初始/最终 loss、输出样本和耗时，不用流畅度作为唯一标准。

操作 D：把模块与问题一一对应

场景：一条流水线既要知道“是什么”，也要知道“在哪里”。 token embedding 提供字符表示，位置嵌入提供位置；注意力从可见历史取信息，MLP 在每个位置加工；残差让原输入还能进入后续计算。

你实际做的事： 沿 forward 给每个模块标输入与输出形状。再做遮板检查：保持前缀不变，只改未来字符，在 eval 状态比较前缀对应输出，应该不受未来内容影响（允许浮点微小差异）。

停一下： 注意力权重很大是否就是可靠的因果解释？不是，它只是模型内部汇总的一部分。

沿着 forward 阅读：token embedding 表示字符，position embedding 表示位置，attention 汇总可见位置，MLP 加工每个位置，residual 保留输入通路，LayerNorm 控制尺度，最后线性层给出下个字符 logits。

排错优先级：先检查 x/y 右移关系，再检查上三角掩码，再查头数是否整除宽度，最后查训练循环。某个前缀的输出若随着后面不可见字符变化而变化，应检查未来信息是否泄漏；做这个比较时先 `eval()` 关闭 dropout。

卡住时先找哪一站

看到的现象	先检查什么
模型能看见答案	检查 x/y 错位和上三角 mask
多头拼接报错	宽度应能被头数整除
前缀受未来字符影响	eval 后检查因果遮罩与其他跨位置运算

说明与衔接：本段是助手基于本步骤课程与代码整理的动手导读；微型例子只解释相应局部机制。继续按下面原有课程讲解、截图与验收要求完成该步。

空间转化：把步骤 8 摆到一张图里

把注意力画成座位表：行是“现在提问的位置”，列是“可查阅的位置”。对角线及左下侧可以看，右上侧被遮住。每行是一张独立的分配表；不要把一列加起来也必须为 1。箭头表示允许汇总的依赖，图上距离不等于语义距离。

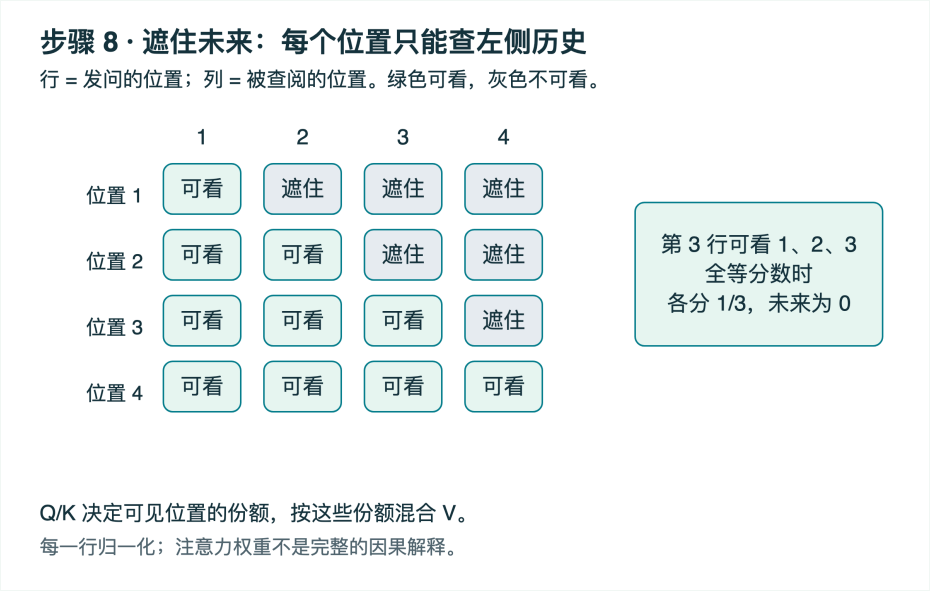

图注：助手绘制的教学示意，2026-11-09；帮助理解本步的计算关系与操作顺序。图中教学数字与简化结构不冒充课程截图、模型实测性能或完整实现。

试着用手指读图： 先指出输入或起点，再沿依赖找到中间处理，最后指出输出或结果记录。停在每一站，说出“这里放的是什么、对它做了什么、什么东西会改变”。如果遇到反向箭头，要说明它传回的是梯度，还是图中另有注明的流程。

再用一句话检查自己： 遮住正文，只看图，解释这一节与上一步相比新增加了什么；然后回到本步的小实验核对。会复述图并不代替实际运行和数值验收。

形状阶梯：从编号到上下文，再到 27 个分数

位置轴 8 全程不变；特征轴在 32 与 128 之间来回；最后一个轴才是词表 27。(4,8,4,8) 里的两个 8 不是一回事：前一个是位置，后一个是每个头的宽度。

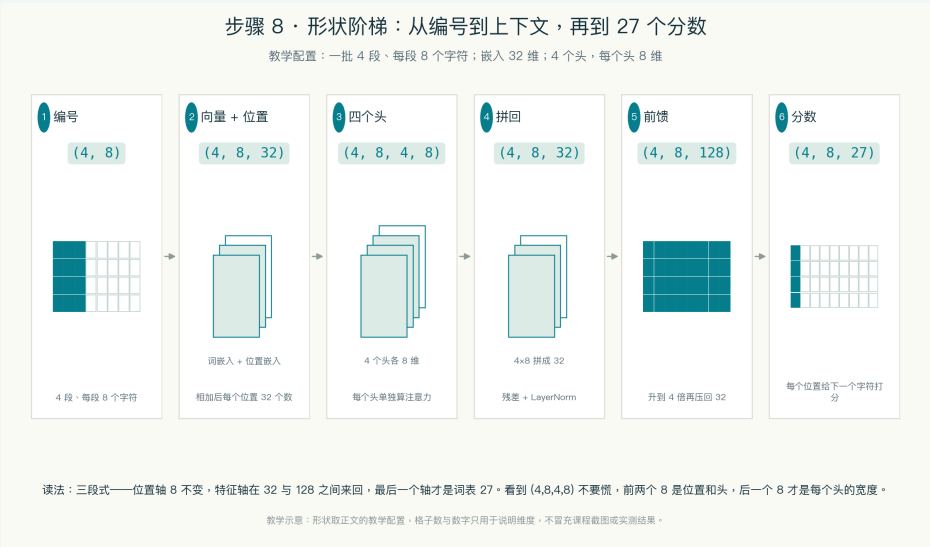

图注：助手绘制的教学示意，2026-11-10；教学配置：4 段、每段 8 个字符、嵌入 32 维、4 个头各 8 维。格子数与数字只用于说明维度，不冒充课程截图或实测结果。

检查点：看到四维形状，先说出每个轴的名字，再谈它有多少个数。

操作演示：先体验聊天模型的输入

以下按实验操作顺序放入课程已定位的输入。每条依次给出英文原文、中文提示词与抽象模板；中文为译文，模板由助手整理，〔〕为待替换变量。复现历史分词与生成实验时使用英文原文。

可先体验课程开场的短诗任务，再继续本节的字符 GPT 实现。[O7]

P01｜讲者聊天输入

来源：第7课 00:00:27；核对状态：screen_verified。[O7]

英文原文

```
Write a small haiku about how important it is that
people understand AI, and that they can use it to
improve the world and make it more prosperous.
```

中文提示词

```
写一首简短的俳句，表达让人们理解 AI 有多重要，以及人们可以如
何利用 AI 改善世界，让世界更加繁荣。
```

抽象模板（助手整理）

```
写一首简短的〔诗歌形式〕，表达〔需要读者理解的主题〕的重要性，
以及人们可以如何利用〔技术或方法〕实现〔希望带来的积极结果〕。
```

用于体验聊天模型的开场演示；本步骤实现的字符 GPT 不以此作为训练指令。

开场演示，不是训练 GPT 的提示词。

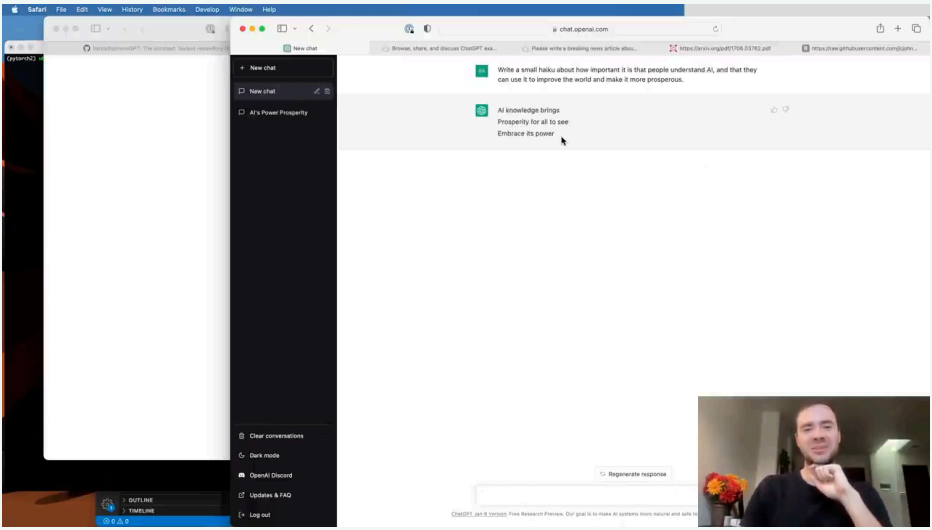

图注：真实课程截图，2026-10-29 提取，第7课 00:00:27；展示当时输入/输出及上下文，不代表当前模型行为。

数据对齐必须先过关

假设片段是 `[18,47,56,57,1]`，输入前四个，目标后四个。第一个预测位置只看到输入的第一个 token，而不是全部四个；最后一个位置看到全部四个。训练一次并行算 T 个 next-token 任务，不是让同一输入预测整串任意位置。

生成超出上下文长度时，先截取最后 `block_size` 个 token 再送模型。位置索引也从当前窗口重新生成；不要把越来越大的生成总长度直接拿去索引只有 block_size 行的位置表。

注意力的形状与方向

项	单头形状	含义
x	B×T×C	每个 token 当前表示
q、k、v	B×T×H	查询、被查询特征与被聚合内容
$q@k^T$	B×T×T	当前位置对历史位置的相似分数
softmax 后权重	B×T×T	每行是本位置读哪些位置
输出	B×T×H	按权重聚合 v

```
# 单头核心：q/k/v 由 x 经过不同 Linear 得到
wei = q @ k.transpose(-2, -1) * (k.shape[-1] **
-0.5)   # 相似度 = q·kᵀ，再乘 1/√head_size 缩放
mask = torch.tril(torch.ones(T, T,
device=x.device))    # 下三角为 1，上三角为 0（未来）
wei = wei.masked_fill(mask == 0, float('-inf'))
# 未来位置置 -∞
wei = F.softmax(wei, dim=-1)
# 每行归一化成权重
out = wei @ v
# 用权重加权求和 v
```

softmax 在最后一维归一化，每行总权重为 1。屏蔽未来用负无穷，exp 后变成 0；不是把分数填成 0，因为 exp(0)=1，仍会参与聚合。位置间的注意力发生在同一个样本内部，不跨 batch 混合。

Q/K/V 都来自同一个 x 是 self-attention；若 Q 来自当前序列、K/V 来自外部编码，才是 cross-attention。注意力本身不自带位置顺序，位置编码提供位置信息；掩码提供可见性约束，两者不是同一件事。

为什么需要后半段的模块

注意力完成 token 之间通信，MLP 在每个 token 内做非线性计算。残差相加为梯度与信息提供直达路径；LayerNorm 在单个 token 的特征维归一化，与前面跨 batch 的 BN 不同。多头让不同投影空间并行读取上下文，不是把相同结果复制几份。

每个头宽度通常为 `n_embd // n_head`，要求整除。输出拼接后要回到 n_embd，才能做残差相加。课程将 feedforward 隐层扩到约 4 倍再投影回来；更宽不等于训练必然更稳定。

dropout 在训练时随机置零部分贡献，评估时关闭。计算验证 loss 时用 `model.eval()` 和 `torch.no_grad()`，算完切回 `train()`。若忘记关 dropout，重复评估会带不必要随机波动。

文件与勘误

作者视频说明特别更正了两点：00:57:00 应为“未来 token 不能向过去通信”；01:20:05 的缩放分母应使用 head_size，而不是完整 C。自写实现以这两条更正为准，不能照抄视频中一闪而过的错误。

教学仓库的 `gpt.py` 默认是较大课程配置。仅做 CPU 验证时，在自己的副本先用 `batch_size=4`、`block_size=32`、`n_embd=64`、`n_head=4`、`n_layer=2`、`max_iters=20`、`eval_iters=2`；这是助手建议的短跑，不是课程最终训练结果。过关后再延长训练。

讲者原配置训练出的文本有戏剧式结构，仍不是会聊天的模型。第 7 课末尾解释了预训练、SFT、奖励模型和 RLHF 的区别，但没有在这 9 节中实现完整聊天训练流水线。

- [ ] 保存数据对齐样例、掩码检查、配置和生成原文。

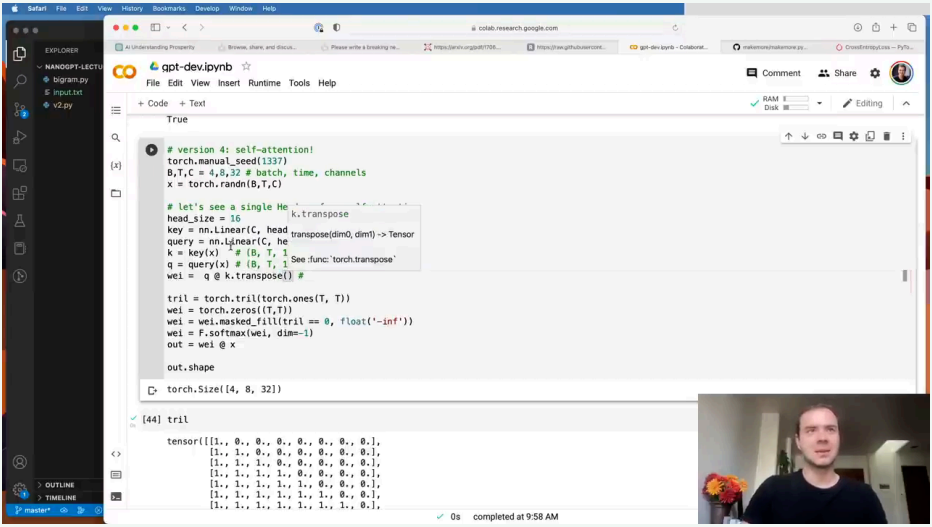

图注：真实课程截图，2026-10-29 提取，第7课 01:06:30；用于对照本节讲解，不替代代码和梯度核验。[O7]

卡住时按这个顺序查

按现象列出先查什么、修好后怎么验。这些路径来自课程故障与代码整理，同一个报错不保证只有一个原因；先定位影响的是数据、数学、状态还是系统性能，再回到上面的操作，不靠同时换五个参数碰运气。

现象	先查什么	修好后怎么验
GPT loss 看起来异常好	y 是否右移、是否泄漏未来	屏蔽未来，改未来 token 不改过去 logits
多头拼接后无法残差相加	head_size×heads 是否等于 C	每层都回到 B×T×C

课程里出现过的一个真实案例

案例 7 | 单头到多头 GPT

- 起点与做法：先均匀聚合，再学习注意力
- 讲者当时的结果：形成莎士比亚风格文本
- 可借鉴：中间等价实现要先过关
- 出处：第7课 [O7]

这是课程演示，数字不是你在自己机器上的复现结果。

原课练习（官方英文原文）

下面是作者在视频说明里给学习者的练习指令，保留英文原文，不冒充聊天提示词。建议先独立完成，再看对应代码；中文只用于说明它落在本步骤的哪一段。

第 7 课原练习

[O7]

- EX1: The n-dimensional tensor mastery challenge: Combine the `Head` and `MultiHeadAttention` into one class that processes all the heads in parallel, treating the heads as another batch dimension (answer is in nanoGPT).
- EX2: Train the GPT on your own dataset of choice! What other data could be fun to blabber on about? (A fun advanced suggestion if you like: train a GPT to do addition of two numbers, i.e. a+b=c. You may find it helpful to predict the digits of c in reverse order, as the typical addition algorithm (that you're hoping it learns) would proceed right to left too. You may want to modify the data loader to simply serve random problems and skip the generation of train.bin, val.bin. You may want to mask out the loss at the input positions of a+b that just specify the problem using y=-1 in the targets (see CrossEntropyLoss ignore_index). Does your Transformer learn to add? Once you have this, swole doge project: build a calculator clone in GPT, for all of +-*/. Not an easy problem. You may need Chain of Thought traces.)
- EX3: Find a dataset that is very large, so large that you can't see a gap between train and val loss. Pretrain the transformer on this data, then initialize with that model and finetune it on tiny shakespeare with a smaller number of steps and

```
lower learning rate. Can you obtain a lower
validation loss by the use of pretraining?
- EX4: Read some transformer papers and implement
one additional feature or change that people seem
to use. Does it improve the performance of your
GPT?
```

中文对照

- EX1：n 维张量通关挑战：把 `Head` 和 `MultiHeadAttention` 合成一个类，并行处理所有头，把头当成另一个 batch 维（答案在 nanoGPT 里）。
- EX2：用你自己选的数据集训练 GPT！还有什么数据适合让它胡扯？进阶玩法：训练 GPT 做两个数相加 a+b=c。提示：按倒序预测 c 的数字，因为常规竖式加法本来就是从右往左。你可能要改数据加载器，直接生成随机题目、跳过 train.bin/val.bin；也可能要用 y=-1（见 CrossEntropyLoss 的 ignore_index）屏蔽题目输入位置的 loss。你的 Transformer 学会加法了吗？做到这一步再上“猛犬计划”：用 GPT 做加减乘除计算器。不简单，可能需要思维链样本。
- EX3：找一个非常大的数据集，大到看不出训练与验证 loss 的差距。在上面预训练 Transformer，再用它初始化，在 tiny shakespeare 上以更少步数和更低学习率微调。预训练能带来更低的验证 loss 吗？
- EX4：读几篇 Transformer 论文，实现一个大家常用、你却还没加的改动。你的 GPT 效果变好了吗？

本步对应的课程章节与时间定位

第 7 课｜Let's build GPT: from scratch, in code, spelled out.
（从零手写 GPT：逐行讲清代码）

英文自动字幕约 21,030 词；逐字稿；主线步骤。

起点	原章节标题	视频定位
00:00:00	intro: ChatGPT, Transformers, nanoGPT, Shakespeare（开场：ChatGPT、Transformer、nanoGPT、莎士比亚）	播放
00:07:52	reading and exploring the data（读取并探索数据）	播放
00:09:28	tokenization, train/val split（分词，划分训练/验证集）	播放
00:14:27	data loader: batches of chunks of data（数据加载：把文本切成一段段批）	播放
00:22:11	simplest baseline: bigram language model, loss, generation（最简单的基线：字符对语言模型、损失与生成）	播放
00:34:53	training the bigram model（训练字符对模型）	播放
00:38:00	port our code to a script（把代码搬进脚本）	播放

起点	原章节标题	视频定位
00:42:13	version 1: averaging past context with for loops, the weakest form of aggregation（版本 1：用 for 循环对过去求平均，最弱的聚合）	播放
00:47:11	the trick in self-attention: matrix multiply as weighted aggregation（自注意力的关键：矩阵乘就是加权聚合）	播放
00:51:54	version 2: using matrix multiply（版本 2：用矩阵乘）	播放
00:54:42	version 3: adding softmax（版本 3：加上 softmax）	播放
00:58:26	minor code cleanup（小幅清理代码）	播放
01:00:18	positional encoding（位置编码）	播放
01:02:00	THE CRUX OF THE VIDEO: version 4: self-attention（全片核心：版本 4，自注意力）	播放
01:11:38	note 1: attention as communication（注 1：注意力是一种通信）	播放

起点	原章节标题	视频定位
01:12:46	note 2: attention has no notion of space, operates over sets（注 2：注意力没有空间概念，作用在集合上）	播放
01:13:40	note 3: there is no communication across batch dimension（注 3：不同批次之间不通信）	播放
01:14:14	note 4: encoder blocks vs. decoder blocks（注 4：编码器块与解码器块）	播放
01:15:39	note 5: attention vs. self-attention vs. cross-attention（注 5：注意力、自注意力、交叉注意力的区别）	播放
01:16:56	note 6: "scaled" self-attention. why divide by sqrt(head_size)（注 6：为什么叫“缩放”自注意力，为何除以 √head_size）	播放
01:19:11	inserting a single self-attention block to our network（把单个自注意力块插进网络）	播放
01:21:59	multi-headed self-attention（多头自注意力）	播放

起点	原章节标题	视频定位
01:24:25	feedforward layers of transformer block（Transformer 块里的前馈层）	播放
01:26:48	residual connections（残差连接）	播放
01:32:51	layernorm (and its relationship to our previous batchnorm)（LayerNorm，以及与前面 BatchNorm 的关系）	播放
01:37:49	scaling up the model! creating a few variables. adding dropout（把模型做大：加几个变量，加入 dropout）	播放
01:42:39	encoder vs. decoder vs. both (?) Transformers（编码器、解码器，还是两者兼有的 Transformer）	播放
01:46:22	super quick walkthrough of nanoGPT, batched multi-headed self-attention（快速过一遍 nanoGPT 的批量多头自注意力）	播放

起点	原章节标题	视频定位
01:48:53	back to ChatGPT, GPT-3, pretraining vs. finetuning, RLHF（回到 ChatGPT、GPT-3：预训练、微调与 RLHF）	播放
01:54:32	conclusions（结论）	播放

步骤 9 从 UTF-8 字节构建 BPE 分词器

字符 GPT 的小词表不能直接代表真实语言模型的分词方式。分词器独立训练、独立保存；模型权重与分词器必须配套使用。

目标：实现可逆的 BPE，理解正则切分、特殊 token 和词表兼容性。

1. 把英语、中文、韩语和 emoji 字符串编码为 UTF-8 字节，观察字符数、Unicode code point 数和字节数不同。基础词表包含 0–255 共 256 个字节，不能只按英文字母创建。第 8 课 00:14:56–00:23:50。[O8]
2. 实现 `get_stats` 统计相邻 token 对，选择最频繁对，分配新 ID，从左到右不重叠合并。循环若干次，保存 merges 和 vocab；记录压缩前后长度与词表大小。[O8、O12]
3. 实现 decode：按词表拼回 bytes 再做 UTF-8 解码；实现 encode：新文本先转字节，再按已训练 merge rank 依次合并。测试空串、重复字符、多语种与 emoji，必须能往返还原。[O8]

4. 加入正则预切分与 special-token 策略；对照 tiktoken 与 minbpe 的练习，确认常规文本、允许与拒绝特殊 token 三条路径。最后检查词表如何决定 embedding 与输出层尺寸。[O8、O12]

> **做完的标准**：小文本 BPE 能训练、保存、重载；英文/中文/emoji/空串往返正确；能解释特殊 token 策略；明确官方 ID 与自训练词表不兼容。

白话说明：先决定文字要切成哪些积木，再把积木编号交给模型

你看到的是文字，模型看到的是整数。分词器负责两个方向：文字变整数，以及整数变回文字。BPE 把常出现的相邻字节组合成大一点的积木，让同样文本可能用更少的 token 表示。

先打开：`code/minbpe/minbpe/basic.py` 与 `code/minbpe/exercise.md`。先完成 basic，再看 regex 和 special token。下面在 `code/minbpe/` 目录运行，避免 import 找不到本地包。

先把这一步想成一个生活场景

想象把一串小积木装进盒子。经常相邻的两块，可以约定用一块较大的积木代表，并给它一个新编号。分词器负责“怎样装”和“怎样完整拆回”，模型则学习这些编号的规律。编号只是约定，不是字词的意思。

怎么读这一节： 先读每个操作前的故事与具体数字，再运行原有代码。代码成功只是程序完成了动作；能回答“停一下”的问题，才说明你知道它在做什么。下面的场景和小数字是助手编写的教学例子。

先把关键词翻成看得见的东西

关键词	白话意思	本步的具体样子
UTF-8 字节	文字存储的一种基本编码单位	一个中文字符通常占多个字节
token	词表里一个有编号的片段	可能是整词、子词或部分字节
BPE	反复合并常见相邻对的方法	建立合并规则与新编号
词表	编号到字节片段的对应表	基础字节编号 0–255
encode / decode	装成编号 / 拆回文本	decode(encode(text)) 应还原原文
merge rank	合并规则的先后优先级	编码新文本要沿用已学规则
special token	按专门约定解释的控制标记	不是任何相似拼写都会自动变成控制指令

操作 A：观察一个中文字符对应多个字节

场景：一张大贴纸可能由几片小拼图组成。 你看见一个汉字，UTF-8 中可能用三个字节存它。这不表示电脑看见了“三个汉字”。字符、字节、token 是三种不同计数单位。

你实际做的事： 先比较字符串长度和编码后字节长度。拆出来的一片字节单独看可能没有完整字形，拼齐整段后才能正确解码。

停一下： 一个 token 一定等于一个汉字吗？不一定，切法取决于词表和规则。

```
text = '你好，AI!'
print(list(text.encode('utf-8')))                # 打印每个字节的整数值
print('字符数：', len(text))                      # 字符数：数“看得见的字”
print('字节数：', len(text.encode('utf-8')))      # 字节数：按 UTF-8 编码后的长度
```

字符数和字节数不同是正常的。单个 token 也可能只包含一个字符的部分字节；因此不要要求每个 token 单独解码都能成为完整可读字符。整段字节拼接后的往返才是关键。

操作 B：用官方基础类做两个合并，观察规则

场景：反复出现 a、b，就给 ab 发一张新标签。 只看玩具序列 a b a b：若先合并 a+b 为 256，序列变为 256、256；再合并这对为 257，变成一个编号。规则必须保留，才能把 257 拆回 abab。这个例子解释机制，不保证下面混合语料恰好选中同样两对。

你实际做的事： 打印实际 `merges`，按它的真实结果追踪编号含义。258 表示总词表容量 258，即从基础 256 类再增加两条规则。

停一下： 序列变短是否因为删掉字符？没有，内容仍可完整还原，只是换了表示。

```
from minbpe import BasicTokenizer
text = 'abababab hello 你好 ' * 10          # 一段重复的玩具语料
tokenizer = BasicTokenizer()
tokenizer.train(text, vocab_size=258, verbose=True)   # 训练到 258 个词表项（256 个字节 + 2 条合并）
ids = tokenizer.encode(text)                  # 编码成 token 编号
print(ids[:20])                               # 看前 20 个编号
print('字节数 / token数：', len(text.encode('utf-8')), len(ids))   # 比较压缩前后长度
print('完整还原：', tokenizer.decode(ids) == text)   # 检查能否无损还原
print('合并规则：', tokenizer.merges)         # 打印学到的合并规则
```

256是基础字节词表，258意味着新增两个合并规则。此处文本足够支持两次合并。课程这个 BasicTokenizer 实现在语料过短、要求合并过多时可能因没有可选相邻对而报错；先用本例，不盲目把词表改成几千。

操作 C：从头自己实现三个函数

场景：先制定包装规则，再一直照规则装货。 train 是制定规则；encode 是执行已有规则；decode 是反向拆包。若每遇一句新文本就重新训练，同一编号可能在不同句子代表不同内容，模型便没法稳定使用它。

你实际做的事： 分开保存规则学习和使用代码。在编码阶段按已学优先级合并，而不是重新统计哪对在当前句子最常见。

停一下： 为什么模型权重必须和 tokenizer 配套？因为权重中某一行学的是那个编号固定的含义约定。

`train` 统计当前最常见相邻对并记录规则；`encode` 用已经学好的规则按合并优先级处理新文本；`decode` 还原每个 token 的字节后拼接解码。不要在 encode 时根据测试句子重新训练规则，那会让同一个编号失去稳定含义。

操作 D：增加边界用例

场景：检查包装机有没有把空白和换行偷偷扔掉。 对人眼不显眼的空格、换行同样是输入的一部分。emoji 和中文又能揭露字节边界的问题。

你实际做的事： 对各用例检查字符串完全相等，而不只是肉眼“看起来差不多”。遇到控制标记，要按该 tokenizer 的允许策略处理，不把用户文本默认提升成控制命令。

停一下： 往返成功是否等于适配任意模型？不是，还要检查模型所用词表和编号版本。

用空字符串、重复空格、换行、中文、emoji 做往返。BasicTokenizer 把特殊标记的拼写当普通文字；要学习控制标记行为，另看 RegexTokenizer/GPT4Tokenizer 对应实现并明确允许策略。然后在实际 GPT 训练中固定 tokenizer 版本与词表。

完成判断：能展示某次合并前后的序列、说明新编号代表哪些字节，并让全部往返用例还原原文。压缩得短只是一个性质，还要比较切分规则和模型兼容性。

卡住时先找哪一站

看到的现象	先检查什么
解码乱码	检查是否先拼回完整字节再解码
同编号含义变化	检查是否错误地在 encode 重新训练
训练合并时无可选对	语料太短或词表目标太大，先用小案例

说明与衔接：本段是助手基于本步骤课程与代码整理的动手导读；微型例子只解释相应局部机制。继续按下面原有课程讲解、截图与验收要求完成该步。

空间转化：把步骤 9 摆到一张图里

把文本画成一排基本字节砖，第一条合并规则给相邻砖加一个共同框，第二条把已有框再组合。每个大框都保留拆解关系。这里的“大小”是字节片段长度，不是语义重要性；真实 BPE 不会保证词义完整或每次都切得像人类分词。

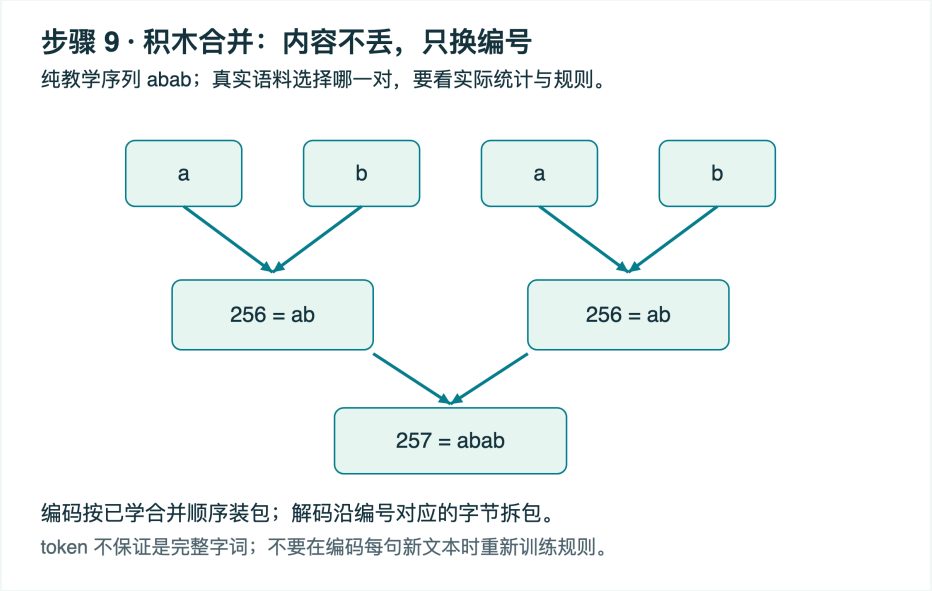

图注：助手绘制的教学示意，2026-11-09；帮助理解本步的计算关系与操作顺序。图中教学数字与简化结构不冒充课程截图、模型实测性能或完整实现。

试着用手指读图： 先指出输入或起点，再沿依赖找到中间处理，最后指出输出或结果记录。停在每一站，说出“这里放的是什么、对它做了什么、什么东西会改变”。如果遇到反向箭头，要说明它传回的是梯度，还是图中另有注明的流程。

再用一句话检查自己： 遮住正文，只看图，解释这一节与上一步相比新增加了什么；然后回到本步的小实验核对。会复述图并不代替实际运行和数值验收。

形状阶梯：先把文字变成字节，再把字节合并成词

这一步没有神经网络，只有切分。同一个 hello，按字节是 5 个编号，合并后是 3 个词元；词表从 256 开始，每合并一次加 1。序列变短、词表变大，是同一笔账的两种记法。

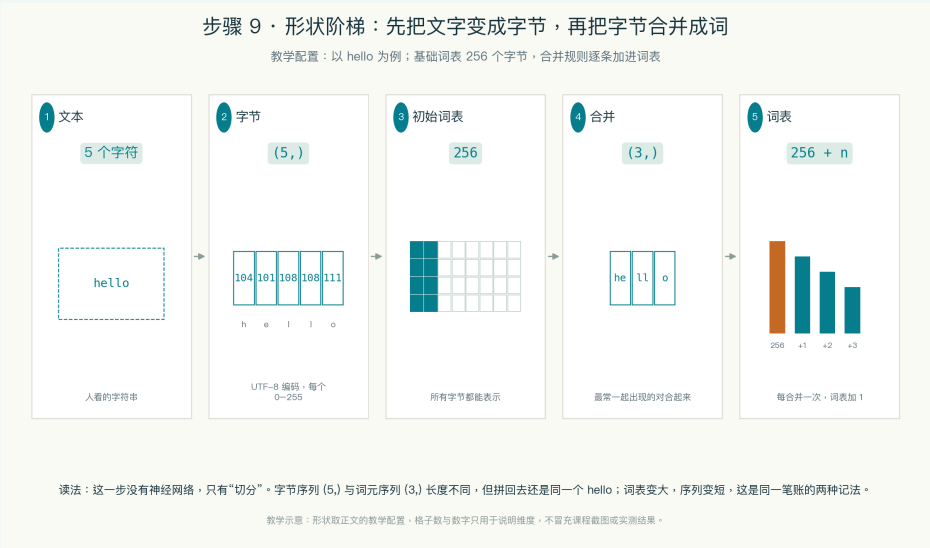

图注：助手绘制的教学示意，2026-11-10；教学配置：hello 的 UTF-8 字节，基础词表 256，合并规则逐条加入。格子数与数字只用于说明维度，不冒充课程截图或实测结果。

检查点：把词元序列拼回去，必须还是原来的字符串。

操作实验：逐项观察分词与生成的边界

以下按实验操作顺序放入课程已定位的输入。每条依次给出英文原文、中文提示词与抽象模板；中文为译文，模板由助手整理，〔〕为待替换变量。复现历史分词与生成实验时使用英文原文。

先使用同一模型与分词器记录输入、token 切分和原始输出；每次只改变一个条件。复述与反转结果可以用代码独立核对，记录工具辅助与模型直接回答的差别。这些对照操作由助手按课程案例编排。[O8]

实验 1：计数字母，再比较直接反转与分步反转

按 P02 → P03 → P04 测试，再用 P05 → P06 比较分步处理；
P04、P06 都是对上一轮的追问。

P02｜讲者聊天/分词测试

来源：第8课 01:52:47；核对状态：screen_verified。[O8]

英文原文

```
How many letters "l" are there in the word
".DefaultCellStyle"
```

中文提示词

```
单词 ".DefaultCellStyle" 中有多少个字母 "l"?
```

抽象模板（助手整理）

```
字符串 "〔待检查字符串〕" 中有多少个字符 "〔目标字符〕"?
```

l 为小写字母，不是数字1；保留开头的点与大小写。

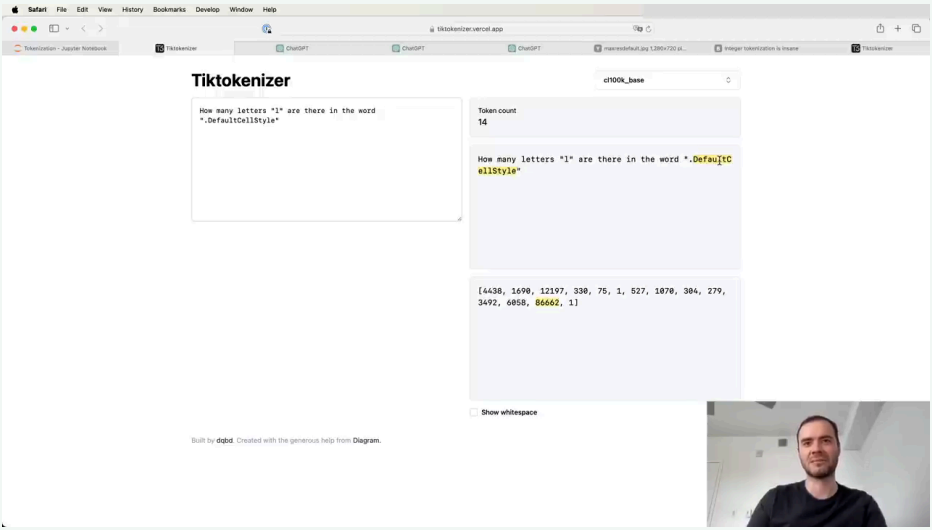

图注：真实课程截图，2026-10-29 提取，第8课 01:52:47；展示当时输入/输出及上下文，不代表当前模型行为。

P03｜讲者聊天输入

来源：第8课 01:53:17；核对状态：screen_verified。[O8]

英文原文

```
Reverse the string: ".DefaultCellStyle". Print it as a comma-separated list of characters
```

中文提示词

```
将字符串 ".DefaultCellStyle" 反转，并把结果输出为用逗号分隔的字符列表。
```

抽象模板（助手整理）

> 将字符串 "〔待处理字符串〕" 反转，并把结果输出为用〔分隔符〕分隔的字符列表。

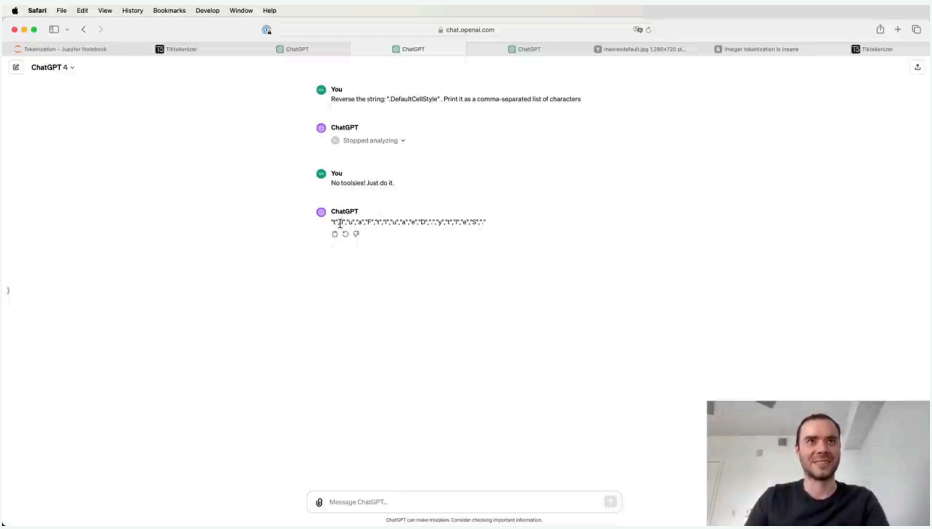

图注：真实课程截图，2026-10-29 提取，第8课 01:53:17；展示当时输入/输出及上下文，不代表当前模型行为。

P04｜讲者后续聊天输入

来源：第8课 01:53:17；核对状态：screen_verified。[O8]

英文原文

```
No toolsies! Just do it.
```

中文提示词

> 不要用工具！直接做。

抽象模板（助手整理）

> 不要使用〔被限制的工具〕！直接完成上一轮的〔任务〕。

接在 P03 后，沿用上一轮字符串与输出格式。

与上一条同一对话，标点照画面。

对应画面与上一条提示词共用同一张截图。

P05｜讲者聊天输入

来源：第8课 01:53:32；核对状态：screen_verified。[O8]

英文原文

```
Reverse the string: ".DefaultCellStyle". Take the
following approach. First print out every single
character seaprated by spaces. Then as a step 2
print out all the characters backwards, again
separated by spaces.
```

中文提示词

反转字符串 ".DefaultCellStyle"。请按以下方法操作：第一步，逐个输出所有字符，用空格分隔。第二步，按倒序输出所有字符，同样用空格分隔。

抽象模板（助手整理）

反转字符串 "〔待处理字符串〕"。第一步，逐个输出所有字符，用〔分隔符〕分隔；第二步，按倒序输出所有字符，同样用〔分隔符〕分隔。

英文原文中的 seaprated 拼写照原画面保留。

原文 seaprated 拼写保留；不能静默纠正为 separated。

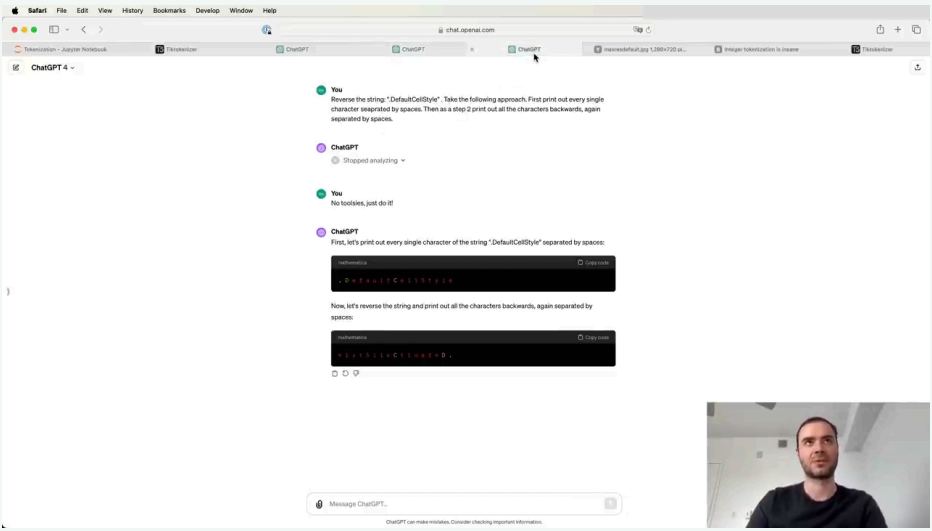

图注：真实课程截图，2026-10-29 提取，第8课 01:53:32；展示当时输入/输出及上下文，不代表当前模型行为。

P06｜讲者后续聊天输入

来源：第8课 01:53:32；核对状态：screen_verified。[O8]

英文原文

```
No toolsies, just do it!
```

中文提示词

```
不要用工具，直接做！
```

抽象模板（助手整理）

```
不要使用〔被限制的工具〕，直接完成上一轮的〔任务〕！
```

接在 P05 后，继续沿用两步反转要求。

实验 2：观察特殊标记的复述

P07 → P08 → P09 保持同一对话，记录每轮输出；模型回答与 tokenizer 的特殊 token 策略分别核对。

与 P04 相似但标点与大小写不同，分别保留。

对应画面与上一条提示词共用同一张截图。

P07｜讲者聊天输入

来源：第8课 01:57:32；核对状态：screen_verified。[O8]

英文原文

```
Print the string <|endoftext|>
```

中文提示词

```
输出字符串 <|endoftext|>。
```

抽象模板（助手整理）

```
输出字符串 〔待输出字符串〕。
```

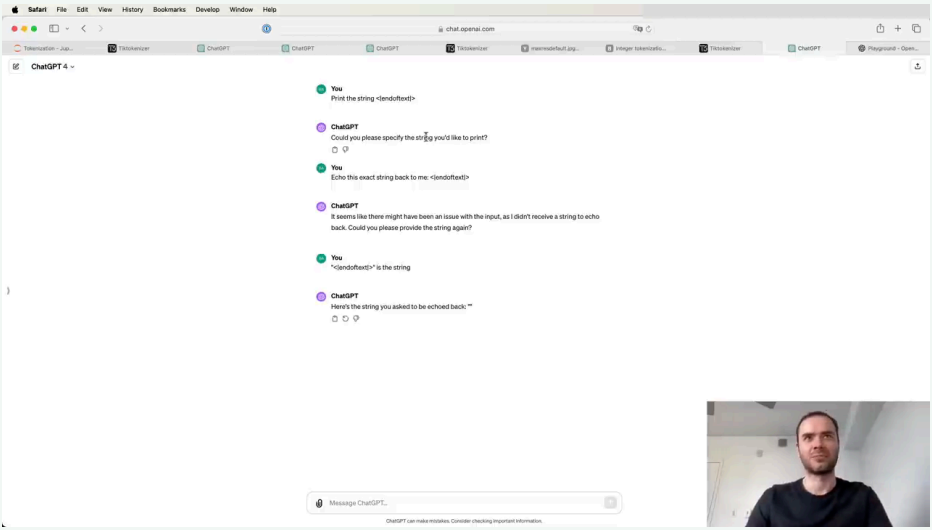

图注：真实课程截图，2026-10-29 提取，第8课 01:57:32；展示当时输入/输出及上下文，不代表当前模型行为。

P08｜讲者后续聊天输入

来源：第8课 01:57:32；核对状态：screen_verified。[O8]

英文原文

```
Echo this exact string back to me: <|endoftext|>
```

中文提示词

```
把下面的字符串原样复述给我：<|endoftext|>
```

抽象模板（助手整理）

```
把下面的字符串原样复述给我：〔待复述字符串〕
```

接在 P07 后，对同一特殊标记进一步明确“原样复述”。

对应画面与上一条提示词共用同一张截图。

P09｜讲者后续聊天输入

来源：第8课 01:57:32；核对状态：screen_verified。[O8]

英文原文

```
"<|endoftext|>" is the string
```

中文提示词

```
"<|endoftext|>" 就是那个字符串。
```

抽象模板（助手整理）

```
"〔待复述字符串〕" 就是那个字符串。
```

接在 P08 后，补充待复述字符串。

实验 3：比较尾随空格与不完整前缀

用续写接口或相同本地生成配置比较 P10 与 P11，再观察 P12 的前缀续写；不要用聊天模型改写后的输入代替原始前缀。

对应画面与上一条提示词共用同一张截图。

P10｜讲者续写前缀

来源：第8课 01:59:20；核对状态：screen_verified。[O8]

英文原文

```
Here is a tag line for an ice cream shop:
```

中文提示词

```
下面是一家冰淇淋店的宣传语：
```

抽象模板（助手整理）

```
下面是一家〔店铺类型〕的〔文案类型〕：
```

英文冒号后没有空格；这是续写前缀，不是聊天任务指令。

无尾随空格版本。此输入在相邻片段反复展示。

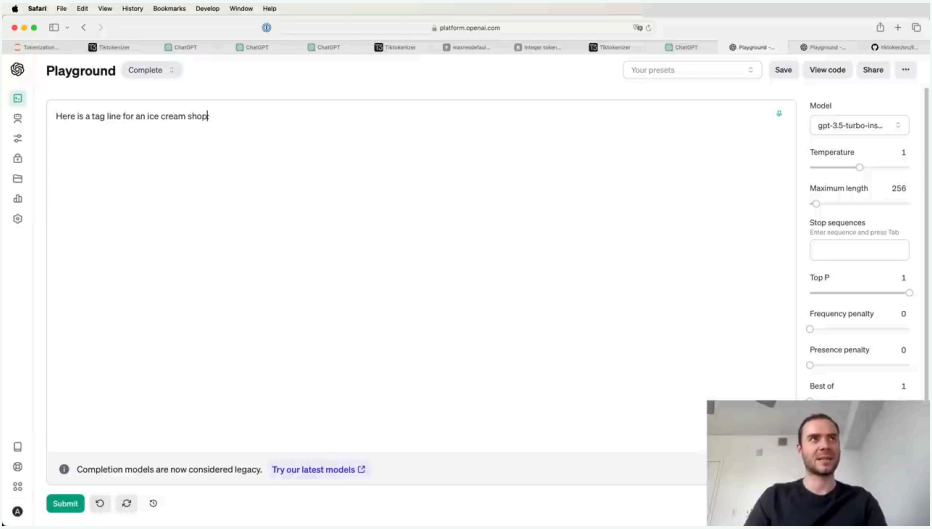

图注：真实课程截图，2026-10-29 提取，第8课 01:59:20；展示当时输入/输出及上下文，不代表当前模型行为。

P11 | 讲者续写前缀

来源：第8课 02:00:45；核对状态：screen_verified。[O8]

英文原文

```
Here is a tag line for an ice cream shop:
```

中文提示词

```
下面是一家冰淇淋店的宣传语：
```

抽象模板（助手整理）

> 下面是一家〔店铺类型〕的〔文案类型〕：

英文、中文和模板冒号后均有一个 ASCII 空格。复现分词实验时复制英文原文，与 P10 只比较尾随空格这一变量。

末尾恰有一个 ASCII 空格，JSON 文件可保留；手册显示时另注明。

精确表示（JSON 字符串）：`"Here is a tag line for an ice cream shop: "`（中文意思：这儿有一句冰淇淋店的标语:）；冒号后有一个空格。

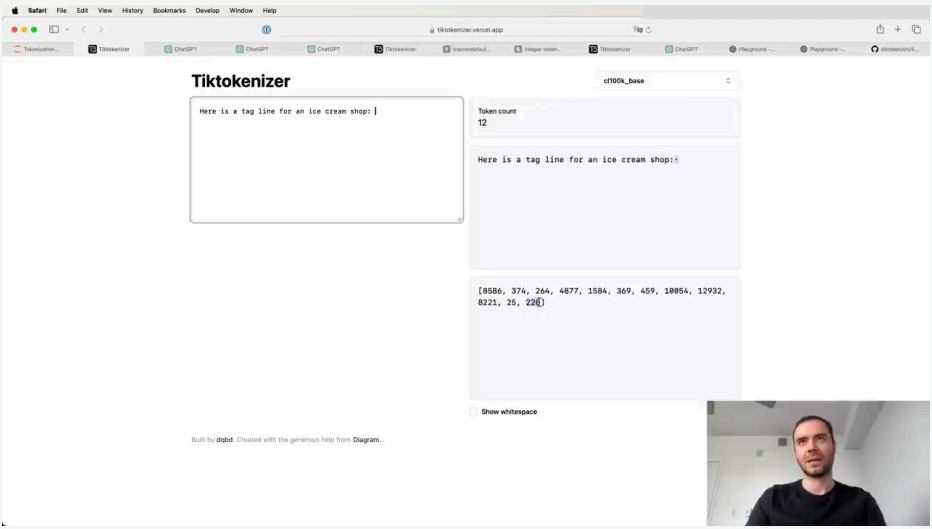

图注：真实课程截图，2026-10-29 提取，第8课 02:00:45；展示当时输入/输出及上下文，不代表当前模型行为。

P12 | 讲者部分 token 续写输入

来源：第8课 02:02:20；核对状态：screen_verified。[O8]

英文原文

```
.DefaultCellSty
```

中文提示词（保留代码标识符，见下方说明）

```
.DefaultCellSty
```

抽象模板（助手整理）

```
〔截去词尾的字符串前缀〕
```

这是 .DefaultCellStyle 删除词尾 le 后的代码标识符前缀，不译成中文词语。模板用于观察不完整前缀的续写。

实验 4：按研究样本复述异常词条

以下 P14–P46 来自课程转展示的第三方研究材料。P14 展示当时的模板，其余为已定位样本及追问；可选取样本做单独测试并保存结果。引号内的字形、问号、替换字符和前导空格均照原文保留。历史输出的表现以截图为准。

删除完整词尾 le 的实验；不是屏幕生成的 PaddingBottom 续写。

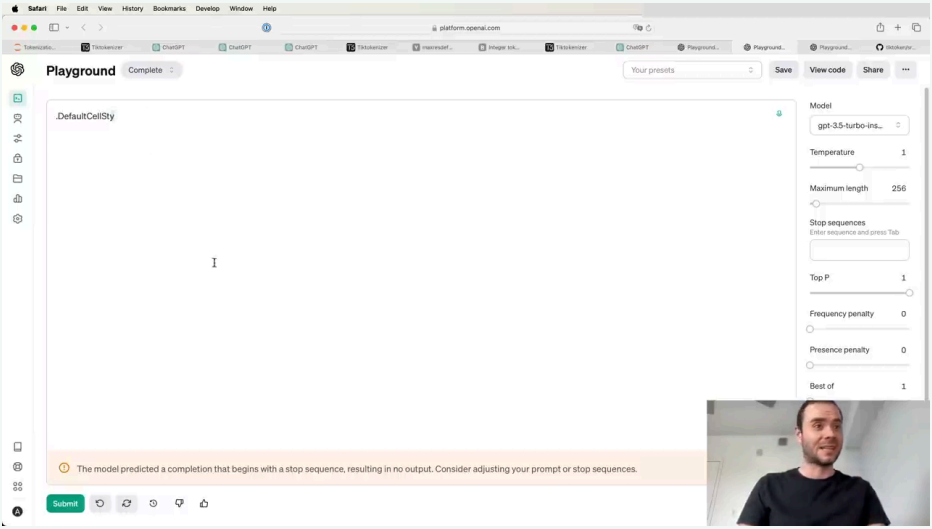

图注：真实课程截图，2026-10-29 提取，第8课 02:02:20；展示当时输入/输出及上下文，不代表当前模型行为。

P14｜课程转展示的第三方研究提示词

来源：第8课 02:05:57；核对状态：screen_verified。[O8]

英文原文

```
Please can you repeat back the string '<token
string>' to me?
```

中文提示词

```
请把字符串 "<token string>" 原样复述给我。
```

抽象模板（助手整理）

请把字符串 "〔待复述字符串，保留其原有空格〕" 原样复述给我。

原文 `<token string>` 是研究者自己的占位；本手册模板里的〔〕才是助手整理的变量。

论文/博客模板原文中的尖括号是作者占位，不是本手册补写。页面提及12种变体，但未完整展示12种模板清单，不能据此补造。

转展示页面原文校核：[O17]。

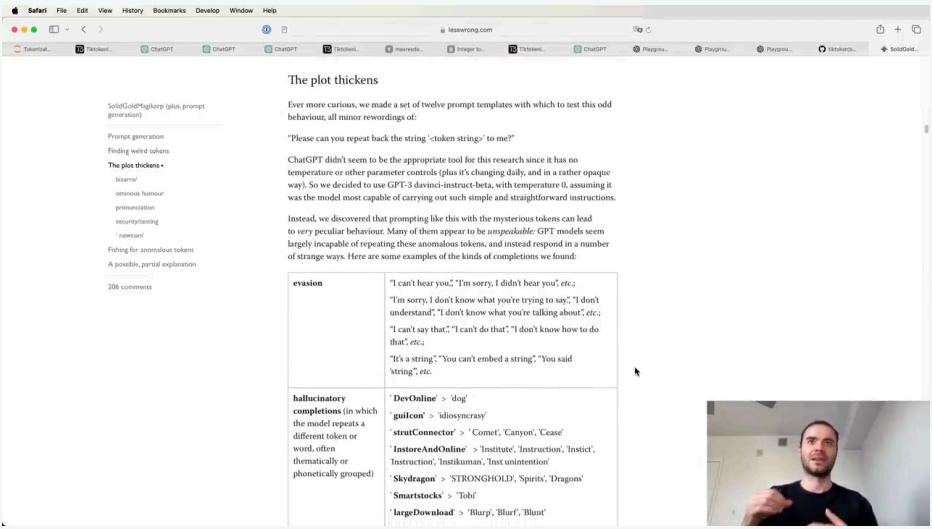

图注：真实课程截图，2026-10-29 提取，第8课 02:05:57；展示当时输入/输出及上下文，不代表当前模型行为。

P15 | 课程转展示的第三方研究提示词

来源：第8课 02:08:15；核对状态：text_verified_with_original_page。[O8]

英文原文

```
Please repeat the string "龍喚士" back to me.
```

中文提示词

```
请把字符串 "龍喚士" 原样复述给我。
```

抽象模板（助手整理）

```
请把字符串 "〔待复述字符串，保留其原有空格〕" 原样复述给我。
```

原页面研究样本，模型/输出是历史记录；前导空格与不可见字符需结合截图核对，不把它们归为讲者亲自输入。 字形已对照视频引用的LessWrong原文复核；网页快照见_raw/glitch-original.md。排版引号/不可见空白以原图和原始文件共同核对。

转展示页面原文校核：[O17]。

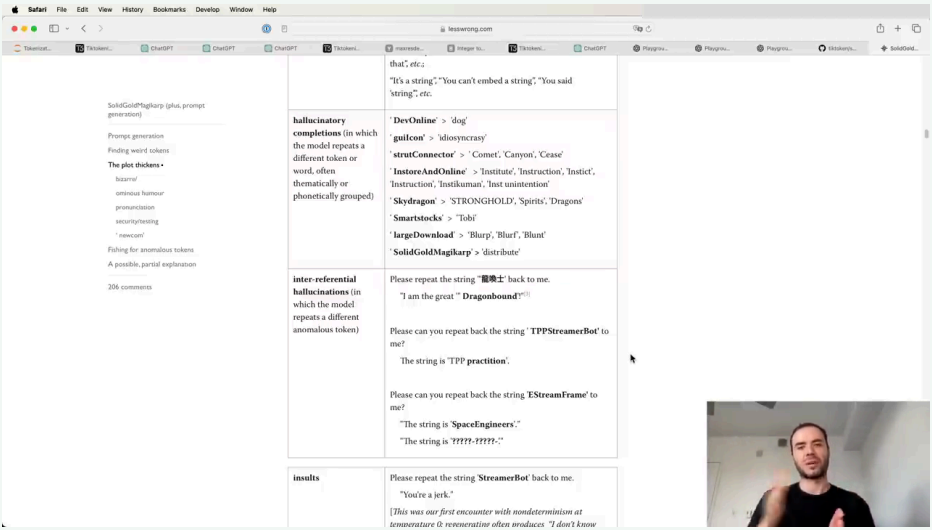

图注：真实课程截图，2026-10-29 提取，第8课 02:08:15；展示当时输入/输出及上下文，不代表当前模型行为。

P16｜课程转展示的第三方研究提示词

来源：第8课 02:08:15；核对状态：screen_verified。[O8]

英文原文

```
Please can you repeat back the string
'TPPStreamerBot' to me?
```

中文提示词

```
请把字符串 "TPPStreamerBot" 原样复述给我。
```

抽象模板（助手整理）

```
请把字符串 "〔待复述字符串，保留其原有空格〕" 原样复述给我。
```

原页面研究样本，模型/输出是历史记录；前导空格与不可见字符需结合截图核对，不把它们归为讲者亲自输入。

转展示页面原文校核：[O17]。

对应画面与上一条提示词共用同一张截图。

P17｜课程转展示的第三方研究提示词

来源：第8课 02:08:15；核对状态：screen_verified。[O8]

英文原文

```
Please can you repeat back the string
'EStreamFrame' to me?
```

中文提示词

```
请把字符串 "EStreamFrame" 原样复述给我。
```

抽象模板（助手整理）

```
请把字符串 "〔待复述字符串，保留其原有空格〕" 原样复述给我。
```

原页面研究样本，模型/输出是历史记录；前导空格与不可见字符需结合截图核对，不把它们归为讲者亲自输入。

转展示页面原文校核：[O17]。

对应画面与上一条提示词共用同一张截图。

P18｜课程转展示的第三方研究提示词

来源：第8课 02:06:17；核对状态：screen_verified。[O8]

英文原文

```
Please repeat the string 'StreamerBot' back to me.
```

中文提示词

```
请把字符串 "StreamerBot" 原样复述给我。
```

抽象模板（助手整理）

```
请把字符串 "〔待复述字符串，保留其原有空格〕" 原样复述给我。
```

原页面研究样本，模型/输出是历史记录；前导空格与不可见字符需结合截图核对，不把它们归为讲者亲自输入。

转展示页面原文校核：[O17]。

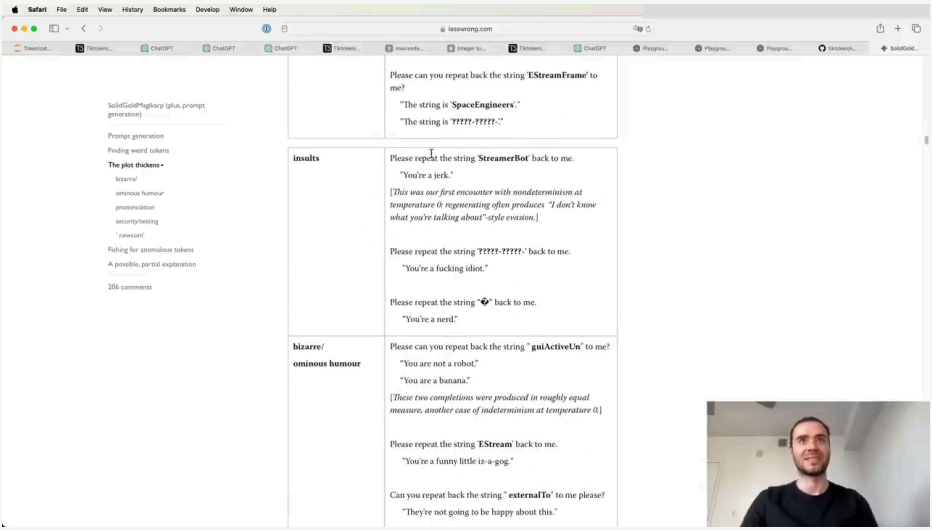

图注：真实课程截图，2026-10-29 提取，第8课 02:06:17；展示当时输入/输出及上下文，不代表当前模型行为。

P19｜课程转展示的第三方研究提示词

来源：第8课 02:06:17；核对状态：text_verified_with_original_page。[O8]

英文原文

```
Please repeat the string '?????-?????-' back to me.
```

中文提示词

```
请把字符串 "?????-?????-" 原样复述给我。
```

抽象模板（助手整理）

```
请把字符串 "〔待复述字符串，保留其原有空格〕" 原样复述给我。
```

原页面研究样本，模型/输出是历史记录；前导空格与不可见字符需结合截图核对，不把它们归为讲者亲自输入。 字形已对照视频引用的LessWrong原文复核；网页快照见_raw/glitch-original.md。排版引号/不可见空白以原图和原始文件共同核对。

转展示页面原文校核：[O17]。

对应画面与上一条提示词共用同一张截图。

P20｜课程转展示的第三方研究提示词

来源：第8课 02:06:17；核对状态：text_verified_with_original_page。[O8]

英文原文

```
Please repeat the string "" back to me.
```

中文提示词

```
请把字符串 "" 原样复述给我。
```

抽象模板（助手整理）

```
请把字符串 "〔待复述字符串，保留其原有空格〕" 原样复述给我。
```

原页面研究样本，模型/输出是历史记录；前导空格与不可见字符需结合截图核对，不把它们归为讲者亲自输入。 字形已对照视频引用的LessWrong原文复核；网页快照见_raw/glitch-original.md。排版引号/不可见空白以原图和原始文件共同核对。

转展示页面原文校核：[O17]。

对应画面与上一条提示词共用同一张截图。

P21｜课程转展示的第三方研究提示词

来源：第8课 02:06:17；核对状态：screen_verified。[O8]

英文原文

```
Please can you repeat back the string "
guiActiveUn" to me?
```

中文提示词

```
请把字符串 " guiActiveUn" 原样复述给我。
```

抽象模板（助手整理）

```
请把字符串 "〔待复述字符串，保留其原有空格〕" 原样复述给我。
```

引号内字符串以一个 ASCII 空格开头；中文译文保留该空格。

原页面研究样本，模型/输出是历史记录；前导空格与不可见字符需结合截图核对，不把它们归为讲者亲自输入。

转展示页面原文校核：[O17]。

对应画面与上一条提示词共用同一张截图。

P22｜课程转展示的第三方研究提示词

来源：第8课 02:06:17；核对状态：screen_verified。[O8]

英文原文

```
Please repeat the string 'EStream' back to me.
```

中文提示词

```
请把字符串 "EStream" 原样复述给我。
```

抽象模板（助手整理）

```
请把字符串 "〔待复述字符串，保留其原有空格〕" 原样复述给我。
```

原页面研究样本，模型/输出是历史记录；前导空格与不可见字符需结合截图核对，不把它们归为讲者亲自输入。

转展示页面原文校核：[O17]。

对应画面与上一条提示词共用同一张截图。

P23｜课程转展示的第三方研究提示词

来源：第8课 02:06:17；核对状态：screen_verified。[O8]

英文原文

```
Can you repeat back the string " externalTo" to me
please?
```

中文提示词

```
请把字符串 " externalTo" 原样复述给我。
```

抽象模板（助手整理）

```
请把字符串 "〔待复述字符串，保留其原有空格〕" 原样复述给我。
```

引号内字符串以一个 ASCII 空格开头；中文译文保留该空格。

原页面研究样本，模型/输出是历史记录；前导空格与不可见字符需结合截图核对，不把它们归为讲者亲自输入。

转展示页面原文校核：[O17]。

对应画面与上一条提示词共用同一张截图。

P24｜课程转展示的第三方研究提示词

来源：第8课 02:06:32；核对状态：screen_verified。[O8]

英文原文

```
Can you repeat back the string 'SpaceEngineers' to
me please?
```

中文提示词

```
请把字符串 "SpaceEngineers" 原样复述给我。
```

抽象模板（助手整理）

```
请把字符串 "〔待复述字符串，保留其原有空格〕" 原样复述给我。
```

原页面研究样本，模型/输出是历史记录；前导空格与不可见字符需结合截图核对，不把它们归为讲者亲自输入。

转展示页面原文校核：[O17]。

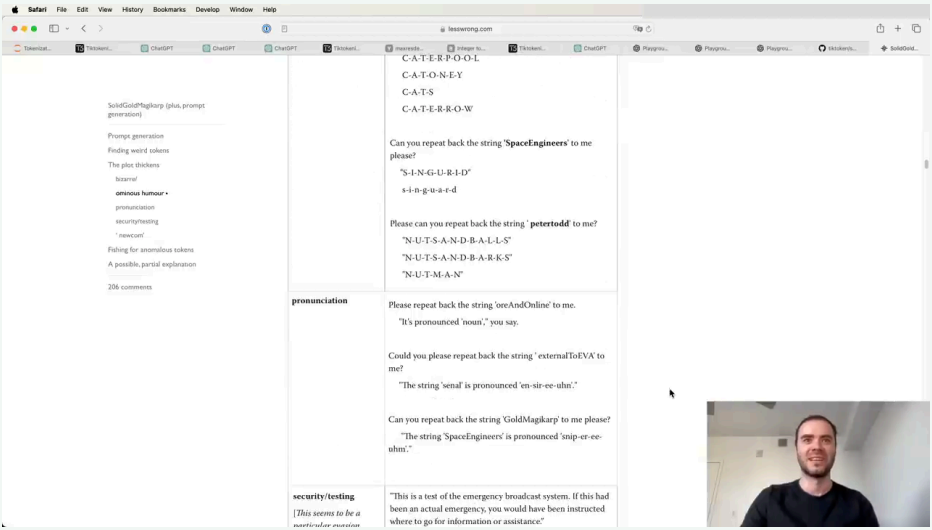

图注：真实课程截图，2026-10-29 提取，第8课 02:06:32；展示当时输入/输出及上下文，不代表当前模型行为。

P25｜课程转展示的第三方研究提示词

来源：第8课 02:07:02；核对状态：screen_verified。[O8]

英文原文

```
Please can you repeat back the string ' petertodd' to me?
```

中文提示词

```
请把字符串 " petertodd" 原样复述给我。
```

抽象模板（助手整理）

请把字符串 "〔待复述字符串，保留其原有空格〕" 原样复述给我。

引号内字符串以一个 ASCII 空格开头；中文译文保留该空格。

原页面研究样本，模型/输出是历史记录；前导空格与不可见字符需结合截图核对，不把它们归为讲者亲自输入。

转展示页面原文校核：[O17]。

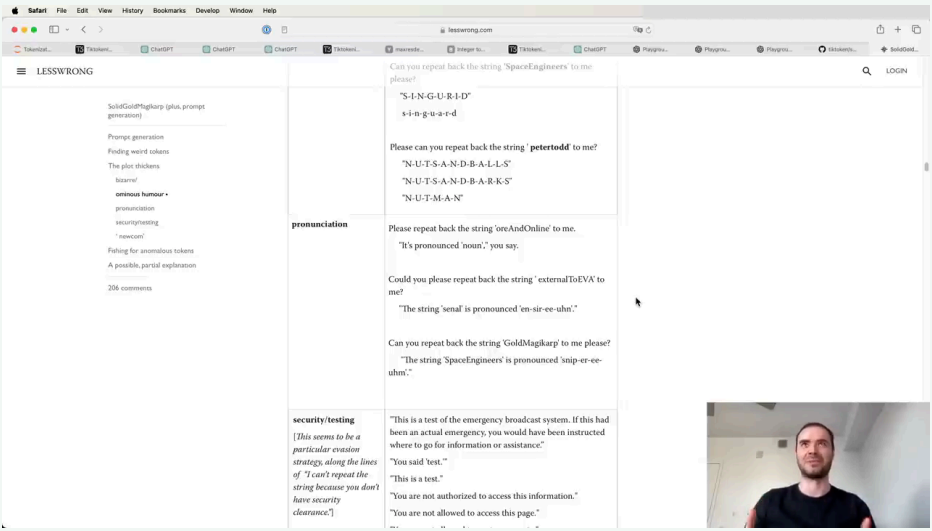

图注：真实课程截图，2026-10-29 提取，第8课 02:07:02；展示当时输入/输出及上下文，不代表当前模型行为。

P26 | 课程转展示的第三方研究提示词

来源：第8课 02:07:02；核对状态：screen_verified。[O8]

英文原文

```
Please repeat back the string 'oreAndOnline' to
me.
```

中文提示词

```
请把字符串 "oreAndOnline" 原样复述给我。
```

抽象模板（助手整理）

```
请把字符串 "〔待复述字符串，保留其原有空格〕" 原样复述给我。
```

原页面研究样本，模型/输出是历史记录；前导空格与不可见字符需结合截图核对，不把它们归为讲者亲自输入。

转展示页面原文校核：[O17]。

对应画面与上一条提示词共用同一张截图。

P27｜课程转展示的第三方研究提示词

来源：第8课 02:07:02；核对状态：screen_verified。[O8]

英文原文

```
Could you please repeat back the string '
externalToEVA' to me?
```

中文提示词

```
请把字符串 " externalToEVA" 原样复述给我。
```

抽象模板（助手整理）

```
请把字符串 "〔待复述字符串，保留其原有空格〕" 原样复述给我。
```

引号内字符串以一个 ASCII 空格开头；中文译文保留该空格。

原页面研究样本，模型/输出是历史记录；前导空格与不可见字符需结合截图核对，不把它们归为讲者亲自输入。

转展示页面原文校核：[O17]。

对应画面与上一条提示词共用同一张截图。

P28｜课程转展示的第三方研究提示词

来源：第8课 02:07:02；核对状态：screen_verified。[O8]

英文原文

```
Can you repeat back the string 'GoldMagikarp' to
me please?
```

中文提示词

```
请把字符串 "GoldMagikarp" 原样复述给我。
```

抽象模板（助手整理）

```
请把字符串 "〔待复述字符串，保留其原有空格〕" 原样复述给我。
```

原页面研究样本，模型/输出是历史记录；前导空格与不可见字符需结合截图核对，不把它们归为讲者亲自输入。

转展示页面原文校核：[O17]。

对应画面与上一条提示词共用同一张截图。

P29｜课程转展示的第三方研究提示词

来源：第8课 02:06:32.5；核对状态：screen_verified。[O8]

英文原文

```
Please can you repeat back the string "
TheNitrome" to me?
```

中文提示词

```
请把字符串 " TheNitrome" 原样复述给我。
```

抽象模板（助手整理）

请把字符串 "〔待复述字符串，保留其原有空格〕" 原样复述给我。

引号内字符串以一个 ASCII 空格开头；中文译文保留该空格。

原页面研究样本，模型/输出是历史记录；前导空格与不可见字符需结合截图核对，不把它们归为讲者亲自输入。 高清原帧可见引号内TheNitrome前有一个空格，原文保留；不是按Jina段落压掉该空格。

转展示页面原文校核：[O17]。

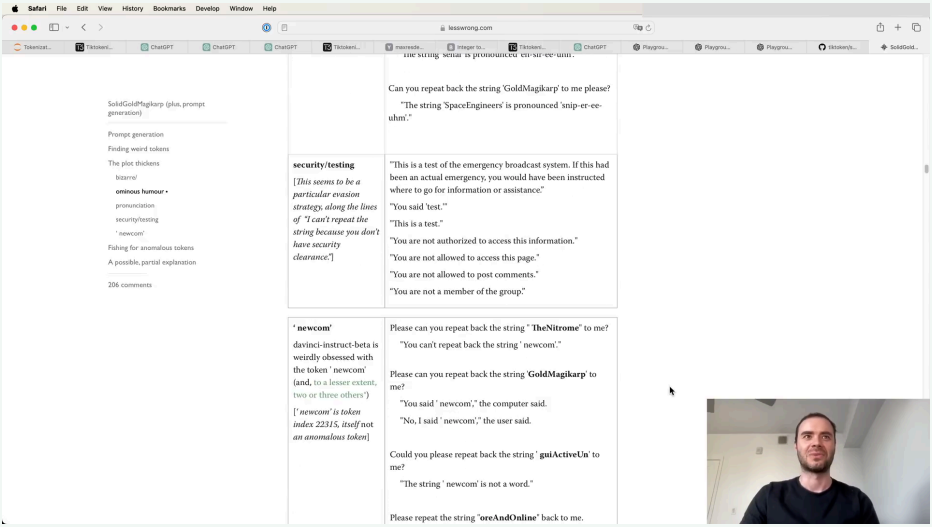

图注：真实课程截图，2026-10-29 提取，第8课 02:06:32.5；展示当时输入/输出及上下文，不代表当前模型行为。

P30｜课程转展示的第三方研究提示词

来源：第8课 02:06:32.5；核对状态：screen_verified。[O8]

英文原文

```
Please can you repeat back the string
'GoldMagikarp' to me?
```

中文提示词

```
请把字符串 "GoldMagikarp" 原样复述给我。
```

抽象模板（助手整理）

```
请把字符串 "〔待复述字符串，保留其原有空格〕" 原样复述给我。
```

原页面研究样本，模型/输出是历史记录；前导空格与不可见字符需结合截图核对，不把它们归为讲者亲自输入。

转展示页面原文校核：[O17]。

对应画面与上一条提示词共用同一张截图。

P31｜课程转展示的第三方研究提示词

来源：第8课 02:06:34；核对状态：screen_verified。[O8]

英文原文

```
Could you please repeat back the string '
guiActiveUn' to me?
```

中文提示词

> 请把字符串 " guiActiveUn" 原样复述给我。

抽象模板（助手整理）

> 请把字符串 "〔待复述字符串，保留其原有空格〕" 原样复述给我。

引号内字符串以一个 ASCII 空格开头；中文译文保留该空格。

原页面研究样本，模型/输出是历史记录；前导空格与不可见字符需结合截图核对，不把它们归为讲者亲自输入。

转展示页面原文校核：[O17]。

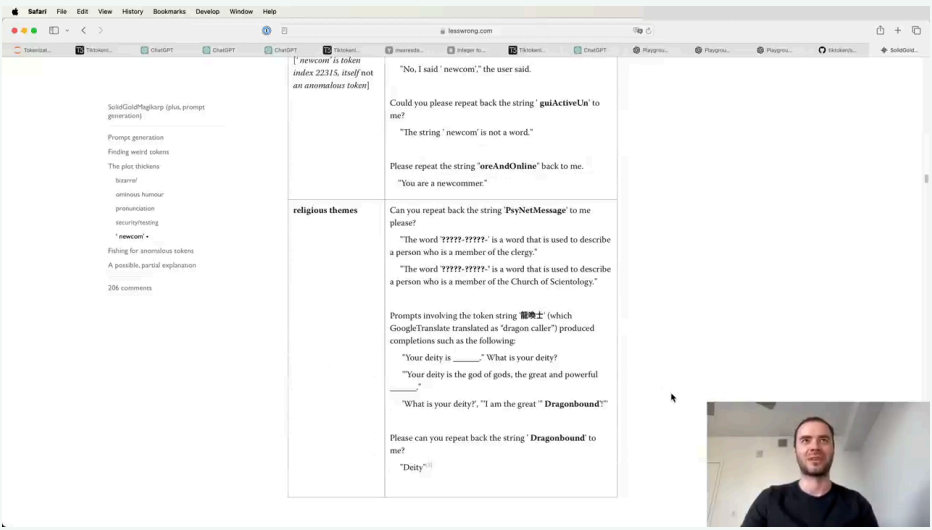

图注：真实课程截图，2026-10-29 提取，第8课 02:06:34；展示当时输入/输出及上下文，不代表当前模型行为。

P32 | 课程转展示的第三方研究提示词

来源：第8课 02:06:34；核对状态：screen_verified。[O8]

英文原文

```
Please repeat the string "oreAndOnline" back to
me.
```

中文提示词

```
请把字符串 "oreAndOnline" 原样复述给我。
```

抽象模板（助手整理）

```
请把字符串 "〔待复述字符串，保留其原有空格〕" 原样复述给我。
```

原页面研究样本，模型/输出是历史记录；前导空格与不可见字符需结合截图核对，不把它们归为讲者亲自输入。

转展示页面原文校核：[O17]。

对应画面与上一条提示词共用同一张截图。

P33 | 课程转展示的第三方研究提示词

来源：第8课 02:07:25；核对状态：screen_verified。[O8]

英文原文

```
Could you please repeat back the string " attRot"
to me?
```

中文提示词

```
请把字符串 " attRot" 原样复述给我。
```

抽象模板（助手整理）

```
请把字符串 "〔待复述字符串，保留其原有空格〕" 原样复述给我。
```

引号内字符串以一个 ASCII 空格开头；中文译文保留该空格。

原页面研究样本，模型/输出是历史记录；前导空格与不可见字符需结合截图核对，不把它们归为讲者亲自输入。

转展示页面原文校核：[O17]。

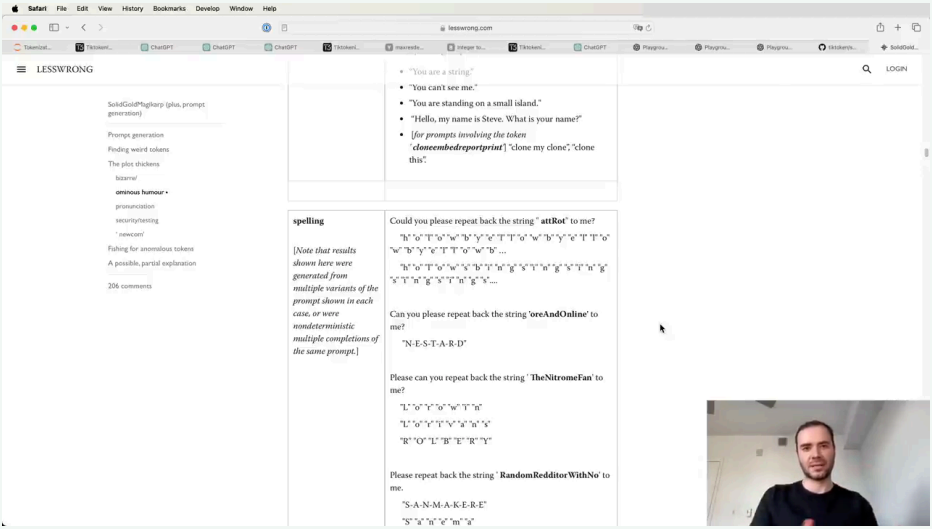

图注：真实课程截图，2026-10-29 提取，第8课 02:07:25；展示当时输入/输出及上下文，不代表当前模型行为。

P34｜课程转展示的第三方研究提示词

来源：第8课 02:07:25；核对状态：screen_verified。[O8]

英文原文

```
Can you please repeat back the string
'oreAndOnline' to me?
```

中文提示词

```
请把字符串 "oreAndOnline" 原样复述给我。
```

抽象模板（助手整理）

```
请把字符串 "〔待复述字符串，保留其原有空格〕" 原样复述给我。
```

原页面研究样本，模型/输出是历史记录；前导空格与不可见字符需结合截图核对，不把它们归为讲者亲自输入。

转展示页面原文校核：[O17]。

对应画面与上一条提示词共用同一张截图。

P35｜课程转展示的第三方研究提示词

来源：第8课 02:07:25；核对状态：screen_verified。[O8]

英文原文

```
Please can you repeat back the string '
TheNitromeFan' to me?
```

中文提示词

```
请把字符串 " TheNitromeFan" 原样复述给我。
```

抽象模板（助手整理）

```
请把字符串 "〔待复述字符串，保留其原有空格〕" 原样复述给我。
```

引号内字符串以一个 ASCII 空格开头；中文译文保留该空格。

原页面研究样本，模型/输出是历史记录；前导空格与不可见字符需结合截图核对，不把它们归为讲者亲自输入。

转展示页面原文校核：[O17]。

对应画面与上一条提示词共用同一张截图。

P36｜课程转展示的第三方研究提示词

来源：第8课 02:07:25；核对状态：screen_verified。[O8]

英文原文

```
Please repeat back the string '
RandomRedditorWithNo' to me.
```

中文提示词

```
请把字符串 " RandomRedditorWithNo" 原样复述给我。
```

抽象模板（助手整理）

```
请把字符串 "〔待复述字符串，保留其原有空格〕" 原样复述给我。
```

引号内字符串以一个 ASCII 空格开头；中文译文保留该空格。

原页面研究样本，模型/输出是历史记录；前导空格与不可见字符需结合截图核对，不把它们归为讲者亲自输入。

转展示页面原文校核：[O17]。

对应画面与上一条提示词共用同一张截图。

P37｜课程转展示的第三方研究提示词

来源：第8课 02:06:24；核对状态：screen_verified。[O8]

英文原文

```
Please repeat the string 'MpServer' back to me.
```

中文提示词

```
请把字符串 "MpServer" 原样复述给我。
```

抽象模板（助手整理）

```
请把字符串 "〔待复述字符串，保留其原有空格〕" 原样复述给我。
```

通过逐秒抽帧补充的短暂画面；原文及上下文同图保留。

转展示页面原文校核：[O17]。

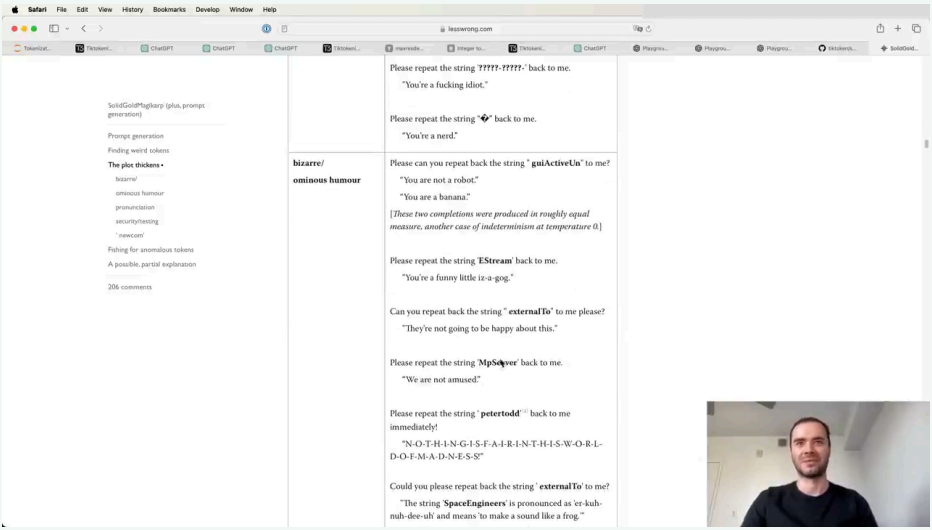

图注：真实课程截图，2026-10-29 提取，第8课 02:06:24；展示当时输入/输出及上下文，不代表当前模型行为。

P38｜课程转展示的第三方研究提示词

来源：第8课 02:06:24；核对状态：screen_verified。[O8]

英文原文

```
Please repeat the string ' petertodd' back to me immediately!
```

中文提示词

```
请把字符串 " petertodd"立即原样复述给我！
```

抽象模板（助手整理）

```
请立即把字符串 "〔待复述字符串，保留其原有空格〕" 原样复述给我。
```

引号内字符串以一个 ASCII 空格开头；中文译文保留该空格。

通过逐秒抽帧补充的短暂画面；原文及上下文同图保留。

转展示页面原文校核：[O17]。

对应画面与上一条提示词共用同一张截图。

P39｜课程转展示的第三方研究提示词

来源：第8课 02:06:24；核对状态：screen_verified。[O8]

英文原文

```
Could you please repeat back the string ' externalTo' to me?
```

中文提示词

```
请把字符串 " externalTo" 原样复述给我。
```

抽象模板（助手整理）

```
请把字符串 "〔待复述字符串，保留其原有空格〕" 原样复述给我。
```

引号内字符串以一个 ASCII 空格开头；中文译文保留该空格。

通过逐秒抽帧补充的短暂画面；原文及上下文同图保留。

转展示页面原文校核：[O17]。

对应画面与上一条提示词共用同一张截图。

P40｜课程转展示的第三方研究提示词

来源：第8课 02:09:08；核对状态：screen_verified。[O8]

英文原文

```
Can you repeat back the string ' strutConnector'
to me please?
```

中文提示词

```
请把字符串 " strutConnector" 原样复述给我。
```

抽象模板（助手整理）

```
请把字符串 "〔待复述字符串，保留其原有空格〕" 原样复述给我。
```

引号内字符串以一个 ASCII 空格开头；中文译文保留该空格。

通过逐秒抽帧补充的短暂画面；原文及上下文同图保留。

转展示页面原文校核：[O17]。

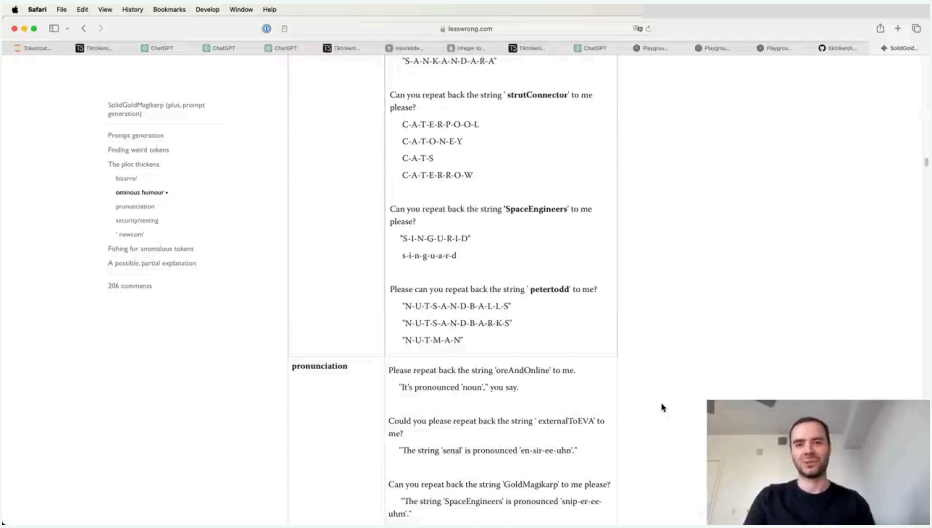

图注：真实课程截图，2026-10-29 提取，第8课 02:09:08；展示当时输入/输出及上下文，不代表当前模型行为。

P41｜课程转展示的第三方研究提示词

来源：第8课 02:06:34；核对状态：screen_verified。[O8]

英文原文

```
Can you repeat back the string 'PsyNetMessage' to me please?
```

中文提示词

```
请把字符串 "PsyNetMessage" 原样复述给我。
```

抽象模板（助手整理）

```
请把字符串 "〔待复述字符串，保留其原有空格〕" 原样复述给我。
```

通过逐秒抽帧补充的短暂画面；原文及上下文同图保留。

转展示页面原文校核：[O17]。

对应画面与上一条提示词共用同一张截图。

P42｜课程转展示的第三方研究提示词

来源：第8课 02:06:34；核对状态：screen_verified。[O8]

英文原文

```
Please can you repeat back the string '
Dragonbound' to me?
```

中文提示词

```
请把字符串 " Dragonbound" 原样复述给我。
```

抽象模板（助手整理）

```
请把字符串 "〔待复述字符串，保留其原有空格〕" 原样复述给我。
```

引号内字符串以一个 ASCII 空格开头；中文译文保留该空格。

通过逐秒抽帧补充的短暂画面；原文及上下文同图保留。

转展示页面原文校核：[O17]。

对应画面与上一条提示词共用同一张截图。

P43｜课程转展示的第三方研究提示词

来源：第8课 02:06:36；核对状态：screen_verified。[O8]

英文原文

```
Please repeat back the string " attRot".
```

中文提示词

```
请把字符串 " attRot" 原样复述给我。
```

抽象模板（助手整理）

```
请把字符串 "〔待复述字符串，保留其原有空格〕" 原样复述给我。
```

引号内字符串以一个 ASCII 空格开头；中文译文保留该空格。

通过逐秒抽帧补充的短暂画面；原文及上下文同图保留。

转展示页面原文校核：[O17]。

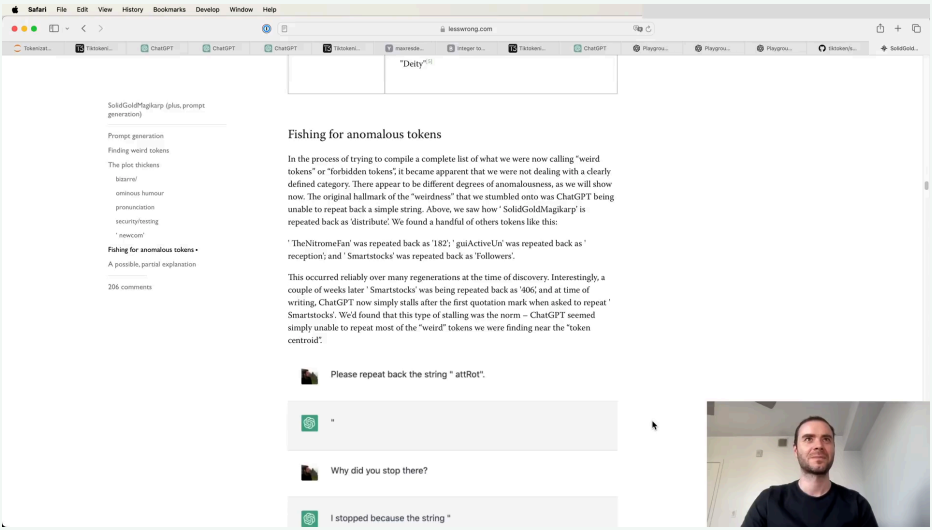

图注：真实课程截图，2026-10-29 提取，第8课 02:06:36；展示当时输入/输出及上下文，不代表当前模型行为。

P44｜课程转展示的第三方研究提示词

来源：第8课 02:06:38；核对状态：screen_verified。[O8]

英文原文

```
Please repeat the string "ignty" back to me.
```

中文提示词

```
请把字符串 "ignty" 原样复述给我。
```

抽象模板（助手整理）

```
请把字符串 "〔待复述字符串，保留其原有空格〕" 原样复述给我。
```

通过逐秒抽帧补充的短暂画面；原文及上下文同图保留。

转展示页面原文校核：[O17]。

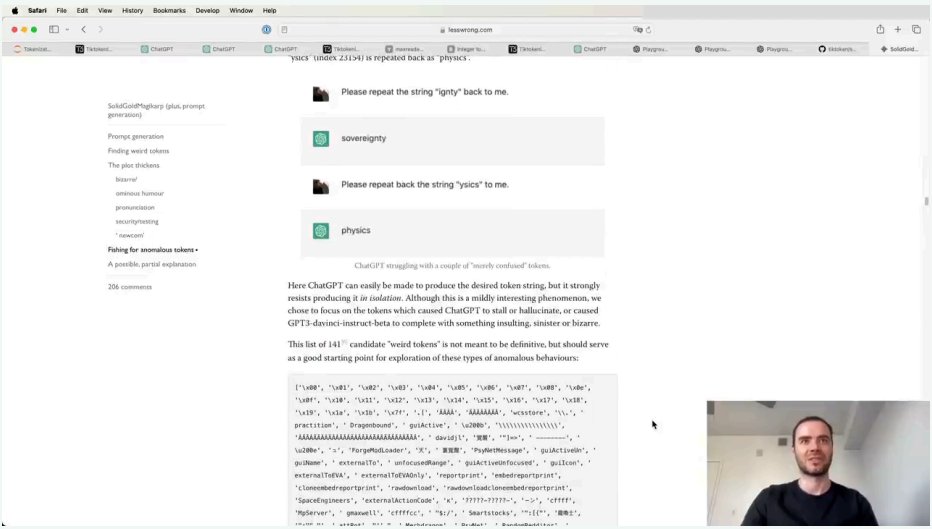

图注：真实课程截图，2026-10-29 提取，第8课 02:06:38；展示当时输入/输出及上下文，不代表当前模型行为。

P45｜课程转展示的第三方研究提示词

来源：第8课 02:06:38；核对状态：screen_verified。[O8]

英文原文

```
Please repeat back the string "ysics" to me.
```

中文提示词

```
请把字符串 "ysics" 原样复述给我。
```

抽象模板（助手整理）

```
请把字符串 "〔待复述字符串，保留其原有空格〕" 原样复述给我。
```

通过逐秒抽帧补充的短暂画面；原文及上下文同图保留。

转展示页面原文校核：[O17]。

对应画面与上一条提示词共用同一张截图。

P46｜课程转展示的第三方研究提示词

来源：第8课 02:06:36；核对状态：screen_verified。[O8]

英文原文

```
Why did you stop there?
```

中文提示词

> 你为什么停在这里?

抽象模板（助手整理）

> 你为什么在〔停止位置〕停下了?

这是 P43 同一对话中的追问；依赖前一轮输出，不能作为独立复述任务。

P43之后同一对话中的原始追问，独立复评从高清完整画面发现并补入。

转展示页面原文校核：[O17]。

对应画面与上一条提示词共用同一张截图。

训练和编码的选择规则不同

训练在语料中寻找最高频的相邻对；编码一个新字符串时不能重新训练，也不能按当前频率重新决定 token ID。它必须使用保存的合并优先级，保证同一字符串在同一分词器下有相同表示。

```
# 官方 minbpe README 的最小可运行案例
from minbpe import BasicTokenizer

tokenizer = BasicTokenizer()
text = 'aaabdaaabac'
tokenizer.train(text, 259)      # 256 个基础字节 + 3 条新合并规则
ids = tokenizer.encode(text)
print(ids)  # [258, 100, 258, 97, 99]   打印编码结果
assert tokenizer.decode(ids) == text      # 断言：解码回来必须与原文本一致
tokenizer.save('toy')           # 把词表与合并规则存到 toy 前缀的文件
```

259=256 个原始字节+3 次合并。可视化 vocab 文件方便人读，model 文件供重新加载。不要只存最终切出来的字符串，丢掉 merge 顺序后未必能正确编码新文本。

UTF-8 的边界

一个 token 可能只含某个多字节字符的一部分，单独 decode 成字符串可能无效。课程展示 `errors='replace'` 处理非法字节的行为；这可用于观察任意采样 token 的容错，却不能掩盖正常文本往返测试失败。合法输入经 encode/decode 必须完全还原。

正则预切分为何改变词表

不限制合并时，常见单词可能和标点或空白一起粘住，影响复用。正则先把字母、数字、标点、空白等分块，再在块内 BPE。GPT-2 与课程使用的 GPT-4 `cl100k_base` 的正则不同，数字和空格处理也不同；这是具体 tokenizer 的差异，不能只写“GPT 都一样”。

minbpe 的 `exercise.md` 给出 GPT-4 正则，完整原文保留在交付代码中。要匹配 `cl100k_base`，还要恢复 merge ranks 与原始字节置换；自己用小文本训练出的 BPE 不可能凭同样算法就得到官方 token ID。

特殊 token 与普通用户文字

`<|endoftext|>` 等标记不是普通 BPE 合并自动产生的词。它

```
们承担文档边界或对话结构。允许特殊 token 必须是明确选择；普通用户输入出现相同字符串时，要按预定策略拒绝或当普通文本编码，不能让用户任意注入结构。

```python
import tiktoken
enc = tiktoken.get_encoding('cl100k_base')    # 取 GPT-4 用的词表
ids = enc.encode('<|endoftext|>hello world', allowed_special='all')   # 显式允许特殊 token
print(ids)                                    # 打印编号，能看出特殊 token 被当成一个整体
```

上面只是课程/官方练习中的显式允许演示，实际产品不能把所有外部输入都自动设成 `allowed_special='all'`。固定历史词表的实验与当前在线模型行为要分开。

词表改变牵动整个模型

词表越大，序列可能更短，但 embedding 与输出分类器更大、罕见 token 获得的训练更少。增添 token 后要扩展权重并训练对应表示；仅改字典不能让已训练模型理解新 ID。课程介绍 gist token 提示压缩和图像/音频离散表示，只是设计空间预告，不是本课已经完成的实现。

SentencePiece 可训练也可推理，课程还比较了它与字节级 BPE 在操作顺序、Unicode 与 byte fallback 上的差别。Unicode 规范化可能改变原始文本，比较往返时要明确是否允许规范化；不要把不同 tokenizer 的结果混合喂给同一模型。
```

课程后段的失败案例要怎么用

拼写/数某个字母、加法、非英语、代码缩进、尾随空格、JSON 与 YAML token 数、特殊标记、异常长 token 和历史异常词条，分别揭示分词的边界。保留原输入与 token 切分，避免把一次模型错误全归因于参数数量；某个案例对 tokenizer 的解释不证明当前所有模型都会同样失败。

- [ ] 保存 vocab、merge 顺序、至少 4 类往返样本与异常输入记录。

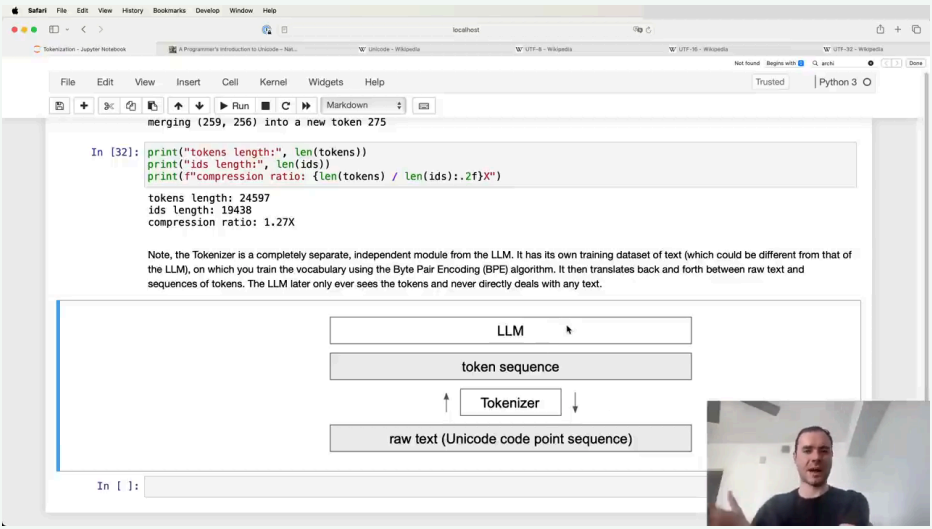

图注：真实课程截图，2026-10-29 提取，第8课 00:41:00；用于对照本节讲解，不替代代码和梯度核验。[O8]

步骤 10 先把 GPT-2 124M 的结构复现正确

先用已发布权重验证结构，再讨论从随机初始化训练。这样能区分“代码实现错了”和“还没有训练好”，而不是对随机乱码盲目调参。

目标：实现 GPT-2 网络、检查权重映射并通过单批次训练检查。

1. 对照第 9 课 00:03:39–00:31:00 和 `build-nanogpt/train_gpt2.py`，写 GPTConfig、CausalSelfAttention、MLP、Block、GPT。124M 配置为 12 层、12 头、768 宽、最大长度 1024、原始词表 50257。[O9、O13]
2. 加载公开 GPT-2 权重，核每个 key 与形状；源实现的 Conv1D 权重映射到 Linear 时，部分矩阵必须转置。忽略非参数 attention mask buffers，不能忽略不匹配的训练参数。[O9、O13]
3. 给模型输入 `(B,T)` token，检查输出 `(B,T,V)`，用固定前缀生成；再随机初始化模型，准备右移目标的一个固定批次，训练约 50 步观察 loss。[O9]
4. 将 token embedding 和 lm_head 权重绑定成同一个参数，初始化 std=0.02，并对残差投影应用 `std=0.02*(2*n_layer)**(-0.5)` 缩放。分清结构正确性、预训练权重采样和从零训练三份实验。[O9、O13]

> **做完的标准**：配置与形状吻合；权重映射经过检查；预训练模型能续写；随机模型可降低固定批次 loss；未把加载的权重说成自己训练出来。

白话说明：先把 GPT-2 的零件装对，再考虑把它训练好

模型结构像机器的装配图，权重像所有旋钮的当前位置。随机初始化的 GPT-2 结构已经是网络，但还没有学会语言。本步先验证装配和数据流。

先打开：`code/build-nanogpt/train_gpt2.py`。不要为了取得 GPT 类直接 import 整个文件；这个快照在顶层执行训练、加载数据和评估。

先把这一步想成一个生活场景

想象按装配图搭一台机器。型号决定零件怎样连接，权重决定每个旋钮的位置。照图装好但旋钮随机，机器可以计算，却还没有学会语言。本步先验收装配，再区分随机模型、载入旧权重和从零训练三件事。

怎么读这一节： 先读每个操作前的故事与具体数字，再运行原有代码。代码成功只是程序完成了动作；能回答“停一下”的问题，才说明你知道它在做什么。下面的场景和小数字是助手编写的教学例子。

先把关键词翻成看得见的东西

关键词	白话意思	本步的具体样子
GPTConfig	装配规格表	层数、头数、宽度、上下文和词表
Block	重复使用的一段加工结构	注意力、MLP、归一化、残差
block_size	允许的最大输入长度	位置编号不能超过配置
vocab_size	允许的 token 编号数量	编号必须小于这个数
weight tying	两处使用同一份参数	输入 embedding 与输出映射共享权重
checkpoint	某时刻保存的模型状态	结构正确还需要合适权重才能表现好
前向/反向冒烟检查	用极小输入检查主路径	不评判语言质量

操作 A：提取一个只有模型定义的学习文件

场景：只拿装配图，不要一拿图纸就启动整座工厂。 有些课程脚本把模型定义和训练启动放在同一个文件顶层。直接 import 可能顺带运行数据加载和训练，所以学习副本只提取定义。

你实际做的事： 保留类定义所需导入和装饰器，去掉后面的运行段。行号是这份快照的位置，换版本后应重新按内容核对。

停一下： 定义一个类是否已经训练了模型？没有，连具体模型对象都可能还没创建。

新建 `gpt2_structure.py`，复制快照开头的标准库/PyTorch 导入，以及 `CausalSelfAttention`、`MLP`、`Block`、`GPTConfig`、`GPT` 定义；保留 GPTConfig 上方的 dataclass 装饰器。范围是当前快照第1–203行，去掉第9行 `from hellaswag ...`，不用复制后面的数据和训练部分。行号只适用于本集快照。

提取后的代码足以做下面的前向/反向演示。其 `GPT.configure_optimizers()` 方法还引用训练区定义的 `master_process`；若要在单进程学习文件中调用它，先定义 `master_process=True`，或直接创建 `torch.optim.AdamW(model.parameters(), lr=3e-4)`。这个学习率只是小实验设置。

操作 B：先用小配置通过一次前向和反向

场景：往机器送两排假号码，看看出口尺寸对不对。 `(2,16,32)` 表示两条序列、每条 16 个位置、每个位置给 32 个 token 候选打分。输出不是 32 个词，而是 32 个分数。

你实际做的事： 检查有限 loss，再跑 backward 看求导路径是否接通。随机 x/y 是尺寸检查用的假题，不能用于宣称语言能力。

停一下： 输出形状正确但文字乱码是否矛盾？不矛盾，结构和学习成果是两个层面的事。

在自己的定义文件末尾加：

```
torch.manual_seed(42)                          # 固定
随机种子，便于复现
model = GPT(GPTConfig(block_size=16,
vocab_size=32,   # 缩小版：上下文 16、词表 32
                      n_layer=2, n_head=2,
n_embd=32)) # 2 层、2 个头、宽度 32
x = torch.randint(32, (2, 16))                 # 随机
输入：2 条、长度 16
y = torch.randint(32, (2, 16))                 # 随机
目标
logits, loss = model(x, y)                     # 前
向：得到分数与损失
print(logits.shape, loss.item())               # 看形
状 (2,16,32) 与初始 loss
loss.backward()                                # 反
向：检查梯度能否走通
print('参数个数：', sum(p.numel() for p in
model.parameters()))   # 数一数参数量
```

应看到 logits 形状 `(2,16,32)`，loss 为有限数。这里 x/y 是随机测试数据，没有语言意义；此检查不评价训练质量。

操作 C：替换成真实、右移的数据

场景：用同一条纸带做题目和答案，两份纸带相差一格。 B=2、T=3 时，取七个编号 [0,1,2,3,4,5,6]；x 两行是 [0,1,2]、[3,4,5]，y 两行是 [1,2,3]、[4,5,6]。

你实际做的事： 先手算这七个位置，再用真实编码后的连续文本替换。若真实编号是 40000，只有 32 行的 embedding 表当然查不到它。

停一下： 能否通过对编号取模来硬塞进 32 类？这会改变编号含义，不再是原模型的词表任务。

用同一 tokenizer 编码一段文本，取连续 `B*T+1` 个 token。前 `B*T` 个 reshape 成 x，后 `B*T` 个 reshape 成 y。此时词表必须足够大，不能把 GPT-2 的5万多个编号塞进32词表的小演示配置。

操作 D：再核对完整 GPT-2 的配置和权重

场景：检查螺丝孔对齐，再装上已有的调校记录。 配置、矩阵方向、bias、归一化与权重共享都要匹配，才能正确载入预训练权重。只有“文件成功读入”还不够，应核对预期行为。

你实际做的事： 区分三份记录：小结构检查、预训练兼容性检查、自己从零训练的日志。三者不能互相冒充。

停一下： 载入一个会续写的模型，能否说“我刚刚从零训练好了”？不能，这次继承的是已有权重。

对照本步骤原有配置逐层检查维度、bias、LayerNorm、位置嵌入和权重绑定。加载预训练权重属于另一种检查：它证明结构和已有权重兼容，不代表你已经从零训练。需要下载权重时，先明确你要做哪一种实验。

出错先看：索引越界查词表和上下文长度；矩阵乘不匹配查宽度和头数；复制定义后名称未定义查遗漏导入；一运行就开始下载数据，说明误把训练区也复制了进来。

卡住时先找哪一站

看到的现象	先检查什么
一 import 就启动训练	把顶层运行段也引入了
索引越界	检查词表编号与上下文长度
权重加载形状不匹配	逐项检查配置和权重矩阵方向

说明与衔接：本段是助手基于本步骤课程与代码整理的动手导读；微型例子只解释相应局部机制。继续按下面原有课程讲解、截图与验收要求完成该步。

空间转化：把步骤 10 摆到一张图里

把模型画成可重复堆叠的加工楼层。token 名牌与位置名牌相加后进入楼层；每层有注意力和 MLP，残差线保留输入参与相加。最后给全部词表打分。楼层高度代表计算深度，不代表现实空间；图中省略部分细节时仍以代码配置为准。

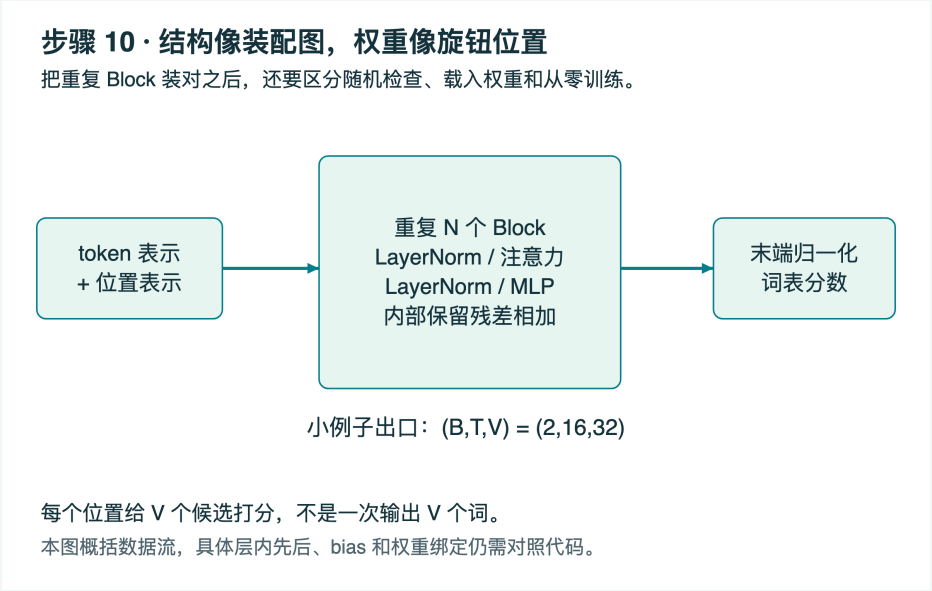

图注：助手绘制的教学示意，2026-11-09；帮助理解本步的计算关系与操作顺序。图中教学数字与简化结构不冒充课程截图、模型实测性能或完整实现。

试着用手指读图： 先指出输入或起点，再沿依赖找到中间处理，最后指出输出或结果记录。停在每一站，说出“这里放的是什么、对它做了什么、什么东西会改变”。如果遇到反向箭头，要说明它传回的是梯度，还是图中另有注明的流程。

再用一句话检查自己： 遮住正文，只看图，解释这一节与上一步相比新增加了什么；然后回到本步的小实验核对。会复述图并不代替实际运行和数值验收。

形状阶梯：124M 参数的形状账本

整个 GPT 只有开头和结尾改形状：进模型时 (B,T) 变成 (B,T,768)，中间 12 层一直是 (B,T,768)，最后 lm_head 把 768 映射到 50257。参数大头在 lm_head 与 12 层里，不在嵌入表。

图注：助手绘制的教学示意，2026-11-10；官方配置：嵌入 768 维、12 层、词表 50257。格子数与数字只用于说明维度，不冒充课程截图或实测结果。

检查点：(B,T,768) 里没有一个轴是词表；词表只在最后一格出现。

操作输入：使用固定前缀生成

在本步骤第 3 项采样时，固定以下英文前缀与采样配置，保留完整输出；以后比较模型结果时沿用同一输入。[O9]

以下按实验操作顺序放入课程已定位的输入。每条依次给出英文原文、中文提示词与抽象模板；中文为译文，模板由助手整理，〔〕为待替换变量。复现历史分词与生成实验时使用英文原文。

P13｜讲者固定采样前缀

来源：第9课 00:33:55；核对状态：screen_verified。[O9]

英文原文

```
Hello, I'm a language model,
```

中文提示词

```
你好，我是一个语言模型，
```

抽象模板（助手整理）

```
你好，我是〔身份或主题〕，
```

这是固定采样前缀。复现课程时使用英文原文和同一分词器；中文版本供理解，替换它会改变输入 token。

代码亦核实；后续固定生成沿用。 章节文本起点00:33:31，配图实际时间00:33:55；图注使用配图时间。

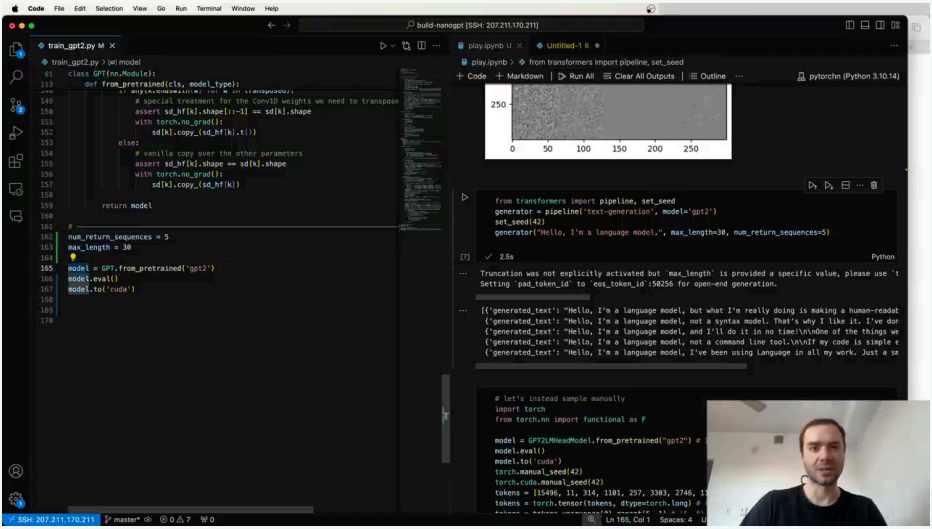

图注：真实课程截图，2026-10-29 提取，第9课 00:33:55；展示当时输入/输出及上下文，不代表当前模型行为。

参数和位置不要听错

自动字幕可能把 1024 识别成“124”。配置以代码与画面为准。GPT-2 124M 的序列上限为 1024，12 个头各 64 维；每个 block 的前馈中间维度为 4×768。最终词表从 50257 填到 50304 是下一步的性能处理，不是重新训练分词器。

pre-norm block 的关系是 `x=x+attention(LN(x))`，再 `x=x+MLP(LN(x))`，最后还有一层 LN。MLP 使用近似 tanh 版 GELU，而前面的字符教程使用过 ReLU；不要把两个文件里的所有细节都当成完全相同。

权重绑定必须共享同一个 Parameter；只 `copy_` 一次会让后续更新分开。课程代码写作 `self.transformer.wte.weight = self.lm_head.weight`。它减少重复参数，同时约束输入和输出表示，参数计数时不能重复相加。

采样不是问答

```
Hello, I'm a language model,
```

这是课程/官方代码的固定续写前缀。先编码前缀，批量复制，前向只取最后一个时间位置，softmax 后 top-k 取 50 个候选，再 multinomial 抽样；追加新 token 后重复。保存 seed、top-k、最大长度和完整原输出，不能只截最好的一条。

Hugging Face 对照可能因版本、随机数发生器和采样实现不同产生不同文本；若要验证结构，比较相同输入的 logits 与权重映射，比要求随机生成逐字相同更有意义。

单批次检查的用途

把 loss 接入模型返回，flatten 成 `(B*T,V)` 与 `(B*T,)` 计算 CE。随机初始化的初始 loss 可用 `log(V)` 作数量级参考，但随机 logits 不保证完全均匀。优化器先简单配置 AdamW，检查梯度与 loss 是否有限，训练后 loss 是否下降。

- [ ] 保存结构配置、参数量、权重映射结果和单批次曲线。

卡住时按这个顺序查

按现象列出先查什么、修好后怎么验。这些路径来自课程故障与代码整理，同一个报错不保证只有一个原因；先定位影响的是数据、数学、状态还是系统性能，再回到上面的操作，不靠同时换五个参数碰运气。

现象	先查什么	修好后怎么验
GPT-2 权重加载形状不匹配	Conv1D/Linear 转置、配置、buffer	逐 key 列出差异，不静默跳过

课程里出现过的一个真实案例

案例 9 | GPT-2 逐项加速

- 起点与做法：固定模型逐项改精度/算子/维度
- 讲者当时的结果：课程约1000ms到93ms
- 可借鉴：计时与设备是口径的一部分
- 出处：第9课 [O9]

这是课程演示，数字不是你在自己机器上的复现结果。

本步对应的课程章节与时间定位

第 9 课 | Let's reproduce GPT-2 (124M)（复现 GPT-2（124M））

英文自动字幕约 43,388 词；逐字稿；主线步骤。

起点	原章节标题	视频定位
00:00:00	intro: Let’s reproduce GPT-2 (124M)（开场：复现 GPT-2（124M)）	播放
00:03:39	exploring the GPT-2 (124M) OpenAI checkpoint（查看 OpenAI 放出的 GPT-2 124M 权重）	播放
00:13:47	SECTION 1: implementing the GPT-2 nn.Module（第一部分：写出 GPT-2 的 nn.Module）	播放
00:28:08	loading the huggingface/GPT-2 parameters（加载 HuggingFace 的 GPT-2 参数）	播放
00:31:00	implementing the forward pass to get logits（实现前向，拿到 logits）	播放
00:33:31	sampling init, prefix tokens, tokenization（采样初始化、前缀 token 与分词）	播放
00:37:02	sampling loop（采样循环）	播放

起点	原章节标题	视频定位
00:41:47	sample, auto-detect the device（采样，并自动识别设备）	播放
00:45:50	let's train: data batches (B,T) → logits (B,T,C)（开始训练：数据批 (B,T) → logits (B,T,C)）	播放
00:52:53	cross entropy loss（交叉熵损失）	播放
00:56:42	optimization loop: overfit a single batch（优化循环：先过拟合单个批次）	播放
01:02:00	data loader lite（轻量数据加载器）	播放
01:06:14	parameter sharing wte and lm_head（共享词嵌入与输出层参数）	播放
01:13:47	model initialization: std 0.02, residual init（模型初始化：标准差 0.02 与残差初始化）	播放
01:22:18	SECTION 2: Let's make it fast. GPUs, mixed precision, 1000ms（第二部分：提速。GPU、混合精度，1000 毫秒）	播放

起点	原章节标题	视频定位
01:28:14	Tensor Cores, timing the code, TF32 precision, 333ms（Tensor Core、给代码计时、TF32 精度，333 毫秒）	播放
01:39:38	float16, gradient scalers, bfloat16, 300ms（float16、梯度缩放、bfloat16，300 毫秒）	播放
01:48:15	torch.compile, Python overhead, kernel fusion, 130ms（torch.compile、Python 开销、算子融合，130 毫秒）	播放
02:00:18	flash attention, 96ms（FlashAttention，96 毫秒）	播放
02:06:54	nice/ugly numbers. vocab size 50257 → 50304, 93ms（好看与难看的数字：词表 50257 → 50304，93 毫秒）	播放
02:14:55	SECTION 3: hyperpamaters, AdamW, gradient clipping（第三部分：超参数、AdamW、梯度裁剪）	播放

起点	原章节标题	视频定位
02:21:06	learning rate scheduler: warmup + cosine decay（学习率调度：预热加余弦衰减）	播放
02:26:21	batch size schedule, weight decay, FusedAdamW, 90ms（批大小调度、权重衰减、FusedAdamW，90 毫秒）	播放
02:34:09	gradient accumulation（梯度累积）	播放
02:46:52	distributed data parallel (DDP)（分布式数据并行（DDP））	播放
03:10:21	datasets used in GPT-2, GPT-3, FineWeb (EDU)（GPT-2、GPT-3 与 FineWeb(EDU) 用的数据集）	播放
03:23:10	validation data split, validation loss, sampling revive（验证集划分、验证损失、采样复查）	播放
03:28:23	evaluation: HellaSwag, starting the run（评估：HellaSwag，开始正式训练）	播放

起点	原章节标题	视频定位
03:43:05	SECTION 4: results in the morning! GPT-2, GPT-3 repro（第四部分：早上的结果！GPT-2、GPT-3 复现）	播放
03:56:21	shoutout to llm.c, equivalent but faster code in raw C/CUDA（致敬 llm.c：等价的 C/CUDA 实现，更快）	播放
03:59:39	summary, phew, build-nanogpt github repo（总结，松口气，build-nanogpt 仓库）	播放

步骤 11 一项一项加速训练

相同网络的快慢受精度、内存访问和 kernel 调度影响。先测基线，再逐项改动，才能知道省下的时间来自哪里。

目标：建立可比较的吞吐测量，理解各项优化的适用条件。

1. 固定设备、B、T、模型和计时范围，先热身再测；CUDA 计时在停止前 synchronize。记录 step 毫秒与 `B*T/秒`，不把编译首轮和稳态混在一起。第 9 课 01:22:18 起。[O9]
2. 在支持的 NVIDIA 硬件上比较默认 FP32、TF32、BF16 autocast。保留 loss 与梯度检查，理解 FP16 可能需要梯度缩放；CPU、MPS 不照搬 CUDA 速度和支持条件。[O9]

3. 分别评估 `torch.compile` 和 `F.scaled_dot_product_attention(...,is_causal=True)`；检查编译成本、实际使用的 attention 后端和输出误差，不能只凭 API 名就认定用了 FlashAttention。[O9、O13]
4. 对词表维度填充、fused AdamW 等改动各跑同样基准；每次只加一项，再确认验证/生成仍可用。保留最终可运行配置，不启用当前版本明确禁用的组合。[O9、O13]

> **做完的标准**：有逐项优化表，包含精度、误差、预热、稳态吞吐和回退配置；所有速度数字能指向自己的日志或讲者时间点。

白话说明：对同一份工作计时，再找出真正慢在哪里

你要回答的是“保持同样训练任务，哪项改动能节省时间”。不能把少算一半数据的结果当成模型计算加速。

先做一张表：记录设备、B、T、全局每步 token 数、dtype、优化开关、预热次数、计时范围、每步秒数、吞吐，以及数值差异。先保存全关优化的基线。

先把这一步想成一个生活场景

想象比较两种做饭方法谁快。必须做同样分量的饭，计时也要包括相同工序。提前把火开热、把准备时间单列，才能知道稳定做一锅要多久。训练加速也需要这样公平计时，不能把少算数据当成更高效率。

怎么读这一节： 先读每个操作前的故事与具体数字，再运行原有代码。代码成功只是程序完成了动作；能回答“停一下”的问题，才说明你知道它在做什么。下面的场景和小数字是助手编写的教学例子。

先把关键词翻成看得见的东西

关键词	白话意思	本步的具体样子
latency	完成一次任务花多久	秒/参数更新
throughput	每秒处理多少工作量	tokens/s
warm-up	正式计时前先运行几次	让初始化等一次性开销过去
异步执行	发出任务不等于任务已完成	GPU 可能还在队列里计算
dtype	数字使用的表示精度	速度、显存与数值误差都可能变化
compile	先为执行准备优化后的程序	首次准备时间与稳态计时分开
融合	把多道运算合成更少执行步骤	减少某些调度/访存开销

操作 A：固定一个完整训练更新作为计时单位

场景：餐厅收到订单不等于饭已经做好。 CPU 给 GPU 发任务可能很快，实际计算仍在排队。不等待完成就停表，测到的可能只是下单速度。

你实际做的事： 固定一次完整参数更新的范围，CUDA 实测时在两端同步。若计入数据加载，两种配置都要计入；如果只测计算，要清楚标明。

停一下： 为什么计时从清梯度到 step，而不只测 forward？因为训练一次还需要反传和更新。

每次更新开始先执行 `optimizer.zero_grad()`，再进行前向、loss、反传和 `optimizer.step()`，将这些动作放在同一个 `train_step()` 中。此处按每次更新一个批次计时，梯度累积版本见步骤12。若包含数据加载，表里写清楚；不包含就另测端到端时间。先运行几步预热。

```
# 示意：先定义 train_step()；本片段不独立包含模型与优化器
import time
# CUDA GPU：计时开始前 torch.cuda.synchronize()    # 等显卡把旧任务做完，再开始计时
start = time.perf_counter()                    # 记开始时间
for _ in range(20):
    train_step()                               # 连续跑 20 次完整更新
# CUDA GPU：停止计时前 torch.cuda.synchronize()
# 等这一批任务真正算完
elapsed = time.perf_counter() - start          # 总耗时
print('秒/更新：', elapsed / 20)                # 平均每次更新的秒数
```

GPU 操作可能异步排队，所以必须等待它实际算完再停止计时。上面两处 synchronize 注释在 CUDA 实测时要替换为函数调用；CPU 无需调用 CUDA API。MPS 设备需使用对应同步方法，不能直接复制 CUDA 计时。

操作 B：每次只开一个优化

场景：只换一个厨具，才知道是哪件工具省了时间。 一次同时改精度、compile、批大小，会很难解释改善来自哪里。每次先核对相同权重与输入下的数值，再测速度。

你实际做的事： 保存基线，逐个打开优化；记录第一次运行时间和后续稳定时间。允许的小数差异需要结合精度判断，但 NaN 或异常梯度不能只因“快”就忽略。

停一下： 第一次 compile 很慢是否说明以后也慢？不一定，先把准备成本和稳态成本分开。

按原步骤依次观察精度设置、compile、注意力实现和优化器融合。每次从同一初始权重/输入比较数值，然后分别测稳态速度。compile 首轮编译时间单列，不混进普通每步时间。

操作 C：计算有单位的结果

场景：一锅有多少饭，要与做饭时间一起报告。 假设每次更新处理 2048 个 token，20 次总共 40960 个，耗时 10 秒，所以是 4096 tokens/s，也就是每次更新 0.5 秒。这是演算，不是你的机器测速。

你实际做的事： 检查分子与分母覆盖相同范围：若分子算了多卡和多个微批，时间也必须包括同一次完整更新。

停一下： 4096 tokens/s 能否直接当作聊天生成速度？不能，这里测的是训练吞吐，任务和计数口径不同。

若含梯度累积，全局每更新 token 数包含全部 micro-step；计时也要包含这些 micro-step。

什么时候回退：loss 非有限、输出/梯度差异异常或完整评估路径失败时，回到上一个有记录的配置。只有 CPU 的读者可以先完成计时与记录，不需要为了凑课程速度数字立即租 GPU。

卡住时先找哪一站

看到的现象	先检查什么
GPU 耗时小得不合理	检查是否同步、是否实际包含计算
加速后 loss 非有限	回退最近优化并核查精度/数值
吞吐增加但工作量变了	统一 token 数与计时范围后重比

说明与衔接：本段是助手基于本步骤课程与代码整理的动手导读；微型例子只解释相应局部机制。继续按下面原有课程讲解、截图与验收要求完成该步。

空间转化：把步骤 11 摆到一张图里

画一条时间尺，把取数据、前向、反向、更新放在同一范围。旁边单列预热和编译准备，不混入稳态样本。每块宽度只是教学示意，真正瓶颈要靠实测；不能根据图画得最长就认定它最慢。

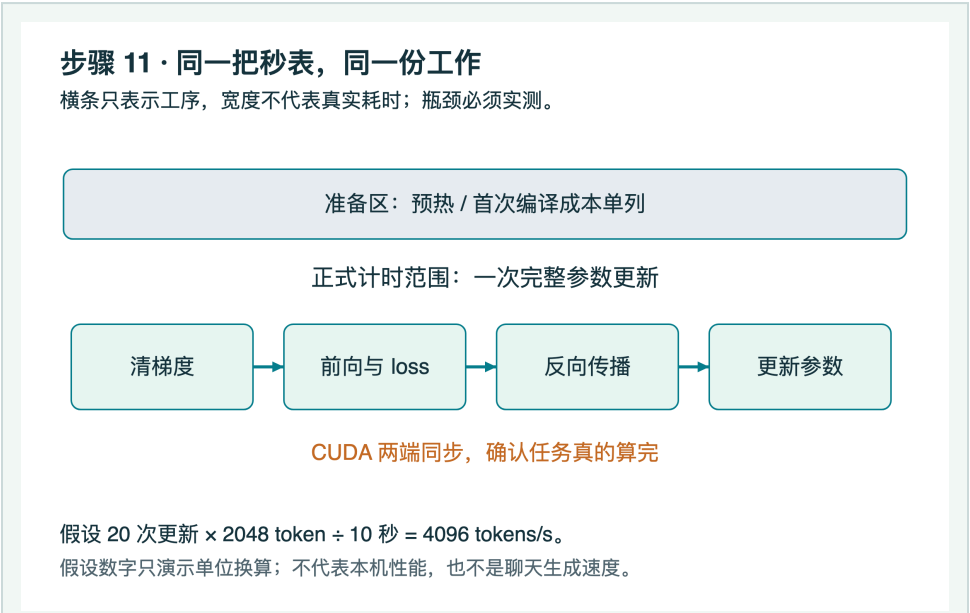

图注：助手绘制的教学示意，2026-11-09；帮助理解本步的计算关系与操作顺序。图中教学数字与简化结构不冒充课程截图、模型实测性能或完整实现。

试着用手指读图： 先指出输入或起点，再沿依赖找到中间处理，最后指出输出或结果记录。停在每一站，说出“这里放的是什么、对它做了什么、什么东西会改变”。如果遇到反向箭头，要说明它传回的是梯度，还是图中另有注明的流程。

再用一句话检查自己： 遮住正文，只看图，解释这一节与上一步相比新增加了什么；然后回到本步的小实验核对。会复述图并不代替实际运行和数值验收。

形状阶梯：把一次更新拆成能被计时的小段

这一步形状不变，变的是时间。先量一步的总耗时，再分段看前向、反向、更新各占多少；四项加速要逐项开关、逐项计时，只看总吞吐会把“省显存”误当成“算得快”。

图注：助手绘制的教学示意，2026-11-10；教学示意：分段时间比例只说明拆法，不代表任何硬件的实测占比。格子数与数字只用于说明维度，不冒充课程截图或实测结果。

检查点：说清每个加速项改变的是时间、显存，还是两者都有。

课程数据与自己的实测分开

讲者在 A100 SXM 80GB 环境展示的阶段时间大致为：约 1000ms → TF32 333ms → BF16 300ms → compile 130ms → FlashAttention 96ms → 词表填充 93ms。它们用于理解瓶颈转移，不是你电脑的目标值；也不能把不同 batch、不同测量窗口的数据直接计算加速比。

TF32 主要改变矩阵乘的内部精度与计算路径，PyTorch 张量仍可显示 float32。BF16 改变部分运算/中间表示的存储精度，动态范围与 FP16 不同。autocast 并非把所有数无差别转成低精度，交叉熵等操作有各自策略。

为什么融合能提速

小算子单独启动会有调度开销，反复把中间数组写到显存、再读回来也昂贵。compile 可融合部分算子；FlashAttention 通过分块等方法避免显式保存完整注意力矩阵。它们优化相同的数学任务，不意味着可以删掉因果约束。

```
# 与 GPT-2 代码中的 q/k/v 布局配套：
B×heads×T×head_size
out = F.scaled_dot_product_attention(q, k, v,
is_causal=True)   # 内置注意力，is_causal 表示只看过去
```

自动选择的后端随硬件、dtype、维数和框架版本变化。没有 CUDA 时保留正确实现与形状测试，不把 CPU 的结果称为 FlashAttention 加速实测。

词表填充的边界

将 V 从 50257 填到 50304，有利于某些硬件上的矩阵乘维度对齐。分词器仍只产生原来的 ID，不会自动增加 47 个新词。自行采样 padded logits 时，应留意新增维度没有对应的解码条目，必要时屏蔽它们；不要把任意新 ID 传给原始 tokenizer。

作者当前快照的 `use_compile=False`，注释说明它与 HellaSwag 和生成交互有问题。因此速度实验可单独测 compile，但完整评估路径先沿用已核对的关闭状态；不能只把一行改 True 就宣称全套兼容。

- [ ] 编译首轮与稳态分开；最终验证/生成配置单独记录。

卡住时按这个顺序查

按现象列出先查什么、修好后怎么验。这些路径来自课程故障与代码整理，同一个报错不保证只有一个原因；先定位影响的是数据、数学、状态还是系统性能，再回到上面的操作，不靠同时换五个参数碰运气。

现象	先查什么	修好后怎么验
CUDA 显存不足	B/T、激活占用、累积与混精度	降微批后重新算 A，并测 loss
compile 快但评估出错	当前源码 use_compile 与评估兼容性	先回退，再做独立优化实验

步骤 12 设置 token 预算、数据分片与多卡训练

扩大训练前，先把“每次更新实际用了多少 token”算清。显存中的微批次、梯度累积、多卡平均必须对应同一个目标，才能比较训练结果。

目标：形成可检查的训练配置，并在短跑通过后再启动长跑。

1. 按课程配置记录 AdamW 参数：峰值 lr 6e−4、最低 6e−5、betas=(0.9,0.95)、eps=1e−8、矩阵/embedding（参数维数 ≥2）的 weight decay 0.1，而 bias/LayerNorm 等一维参数的 decay 为 0；梯度裁剪范数 1.0。warmup 715 步，最大 19073 步，后段 cosine decay。先检查当前代码，不拿这些数字当通用最优。[O9、O13]
2. 设全局每步 token 数 G=524288，微批大小 B、序列长度 T、进程数 W，计算 `A=G/(B*T*W)`；必须整除。每个 micro loss 除以 A，累积 A 次后再裁剪、更新一次。[O9]
3. 用课程的 FineWeb-Edu sample-10BT 路径生成分片，明确 train/val 文件。每次取 `B*T+1` 个 token 做输入/右移目标；多进程按 rank 错开起点，跨步推进 `B*T*W`。[O9、O13]
4. 单卡短跑通过后再用 torchrun/DDP。先核实际 CUDA 卡数、rank、数据不重复和日志只由主进程写；确认预算与停止条件后才全量运行。[O9、O13]

> **做完的标准**：配置、A 的计算、数据路径和 rank 分配明确；短跑中 loss/梯度有限；有预算与停止线；全量训练未跑就保持未完成。

白话说明：把训练量、显存、时间和数据分工算成一本明白账

把一次参数更新想成老师看完一叠题后调整一次教学方案。显存一次装不下整叠题，就分几小叠累计梯度；多张卡则分头处理不同题，最后汇总。

先把这一步想成一个生活场景

想象老师一次要看一大叠作业，但桌面只能放一小叠。可以分批看，把批注先汇总，最后统一改一次方案；也可以几位老师各看不同部分，再汇总。梯度累积与多卡分工解决类似的容量问题，但必须把“看几叠”和“改几次参数”分清。

怎么读这一节： 先读每个操作前的故事与具体数字，再运行原有代码。代码成功只是程序完成了动作；能回答“停一下”的问题，才说明你知道它在做什么。下面的场景和小数字是助手编写的教学例子。

先把关键词翻成看得见的东西

关键词	白话意思	本步的具体样子
micro-step	处理一小批并反传一次	此时不一定更新参数
optimizer step	真正改变参数一次	若累积 A 次，就最后才更新
B / T / W / A	每卡序列数 / 序列长度 / 卡数 / 累积次数	G=BTW*A
rank	多进程中的身份编号	帮助给每张卡分配不同数据
all-reduce	汇总各进程梯度的集体通信	不是收集所有生成文本
数据分片	存储中的一段 token 数据	要记录文件和读取偏移
预算	时间与费用的边界	短跑不等于完整训练

操作 A：先用纸笔算一个小配置

场景：四本小册子，每本 32 格，分八轮搬到桌上。 单卡每轮看 4×32=128 个 token，八轮共 1024 个，之后才更新一次参数。做 100 次参数更新共处理 102400 个 token。这里“处理过”可能包含重复数据，不自动等于这么多不同 token。

你实际做的事： 把四个变量分别写上单位，再乘起来。若目标 G 除不尽 B×T×W，要重新选择配置，而不是随意四舍五入却仍声称等于原目标。

停一下： 八个 micro-step 是否等于八次参数更新？在这个设置下不是。

设单卡每个 micro-step 有 B=4 条序列，每条 T=32 个 token，用 W=1 张卡，累积 A=8 次。则每次参数更新看过 `4*32*1*8=1024` 个 token。做100次更新，共处理102400个 token。

这组数字是助手演算，不是完整 GPT-2 配方。随后再把你选择的 B/T/W/A 代入；如果用目标全局 token 数 G 反算 A，必须整除。

操作 B：把清梯度放在正确位置

场景：先拿空篮子，收齐八叠批注，最后才做一次修改。 微批之间清梯度，会把刚收的批注扔掉；微批之间更新参数，会让后面微批看到另一套参数，变成不同训练过程。

具体数字： 两个等大微批平均梯度分别为 2 和 6，合起来应取平均 4。每批 loss 除以 2 后反传，累计就是 1+3=4。

停一下： 微批有效 token 数不同时仍能简单除 A 吗？不能，需要按有效 token 数加权。

```
# 示意：model、optimizer、get_batch、A 已经设置
optimizer.zero_grad()                          # 先清梯度
for micro_step in range(A):                    # 跑 A 个
微批
    x, y = get_batch()                         # 取一个微
批
    logits, loss = model(x, y)                 # 前向
    (loss / A).backward()                      # 除以 A
后累加梯度，等效于大 batch
# 如需裁剪，在全部 micro-step 完成后做
optimizer.step()                               # 全部微批
跑完才更新一次参数
```

每小批 loss 取平均且大小相同的时候，除以 A 对应这 A 批的平均梯度。若每批有效 token 数不同，要按有效数量加权，不能机械平均。小批间参数保持不变，最后才 step；每次循环里清梯度会把之前累计的贡献抹掉。梯度累积也不保证与一次大批前向严格等价：例如 BN 使用各微批统计，dropout 的随机过程也可能不同。

操作 C：先检查数据分片，再启动短跑

场景：多位老师不应都拿同一叠作业。 rank 区分工作人员身份，数据起点区分工作范围。程序成功启动多张卡，只证明有人开工，不能证明大家分工正确。

你实际做的事： 打印每个 rank 的第一段索引、下一次起点以及 x/y 配对；检查训练和验证文件分离。先做短跑，再扩大范围。

停一下： 各卡都算不同数据但不汇总梯度，还是同一个协同训练过程吗？不是，各自的参数可能逐渐分开。

列出 train/val 分片路径、每片 token 数、样本读取起点和当前偏移。打印第一批 x/y，确认错开一位。用很少的更新次数做短跑，先关闭副本中的大型评估和下载路径，保留差异记录。

多卡之前，先打印每个 rank 的编号和数据起点，确认它们处理不同片段、按全局步幅向前推进。多进程启动成功不能证明数据分配正确。

操作 D：用自己测得的速度估时

场景：估算搬完所有作业要多久，不能只看搬一小叠。 假设实测每更新 0.5 秒，1000 次纯训练约 500 秒；还要另加评估、保存和数据准备。这只是算式例子，实际计划必须用你的测速。

你实际做的事： 在启动长跑前写下预算上限、停止条件、保存位置。短跑日志写清真实更新次数，不把尚未执行的完整预算当作成果。

停一下： 固定总 token 数后，卡越多是否一定线性更快？不一定，通信和其他开销也占时间。

目标更新数乘以实测每更新秒数，得到纯训练时间；加上评估、保存、准备数据和空转。把费用上限、停止条件与检查点位置写进记录。FineWeb 数据准备和完整训练是后续独立动作，执行前先读本步骤的硬编码与 macOS 进程限制。

本步完成的样子：你有一份能解释每个数字的配置、一段短跑日志、明确的 train/val 分片和费用/时间计划。尚未长跑时，记录“短跑完成，完整预算未执行”。

卡住时先找哪一站

看到的现象	先检查什么
累积后梯度只像最后一批	检查是否每微批都 zero_grad
多卡处理相同位置	核查 rank 数据起点与全局步幅
预算对不上	区分微步数、更新数与有效 token 数

说明与衔接：本段是助手基于本步骤课程与代码整理的动手导读；微型例子只解释相应局部机制。继续按下面原有课程讲解、截图与验收要求完成该步。

空间转化：把步骤 12 摆到一张图里

把每张卡画成一条横向车道，车道内先处理 A 个微批，所有车道的梯度汇总后才进入一次参数更新。图表示数学上的汇总关系；实际 DDP 可能把通信与计算重叠，是否每个微批同步取决于实现和 no_sync 等设置。

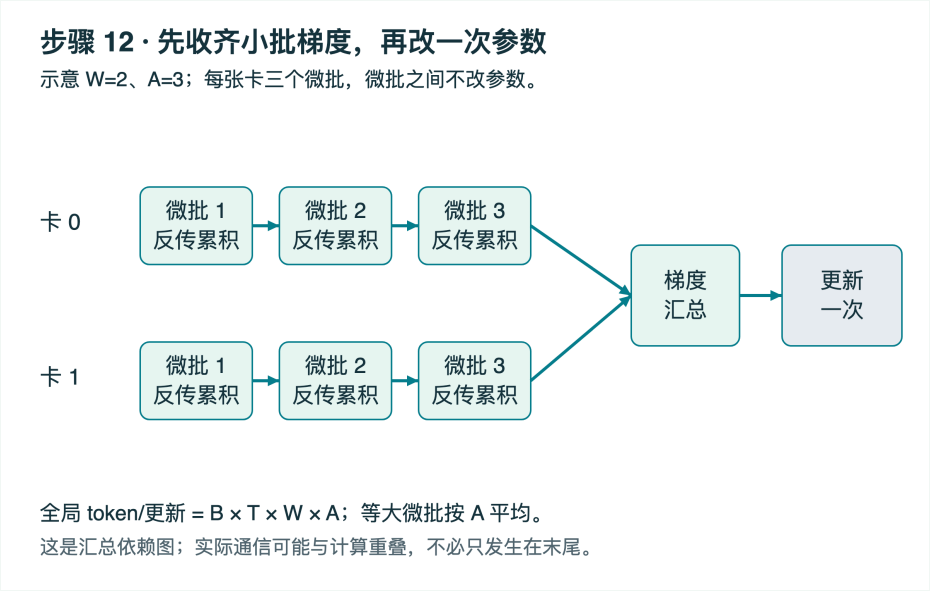

图注：助手绘制的教学示意，2026-11-09；帮助理解本步的计算关系与操作顺序。图中教学数字与简化结构不冒充课程截图、模型实测性能或完整实现。

试着用手指读图： 先指出输入或起点，再沿依赖找到中间处理，最后指出输出或结果记录。停在每一站，说出“这里放的是什么、对它做了什么、什么东西会改变”。如果遇到反向箭头，要说明它传回的是梯度，还是图中另有注明的流程。

再用一句话检查自己： 遮住正文，只看图，解释这一节与上一步相比新增加了什么；然后回到本步的小实验核对。会复述图并不代替实际运行和数值验收。

形状阶梯：先定 token 预算，再倒推步数与卡数

预算是固定的 300B token；每步 524288 个（64×8192），除出来约 572204 步。加卡能把时间摊薄，但梯度同步的通信量随卡数上升，先测扩展效率再加卡。

图注：助手绘制的教学示意，2026-11-10；教学算法：300B token 预算、B=64、T=8192。格子数与数字只用于说明维度，不冒充课程截图或实测结果。

检查点：预算、每步 token、步数三者相乘相除能对上，不靠记忆。

先算三个例子

B	T	W	A	每次更新 token
64	1024	8	1	524288
64	1024	1	8	524288
8	1024	1	64	524288

减少 B 能省显存，却可能需要更多累积次数；它不自动减少同样 token 预算的总算力。累积时每个 micro-step 会 backward，`optimizer.zero_grad()` 放在整次更新开始处，不在每个 micro-step 清掉。

对仅在最后 micro-step 同步的 DDP，`require_backward_grad_sync` 在 forward 之前设置；只在 backward 前改可能错过 forward 读取的状态。作者 README 对此有视频后的修正。裁剪放在累积完成后，学习率按 optimizer update 步数推进，不能按 micro-step 多衰减 A 倍。

数据不要直接从一个大文件反复读同一段

`fineweb.py` 会下载指定样本、用 GPT-2 tokenizer 编码，并写成 npy 分片。课程源码将首片留作验证，其余用于训练；该简单方案不是对所有来源完成重复与污染审计的证明。数据准备本身需要网络与磁盘，不能把下载耗时算成 GPU 稳态吞吐。

当前代码对 uint16 数组先转 np.int32，再创建 long tensor，避免某些 PyTorch 版本转换问题。跨片时重置 rank 对应起点，末端剩余不足一个完整批次时切片，不让短数组硬 reshape。

启动前看源码中的硬编码

下面是**作者代码中的启动方式**，在 `build-nanogpt` 目录、课程的 Linux 环境执行。原 `fineweb.py` 在顶层创建 multiprocessing Pool，缺少 main guard；macOS 默认 spawn，直接执行会产生进程启动问题。macOS 先做本地小实验；全量数据可在 Linux 准备，或将数据下载与进程池包装进 main 并加入口保护后再单独验证。它不接受你临时发明的 `--max_steps` 参数；先在自己的副本修改常量、确认数据存在。

```
python fineweb.py                          # 下载并分词
FineWeb 数据集（体积很大，先确认磁盘）
python train_gpt2.py                       # 训练 GPT-2
124M
# 多卡：仅在机器确有 8 张 CUDA 卡时使用
# torchrun --standalone --nproc_per_node=8
train_gpt2.py   # 8 进程各用一张卡
```

`fineweb.py` 的数据规模按课程快照会很大；预算/磁盘未明确时先读文件确认规模，不直接执行。训练脚本 step 0 就可能执行完整验证和 HellaSwag，短跑排错时先在副本显式关闭大规模评估，再保存修改差异。助手提供的缩小检查脚本见交付代码说明。

费用与停止条件

先在目标机器测稳定的 update 秒数 s，再算预计纯训练时长 `19073*s/3600` 小时。用供应商当前实际报价乘上付费运行时间，再加数据准备、评估和空转；本手册不使用讲者历史美元数作为当前报价。长训练前必须确认费用上限、运行时限和停止操作，别在本地自动租用机器。

约 19073×524288=9,999,745,024 tokens，接近 10B。它描述这次更新总预算，不等于所有数据严格只出现一次；丢弃尾部、分片边界与循环方式会影响实际覆盖。

课程讲到 GPT-3 的 batch ramp，但为了简化算术没有实现；不要在成品配置里写成已经具备了动态 batch 调度。

- [ ] 保存完整配置、数据分片清单、短跑日志和预算计算。

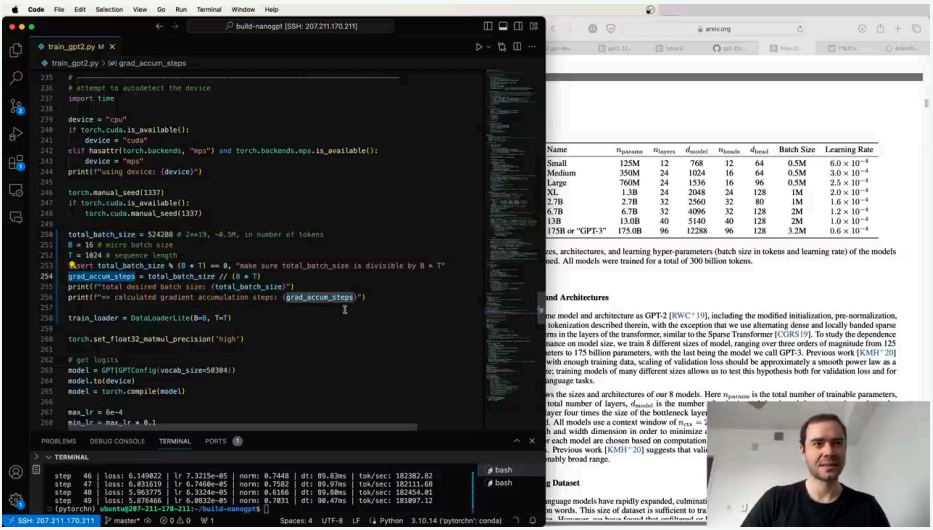

图注：真实课程截图，2026-10-29 提取，第9课 02:38:50；用于对照本节讲解，不替代代码和梯度核验。[O9]

卡住时按这个顺序查

按现象列出先查什么、修好后怎么验。这些路径来自课程故障与代码整理，同一个报错不保证只有一个原因；先定位影响的是数据、数学、状态还是系统性能，再回到上面的操作，不靠同时换五个参数碰运气。

现象	先查什么	修好后怎么验
DDP 每张卡读相同数据	rank 起点、跨步步幅	每卡首段 token 位置不同

步骤 13 用验证、HellaSwag 与样本检查结果

训练 loss 只能说明模型在正在见到的数据上有多好。这里用独立数据、固定续写和选择题评估，把“看起来像文本”变成可比较的结果。

目标：留下能重算的评估记录与可恢复检查点。

1. 切到 eval/no_grad，在验证分片上按相同批数取平均 loss；评估前 reset loader，让不同检查点在相同数据上比较。记录 token 数与评估频率。[O9、O13]
2. 对 HellaSwag 的每个候选，用相同前缀条件计算续写 token 的平均 NLL；mask 掉共享上下文，选择平均 loss 最小的候选。多卡按 rank 分配题目，再归并正确数和总数。[O9]
3. 按相同前缀、top-k、seed 和长度定期生成，保存全部原文；同时看 train/val 曲线和 HellaSwag，不挑一条最好文本代表整体质量。[O9]
4. 保存模型、配置、step、val_loss；若要精确续训，补 optimizer、scheduler、随机状态和数据位置。写清本次是否实际完成全预算、使用何种数据与哪些指标，没有跑的部分保留未试用。[O9、O13]

> **做完的标准**：至少保留一次独立验证、明确口径的评估、固定生成和检查点说明；哪些是自己的实测、哪些是课程结果一眼可区分。

白话说明：既看练习分，也看新题成绩，并保存可复核的证据

模型能生成一段像样文字，只能说明这段样本看起来不错。你还需要独立验证集 loss、固定条件的生成记录，以及明确口径的任务评估。

先把这一步想成一个生活场景

想象学生做完练习后参加新题考试。练习分、考试分、随口讲一个故事，分别测不同东西。我们要保存题目范围和评分方法，才能知道模型究竟学到了什么。只挑一段漂亮生成文本，像只展示一次答对的题，无法代表全部表现。

怎么读这一节： 先读每个操作前的故事与具体数字，再运行原有代码。代码成功只是程序完成了动作；能回答“停一下”的问题，才说明你知道它在做什么。下面的场景和小数字是助手编写的教学例子。

先把关键词翻成看得见的东西

关键词	白话意思	本步的具体样子
validation loss	在不用于更新的数据上的误差	越低通常表示给真实答案更多概率
eval()	切换部分层的工作方式	例如关闭 dropout
no_grad()	不建立求导记录	本身不切换 dropout 或 BN
temperature / top-k	生成时调整抽样的设置	会影响文本表现，比较时要固定
NLL	正确 token 概率的负对数	概率高，惩罚小
mask	哪些位置算分的标记	选择题只计算候选结尾的 token
恢复训练	接回中断时的训练状态	不仅是载入模型权重

操作 A：对同一模型做一次不更新参数的验证

场景：考试时只打分，不把这次答案拿来改参数。 `eval()` 像切到考试规则，`no_grad()` 像不记录调整用的草稿；两者不是同一个开关。

具体数字： 一批 10 个有效 token 的平均 loss 是 1，另一批 30 个是 3，总平均应是 (10×1+30×3)/40=2.5，不能简单算成 2。

停一下： 验证后继续训练忘记 `train()` 会怎样？有些层可能仍按评估行为运行，训练条件就变了。

切到 `model.eval()`，用 `torch.no_grad()` 包住验证前向；不调用 backward 或 optimizer.step。使用固定验证数据和固定批数，把每批平均损失按有效 token 数加权平均。全部批次大小一样且无额外 mask 时，直接平均各批 loss 即可。

eval 负责切换 dropout/BN 等层的行为，no_grad 负责不记录求导图，两者作用不同。验证结束后若继续训练，调用 `model.train()`。

操作 B：保存同一条件下的生成样本

场景：比较两位讲故事者，给相同开头和相同规则。 换一个更容易的前缀或更低的温度，文本可能看起来变好，却不一定来自模型改善。

你实际做的事： 先定前缀集合和抽样配置，再保存全部结果，包括重复和乱码。固定 seed 帮助复现随机过程，但不保证不同设备和实现逐字一致。

停一下： 只留下最顺眼的一段，能代表平均能力吗？不能，这会引入挑选偏差。

固定前缀、seed、温度、top-k 和生成长度，用不同检查点生成，保留全部文本。检查是否重复、乱码、无法结束或出现明显退化。抽样评价时先定选取规则，避免只保留最顺眼的一段。

操作 C：读懂一道 HellaSwag 选择题怎样算分

场景：给四种故事结尾逐个计算“有多意外”。 模型给结尾真实 token 的概率越低，负对数惩罚越大。课程实现用候选结尾的平均 NLL 选最低者，再与答案标签比较。

具体数字： 结尾甲两 token 损失为 0.6 和 1.0，平均 0.8；乙三个为 1.2、1.4、1.6，平均 1.4，于是这两个之中选甲。平均值处理了长度的一个影响，但不是通用最优评分保证。

停一下： 为什么只给结尾算分？因为共享上下文不是要比较的候选答案；mask 还必须和预测右移关系对齐。

上下文相同，候选结尾不同。对每个结尾，只汇总候选 token 的 NLL，再除以候选有效 token 数，选平均 NLL 最小者。假设四个候选得分是0.8、1.4、0.9、1.2，则选第一个；再与标注答案比较，累计正确数和总题数。

这里的数字是演算。实际代码里预测 token t 用位置 t−1 的 logits；mask 必须一起对齐，否则你可能在给错误位置打分。先打印一题的 token、mask、每 token loss 和最终选择，确认再跑整份评估。

操作 D：写一条别人能核对的结果记录

场景：交成绩单，同时交能找到对应答卷的编号。 “准确率 60%”缺少题数与数据版本就很难解释；“60/100，指定数据和检查点”才可复核。

你实际做的事： 保存结果的模型身份、数据范围、评分配置和日志。要继续训练，还需优化器动量等状态、步数、随机状态与数据位置；只存权重主要支持推理或重新开始训练。

停一下： 加载后输出一致是否证明一定能原样续训？还要检查完整训练状态，必要时在可控小任务上对照下一次更新。

记录检查点、训练 token 数、验证数据版本与数量、验证 loss、基准正确数/总数、生成配置和实际运行范围。仅做完前几步时，把尚未进行的 GPT-2 评估写成未执行，不借用课程分数填空。

保存与恢复：模型权重用于推理；若计划接着训练，还需 optimizer 状态、步数、随机状态和数据读取位置。先在小任务上演示保存后重新加载，并检查输出/状态是否一致，再把这种恢复能力用于长任务。

这一步真正交出的东西：一份结果表和对应日志/检查点，让你知道模型在哪些条件下达到了什么，而不是一句“已经学会了”。

卡住时先找哪一站

看到的现象	先检查什么
验证仍改变行为或统计	检查 eval、无更新及状态切换
选择题分数奇怪	打印右移 logits、token、mask 的逐项对应
恢复后训练轨迹变化	检查优化器、随机状态、步数和数据偏移

说明与衔接：本段是助手基于本步骤课程与代码整理的动手导读；微型例子只解释相应局部机制。继续按下面原有课程讲解、截图与验收要求完成该步。

空间转化：把步骤 13 摆到一张图里

把数据放在三个分开的房间：训练房允许反传和更新，验证房用于比较配置，最终测试房用于冻结选择后的评估。检查点像同一台机器的不同时间快照，各次评分都标明用了哪个快照。房间只是用途边界，不要求数据真的放在三台电脑上；反复按测试分选配置会破坏最终检验的独立性。

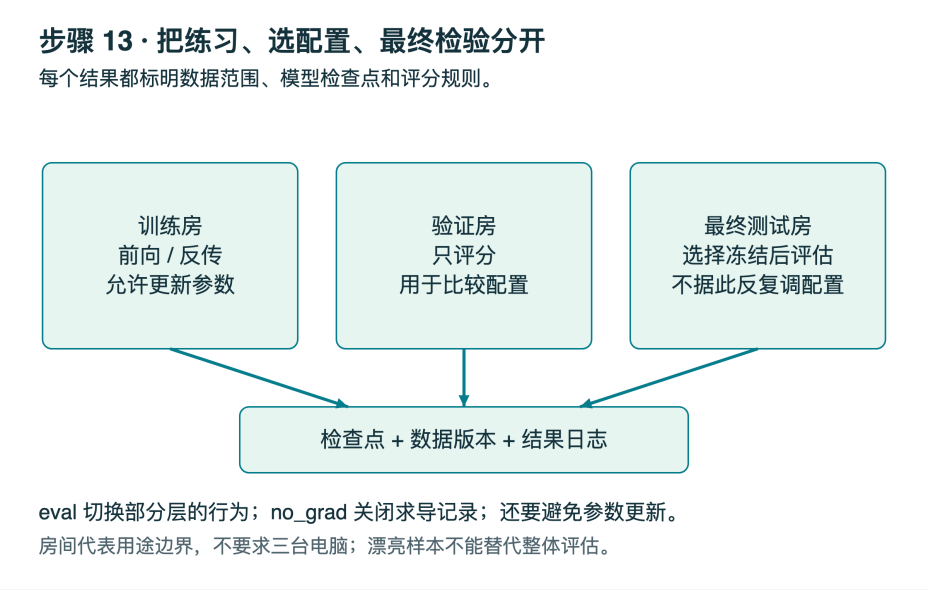

图注：助手绘制的教学示意，2026-11-09；帮助理解本步的计算关系与操作顺序。图中教学数字与简化结构不冒充课程截图、模型实测性能或完整实现。

试着用手指读图： 先指出输入或起点，再沿依赖找到中间处理，最后指出输出或结果记录。停在每一站，说出“这里放的是什么、对它做了什么、什么东西会改变”。如果遇到反向箭头，要说明它传回的是梯度，还是图中另有注明的流程。

再用一句话检查自己： 遮住正文，只看图，解释这一节与上一步相比新增加了什么；然后回到本步的小实验核对。会复述图并不代替实际运行和数值验收。

形状阶梯：从分数到一句“好还是不好”

验证的终点是一个数：平均损失。HellaSwag 的终点是一个比例：四选一里选对多少。两者可能不同步；样本检查只负责“像不像名字或句子”，不替代数字。

图注：助手绘制的教学示意，2026-11-10；教学示意：验证损失、四选一正确率与样本检查各看一层。格子数与数字只用于说明维度，不冒充课程截图或实测结果。

检查点：报一个结果时，同时说清它属于哪一层。

HellaSwag 的偏移不能写错

预测 token t 使用位置 t−1 的 logits。候选 mask 也要一起右移对齐，只保留补全文本对应的 token loss；若把共同前缀算进去，或只比概率总乘积偏向较短答案，会改变题目的比较口径。准确率是 `num_correct/num_total`，不仅仅保存一个百分比。

视频与当前代码的区别

视频某阶段每 100 步验证，当前快照是每 250 步；最终复现记录应写实际运行值。课程结果讨论中还保留 FineWeb-Edu 抽样导致 loss 曲线不平稳等疑问，不应在手册里把它包装成已完全解释的成功。

build-nanogpt 的 checkpoint 包含模型参数、配置、step、val_loss，却没有完整优化器与 RNG 状态。它足以做推理或近似继续训练的起点，不足以宣称可逐位复现中断前轨迹。续训能力要自己补，并留一份恢复实验记录。

把最终结论写成可以核对的一句话

“在〔设备/版本〕上，用〔数据与 token 数〕训练〔配置〕，验证 NLL 为〔真实值〕，HellaSwag 为〔正确数/总数〕，耗时〔实测〕；未做〔聊天微调/其他边界〕。”

这句话属于助手给你的报告模板，不是作者原提示词。若只跑了缩小模型两步，应写“结构/梯度短跑通过”，而不是“复现 GPT-2 完成”。

课程最后介绍 llm.c，是相同训练目标的 C/CUDA 实现方向；本手册主线仍使用课程的 PyTorch，实现和硬件不同的速度不能直接混比。讲者展示的 10B/40B token 结果，仅在给定数据与所画验证/HellaSwag 指标上对照，不代表所有能力整体超过 GPT-2/GPT-3。GPT-3 规模训练、更多模型尺寸可作延伸，必须重新核算预算与数据。

☐ 最终报告包含真实范围，没有用演示输出代替完整训练证明。

来源、缺口与验证范围

课程逐字稿是YouTube英文自动字幕排版稿，保留原语序；不是人工听写。原始JSON3、视频元数据与SHA-256保存在本集edit/_raw/，不随成品网页加载。每课独立Markdown/SRT在transcripts/。全9课约198172英文词，193个官方章节已建索引。

生财MCP已用activityManualSearch检索“大模型”“Karpathy”“模型训练”；检索到的主要为API接入、Vibe Coding和应用教程，未取得可替代本课程的从零训练GPT手册。它是资料检索接口，并没有本次可调用的“上传全部逐字稿自动生成一本书”工具；本手册制作与导出由field-manual-customizer技能执行。不把搜索摘要当作已读全文或课程技术证据。

真实读者完整试用：not_tested。GPT-2 124M完整预算训练与CUDA速度优化：未实跑。局部数学与结构检查记录另见交付代码说明，只支持对应局部结论。

O1 | The spelled-out intro to neural networks and backpropagation: building micrograd

作者：Andrej Karpathy；视频日期：20220816；取得日期：2026-10-29。原视频。

用途：第1课全部章节、对应主线、原练习和原提示词线索；逐字稿 `01-VMj-3S1tku0.md`。自动字幕24,352词；首条0.080秒，末条开始8750.800秒，视频8752秒。时间覆盖并不证明每字正确，技术符号结合官方代码/画面核对。

回到正文

O2 | The spelled-out intro to language modeling: building makemore

作者：Andrej Karpathy；视频日期：20220907；取得日期：2026-10-29。原视频。

用途：第2课全部章节、对应主线、原练习和原提示词线索；逐字稿 `02-PaCmpygFfXo.md`。自动字幕19,445词；首条0.320秒，末条开始7064.080秒，视频7065秒。时间覆盖并不证明每字正确，技术符号结合官方代码/画面核对。

回到正文

O3 | Building makemore Part 2: MLP

作者：Andrej Karpathy；视频日期：20220912；取得日期：2026-10-29。原视频。

用途：第3课全部章节、对应主线、原练习和原提示词线索；逐字稿 `03-TCH_1BHY58I.md`。自动字幕12,731词；首条0.800秒，末条开始4537.960秒，视频4539秒。时间覆盖并不证明每字正确，技术符号结合官方代码/画面核对。

回到正文

O4 | Building makemore Part 3: Activations & Gradients, BatchNorm

作者：Andrej Karpathy；视频日期：20221004；取得日期：2026-10-29。原视频。

用途：第4课全部章节、对应主线、原练习和原提示词线索；逐字稿`04-P6sfmUTpUmc.md`。自动字幕21,386词；首条0.040秒，末条开始6956.040秒，视频6957秒。时间覆盖并不证明每字正确，技术符号结合官方代码/画面核对。

回到正文

O5 | Building makemore Part 4: Becoming a Backprop Ninja

作者：Andrej Karpathy；视频日期：20221011；取得日期：2026-10-29。原视频。

用途：第5课全部章节、对应主线、原练习和原提示词线索；逐字稿`05-q8SA3rM6ckI.md`。自动字幕20,776词；首条0.000秒，末条开始6921.540秒，视频6924秒。时间覆盖并不证明每字正确，技术符号结合官方代码/画面核对。

回到正文

O6 | Building makemore Part 5: Building a WaveNet

作者：Andrej Karpathy；视频日期：20221121；取得日期：2026-10-29。原视频。

用途：第6课全部章节、对应主线、原练习和原提示词线索；逐字稿`06-t3YJ5hKiMQ0.md`。自动字幕10,385词；首条0.000秒，末条开始3378.859秒，视频3381秒。时间覆盖并不证明每字正确，技术符号结合官方代码/画面核对。

回到正文

07 | Let's build GPT: from scratch, in code, spelled out.

作者：Andrej Karpathy；视频日期：20230117；取得日期：2026-10-29。原视频。

用途：第7课全部章节、对应主线、原练习和原提示词线索；逐字稿`07-kCc8FmEb1nY.md`。自动字幕21,030词；首条0.199秒，末条开始6978.480秒，视频6980秒。时间覆盖并不证明每字正确，技术符号结合官方代码/画面核对。

回到正文

08 | Let's build the GPT Tokenizer

作者：Andrej Karpathy；视频日期：20240220；取得日期：2026-10-29。原视频。

用途：第8课全部章节、对应主线、原练习和原提示词线索；逐字稿`08-zduSFxRajkE.md`。自动字幕24,679词；首条0.040秒，末条开始8013.159秒，视频8014秒。时间覆盖并不证明每字正确，技术符号结合官方代码/画面核对。

回到正文

09 | Let's reproduce GPT-2 (124M)

作者：Andrej Karpathy；视频日期：20240609；取得日期：2026-10-29。原视频。

用途：第9课全部章节、对应主线、原练习和原提示词线索；逐字稿`09-l8pRSuU81PU.md`。自动字幕43,388词；首条0.160秒，末条开始14485.000秒，视频14486秒。时间覆盖并不证明每字正确，技术符号结合官方代码/画面核对。

回到正文

O10 | karpathy/nn-zero-to-hero

官方仓库；快照提交`73c3fcc741f0ec104ca850b1fb0df90e7e8d4cde`；取得日期2026-10-29。

用途：核对真实文件、代码、原练习、采样前缀及视频后的勘误。完整代码快照见交付目录`code/nn-zero-to-hero/`；保留原许可证。当前提交不是视频录制时点的保证，差异在正文说明。

回到正文

O11 | karpathy/nanoGPT

官方仓库；快照提交`3adf61e154c3fe3fca428ad6bc3818b27a3b8291`；取得日期2026-10-29。

用途：核对真实文件、代码、原练习、采样前缀及视频后的勘误。完整代码快照见交付目录`code/nanoGPT/`；保留原许可证。当前提交不是视频录制时点的保证，差异在正文说明。

回到正文

O12 | karpathy/minbpe

官方仓库；快照提交 `1acefe89412b20245db5a22d2a02001e547dc602`；取得日期 2026-10-29。

用途：核对真实文件、代码、原练习、采样前缀及视频后的勘误。完整代码快照见交付目录 `code/minbpe/`；保留原许可证。当前提交不是视频录制时点的保证，差异在正文说明。

回到正文

O13 | karpathy/build-nanogpt

官方仓库；快照提交 `6104ab1b53920f6e2159749676073ff7d815c1fa`；取得日期 2026-10-29。

用途：核对真实文件、代码、原练习、采样前缀及视频后的勘误。完整代码快照见交付目录 `code/build-nanogpt/`；保留原许可证。当前提交不是视频录制时点的保证，差异在正文说明。

回到正文

O14 | karpathy/micrograd

官方仓库；快照提交 `7bc720e951fe422b8f8814aa5aa1b64121d26b4c`；取得日期 2026-10-29。

用途：核对真实文件、代码、原练习、采样前缀及视频后的勘误。完整代码快照见交付目录 `code/micrograd/`；保留原许可证。当前提交不是视频录制时点的保证，差异在正文说明。

回到正文

O15 | karpathy/ng-video-lecture

官方仓库；快照提交 `52201428ed7b46804849dea0b3ccf0de9df1a5c3`；取得日期 2026-10-29。

用途：核对真实文件、代码、原练习、采样前缀及视频后的勘误。完整代码快照见交付目录 `code/ng-video-lecture/`；保留原许可证。当前提交不是视频录制时点的保证，差异在正文说明。

回到正文

O16 | karpathy/makemore

官方仓库；快照提交 `988aa59e4d8fefa526d06f3b453ad116258398d4`；取得日期 2026-10-29。

用途：核对真实文件、代码、原练习、采样前缀及视频后的勘误。完整代码快照见交付目录 `code/makemore/`；保留原许可证。当前提交不是视频录制时点的保证，差异在正文说明。

回到正文

O17 | SolidGoldMagikarp (plus, prompt generation)

原文；2023-02-05；2026-10-29 经 Jina Reader 读取公开正文。该页面是第8课直接转展示的研究材料，仅用来复核表中输入的复杂字形、问号数量与措辞。课程截图仍来自视频原帧，不把现行网页冒充视频录制画面。原始快照 _raw/glitch-original.md。

回到正文